

UNIVERSITY / COLLEGE
DEPARTMENT OF INFORMATION TECHNOLOGY
BIG DATA
TEXT ANALYTICS WITH
HADOOP MAPREDUCE

التقرير العملي المتكامل

مشروع تحليل النصوص باستخدام Hadoop و MapReduce

عنوان المشروع	Big Data Text Analytics with Hadoop MapReduce
المنصة	Cloudera QuickStart VM
التقنيات الأساسية	HDFS + MapReduce + YARN
نوع التطبيق	تحليل نصوص و WordCount متعدد الملفات
إعداد الطالب	مهند نبيل احمد محمد عبدالله

BIG DATA • A DISTRIBUTED TEXT ANALYTICS • HADOOP

تقرير المشروع العملي المتكامل Big Data Text Analytics with Hadoop MapReduce

تحليل نصوص حقيقية باستخدام Hadoop MapReduceHDFS • MapReduce • YARN • Cloudera QuickStart
VM المشروع الأساسي + التحدي المتقدم متعدد الكتب

1. مقدمة

ملاحظة توثيقية: تُدرج لقطات الشاشة الفعلية في الأماكن التالية، مع كتابة عنوان الشكل ومصدر/وصف اللقطة أسفل كل صورة. يهدف هذا المشروع إلى تطبيق المفاهيم الأساسية في مقرر Big Data بصورة عملية ومتكاملة باستخدام بيئة Cloudera QuickStart VM. يبدأ مسار البيانات من ملفات نصية حقيقية، ثم يتم فحصها محلياً في Linux، ورفعها إلى HDFS، وتشغيل WordCount باستخدام MapReduce، ومتابعة المهمة من خلال YARN، ثم تحليل النتائج واستخراجها إلى نظام الملفات المحلي. تم تنفيذ المشروع على كتاب The Adventures of Sherlock Holmes، مع توسيع التجربة وفق التحدي المتقدم الوارد في ملزمة الدكتور لي شمل عدة كتب نصية من Project Gutenberg ومعالجة الملفات دفعة واحدة داخل HDFS.

2. أهداف المشروع

- تحميل واستخدام Dataset نصية حقيقية.
- فحص البيانات قبل إدخالها إلى Hadoop.
- إنشاء مساحة منظمة للبيانات داخل HDFS.
- رفع الملفات من Linux إلى HDFS والتحقق من وجودها.
- تشغيل برنامج WordCount باستخدام MapReduce.
- فهم العلاقة بين HDFS و MapReduce و YARN.
- تحليل تكرار الكلمات والبحث عن كلمات محددة.
- استخراج النتائج من HDFS إلى Linux.
- تطبيق التحدي المتقدم على عدة كتب ودمج نتائجها في تحليل واحد.

3. بيئة التنفيذ

العنصر	القيمة
المنصة	Cloudera QuickStart VM
Hadoop	2.6.0-cdh5.13.0
نظام الملفات المحلي	Linux
نظام الملفات الموزع	HDFS

إدارة الموارد	YARN
خوارزمية المعالجة	MapReduce / WordCount
مصدر الكتب	Project Gutenberg
مسار العمل المحلي	/home/cloudera/finalProject

4. البيانات المستخدمة

البيانات الأساسية هي كتاب The Adventures of Sherlock Holmes من Project Gutenberg، بالملف 1661-0.txt. ووفق التنفيذ الفعلي، تم كذلك تجهيز مجموعة متعددة الكتب للتحدي المتقدم.

الملف	عدد الكلمات المحلي في التحقق
1661-0.txt – Sherlock Holmes	107,562
alice.txt – Alice's Adventures in Wonderland	29,569
frankenstein.txt – Frankenstein	78,106
pride.txt – Pride and Prejudice	130,416
الإجمالي	345,653

ملاحظة: أرقام عدد الكلمات أعلاه هي نتائج فحص الملفات محليًا باستخدام أدوات Linux، وليست عدد الكلمات الفريدة في مخرجات WordCount.

5. فحص البيانات قبل Hadoop

تم التحقق من وجود الملفات وحجمها ومحتواها وعدد الأسطر والكلمات قبل إدخالها إلى HDFS. كما تم التحقق من بداية ونهاية النصوص للتأكد من أن الملفات النصية صالحة للمعالجة.

```
ls -lh 1661-0.txt
head -20 1661-0.txt
tail -20 1661-0.txt
wc -l 1661-0.txt
wc -w 1661-0.txt
```

6. تنظيم البيانات داخل HDFS

تم فصل المسار الأساسي الخاص بكتاب Sherlock Holmes عن مسار التحدي المتقدم متعدد الكتب. هذا يحافظ على متطلبات المشروع الأساسي، وفي الوقت نفسه يضيف تجربة متعددة الملفات.

```
hdfs dfs -mkdir -p /bigdata/sherlock/input
hdfs dfs -mkdir -p /bigdata/books/input
```

المسارات الأساسية المستخدمة:

```
/bigdata/sherlock/input/1661-0.txt
/bigdata/sherlock/output/
```

مسارات التحدي المتقدم:

```
/bigdata/books/input/
/bigdata/books/output/
```

7. رفع البيانات والتحقق منها

تم رفع كتاب Sherlock إلى مسار المشروع الأساسي، كما تم رفع الكتب الأربعة إلى `bigdata/books/input/` لتنفيذ التحدي المتقدم.

```
hdfs dfs -put -f 1661-0.txt /bigdata/sherlock/input/
hdfs dfs -put -f *.txt /bigdata/books/input/
hdfs dfs -ls -h /bigdata/sherlock/input
hdfs dfs -ls -h /bigdata/books/input
hdfs dfs -du -h /bigdata/books/input
```

8. Data Cleaning

تم تنفيذ خطوة إضافية لتنظيف النصوص بإزالة علامات الترقيم، ثم تم الاحتفاظ بمسارين: Raw للمعالجة الأصلية المطلوبة في الملزمة، وCleaned للمقارنة التعليمية. هذا لا يستبدل WordCount الأساسي، وإنما يوضح أثر تجهيز البيانات على نتائج تحليل النص.

```
sed 's/[[:punct:]]//g' input.txt > input-clean.txt
```

نتج عن التنفيذ مسارات cleaned داخل HDFS لكل من Sherlock والمجموعة متعددة الكتب.

9. تشغيل WordCount على Raw – Sherlock

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
wordcount \
/bigdata/sherlock/input \
/bigdata/sherlock/output
```

انتهت المهمة بنجاح، وظهر ملف `SUCCESS_` مع ملف النتائج `part-r-00000`. وجود `SUCCESS_` يدل على اكتمال الـ Job بنجاح، بينما توجد البيانات الفعلية في ملف `part-r-00000`.

10. نتائج الكلمات المطلوبة في Sherlock

الكلمة	عدد مرات الظهور
Holmes	198
Watson	4
Sherlock	96
London	20
Lestrade	21

بحسب مخرجات Hadoop الفعلية، كانت Holmes هي الأعلى بين الكلمات الخمس المحددة، تليها Sherlock، ثم Lestrade، ثم London، ثم Watson.

مهم: هذه الأعداد تمثل WordCount الخام كما نُفذ في المشروع؛ لذلك قد تظهر اختلافات بين الكلمات بسبب حالة الأحرف وعلامات الترقيم وطريقة تقسيم الكلمات.

11. أعلى 20 كلمة في Sherlock

تم تنفيذ الأمر المطلوب في الملزمة لاستخراج أعلى الكلمات تكراراً:

```
hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head -20
```

تم تنفيذ الأمر فعلياً على Cloudera VM وظهرت النتائج (انظر الشكل 4-ب):

```
the=5412, and=2794, of=2724, to=2702, a=2575, I=2533, in=1706, that=1557, was=1361, his=1096, is=1073, you=1034, he=1014, it=977, my=901, have=894, with=843, had=807, as=776, which=753
```

12. MapReduce في المشروع

استخدم WordCount نموذج MapReduce لتحويل النص إلى أزواج من الشكل (word, 1)، ثم تجميع القيم المتشابهة، ثم جمع قيم كل كلمة لإنتاج العدد النهائي.

المرحلة	الوظيفة
Input	قراءة ملفات النص من HDFS
Mapper	إنتاج كل كلمة مع القيمة 1
Shuffle	تجميع القيم الخاصة بالكلمة نفسها
Reducer	جمع القيم وإنتاج العدد النهائي
Output	حفظ النتائج في part-r-00000

13. YARN ودوره

YARN مسؤول عن إدارة موارد بيئة Hadoop وتشغيل المهمة من خلال تخصيص الموارد والـ Containers للتطبيقات. تم التحقق من تشغيل ResourceManager وNodeManager، كما ظهرت عقدة YARN بحالة RUNNING.

```
yarn node -list
```

يمكن متابعة التطبيقات من واجهة YARN على المنفذ 8088 أثناء تنفيذ المهمة.

14. الفرق بين Linux وHDFS

Linux	HDFS
نظام ملفات محلي على الجهاز	نظام ملفات موزع خاص بـHadoop
يستخدم أوامر مثل ls وcat وcp	يستخدم أوامر مثل ls -ls وcat وput
مناسب للملفات المحلية	مصمم لتخزين ومعالجة البيانات في بيئة Hadoop
الملف المحلي هو نسخة مستقلة على الجهاز	الملف داخل HDFS جزء من مساحة تخزين Hadoop

15. مكان النتيجة النهائية

```
/bigdata/sherlock/output/part-r-00000
```

```
/home/cloudera/sherlock_wordcount.txt
```

تم استخدام `getmerge` لاستخراج نتيجة HDFS إلى Linux:

```
hdfs dfs -getmerge /bigdata/sherlock/output sherlock_wordcount.txt
```

16. التحدي المتقدم – Multiple Books

تم تطبيق التحدي المتقدم المذكور في ملزمة الدكتور. بدل الاختصار على كتاب واحد، تم استخدام أربعة ملفات نصية ووضعها معًا في `bigdata/books/input/`، ثم تشغيل `WordCount` مرة واحدة على المجموعة كاملة.

ملف HDFS	الكتاب
1661-0.txt	The Adventures of Sherlock Holmes
alice.txt	Alice's Adventures in Wonderland
frankenstein.txt	Frankenstein
pride.txt	Pride and Prejudice

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
wordcount \
/bigdata/books/input \
/bigdata/books/output
```

تم إنشاء `bigdata/books/output/part-r-00000/` وظهر `SUCCESS_`، كما تم استخراج النتائج إلى Linux في `books_wordcount.txt`.

17. نتائج حجم الكتب في التحدي المتقدم

اعتمادًا على فحص الملفات المحلية قبل المعالجة، كان أكبر ملف من حيث عدد الكلمات هو `Pride and Prejudice` بعدد 130,416 كلمة، يليه `Sherlock Holmes`، ثم `Frankenstein`، ثم `Alice's Adventures in Wonderland`.

عدد الكلمات	الكتاب	الترتيب حسب عدد الكلمات
130,416	Pride and Prejudice	1
107,562	The Adventures of Sherlock Holmes	2
78,106	Frankenstein	3
29,569	Alice's Adventures in Wonderland	4

الإجمالي التقريبي وفق فحص `wc -w` للملفات الأربعة: 345,653 كلمة.

18. المعالجة متعددة الملفات

التجربة توضح أن WordCount يستطيع استقبال مجلد يحتوي على عدة ملفات كنقطة إدخال واحدة، ثم معالجة محتواها وإنتاج نتيجة مجمعة. وهذا يحقق الفكرة الأكاديمية للتحدي: الانتقال من تحليل كتاب واحد إلى معالجة مجموعة ملفات نصية في مهمة واحدة.

كما تم تنفيذ نسخة Cleaned متعددة الكتب في `bigdata/books/input_clean/` وإنتاج نتائجها في `bigdata/books/output_clean/`، وهي إضافة للمقارنة وليست بديلاً عن المسار Raw المطلوب.

19. لماذا يصبح Hadoop أكثر فائدة مع زيادة البيانات والملفات؟

كلما زادت كمية البيانات وعدد الملفات، تصبح الحاجة إلى إدارة التخزين والمعالجة أكثر أهمية. Hadoop يوفر HDFS لتخزين البيانات ضمن بيئة موزعة، وMapReduce لمعالجة البيانات، وYARN لإدارة الموارد وتشغيل المهام. لذلك فإن الانتقال من ملف واحد إلى عدة ملفات يوضح بصورة أفضل فكرة المعالجة الموزعة وإدارة مجموعات البيانات الأكبر.

20. دورة حياة البيانات في المشروع

تمثل التجربة دورة متكاملة تبدأ بالحصول على بيانات حقيقية ثم فحصها وتنظيمها ورفعها إلى HDFS، يلي ذلك تشغيل MapReduce ومتابعة المهمة بواسطة YARN، ثم تحليل النتائج واستخراجها إلى Linux.

Real Data → Validation → HDFS Organization → Ingestion → MapReduce → YARN → Analysis → Extraction

21. إجابات أسئلة المهمة العملية

1. ما أكثر الكلمات تكراراً في النص Sherlock؟

أكثر الكلمات تكراراً في النص هي كلمة «the» وظهرت 5,412 مرة، تليها الكلمات الشائعة (Stop Words) مثل «and» (2,794) و «of» (2,724) و «to» (2,702) و «a» (2,575) و «I» (2,533).

الترتيب	الكلمة	التكرار	الترتيب	الكلمة	التكرار
1	the	5,412	11	is	1,073
2	and	2,794	12	you	1,034
3	of	2,724	13	he	1,014
4	to	2,702	14	it	977
5	a	2,575	15	my	901
6	I	2,533	16	have	894
7	in	1,706	17	with	843
8	that	1,557	18	had	807
9	was	1,361	19	as	776
10	his	1,096	20	which	753

2. كم مرة ظهرت الكلمات المطلوبة؟

مقارنة تكرار الكلمات المطلوبة في النص الخام (Raw) مقابل النص المنظف (Cleaned):

الكلمة	التكرار الخام (Raw)	التكرار المنظف (Cleaned)	الفارق والملاحظة
Holmes	198	460	إزالة الفواصل والنقاط (+262) (الملتصقة بالاسم)
Watson	4	81	أغلبها كان ملتصقاً بفواصل (+77) (Watson, و Watson مثل)
Sherlock	96	97	قلة اتصال الاسم الأول (+1) (بعلامات ترقيم)
London	20	39	إزالة علامات الترقيم في (+19) (ختام الجمل)
Lestrade	21	37	إزالة علامات الاقتباس (+16) (والفواصل)

3. ما الكلمات العشرون الأعلى تكراراً؟

تم استخراجها بأمر: `hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head -20` وتظهر النتائج في الجدول التالي مرتبة تنازلياً:

الترتيب	الكلمة	التكرار	الترتيب	الكلمة	التكرار
1	the	5,412	11	is	1,073
2	and	2,794	12	you	1,034
3	of	2,724	13	he	1,014
4	to	2,702	14	it	977
5	a	2,575	15	my	901
6	I	2,533	16	have	894
7	in	1,706	17	with	843
8	that	1,557	18	had	807
9	was	1,361	19	as	776
10	his	1,096	20	which	753

4. ما الفرق بين Linux وHDFS؟

Linux يدير نظام الملفات المحلي، بينما HDFS نظام ملفات موزع مخصص لبيئة Hadoop وتخزين البيانات ضمنها.

5. ما وظيفة MapReduce؟

معالجة النص بصورة موزعة عبر Mapper ثم Shuffle ثم Reducer لإنتاج WordCount.
6. ما وظيفة YARN؟

إدارة موارد Hadoop وتشغيل تطبيقات المعالجة من خلال جدولة الموارد والـ Containers.
7. أين توجد النتيجة النهائية؟

في HDFS داخل bigdata/sherlock/output/part-r-00000/، ويمكن استخراجها محليًا إلى
/home/cloudera/sherlock_wordcount.txt/

22. الملفات والمسارات الناتجة

الغرض	المسار
بيانات Sherlock الخام	/bigdata/sherlock/input
نتائج WordCount الخام	/bigdata/sherlock/output
بيانات Sherlock بعد التنظيف	/bigdata/sherlock/input_clean
نتائج WordCount بعد التنظيف	/bigdata/sherlock/output_clean
الكتب الأربعة للتحدي المتقدم	/bigdata/books/input
نتيجة WordCount المجمعة للكتب	/bigdata/books/output
الكتب الأربعة بعد التنظيف	/bigdata/books/input_clean
نتائج WordCount للنسخة المنظمة	/bigdata/books/output_clean
نتيجة Sherlock المستخرجة إلى Linux	/home/cloudera/sherlock_wordcount.txt
نتيجة WordCount متعددة الكتب المستخرجة إلى Linux	/home/cloudera/books_wordcount.txt

23. لقطات الشاشة المطلوبة للتسليم

- لقطة 1: البيانات داخل HDFS، ويفضل إظهار /bigdata/sherlock/input/، ويمكن إضافة لقطة /bigdata/books/input/ لإثبات التحدي المتقدم.
- لقطة 2: تنفيذ MapReduce أثناء تشغيل Job.
- لقطة 3: التطبيق داخل YARN وظهور Application ID وحالة المهمة ومراحل Map/Reduce.
- لقطة 4: النتائج داخل /bigdata/sherlock/output/part-r-00000/ وإظهار الكلمات المطلوبة.

24. ملاحظة منهجية حول النتائج

التقرير يميز بين النتائج التي تم تسجيلها فعليًا أثناء التنفيذ وبين القيم التي تحتاج إلى نقل مباشر من مخرج أمر إضافي. أعداد الكلمات المطلوبة ووجود مخرجات Multi-Book وكون Pride and Prejudice الأكبر حسب wc -w مثبتة من نتائج التنفيذ المتاحة. أما جدول أعلى 20 كلمة في Sherlock وأعلى 20 كلمة المجمعة للكتب، وكذلك مقارنة كلمة محددة بين الكتب، فيجب أخذها حرفيًا من مخرجات الأوامر حتى لا يتم إدخال أرقام غير منفذة.

25. الخلاصة

تم تنفيذ مشروع Big Data Text Analytics باستخدام Hadoop MapReduce على بيانات نصية حقيقية، بدءًا من التحقق من الملفات في Linux، مرورًا بتخزينها في HDFS، ثم تشغيل WordCount باستخدام MapReduce ومتابعة المهمة عبر YARN، وانتهاءً بتحليل النتائج واستخراجها إلى Linux.

كما تم تنفيذ التحدي المتقدم متعدد الكتب باستخدام أربعة كتب نصية داخل HDFS ومعالجة المجموعة في Job واحدة. يوضح ذلك بصورة عملية العلاقة بين HDFS و MapReduce و YARN، ويبين كيف يمكن توسيع نفس المنهج من ملف واحد إلى مجموعة من الملفات. المشروع يحقق متطلبات المشروع الأساسي، ويضيف مسار التحدي المتقدم كما ورد في ملزمة الدكتور، مع الحفاظ على فصل النتائج الخام عن نتائج Data Cleaning الإضافية.

26. المرجع

ملزمة المقرر: Big Data Text Analytics with Hadoop MapReduce – مشروع عملي متكامل باستخدام Hadoop MapReduce، HDFS، MapReduce، YARN، Sherlock Holmes، و Cloudera QuickStart VM. مصدر البيانات الأساسي: Project Gutenberg – The Adventures of Sherlock Holmes، الملف 0-1661.txt.

.0-1661.txt — The Adventures of Sherlock Holmes (Arthur Conan Doyle)

<https://www.gutenberg.org/files/1661/1661-0.txt>

alice.txt — Alice's Adventures in Wonderland (Lewis Carroll)

<https://www.gutenberg.org/files/11/11-0.txt>

frankenstein.txt — Frankenstein (Mary Shelley)

<https://www.gutenberg.org/files/84/84-0.txt>

pride.txt — Pride and Prejudice (Jane Austen)

<https://www.gutenberg.org/files/1342/1342-0.txt>

dracula.txt — Dracula (Bram Stoker)

<https://www.gutenberg.org/files/345/345-0.txt>

moby_dick.txt — Moby Dick (Herman Melville)

<https://www.gutenberg.org/files/2701/2701-0.txt>

great_expectations.txt — Great Expectations (Charles Dickens)

<https://www.gutenberg.org/files/1400/1400-0.txt>

ملحق توثيق لقطات الشاشة

يُستخدم هذا الملحق لإدراج الصور المطلوبة في الملزمة، مع توحيد طريقة كتابة عناوين الأشكال ومصادر ها. لا يحتاج الطالب إلى إضافة صور غير مرتبطة بالمشروع.

```
bash: $: command not found
[clouderaquickstart ~]$ hdfs dfs -ls -R -h /bigdata
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:34 /bigdata/books
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:32 /bigdata/books/input
-rw-r--r-- 1 cloudera supergroup 593.3 K 2020-09-17 16:32 /bigdata/books/input/1661-0.txt
-rw-r--r-- 1 cloudera supergroup 170.2 K 2020-09-17 16:32 /bigdata/books/input/alice.txt
-rw-r--r-- 1 cloudera supergroup 430.4 K 2020-09-17 16:32 /bigdata/books/input/frankenstein.txt
-rw-r--r-- 1 cloudera supergroup 794.3 K 2020-09-17 16:32 /bigdata/books/input/pride.txt
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:32 /bigdata/books/input/clean
-rw-r--r-- 1 cloudera supergroup 556.9 K 2020-09-17 16:32 /bigdata/books/input/clean/1661-0-clean.txt
-rw-r--r-- 1 cloudera supergroup 125.8 K 2020-09-17 16:32 /bigdata/books/input/clean/alice-clean.txt
-rw-r--r-- 1 cloudera supergroup 425.2 K 2020-09-17 16:32 /bigdata/books/input/clean/frankenstein-clean.txt
-rw-r--r-- 1 cloudera supergroup 713.6 K 2020-09-17 16:32 /bigdata/books/input/clean/pride-clean.txt
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:34 /bigdata/books/output
-rw-r--r-- 1 cloudera supergroup 349.4 K 2020-09-17 16:34 /bigdata/books/output/part-r-00000
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:34 /bigdata/books/output/clean
-rw-r--r-- 1 cloudera supergroup 0 2020-09-17 16:34 /bigdata/books/output/clean/SUCCESS
-rw-r--r-- 1 cloudera supergroup 176.6 K 2020-09-17 16:34 /bigdata/books/output/clean/part-r-00000
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:49 /bigdata/sherlock
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:32 /bigdata/sherlock/input
-rw-r--r-- 1 cloudera supergroup 593.3 K 2020-09-17 16:32 /bigdata/sherlock/input/1661-0.txt
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:32 /bigdata/sherlock/input/clean
-rw-r--r-- 1 cloudera supergroup 556.9 K 2020-09-17 16:32 /bigdata/sherlock/input/clean/1661-0-clean.txt
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:33 /bigdata/sherlock/output
-rw-r--r-- 1 cloudera supergroup 0 2020-09-17 16:33 /bigdata/sherlock/output/SUCCESS
-rw-r--r-- 1 cloudera supergroup 159.8 K 2020-09-17 16:33 /bigdata/sherlock/output/part-r-00000
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:49 /bigdata/sherlock/output2
-rw-r--r-- 1 cloudera supergroup 159.8 K 2020-09-17 16:49 /bigdata/sherlock/output2/part-r-00000
drwxr-xr-x - cloudera supergroup 0 2020-09-17 16:33 /bigdata/sherlock/output/clean
-rw-r--r-- 1 cloudera supergroup 0 2020-09-17 16:33 /bigdata/sherlock/output/clean/SUCCESS
-rw-r--r-- 1 cloudera supergroup 93.5 K 2020-09-17 16:33 /bigdata/sherlock/output/clean/part-r-00000
drwxr-xr-x - cloudera supergroup 0 2020-09-17 12:29 /bigdata/test
drwxr-xr-x - cloudera supergroup 0 2020-09-17 12:01 /bigdata/test/input
-rw-r--r-- 1 cloudera supergroup 593.3 K 2020-09-17 12:01 /bigdata/test/input/1661-0.txt
drwxr-xr-x - cloudera supergroup 0 2020-09-17 12:29 /bigdata/test/output
-rw-r--r-- 1 cloudera supergroup 0 2020-09-17 12:29 /bigdata/test/output/SUCCESS
-rw-r--r-- 1 cloudera supergroup 159.8 K 2020-09-17 12:29 /bigdata/test/output/part-r-00000
[clouderaquickstart ~]$
```

الشكل (1): نتيجة أمر `hdfs dfs -ls -R -h /bigdata` — تُظهر جميع مسارات HDFS والملفات المرفوعة. المصدر: تنفيذ الطالب على Cloudera QuickStart VM.

```
[clouderaquickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
> wordcount \
> /bigdata/sherlock/input \
> /bigdata/sherlock/output2
26/09/17 16:48:56 INFO client.RMProxy: Connecting to ResourceManager at quickstart.cloudera/127.0.0.1:8032
26/09/17 16:48:56 INFO InputFileInputFormat: Total input paths to process : 1
26/09/17 16:48:56 INFO mapreduce.JobSubmitter: number of splits:1
26/09/17 16:48:56 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1789676854304_0013
26/09/17 16:48:57 INFO mapreduce.Job: Running job: job_1789676854304_0013
26/09/17 16:48:57 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/application_1789676854304_0013/
26/09/17 16:48:57 INFO mapreduce.Job: Running job: job_1789676854304_0013
26/09/17 16:49:02 INFO mapreduce.Job: map 0% reduce 0%
26/09/17 16:49:08 INFO mapreduce.Job: map 100% reduce 0%
26/09/17 16:49:13 INFO mapreduce.Job: map 100% reduce 100%
26/09/17 16:49:14 INFO mapreduce.Job: job_1789676854304_0013 completed successfully
26/09/17 16:49:14 INFO mapreduce.Job: Counters: 49
File System Counters
  FILE: Number of bytes read=113071
  FILE: Number of bytes written=521463
  FILE: Number of read operations=0
  FILE: Number of large read operations=0
  FILE: Number of write operations=0
  HDFS: Number of bytes read=627634
  HDFS: Number of bytes written=163591
  HDFS: Number of read operations=0
  HDFS: Number of large read operations=0
  HDFS: Number of write operations=2
Job Counters
  Launched map tasks=1
  Launched reduce tasks=1
  Data-local map tasks=1
  Total time spent by all maps in occupied slots (ms)=1679872
  Total time spent by all reduces in occupied slots (ms)=1649152
  Total time spent by all map tasks (ms)=3281
  Total time spent by all reduce tasks (ms)=3221
  Total vcore-millisecods taken by all map tasks=3281
  Total vcore-millisecods taken by all reduce tasks=3221
  Total megabyte-millisecods taken by all map tasks=1679872
  Total megabyte-millisecods taken by all reduce tasks=1649152
Map-Reduce Framework
  Map input records=12306
  Map output records=107562
  Map output bytes=1022331
  Map output materialized bytes=113067
  Input split bytes=130
```

الشكل (2-أ): تشغيل Hadoop MapReduce WordCount — يظهر 100% map ثم 100% reduce والإكمال بنجاح.

```
HDFS: Number of large read operations=0
HDFS: Number of write operations=2

Job Counters
  Launched map tasks=1
  Launched reduce tasks=1
  Data-local map tasks=1
  Total time spent by all maps in occupied slots (ms)=1679872
  Total time spent by all reduces in occupied slots (ms)=1649152
  Total time spent by all map tasks (ms)=3281
  Total time spent by all reduce tasks (ms)=3221
  Total vcore-milliseconds taken by all map tasks=3281
  Total vcore-milliseconds taken by all reduce tasks=3221
  Total megabyte-milliseconds taken by all map tasks=1679872
  Total megabyte-milliseconds taken by all reduce tasks=1649152

Map-Reduce Framework
  Map input records=12306
  Map output records=107562
  Map output bytes=1022331
  Map output materialized bytes=113867
  Input split bytes=130
  Combine input records=107562
  Combine output records=15187
  Reduce input groups=15187
  Reduce shuffle bytes=113867
  Reduce input records=15187
  Reduce output records=15187
  Spilled Records=30374
  Shuffled Maps=1
  Failed Shuffles=0
  Merged Map outputs=1
  GC time elapsed (ms)=101
  CPU time spent (ms)=4240
  Physical memory (bytes) snapshot=283901952
  Virtual memory (bytes) snapshot=1125285888
  Total committed heap usage (bytes)=95426416

Shuffle
  Errors
    BAD_ID=0
    CONNECTION=0
    IO_ERROR=0
    WRONG_LENGTH=0
    WRONG_MAP=0
    WRONG_REDUCE=0

File Input Format Counters
  Bytes Read=97384
File Output Format Counters
  Bytes Written=163591
[cloudera@quickstart ~]$
```

الشكل (2-ب): إحصائيات Map-Reduce Framework بعد اكتمال Job.

localhost:8088/cluster

Cloudera Hue Hadoop HBase Impala Spark Solr Oozie Cloudera Manager Getting Started

hadoop All Applications

Cluster Metrics

Apps Submitted	Apps Pending	Apps Running	Apps Completed	Containers Running	Memory Used	Memory Total	Memory Reserved	VCores Used	VCores Total	VCores Reserved
13	0	0	13	0	0 B	8 GB	0 B	0	0	0

Cluster Nodes Metrics

Active Nodes	Decommissioning Nodes	Lost Nodes	Unhealthy Nodes	Rebooted Nodes
1	0	0	0	0

User Metrics for dr who

Apps Submitted	Apps Pending	Apps Running	Apps Completed	Containers Running	Containers Pending	Containers Reserved	Memory Used	Memory Pending	Memory Reserved	VCores Used	VCores Pending	VCores Reserved
0	0	0	0	0	0	0	0 B	0 B	0 B	0	0	0

Tools

Show 20 entries

ID	User	Name	Application Type	Queue	StartTime	FinishTime	State	FinalStatus	Running Containers	Allocated CPU VCoers	Allocated Memory MB	Reserved CPU VCoers	Reserved Memory MB	Progress	Tracking UI
application_1789676854304_0013	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 16:48:57-0700 2026	Thu Sep 17 16:49:12-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0012	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 16:38:17-0700 2026	Thu Sep 17 16:38:35-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0011	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 16:33:41-0700 2026	Thu Sep 17 16:34:06-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0010	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 16:23:24-0700 2026	Thu Sep 17 16:23:37-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0009	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 16:21:56-0700 2026	Thu Sep 17 16:33:13-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0008	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 13:41:26-0700 2026	Thu Sep 17 13:41:43-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0007	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 13:41:02-0700 2026	Thu Sep 17 13:41:18-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0006	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 13:40:40-0700 2026	Thu Sep 17 13:40:52-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0005	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 13:40:17-0700 2026	Thu Sep 17 13:40:31-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0004	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 13:30:12-0700 2026	Thu Sep 17 13:30:27-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0003	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 13:29:55-0700 2026	Thu Sep 17 13:30:05-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0002	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 13:29:11-0700 2026	Thu Sep 17 13:29:28-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History
application_1789676854304_0001	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 13:28:36-0700 2026	Thu Sep 17 13:28:05-0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History

الشكل (3): واجهة YARN ResourceManager localhost:8088 — قائمة تطبيقات MAPREDUCE بحالة SUCCEEDED.

المصدر: Cloudera QuickStart VM — YARN.

```
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | head -30
#1661] 1
$5,000) 1
& 5
&c, 1
&c. 1
($1 1
(3rd 1
(801) 1
(a) 1
(and 1
(any 1
(b) 1
(c) 1
(does 1
(for 1
(if 1
(now 1
(or 3
(the 1
(trademark/copyright) 1
(with 1
(www.gutenberg.org), 1
("the 1
*** 4
- 3
1,100, 1
1. 1
1.A. 1
1.B. 1
1.C 1
cat: Unable to write to output stream.
[cloudera@quickstart ~]$
```

الشكل (4-أ): أول 30 سطر من part-r-000000 بالأمر head -30.

```
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | sort -k2 -nr | head -20
the 5412
and 2794
of 2724
to 2702
a 2575
I 2533
in 1706
that 1557
was 1361
his 1096
is 1073
you 1034
he 1014
it 977
my 901
have 894
with 843
had 807
as 776
which 753
[cloudera@quickstart ~]$
```

الشكل (4-ب): أعلى 20 كلمة تكراراً (sort -k2 -nr | head -20): the=5412 في الصدارة.

```
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | grep -E '^(Holmes|Watson|Sherlock|London|Lestrade)[[:space:]]'
Holmes 198
Lestrade 21
London 20
Sherlock 96
Watson 4
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output_clean/part-r-000000 | grep -E '^(Holmes|Watson|Sherlock|London|Lestrade)[[:space:]]'
Holmes 460
Lestrade 37
London 39
Sherlock 97
Watson 81
[cloudera@quickstart ~]$
```

الشكل (4-ج): الكلمات المطلوبة (Raw/Cleaned: Holmes=198/460, Watson=4/81, Sherlock=96/97)

```
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/books/input
Found 4 items
-rw-r--r-- 1 cloudera supergroup 593.3 K 2026-09-17 16:32 /bigdata/books/input/1661-0.txt
-rw-r--r-- 1 cloudera supergroup 170.2 K 2026-09-17 16:32 /bigdata/books/input/alice.txt
-rw-r--r-- 1 cloudera supergroup 438.4 K 2026-09-17 16:32 /bigdata/books/input/frankenstein.txt
-rw-r--r-- 1 cloudera supergroup 754.3 K 2026-09-17 16:32 /bigdata/books/input/pride.txt
[cloudera@quickstart ~]$
```

الشكل (5): محتويات /bigdata/books/input/ — أربعة كتب مرفوعة للتجدي المتقدم.

المصدر: تنفيذ الطالب على Cloudera QuickStart VM.

```
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output_all_books/part-r-00000 | sort -k2 -nr | head -20/bigdata/books/output_all_books
head: invalid trailing option -- /
try 'head --help' for more information.
cat: /bigdata/sherlock/output_all_books/part-r-00000: No such file or directory
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/books/output_all_books
Found 2 items
-rw-r--r-- 1 cloudera supergroup 0 2026-09-17 18:13 /bigdata/books/output_all_books/_SUCCESS
-rw-r--r-- 1 cloudera supergroup 357824 2026-09-17 18:13 /bigdata/books/output_all_books/part-r-00000
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/books/output_all_books/part-r-00000 | sort -k2 -nr | head -20
the 15672
and 9990
of 9972
to 9899
[ 7265
a 6657
in 5164
was 4501
that 4226
my 3175
his 2885
with 2843
/ou 2797
had 2793
her 2788
it 2696
is 2673
not 2671
re 2612
for 2371
[cloudera@quickstart ~]$
```

الشكل (6): أعلى 20 كلمة مجمعة عبر الكتب الأربعة — the=15672 في الصدارة.

المصدر: MapReduce على Cloudera QuickStart VM/ — /bigdata/books.

```

Applications Places System Thu Sep 24, 1:53 PM cloudera
File Edit View Search Terminal Help
Physical memory (bytes) snapshot=728813568
Virtual memory (bytes) snapshot=2785517568
Total committed heap usage (bytes)=239075328
Shuffle Errors
BAD_ID=0
CONNECTION=0
IO_ERROR=0
WRONG_LENGTH=0
WRONG_MAP=0
WRONG_REDUCE=0
File Input Format Counters
Bytes Read=2883886
File Output Format Counters
Bytes Written=357824
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output_all_books/part-r-00000 | sort -k2 -nr | head -20
cat: '/bigdata/sherlock/output_all_books/part-r-00000': No such file or directory
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output_all_books/part-r-00000 | sort -k2 -nr | head -20/bigdata/books/output_all_books
head: invalid trailing option -- /
Try 'head --help' for more information.
cat: '/bigdata/sherlock/output_all_books/part-r-00000': No such file or directory
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/books/output_all_books
Found 2 items
-rw-r--r-- 1 cloudera supergroup 357824 2026-09-17 18:13 /bigdata/books/output_all_books/SUCCESS
-rw-r--r-- 1 cloudera supergroup 0 2026-09-17 18:13 /bigdata/books/output_all_books/part-r-00000
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/books/output_all_books/part-r-00000 | sort -k2 -nr | head -20
the 15672
and 9990
of 9972
to 9899
I 7265
a 6057
in 5164
was 4501
that 4226
my 3175
his 2885
with 2843
you 2797
had 2793
her 2788
it 2696
as 2673
not 2671
he 2612
for 2371
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/books/challenge analysis/part-r-00000
cat: '/bigdata/books/challenge analysis/part-r-00000': No such file or directory
[cloudera@quickstart ~]$ cd finalProject/
[cloudera@quickstart finalProject]$ wc -l -w *.txt
12306 107562 1661-O.txt
3762 29569 alice.txt
7741 78106 frankenstein.txt
14915 138416 pride.txt
38724 345653 total
[cloudera@quickstart finalProject]$

```

إحصائيات الكلمات والأسطر في الكتب المستخدمة (wc -l -w *.txt):

كتاب Sherlock Holmes (1661-O.txt): يحتوي على 107,562 كلمة و 12,306 سطر.

كتاب Alice in Wonderland (alice.txt): يحتوي على 29,569 كلمة و 3,762 سطر.

كتاب Frankenstein (frankenstein.txt): يحتوي على 78,106 كلمة و 7,741 سطر.

كتاب Pride and Prejudice (pride.txt): يحتوي على 130,416 كلمة و 14,915 سطر.

إجمالي البيانات المعالجة: 345,653 كلمة موزعة على 38,724 سطرًا عبر 4 كتب مختلفة تم تحليلها في وظيفة MapReduce واحدة.


```

Applications | File Edit View VM Tabs Help | cloudera@quickstart:~/finalProject
File Edit View Search Terminal Help
Bytes Read=2003086
File Output Format Counters
Bytes Written=357824
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output_all_books/part-r-00000 | sort -k2 -nr | head -20
cat: '/bigdata/sherlock/output_all_books/part-r-00000': No such file or directory
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output_all_books/part-r-00000 | sort -k2 -nr | head -20/bigdata/books/output_all_books
head: invalid trailing option -- /
Try 'head --help' for more information.
cat: '/bigdata/sherlock/output_all_books/part-r-00000': No such file or directory
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/books/output_all_books
Found 2 items
-rw-r--r-- 1 cloudera supergroup 357824 2026-09-17 18:13 /bigdata/books/output_all_books/part-r-00000
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/books/output_all_books/part-r-00000 | sort -k2 -nr | head -20
the 15672
and 9990
of 9972
to 9899
I 7265
a 6657
in 5164
was 4501
that 4226
my 3172
his 2885
with 2843
you 2797
had 2793
her 2788
it 2696
as 2673
not 2671
he 2612
for 2371
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/books/challenge_analysis/part-r-00000
cat: '/bigdata/books/challenge_analysis/part-r-00000': No such file or directory
[cloudera@quickstart ~]$ cd finalProject/
[cloudera@quickstart finalProject]$ wc -l *.txt
1236 107502 1661-0.txt
3762 29569 alice.txt
7741 78106 frankenstein.txt
14915 138416 pride.txt
38724 345053 total
[cloudera@quickstart finalProject]$ hdfs dfs -ls -h /bigdata/sherlock/input
Found 1 items
-rw-r--r-- 1 cloudera supergroup 593.3 K 2026-09-17 16:32 /bigdata/sherlock/input/1661-0.txt
[cloudera@quickstart finalProject]$ hdfs dfs -du -h /bigdata/sherlock/input
593.3 K 593.3 K /bigdata/sherlock/input/1661-0.txt
[cloudera@quickstart finalProject]$ hdfs dfs -ls -h /bigdata/books/input
Found 4 items
-rw-r--r-- 1 cloudera supergroup 593.3 K 2026-09-17 16:32 /bigdata/books/input/1661-0.txt
-rw-r--r-- 1 cloudera supergroup 170.2 K 2026-09-17 16:32 /bigdata/books/input/alice.txt
-rw-r--r-- 1 cloudera supergroup 438.4 K 2026-09-17 16:32 /bigdata/books/input/frankenstein.txt
-rw-r--r-- 1 cloudera supergroup 754.3 K 2026-09-17 16:32 /bigdata/books/input/pride.txt
[cloudera@quickstart finalProject]$

```

التحقق من مدخلات ومساحات (HDFS Ingestion & Verification):

كتاب شيرلوك هولمز الفردي: يوضح الأمر `hdfs dfs -ls -h /bigdata/sherlock/input` و `hdfs dfs -du -h` أن ملف 1661-txt.0 تم رفعه بنجاح ويشغل مساحة قدرها 593.3 KB داخل نظام الملفات الموزع HDFS.

مدخلات التحدي المتقدم للكتب المتعددة (/bigdata/books/input): تم رفع 4 كتب بنجاح مع أحجامها الدقيقة في HDFS:

1661-0.txt (Sherlock Holmes): بحجم 593.3 KB.

alice.txt (Alice in Wonderland): بحجم 170.2 KB.

frankenstein.txt (Frankenstein): بحجم 438.4 KB.

pride.txt (Pride and Prejudice): بحجم 754.3 KB.

ملاحظه:

هناك 2 ملفات TXT جديده لم يتم معالجتها و تم تنزيلها كانت في حال الاحتياط للحصول على الدرجه الكامله دكتورنا الغالي.

شكرا لجهودكم, وفقكم الله دكتور..