

Big Data Text Analytics Using Hadoop MapReduce

Alice's Adventures in Wonderland

Hadoop - HDFS - MapReduce - YARN

Prepared by:

Wafaa Abdualmaike Alawadi

Report Contents

رقم	القسم
1	المقدمة وأهداف المشروع
2	الأدوات والتقنيات المستخدمة
3	وصف البيانات والتحقق منها
4	إنشاء هيكل المشروع داخل HDFS
5	رفع البيانات إلى HDFS
6	تحليل Blocks و Replication
7	تشغيل MapReduce WordCount
8	مخرجات MapReduce ومراقبة YARN
9	تحليل نتائج WordCount
10	أعلى 20 كلمة تكررًا
11	استخراج النتائج إلى Linux
12	المشكلات والحلول
13	الخاتمة والمراجع
A	ملحق الأوامر الأساسية

Introduction

تُعد البيانات النصية من أكثر أنواع البيانات انتشارًا، ومع زيادة حجمها تصبح الحاجة إلى تقنيات قادرة على التخزين والمعالجة الموزعة أكثر أهمية. يوفر Hadoop بيئة متكاملة لتنظيم البيانات داخل HDFS ومعالجتها باستخدام MapReduce، بينما يتولى YARN إدارة موارد التشغيل ومتابعة المهام.

يهدف هذا المشروع إلى تطبيق مفاهيم مقرر البيانات الضخمة بصورة عملية متكاملة. تبدأ الدورة بالتعامل مع الملف في نظام Linux المحلي، ثم نقله إلى HDFS، وفحص طريقة تخزينه باستخدام Blocks و Replication، ثم تشغيل WordCount باستخدام MapReduce، ومراقبة المهمة من خلال YARN، وتحليل النتائج، وأخيرًا استخراجها إلى Linux.

تم اختيار كتاب Alice's Adventures in Wonderland للكاتب Lewis Carroll كبيانات نصية حقيقية. وتم تطبيق دورة العمل التالية:

Acquisition -> Validation -> Organization -> Ingestion -> Processing -> Orchestration -> Analysis -> Extraction

1.1. أهداف المشروع

Project Objectives

- استخدام Dataset نصية حقيقية وفحصها قبل إدخالها إلى Hadoop.
- التمييز بين نظام الملفات المحلي Linux ونظام HDFS.
- إنشاء مسارات منظمة داخل HDFS ورفع البيانات إليها.
- فحص طريقة تخزين الملف باستخدام Blocks والتعرف على Replication Factor.
- تشغيل Job حقيقي باستخدام MapReduce WordCount وفهم مراحل Mapper و Shuffle و Reducer.
- مراقبة تنفيذ الـ Job باستخدام YARN ResourceManager.
- تحليل الكلمات والشخصيات الأكثر ظهورًا واستخراج أعلى 20 كلمة تكررًا.
- استخراج نتائج المعالجة من HDFS إلى Linux باستخدام getmerge.

2. الأدوات والتقنيات المستخدمة

Tools and Technologies

الأداة / التقنية	الاستخدام في المشروع
VMware Workstation	تشغيل بيئة Cloudera الافتراضية.
Cloudera QuickStart VM	بيئة Hadoop المستخدمة في المشروع.
Linux Terminal	تنفيذ أوامر Linux و Hadoop.
HDFS	تخزين Dataset وإدارة الملفات.
MapReduce / WordCount	معالجة النص وحساب تكرار الكلمات.
YARN	إدارة ومراقبة تنفيذ الـ Job.
fsck / stat	فحص Blocks و Replication.
grep / sort	تحليل النتائج والبحث والترتيب.
getmerge	استخراج نتائج HDFS إلى Linux.

HDFS مسؤول عن التخزين، و MapReduce مسؤول عن المعالجة، بينما يدير YARN موارد التشغيل ومتابعة المهام.

3. وصف البيانات والتحقق منها

Dataset Description and Validation

تم استخدام كتاب Alice's Adventures in Wonderland للكاتب Lewis Carroll كملف نصي باسم alice.txt. وقبل إدخاله إلى Hadoop تم فحصه داخل Linux للتأكد من وجوده ومعرفة حجمه وعدد الأسطر والكلمات.

```
ls -lh alice.txt
wc -l alice.txt
wc -w alice.txt
```

الخاصية	النتيجة
اسم الملف	alice.txt
الحجم التقريبي	170 KB
عدد الأسطر	3736
عدد الكلمات	29465

```
[cloudera@quickstart ~]$ ls -lh alice.txt
-rw-rw-r-- 1 cloudera cloudera 170K Sep 17 10:29 alice.txt
[cloudera@quickstart ~]$ wc -l alice.txt
3736 alice.txt
[cloudera@quickstart ~]$ wc -w alice.txt
29465 alice.txt
[cloudera@quickstart ~]$
```

4. إنشاء هيكل المشروع في نظام الملفات الموزع

Creating the HDFS Project Structure

تم إنشاء مسار منظم للمشروع داخل HDFS، بحيث يكون مجلد input مخصصًا للبيانات التي سيتم معالجتها بواسطة MapReduce.

```
hdfs dfs -mkdir -p /bigdata/alice/input
```

في بيئة Cloudera ظهرت صلاحيات محدودة على جذر HDFS؛ لذلك تم إنشاء المسار باستخدام مستخدم hdfs ثم إعطاء مستخدم cloudera ملكية مجلد المشروع. هذه الخطوة خاصة بإعداد البيئة، بينما المفهوم الأساسي هو تنظيم البيانات داخل HDFS في مسارات واضحة.

5. رفع البيانات إلى نظام الملفات الموزع

Uploading the Dataset to HDFS

بعد تجهيز مسار المشروع تم نسخ الملف من Linux المحلي إلى HDFS باستخدام الأمر put. ينشئ هذا الأمر نسخة داخل HDFS ولا يحذف النسخة الأصلية الموجودة في Linux.

```
hdfs dfs -put alice.txt /bigdata/alice/input/
hdfs dfs -ls -h /bigdata/alice/input
hdfs dfs -du -h /bigdata/alice/input
```

ظهر الملف داخل HDFS بحجم يقارب 169.5 KB، وتم التأكد من إمكانية قراءته مباشرة من HDFS.

```
hdfs dfs -cat /bigdata/alice/input/alice.txt | head -20
```

```
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/alice/input
Found 1 items
-rw-r--r-- 1 cloudera supergroup 169.5 K 2026-09-17 15:06 /bigdata/alice/in
put/alice.txt
[cloudera@quickstart ~]$ hdfs dfs -du -h /bigdata/alice/input
169.5 K 169.5 K /bigdata/alice/input/alice.txt
[cloudera@quickstart ~]$ hdfs fsck /bigdata/alice/input/alice.txt -files -blocks
Connecting to namenode via http://quickstart.cloudera:50070/fsck?ugi=cloudera&fi
les=1&blocks=1&path=%2Fbigdata%2Falice%2Finput%2Falice.txt
FSCK started by cloudera (auth:SIMPLE) from /192.168.91.128 for path /bigdata/al
ice/input/alice.txt at Thu Sep 17 15:21:12 PDT 2026
/bigdata/alice/input/alice.txt 173595 bytes, 1 block(s): OK
0. BP-333635372-127.0.0.1-1508779710286:blk_1073742997_2173 len=173595 Live_repl
=1

Status: HEALTHY
Total size: 173595 B
Total dirs: 0
Total files: 1
Total symlinks: 0
Total blocks (validated): 1 (avg. block size 173595 B)
Minimally replicated blocks: 1 (100.0 %)
Over-replicated blocks: 0 (0.0 %)
Under-replicated blocks: 0 (0.0 %)
Mis-replicated blocks: 0 (0.0 %)
Default replication factor: 1
```

6. تحليل الكتل وعامل التكرار

Blocks and Replication Analysis

تم فحص طريقة تخزين الملف داخل HDFS باستخدام أداة fsck. أظهرت النتائج أن الملف سليم وأنه مخزن في Block واحد، وهو أمر متوقع لأن حجم الملف صغير مقارنة بحجم الـ Block في HDFS.

```
hdfs fsck /bigdata/alice/input/alice.txt -files -blocks
```

المؤشر	النتيجة
Total files	1
Total blocks (validated)	1
Corrupt blocks	0
Missing replicas	0
Number of data-nodes	1
File system status	HEALTHY

```

Average block replication:      1.0
Corrupt blocks:                0
Missing replicas:              0 (0.0 %)
Number of data-nodes:          1
Number of racks:               1
FSCK ended at Thu Sep 17 15:21:12 PDT 2026 in 3 milliseconds

The filesystem under path '/bigdata/alice/input/alice.txt' is HEALTHY
[cloudera@quickstart ~]$ hdfs dfs -stat %r /bigdata/alice/input/alice.txt
1
[cloudera@quickstart ~]$ ls /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
/usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar

```

بعد ذلك تم معرفة عامل التكرار باستخدام الأمر التالي:

```
hdfs dfs -stat %r /bigdata/alice/input/alice.txt
```

كانت النتيجة 1، أي أن Replication Factor يساوي 1. ويرتبط ذلك باستخدام بيئة QuickStart ذات DataNode واحد في هذا التطبيق.

```

[cloudera@quickstart ~]$ hdfs dfs -stat %r /bigdata/alice/input/alice.txt
1

```

7. تشغيل عدّ الكلمات

Running MapReduce WordCount

بعد التأكد من سلامة البيانات تم تشغيل برنامج WordCount الموجود ضمن أمثلة Hadoop. بيانات الإدخال موجودة في المسار `bigdata/alice/output/`، وتُكتب النتائج في المسار `bigdata/alice/input/`.

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount /bigdata/alice/input /bigdata/alice/output
```

تمر المعالجة بالمراحل التالية:

Input -> Mapper -> Shuffle -> Reducer -> Output

يقوم Mapper بتحويل كل كلمة إلى زوج مفتاح وقيمة، مثل المثال التالي:

(Alice, 1)

بعد ذلك تجمع مرحلة Shuffle القيم التي تحمل المفتاح نفسه، ثم يقوم Reducer بجمعها وإنتاج العدد النهائي لمرات ظهور كل كلمة.

8. مخرجات المعالجة ومراقبة المهمة

MapReduce Output and YARN Monitoring

8.1. مخرجات المعالجة

MapReduce Output

بعد انتهاء المهمة تم فحص مجلد الإخراج داخل HDFS.

```
hdfs dfs -ls /bigdata/alice/output
```

ظهر ملفان أساسيان. الملف `SUCCESS_` علامة على نجاح انتهاء الـ Job، بينما يحتوي `part-r-00000` على نتائج WordCount الفعلية.

```
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/alice/output
Found 2 items
-rw-r--r-- 1 cloudera supergroup          0 2026-09-17 15:28 /bigdata/alice/output/_SUC
CESS
-rw-r--r-- 1 cloudera supergroup      61416 2026-09-17 15:28 /bigdata/alice/output/part
-r-000000
```

8.2. مراقبة المهمة

Monitoring the Job Using YARN

تم فتح واجهة YARN ResourceManager على العنوان الموضح أدناه ومتابعة مهمة WordCount.

<http://localhost:8088>

أظهرت الواجهة أن نوع التطبيق MAPREDUCE، وأن الحالة FINISHED والنتيجة النهائية SUCCEEDED، مما يؤكد نجاح تنفيذ المهمة.

الحقل	القيمة
User	cloudera
Name	word count
Application Type	MAPREDUCE
State	FINISHED
Final Status	SUCCEEDED
Elapsed	23 sec

The screenshot shows the YARN ResourceManager web interface in a Mozilla Firefox browser. The URL is http://localhost:8088/cluster/app/application_1789658782827_0001. The interface displays the Hadoop logo and a sidebar with navigation options like Cluster, About, Nodes, Applications, and Scheduler. The main content area shows the 'Application Overview' for the job 'word count' (Application Type: MAPREDUCE). The job status is 'FINISHED' and 'FinalStatus: SUCCEEDED'. It started on 'Thu Sep 17 15:28:33 -0700 2026' and elapsed '23sec'. The 'Tracking URL' is 'History'. Below this, the 'Application Metrics' section shows resource preemption statistics. At the bottom, the 'ApplicationMaster' section shows a table with one attempt: Attempt Number 1, Start Time 'Thu Sep 17 15:28:33 -0700 2026', Node 'quickstart.cloudera:8042', and Logs 'logs'.

Figure 6. YARN ResourceManager showing a FINISHED and SUCCEEDED WordCount job.

9. تحليل النتائج

WordCount Results Analysis

تم استخدام grep للبحث عن خمس شخصيات رئيسية داخل نتائج WordCount، وتظهر أسماء الشخصيات بوضوح في الأوامر التالية.

```
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Alice"
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Rabbit"
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Queen"
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Hatter"
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "King"
```

أظهرت النتائج ملاحظة مهمة: WordCount الأساسي لا ينفذ تنظيفًا للنص؛ لذلك تُعامل الصيغ التي تتضمن علامات ترقيم على أنها قيم مختلفة. يوضح المثال التالي ذلك:

Alice | Alice, | Alice. | Alice;

وهذا يوضح أهمية مرحلة تنظيف البيانات قبل إجراء التحليل النصي المتقدم.

```
cloudera@quickstart:~
File Edit View Search Terminal Help
(WITH 1
(We 1
(Which 2
(a 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Alice"
(Alice 4
Alice 221
Alice! 3
Alice!' 1
Alice)--'and 1
Alice, 76
Alice,) 2
Alice. 54
Alice: 7
Alice; 16
Alice's 11
Alice's, 1
'Alice!' 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Rabbit"
Rabbit 29
Rabbit, 8
Rabbit-Hole 1
Rabbit. 1
Rabbit: 1
Rabbit; 1
Rabbit's 3
Rabbit's--'Pat! 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Queen"
```

```
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Queen"
Queen 34
Queen! 1
Queen!' 1
Queen, 17
Queen,' 1
Queen. 11
Queen: 1
Queen?' 1
Queen's 7
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Hatter"
Hatter 24
Hatter, 10
Hatter. 13
Hatter: 6
Hatter; 1
Hatter's 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "King"
King 27
King, 15
King. 12
King: 2
King; 3
King's 2
```

10. أعلى 20 كلمة تكرارًا

Top 20 Most Frequent Words

تم ترتيب نتائج WordCount اعتمادًا على العمود الثاني الذي يمثل عدد مرات الظهور، من الأعلى إلى الأقل.

```
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | sort -k2 -nr | head -20
```

الكلمة	عدد مرات الظهور
the	1664
and	780
to	773
a	662
of	596
she	484
said	416
in	401
it	356
was	329
you	301
I	260
as	246
that	226
Alice	221
with	214
at	211
her	203
had	175
all	168

توضح النتائج أن الكلمات الأكثر تكرارًا هي في الغالب كلمات وظيفية شائعة في اللغة الإنجليزية، بينما ظهرت كلمة Alice ضمن أعلى الكلمات المرتبطة مباشرة بمحتوى القصة.

```
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | sort -k2 -nr | head -20
the      1664
and      780
to       773
a        662
of       596
she      484
said     416
in       401
it       356
was      329
you      301
I        260
as       246
that     226
Alice    221
with     214
at       211
her      203
had      175
all      168
```

11. استخراج النتائج إلى النظام المحلي

Extracting Results to Linux

بعد اكتمال التحليل كانت النتائج موجودة داخل HDFS. تم استخدام `getmerge` لاستخراج نتائج مجلد `output` إلى ملف محلي واحد في Linux باسم `alice_wordcount.txt`.

```
hdfs dfs -getmerge /bigdata/alice/output alice_wordcount.txt
ls -lh alice_wordcount.txt
head -20 alice_wordcount.txt
```

ظهر الملف المحلي بحجم يقارب 60 KB، مما يؤكد نجاح مرحلة Extraction وانتقال نتائج المعالجة من HDFS إلى Linux.

```
[cloudera@quickstart ~]$ ls -lh alice_wordcount.txt
-rw-r--r-- 1 cloudera cloudera 60K Sep 17 15:52 alice_wordcount.txt
[cloudera@quickstart ~]$ head -20 alice_wordcount.txt
#11] 1
$5,000) 1
($1 1
(801) 1
(Alice 4
(And, 1
(As 1
(Before 1
(Dinah 1
(For, 1
(He 1
(IF 1
(In 1
(It 1
(Sounds 1
(The 3
(WITH 1
(We 1
(Which 2
(a 1
```

12. المشكلات التي تمت مواجهتها وحلولها

Problems Encountered and Solutions

أثناء تنفيذ المشروع ظهرت بعض المشكلات التقنية في بيئة Cloudera QuickStart VM. تم التعامل معها كجزء من تجهيز البيئة قبل استكمال خطوات المشروع الأساسية.

المشكلة	الحل المختصر
كان نظام HDFS في وضع الأمان	تم التحقق من الحالة والخروج من وضع الأمان باستخدام صلاحيات المستخدم hdfs.
ظهرت عقدة البيانات كعقدة غير حية	تمت إعادة تشغيل خدمة DataNode والتحقق حتى ظهرت عقدة حية واحدة واختفت الكتل المفقودة.
صلاحيات إنشاء مجلد تحت جذر HDFS	تم إنشاء المسار بصلاحيات hdfs ثم إعطاء cloudera ملكية مجلد المشروع.
تعذر تنزيل مجموعة البيانات بسبب إعدادات الشبكة والشهادة	تم استخدام نسخة نصية موثوقة، وتجاوز فحص الشهادة في Cloudera القديمة للملف العام فقط.

ساعدت هذه المشكلات على فهم العلاقة العملية بين مكونات التخزين والعقد في Hadoop، وأظهرت أن نجاح أوامر المعالجة يعتمد أولاً على سلامة الخدمات واتصال العقد.

Conclusion and References

13.1. الخاتمة

Conclusion

تم في هذا المشروع تنفيذ دورة عملية متكاملة لمعالجة البيانات النصية باستخدام Hadoop. بدأت العملية بالحصول على Dataset حقيقية وفحصها داخل Linux، ثم تنظيمها ورفعها إلى HDFS، وفحص طريقة التخزين باستخدام Blocks و Replication والتحقق من سلامة الملف. بعد ذلك تم تشغيل مهمة عدّ الكلمات لتحليل محتوى الكتاب، ثم تمت مراقبة التنفيذ من خلال YARN. وبعد اكتمال المعالجة تم تحليل الكلمات والشخصيات، واستخراج أعلى عشرين كلمة تكررًا، وأخيرًا نقل النتائج من HDFS إلى النظام المحلي باستخدام getmerge. أظهر المشروع عمليًا توزيع الأدوار بين مكونات Hadoop: التخزين داخل HDFS، والمعالجة باستخدام MapReduce، وإدارة الموارد من خلال YARN. كما أوضح أهمية تنظيف النصوص قبل التحليل المتقدم، لأن WordCount الأساسي يتعامل مع علامات الترقيم كجزء من الكلمات.

13.2. المراجع

References

- محاضرات مقرر البيانات الضخمة: إدارة الملفات داخل HDFS، والكتل وعامل التكرار، والتطبيق العملي لـ MapReduce، والمشروع العملي المتكامل.
- Lewis Carroll, Alice's Adventures in Wonderland - Project Gutenberg / GITenberg text edition.
- Apache Hadoop environment - Cloudera QuickStart VM.

Appendix: Key Commands

الغرض	الأمر
فحص الخدمات	<code>sudo jps</code>
إنشاء مجلد الإدخال	<code>hdfs dfs -mkdir -p /bigdata/alice/input</code>
رفع Dataset	<code>hdfs dfs -put alice.txt /bigdata/alice/input/</code>
عرض الملف داخل HDFS	<code>hdfs dfs -ls -h /bigdata/alice/input</code>
فحص Blocks	<code>hdfs fsck /bigdata/alice/input/alice.txt -files -blocks</code>
معرفة Replication Factor	<code>hdfs dfs -stat %r /bigdata/alice/input/alice.txt</code>
تشغيل WordCount	<code>hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount /bigdata/alice/input /bigdata/alice/output</code>
عرض مخرجات Job	<code>hdfs dfs -ls /bigdata/alice/output</code>
أعلى 20 كلمة	<code>hdfs dfs -cat /bigdata/alice/output/part-r-000000 sort -k2 -nr head -20</code>
استخراج النتائج	<code>hdfs dfs -getmerge /bigdata/alice/output alice_wordcount.txt</code>