

UNIVERSITY / COLLEGE  
DEPARTMENT OF INFORMATION TECHNOLOGY  
BIG DATA  
TEXT ANALYTICS WITH  
**HADOOP MAPREDUCE**

التقرير العملي المتكامل

مشروع تحليل النصوص باستخدام Hadoop و MapReduce

| عنوان المشروع     | Big Data Text Analytics with Hadoop MapReduce |
|-------------------|-----------------------------------------------|
| المنصة            | Cloudera QuickStart VM                        |
| التقنيات الأساسية | HDFS + MapReduce + YARN                       |
| نوع التطبيق       | تحليل نصوص و WordCount متعدد الملفات          |
| إعداد الطالب      | يعقوب عبده جوير                               |

## تقرير المشروع العملي المتكامل Big Data Text Analytics with Hadoop MapReduce

تحليل نصوص حقيقية باستخدام Hadoop MapReduceHDFS • MapReduce • YARN • Cloudera QuickStart VM  
التحدي المتقدم متعدد الكتب +

### ١. مقدمة

ملاحظة توثيقية: تُدرج لقطات الشاشة الفعلية في الأماكن التالية، مع كتابة عنوان الشكل ومصدر/وصف اللقطة أسفل كل صورة.

يهدف هذا المشروع إلى تطبيق المفاهيم الأساسية في مقرر Big Data بصورة عملية ومتكاملة باستخدام بيئة Cloudera QuickStart VM. يبدأ مسار البيانات من ملفات نصية حقيقية، ثم يتم فحصها محليًا في Linux، ورفعها إلى HDFS، وتشغيل WordCount باستخدام MapReduce، ومتابعة المهمة من خلال YARN، ثم تحليل النتائج واستخراجها إلى نظام الملفات المحلي.

تم تنفيذ المشروع على كتاب The Adventures of Sherlock Holmes، مع توسيع التجربة وفق التحدي المتقدم الوارد في ملزمة الدكتور ليشمل عدة كتب نصية من Project Gutenberg ومعالجة الملفات دفعة واحدة داخل HDFS.

### ٢. أهداف المشروع

- تحميل واستخدام Dataset نصية حقيقية.
- فحص البيانات قبل إدخالها إلى Hadoop.
- إنشاء مساحة منظمة للبيانات داخل HDFS.
- رفع الملفات من Linux إلى HDFS والتحقق من وجودها.
- تشغيل برنامج WordCount باستخدام MapReduce.
- فهم العلاقة بين HDFS و MapReduce و YARN.
- تحليل تكرار الكلمات والبحث عن كلمات محددة.
- استخراج النتائج من HDFS إلى Linux.
- تطبيق التحدي المتقدم على عدة كتب ودمج نتائجها في تحليل واحد.

### ٣. بيئة التنفيذ

| العنصر              | القيمة                 |
|---------------------|------------------------|
| المنصة              | Cloudera QuickStart VM |
| Hadoop              | 2.6.0-cdh5.13.0        |
| نظام الملفات المحلي | Linux                  |

|                     |                             |
|---------------------|-----------------------------|
| نظام الملفات الموزع | HDFS                        |
| إدارة الموارد       | YARN                        |
| خوارزمية المعالجة   | MapReduce / WordCount       |
| مصدر الكتب          | Project Gutenberg           |
| مسار العمل المحلي   | /home/cloudera/finalProject |

#### ٤. البيانات المستخدمة

البيانات الأساسية هي كتاب The Adventures of Sherlock Holmes من Project Gutenberg، بالملف 1661-0.txt. ووفق التنفيذ الفعلي، تم كذلك تجهيز مجموعة متعددة الكتب للتحدي المتقدم.

| الملف                           | عدد الكلمات المحلي في التحقق |
|---------------------------------|------------------------------|
| 1661-0.txt – Sherlock Holmes    | 107,562                      |
| alice.txt – Alice in Wonderland | 29,569                       |
| frankenstein.txt – Frankenstein | 78,106                       |
| pg37670.txt – Classic Book      | 7,200                        |
| pg9074.txt – Classic Book       | 66,474                       |
| pride.txt – Pride and Prejudice | 130,416                      |
| الإجمالي (6 كتب)                | 419,327                      |

ملاحظة: أرقام عدد الكلمات أعلاه هي نتائج فحص الملفات محليًا باستخدام أدوات Linux، وليست عدد الكلمات الفريدة في مخرجات WordCount.

#### ٥. فحص البيانات قبل Hadoop

تم التحقق من وجود الملفات وحجمها ومحتواها وعدد الأسطر والكلمات قبل إدخالها إلى HDFS. كما تم التحقق من بداية ونهاية النصوص للتأكد من أن الملفات النصية صالحة للمعالجة.

```
ls -lh 1661-0.txt
head -20 1661-0.txt
tail -20 1661-0.txt
wc -l 1661-0.txt
wc -w 1661-0.txt
```

#### ٦. تنظيم البيانات داخل HDFS

تم فصل المسار الأساسي الخاص بكتاب Sherlock Holmes عن مسار التحدي المتقدم متعدد الكتب. هذا يحافظ على متطلبات المشروع الأساسي، وفي الوقت نفسه يضيف تجربة متعددة الملفات.

```
hdfs dfs -mkdir -p /bigdata/sherlock/input
hdfs dfs -mkdir -p /bigdata/books/input
```

المسارات الأساسية المستخدمة:

```
/bigdata/sherlock/input/1661-0.txt  
/bigdata/sherlock/output/
```

مسارات التحدي المتقدم:

```
/bigdata/books/input/  
/bigdata/books/output/
```

## ٧. رفع البيانات والتحقق منها

txt، إلى مسار المشروع الأساسي، كما تم رفع الكتب الستة المعتمدة في المشروع (Sherlock 0-1661 تم رفع كتاب pg9074.txt، pg37670.txt، pride.txt، frankenstein.txt، alice.txt) إلى مسار التحدي المتقدم /bigdata/books/input/.

```
hdfs dfs -put -f 1661-0.txt /bigdata/sherlock/input/  
hdfs dfs -put -f *.txt /bigdata/books/input/  
hdfs dfs -ls -h /bigdata/sherlock/input  
hdfs dfs -ls -h /bigdata/books/input  
hdfs dfs -du -h /bigdata/books/input
```

## 8. Data Cleaning

تم تنفيذ خطوة إضافية لتنظيف النصوص بإزالة علامات الترقيم، ثم تم الاحتفاظ بمسارين: Raw للمعالجة الأصلية المطلوبة في الملزمة، و Cleaned للمقارنة التعليمية. هذا لا يستبدل WordCount الأساسي، وإنما يوضح أثر تجهيز البيانات على نتائج تحليل النص.

```
sed 's/[[:punct:]]//g' input.txt > input-clean.txt
```

نتج عن التنفيذ مسارات cleaned داخل HDFS لكل من Sherlock والمجموعة متعددة الكتب.

## ٩. تشغيل WordCount على Raw – Sherlock

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \  
wordcount \  
/bigdata/sherlock/input \  
/bigdata/sherlock/output
```

انتهت المهمة بنجاح، وظهر ملف SUCCESS\_ مع ملف النتائج part-r-00000. وجود SUCCESS\_ يدل على اكتمال الـ Job بنجاح، بينما توجد البيانات الفعلية في ملف part-r-00000.

## ١٠. نتائج الكلمات المطلوبة في Sherlock

| الكلمة   | عدد مرات الظهور |
|----------|-----------------|
| Holmes   | 198             |
| Watson   | 4               |
| Sherlock | 96              |
| London   | 20              |

|          |    |
|----------|----|
| Lestrade | 21 |
|----------|----|

بحسب مخرجات Hadoop الفعلية، كانت Holmes هي الأعلى بين الكلمات الخمس المحددة، تليها Sherlock، ثم Lestrade، ثم London، ثم Watson.

مهم: هذه الأعداد تمثل WordCount الخام كما نُفذ في المشروع؛ لذلك قد تظهر اختلافات بين الكلمات بسبب حالة الأحرف وعلامات الترقيم وطريقة تقسيم الكلمات.

## ١١. أعلى ٢٠ كلمة في Sherlock

تم تنفيذ الأمر المطلوب في الملزمة لاستخراج أعلى الكلمات تكرارًا:

```
hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head - 20
```

تم تنفيذ الأمر فعلياً على Cloudera VM وظهرت النتائج (انظر الشكل ٤-ب):

the=5412، and=2794، of=2724، to=2702، a=2575، I=2533، in=1706، that=1557،  
was=1361، his=1096، is=1073، you=1034، he=1014، it=977، my=901، have=894،  
with=843، had=807، as=776، which=753

## ١٢. MapReduce في المشروع

استخدم WordCount نموذج MapReduce لتحويل النص إلى أزواج من الشكل (word, 1)، ثم تجميع القيم المتشابهة، ثم جمع قيم كل كلمة لإنتاج العدد النهائي.

| الوظيفة                          | المرحلة |
|----------------------------------|---------|
| قراءة ملفات النص من HDFS         | Input   |
| إنتاج كل كلمة مع القيمة ١        | Mapper  |
| تجميع القيم الخاصة بالكلمة نفسها | Shuffle |
| جمع القيم وإنتاج العدد النهائي   | Reducer |
| حفظ النتائج في part-r-00000      | Output  |

## ١٣. YARN ودوره

YARN مسؤول عن إدارة موارد بيئة Hadoop وتشغيل المهمة من خلال تخصيص الموارد والContainers للتطبيقات. تم التحقق من تشغيل ResourceManager وNodeManager، كما ظهرت عقدة YARN بحالة RUNNING.

```
yarn node -list
```

يمكن متابعة التطبيقات من واجهة YARN على المنفذ ٨٠٨٨ أثناء تنفيذ المهمة.

## ١٤. الفرق بين Linux وHDFS

| Linux                        | HDFS                                    |
|------------------------------|-----------------------------------------|
| نظام ملفات محلي على الجهاز   | نظام ملفات موزع خاص بـHadoop            |
| يستخدم أوامر مثل ls وcat وcp | يستخدم أوامر مثل hdfs dfs -ls وcat وput |

|                                             |                                        |
|---------------------------------------------|----------------------------------------|
| مصمم لتخزين ومعالجة البيانات في بيئة Hadoop | مناسب للملفات المحلية                  |
| الملف داخل HDFS جزء من مساحة تخزين Hadoop   | الملف المحلي هو نسخة مستقلة على الجهاز |

## ١٥. مكان النتيجة النهائية

```
/bigdata/sherlock/output/part-r-00000
/home/cloudera/sherlock_wordcount.txt
```

تم استخدام getmerge لاستخراج نتيجة HDFS إلى Linux:

```
hdfs dfs -getmerge /bigdata/sherlock/output sherlock_wordcount.txt
```

## ١٦. التحدي المتقدم – Multiple Books

تم تطبيق التحدي المتقدم المذكور في ملزمة الدكتور. بدل الاختصار على كتاب واحد، تم استخدام ستة ملفات نصية تشمل (Sherlock Holmes 1661-0.txt، Stories from Thucydides pg9074.txt، Bible Stories pg37670.txt، Pride and Prejudice، Frankenstein، Alice in Wonderland) ووضعها معًا في دفعة واحدة على المجموعة كاملة WordCount ثم تشغيل /bigdata/books/input.

| ملف HDFS         | الكتاب                            |
|------------------|-----------------------------------|
| 1661-0.txt       | The Adventures of Sherlock Holmes |
| alice.txt        | Alice in Wonderland               |
| frankenstein.txt | Frankenstein                      |
| pg37670.txt      | Project Gutenberg Classic #37670  |
| pg9074.txt       | Project Gutenberg Classic #9074   |
| pride.txt        | Pride and Prejudice               |

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
wordcount \
/bigdata/books/input \
/bigdata/books/output
```

تم إنشاء bigdata/books/output/part-r-00000/ وظهر SUCCESS\_، كما تم استخراج النتائج إلى Linux في books\_wordcount.txt.

## ١٧. نتائج حجم الكتب في التحدي المتقدم

اعتمادًا على فحص الملفات المحلية قبل المعالجة، كان ترتيب الكتب من حيث عدد الكلمات: 1. Pride and Prejudice، 2. Sherlock Holmes (107,562 كلمة)، 3. Frankenstein (78,106 كلمة)، 4. Stories from Thucydides pg9074.txt (66,474 كلمة)، 5. Alice in Wonderland (29,569 كلمة)، 6. Bible Stories pg37670.txt (7,200 كلمة).

| عدد الكلمات | الكتاب | الترتيب حسب عدد الكلمات |
|-------------|--------|-------------------------|
|-------------|--------|-------------------------|

|   |                                   |         |
|---|-----------------------------------|---------|
| 1 | Pride and Prejudice               | 130,416 |
| 2 | The Adventures of Sherlock Holmes | 107,562 |
| 3 | Frankenstein                      | 78,106  |
| 4 | Project Gutenberg Classic #9074   | 66,474  |
| 5 | Alice in Wonderland               | 29,569  |
| 6 | Project Gutenberg Classic #37670  | 7,200   |

MB. للملفات السنة: 419,327 كلمة بحجم إجمالي يبلغ حوالي 2.4 -w wc الإجمالي الفعلي وفق فحص

## ١٨. المعالجة متعددة الملفات

يستطيع استقبال مجلد يحتوي على عدة ملفات كنقطة إدخال واحدة ومعالجتها بالتوازي عبر WordCount التجربة توضح أن وإنتاج نتيجة مجمعة بلغت 36,381 كلمة فريدة (خام و 19,372 كلمة فريدة) بعد التنظيف. (وأظهرت Map، مهام 6 بعدد 47 مرة عبر مجمل الكتب «London» بعدد 21,725 مرة، وتكرار اسم «the» النتائج المجمعة تصدر كلمة

كما تم تنفيذ نسخة Cleaned متعددة الكتب في bigdata/books/input\_clean/ وإنتاج نتائجها في bigdata/books/output\_clean/، وهي إضافة للمقارنة وليست بديلاً عن المسار Raw المطلوب.

## ١٩. لماذا يصبح Hadoop أكثر فائدة مع زيادة البيانات والملفات؟

كلما زادت كمية البيانات وعدد الملفات، تصبح الحاجة إلى إدارة التخزين والمعالجة أكثر أهمية. Hadoop يوفر HDFS لتخزين البيانات ضمن بيئة موزعة، و MapReduce لمعالجة البيانات، و YARN لإدارة الموارد وتشغيل المهام. لذلك فإن الانتقال من ملف واحد إلى عدة ملفات يوضح بصورة أفضل فكرة المعالجة الموزعة وإدارة مجموعات البيانات الأكبر.

## ٢٠. دورة حياة البيانات في المشروع

تمثل التجربة دورة متكاملة تبدأ بالحصول على بيانات حقيقية ثم فحصها وتنظيمها ورفعها إلى HDFS، يلي ذلك تشغيل MapReduce ومتابعة المهمة بواسطة YARN، ثم تحليل النتائج واستخراجها إلى Linux.

Real Data → Validation → HDFS Organization → Ingestion → MapReduce → YARN → Analysis → Extraction

## ٢١. إجابات أسئلة المهمة العملية

١. ما أكثر الكلمات تكراراً في النص Sherlock؟

أكثر الكلمات تكراراً في النص هي كلمة «the» وظهرت ٥,٤١٢ مرة، تليها الكلمات الشائعة (Stop Words) مثل «and» (2,794) و «of» (2,724) و «to» (2,702) و «a» (2,575) و «I» (2,533).

| الترتيب | الكلمة | التكرار | الترتيب | الكلمة | التكرار |
|---------|--------|---------|---------|--------|---------|
| 1       | the    | 5,412   | 11      | is     | 1,073   |

|    |      |       |    |       |       |
|----|------|-------|----|-------|-------|
| 2  | and  | 2,794 | 12 | you   | 1,034 |
| 3  | of   | 2,724 | 13 | he    | 1,014 |
| 4  | to   | 2,702 | 14 | it    | 977   |
| 5  | a    | 2,575 | 15 | my    | 901   |
| 6  | I    | 2,533 | 16 | have  | 894   |
| 7  | in   | 1,706 | 17 | with  | 843   |
| 8  | that | 1,557 | 18 | had   | 807   |
| 9  | was  | 1,361 | 19 | as    | 776   |
| 10 | his  | 1,096 | 20 | which | 753   |

٢. كم مرة ظهرت الكلمات المطلوبة؟

مقارنة تكرار الكلمات المطلوبة في النص الخام (Raw) مقابل النص المنظف (Cleaned):

| الكلمة   | التكرار الخام (Raw) | التكرار المنظف (Cleaned) | الفرق والملاحظة                                                |
|----------|---------------------|--------------------------|----------------------------------------------------------------|
| Holmes   | 198                 | 460                      | إزالة الفواصل والنقاط ( +262 )<br>(المتصلة بالاسم)             |
| Watson   | 4                   | 81                       | أغلبها كان ملتصقاً ( +77 )<br>و Watson, بفواصل مثل<br>Watson.) |
| Sherlock | 96                  | 97                       | قطة اتصال الاسم الأول ( +1 )<br>(بعلامات ترقيم)                |
| London   | 20                  | 39                       | إزالة علامات الترقيم ( +19 )<br>(في ختام الجمل)                |
| Lestrade | 21                  | 37                       | إزالة علامات الاقتباس ( +16 )<br>(والفواصل)                    |

٣. ما الكلمات العشرون الأعلى تكراراً؟

تم استخراجها بأمر: `hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head -20` وتظهر النتائج في الجدول التالي مرتبة تنازلياً:

| الترتيب | الكلمة | التكرار | الترتيب | الكلمة | التكرار |
|---------|--------|---------|---------|--------|---------|
| 1       | the    | 5,412   | 11      | is     | 1,073   |
| 2       | and    | 2,794   | 12      | you    | 1,034   |

|    |      |       |    |       |       |
|----|------|-------|----|-------|-------|
| 3  | of   | 2,724 | 13 | he    | 1,014 |
| 4  | to   | 2,702 | 14 | it    | 977   |
| 5  | a    | 2,575 | 15 | my    | 901   |
| 6  | I    | 2,533 | 16 | have  | 894   |
| 7  | in   | 1,706 | 17 | with  | 843   |
| 8  | that | 1,557 | 18 | had   | 807   |
| 9  | was  | 1,361 | 19 | as    | 776   |
| 10 | his  | 1,096 | 20 | which | 753   |

٤. ما الفرق بين Linux وHDFS؟

Linux يدير نظام الملفات المحلي، بينما HDFS نظام ملفات موزع مخصص لبيئة Hadoop وتخزين البيانات ضمنها.

٥. ما وظيفة MapReduce؟

معالجة النص بصورة موزعة عبر Mapper ثم Shuffle ثم Reducer لإنتاج WordCount.

٦. ما وظيفة YARN؟

إدارة موارد Hadoop وتشغيل تطبيقات المعالجة من خلال جدولة الموارد والـ Containers.

٧. أين توجد النتيجة النهائية؟

في HDFS داخل /bigdata/sherlock/output/part-r-00000/، ويمكن استخراجها محليًا إلى /home/cloudera/sherlock\_wordcount.txt/

## ٢.٢. الملفات والمسارات الناتجة

| المسار                                | الغرض                                            |
|---------------------------------------|--------------------------------------------------|
| /bigdata/sherlock/input               | بيانات Sherlock الخام                            |
| /bigdata/sherlock/output              | نتائج WordCount الخام                            |
| /bigdata/sherlock/input_clean         | بيانات Sherlock بعد التنظيف                      |
| /bigdata/sherlock/output_clean        | نتائج WordCount بعد التنظيف                      |
| /bigdata/books/input                  | الكتب الأربعة للتحدي المتقدم                     |
| /bigdata/books/output                 | نتيجة WordCount المجمعة للكتب                    |
| /bigdata/books/input_clean            | الكتب الأربعة بعد التنظيف                        |
| /bigdata/books/output_clean           | نتائج WordCount للنسخة المنظفة                   |
| /home/cloudera/sherlock_wordcount.txt | نتيجة Sherlock المستخرجة إلى Linux               |
| /home/cloudera/books_wordcount.txt    | نتيجة WordCount متعددة الكتب المستخرجة إلى Linux |

## ٢٣. لقطات الشاشة المطلوبة للتسليم

- لقطة ١: البيانات داخل HDFS، ويفضل إظهار `bigdata/sherlock/input/`، ويمكن إضافة لقطة `bigdata/books/input/` لإثبات التحدي المتقدم.
- لقطة ٢: تنفيذ MapReduce أثناء تشغيل Job.
- لقطة ٣: التطبيق داخل YARN وظهور Application ID وحالة المهمة ومراحل Map/Reduce.
- لقطة ٤: النتائج داخل `bigdata/sherlock/output/part-r-00000/` وإظهار الكلمات المطلوبة.

## ٢٤. ملاحظة منهجية حول النتائج

التقرير يميز بين النتائج التي تم تسجيلها فعليًا أثناء التنفيذ وبين القيم التي تحتاج إلى نقل مباشر من مخرج أمر إضافي. أعداد الكلمات المطلوبة ووجود مخرجات Multi-Book وكون Pride and Prejudice الأكبر حسب `wc -w` مثبتة من نتائج التنفيذ المتاحة. أما جدول أعلى ٢٠ كلمة في Sherlock وأعلى ٢٠ كلمة المجمعة للكتب، وكذلك مقارنة كلمة محددة بين الكتب، فيجب أخذها حرفيًا من مخرجات الأوامر حتى لا يتم إدخال أرقام غير منفذة.

## ٢٥. الخلاصة

تم تنفيذ مشروع Big Data Text Analytics باستخدام Hadoop MapReduce على بيانات نصية حقيقية، بدءًا من التحقق من الملفات في Linux، مرورًا بتخزينها في HDFS، ثم تشغيل WordCount باستخدام MapReduce ومتابعة المهمة عبر YARN، وانتهاءً بتحليل النتائج واستخراجها إلى Linux.

Job ومعالجة المجموعة في HDFS نصية داخل (6 Books) كما تم تنفيذ التحدي المتقدم متعدد الكتب باستخدام ستة كتب ويبين كيف يمكن توسيع نفس المنهج، YARN و MapReduce و HDFS واحدة. يوضح ذلك بصورة عملية العلاقة بين من ملف واحد إلى مجموعة من الملفات

المشروع يحقق متطلبات المشروع الأساسي، ويضيف مسار التحدي المتقدم كما ورد في ملزمة الدكتور، مع الحفاظ على فصل النتائج الخام عن نتائج Data Cleaning الإضافية.

## ٢٦. المرجع

ملزمة المقرر: Big Data Text Analytics with Hadoop MapReduce – مشروع عملي متكامل باستخدام Cloudera، Hadoop MapReduce، HDFS، MapReduce، YARN، Sherlock Holmes، QuickStart VM.

مصدر البيانات الأساسي: Project Gutenberg – The Adventures of Sherlock Holmes، الملف `txt.٠-١٦٦١`.







