

تقرير مشروع Hadoop MapReduce

تحليل نصي لرواية Alice's Adventures in Wonderland باستخدام Hadoop MapReduce

اسم الطالبة: افنان عادل منصور عبد العزيز دماج

اسم الدكتور: رمزي البازل

١. مقدمة

يهدف هذا المشروع إلى تطبيق تقنيات معالجة البيانات الضخمة باستخدام Hadoop MapReduce على بيانات نصية حقيقية.

تم اختيار رواية Alice's Adventures in Wonderland للكاتب Lewis Carroll كمجموعة بيانات (Dataset)، وتم استخدام الملف النصي ١١.txt كمصدر للبيانات.

مر المشروع بعدة مراحل تبدأ من فحص البيانات، ثم تخزينها داخل نظام الملفات الموزع HDFS، وبعد ذلك تنفيذ خوارزمية WordCount باستخدام MapReduce، ومتابعة تنفيذ المهمة باستخدام YARN، ثم استخراج النتائج وتحليل الكلمات الأكثر تكرارًا.

يمثل المشروع تطبيقًا عمليًا للمفاهيم التي تم تعلمها في مقرر Big Data، وخاصة HDFS و MapReduce و YARN وتحليل البيانات النصية.

٢. فكرة المشروع

تعتمد فكرة المشروع على استخدام Hadoop لمعالجة نص رواية كاملة وحساب عدد مرات ظهور الكلمات المختلفة داخل النص.

تم تنفيذ دورة معالجة البيانات بالشكل التالي:


Dataset → Linux → HDFS → MapReduce → YARN → Results →
Analysis → Linux

ويتمثل الهدف الرئيسي في تحويل النص الخام إلى نتائج يمكن تحليلها والاستفادة منها.

٣. Dataset

تم استخدام ملف نصي باسم:

١١.txt



```
cloudera@quickstart:~$ wget --no-check-certificate https://www.gutenberg.org/cache/epub/1342/pg1342.txt -O pr
ide.txt
--2026-09-20 07:47:45-- https://www.gutenberg.org/cache/epub/1342/pg1342.txt
Resolving www.gutenberg.org... failed: Name or service not known.
wget: unable to resolve host address "www.gutenberg.org"
[cloudera@quickstart ~]$ wget --no-check-certificate https://raw.githubusercontent.com/GITenberg/Alice-s-Advent
ures-in-Wonderland_11/master/11.txt
--2026-09-20 07:49:37-- https://raw.githubusercontent.com/GITenberg/Alice-s-Adventures-in-Wonderland_11/master
/11.txt
Resolving raw.githubusercontent.com... 185.199.111.133, 185.199.110.133, 185.199.109.133, ...
Connecting to raw.githubusercontent.com|185.199.111.133|:443... connected.
WARNING: cannot verify raw.githubusercontent.com's certificate, issued by "/C=US/O=Let's Encrypt/CN=VRL":
Unable to locally verify the issuer's authority.
HTTP request sent, awaiting response... 200 OK
Length: 167546 (164K) [text/plain]
Saving to: "11.txt"

100%[=====] 167,546 151K/s in 1.1s

2026-09-20 07:49:40 (151 KB/s) - "11.txt" saved [167546/167546]

[cloudera@quickstart ~]$
```

ويحتوي الملف على نص رواية:

Alice's Adventures in Wonderland


للكاتب:

Lewis Carroll

ويبلغ حجم الملف المستخدم:

KB ١٥١

تم فحص الملف قبل إدخاله إلى Hadoop للتأكد من وجوده وصحة محتواه.



الشكل (٢): ملف Dataset المستخدم في المشروع.

٤. فحص البيانات

قبل إدخال البيانات إلى Hadoop، تم التأكد من وجود ملف Dataset وقراءة محتواه.

تم استخدام الأمر:

head -20 11.txt

وذلك لعرض بداية الملف والتأكد من أن البيانات عبارة عن نص قابل للمعالجة.


أظهرت القراءة بداية رواية Alice's Adventures in Wonderland واسم المؤلف
.Lewis Carroll

وتم استخدام الأمر:

tail-20 11.txt

وذلك لعرض نهاية الملف والتأكد منه

الشكل (٣): قراءة Dataset




```
cloudera@quickstart:~$ head -20 11.txt
Project Gutenberg's Alice's Adventures in Wonderland, by Lewis Carroll

This eBook is for the use of anyone anywhere at no cost and with
almost no restrictions whatsoever.  You may copy it, give it away or
re-use it under the terms of the Project Gutenberg License included
with this eBook or online at www.gutenberg.org

Title: Alice's Adventures in Wonderland
Author: Lewis Carroll
Posting Date: June 25, 2008 [EBook #11]
Release Date: March, 1994
[Last updated: December 20, 2011]
Language: English
Character set encoding: ASCII

cloudera@quickstart:~$
```



الشكل (٣): عرض جزء من محتوى ملف Dataset قبل المعالجة.

٥. تخزين البيانات باستخدام HDFS

بعد فحص البيانات، تم تخزين ملف Dataset داخل نظام الملفات الموزع HDFS.
تم استخدام المسار:

`user/cloudera/books_alice/`

ويصبح مسار الملف:

`user/cloudera/books_alice/11.txt/`

تم التحقق من وجود الملف داخل HDFS باستخدام الأمر:


`hdfs dfs -ls -h /user/cloudera/books_alice`

وأظهرت النتيجة وجود الملف:

txt.١١

وهذا يؤكد أن Dataset أصبحت موجودة داخل HDFS وجاهزة للمعالجة.

الشكل (٤): Dataset داخل HDFS



الشكل (٤): التحقق من وجود ملف txt.١١ داخل HDFS.

٦. تنفيذ MapReduce باستخدام WordCount

بعد تخزين Dataset في HDFS، تم استخدام برنامج WordCount الموجود ضمن أمثلة Hadoop MapReduce.

تم تنفيذ الأمر التالي:

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-  
examples.jar wordcount /user/cloudera/books_alice  
/user/cloudera/output_alice
```

يمثل المسار الأول:

```
user/cloudera/books_alice/
```

مسار بيانات الإدخال (Input).


أما المسار الثاني:

```
user/cloudera/output_alice/
```

فهو مسار النتائج (Output).

يقوم WordCount بحساب عدد مرات ظهور كل كلمة في النص.

الشكل (٥): تنفيذ MapReduce



الشكل (٥): تنفيذ مهمة WordCount باستخدام Hadoop MapReduce.

٧. آلية عمل MapReduce

تعمل عملية MapReduce بصورة مبسطة من خلال عدة مراحل:

Input → Mapper → Shuffle → Reducer → Output

في مرحلة Mapper يتم تقسيم النص إلى كلمات وإنشاء أزواج من الشكل:

word 1

ثم تقوم مرحلة Shuffle بتجميع الكلمات المتشابهة.

بعد ذلك تقوم مرحلة Reducer بجمع القيم لكل كلمة وإنتاج العدد النهائي لظهورها.

مثال مبسط:

Alice 1

Alice 1

Alice 1

بعد مرحلة Reduce:

Alice 3

وبذلك يتم الحصول على عدد مرات ظهور كل كلمة في Dataset.

٨. متابعة المهمة باستخدام YARN

يستخدم YARN لإدارة موارد Hadoop ومتابعة تنفيذ المهام.


تم فتح واجهة YARN من خلال:

<http://localhost:8088>

ومن خلال الواجهة يمكن متابعة الـ Application المرتبط بمهمة WordCount ومعرفة حالة المهمة ومعلومات التنفيذ.

ظهرت مهمة WordCount ضمن تطبيقات YARN بحالة تنفيذ ناجحة.

الشكل (٦): متابعة MapReduce باستخدام YARN



الشكل (٦): متابعة مهمة WordCount من خلال واجهة YARN.

٩. نتائج MapReduce

بعد انتهاء تنفيذ مهمة WordCount، تم إنشاء مجلد النتائج:

`user/cloudera/output_alice/`

ويحتوي مجلد النتائج على ملفات ناتجة عن عملية MapReduce، ومن أهمها:

`SUCCESS_`

و:


`part-r-00000`

يمثل الملف `SUCCESS_` إشارة إلى نجاح انتهاء الـ Job، بينما يحتوي:

part-r-00000

على النتائج الفعلية لعملية WordCount.

الشكل (٧): نتائج WordCount



الشكل (٧): النتائج الناتجة عن تنفيذ WordCount داخل HDFS.

١٠. البحث عن كلمة Alice

بعد الحصول على نتائج WordCount، تم البحث عن كلمة:

Alice

باستخدام:

```
hdfs dfs -cat /user/cloudera/output_alice/part-r-00000 | grep -w  
"Alice"
```

أظهرت النتائج وجود عدة صيغ للكلمة، ومنها:

Alice 221

Alice, 76

Alice. 54

Alice: 7

Alice; 16

يشير ذلك إلى أن WordCount الأساسي يتعامل مع الكلمات التي تحتوي على علامات الترقيم كعناصر مختلفة.

فمثلاً:


Alice

Alice

.Alice

يمكن أن تظهر كقيم منفصلة.

الشكل (٨): البحث عن Alice



الشكل (٨): البحث عن كلمة Alice داخل نتائج WordCount.

١١. البحث عن كلمات محددة

تم أيضاً البحث عن بعض الكلمات المهمة في النص، ومنها:

Queen

Rabbit

وأظهرت النتائج أن عدد مرات ظهور الكلمات يختلف من كلمة إلى أخرى.
ومن النتائج:

الكلمة	عدد مرات الظهور
Alice	221
Queen	34
Rabbit	29

توضح هذه النتائج إمكانية استخدام WordCount لاستخراج معلومات محددة من النص وتحليل تكرار الكلمات.

الشكل (٩): البحث عن كلمات محددة

```
cloudera@quickstart:~$ hdfs dfs -cat /user/cloudera/output_alice/part-r-00000 | grep -w "Queen"
Queen 34
Queen! 1
Queen's 7
Queen, 17
Queen, 1
Queen, 11
Queen: 1
Queen? 1
cloudera@quickstart:~$ hdfs dfs -cat /user/cloudera/output_alice/part-r-00000 | grep -w "Rabbit"
Rabbit 29
Rabbit's 3
Rabbit's--Pat! 1
Rabbit, 8
Rabbit-Hole 1
Rabbit: 1
Rabbit; 1
```

الشكل (٩): البحث عن الكلمات المحددة داخل نتائج WordCount.

١٢. استخراج أكثر ٢٠ كلمة تكرارًا


تم ترتيب نتائج WordCount تنازليًا حسب عدد مرات ظهور الكلمات باستخدام الأمر:

```
hdfs dfs -cat /user/cloudera/output_alice/part-r-00000 | sort -k2  
-nr | head -n 20
```

الترتيب	الكلمة	التكرار
1	the	5404
2	and	2798
3	of	2720
4	to	2700
5	a	2575
6	I	2533
7	in	1702
8	that	1559
9	was	1360
10	his	1096
11	is	1076
12	you	1029
13	he	1014
14	it	976
15	my	901
16	have	893
17	with	843
18	had	806
19	as	776
20	which	753

وأظهرت النتائج الكلمات العشرين الأعلى تكرارًا كما يلي:

الشكل (١٠): Top 20



الشكل (١٠): الكلمات العشرون الأعلى تكرارًا في نتائج WordCount.

١٣. استخراج النتائج من HDFS إلى Linux

بعد الانتهاء من معالجة البيانات، تم استخراج نتائج MapReduce من HDFS إلى Linux باستخدام الأمر:


```
hdfs dfs -getmerge /user/cloudera/output_alice  
alice_wordcount.txt
```

وبذلك تم إنشاء ملف محلي باسم:

```
alice_wordcount.txt
```

يحتوي الملف على نتائج WordCount التي تم الحصول عليها من Hadoop.

الشكل (١١): ملف النتائج النهائي



الشكل (١١): ملف `alice_wordcount.txt` بعد استخراج نتائج `WordCount`.

١٤. تحليل النتائج

أظهرت نتائج WordCount أن الكلمات الأكثر تكرارًا في النص هي كلمات شائعة في اللغة الإنجليزية مثل:

The

and

A

to

of

كما ظهرت كلمة:

Alice

ضمن الكلمات العشرين الأعلى تكرارًا بعدد:

٢٢١

كما أظهرت النتائج وجود كلمات مرتبطة بشخصيات وأحداث الرواية مثل:

Queen

Rabbit

ويمكن استخدام هذه النتائج للحصول على تصور أولي عن الكلمات الأكثر استخدامًا في النص.

١٥. تأثير علامات الترقيم على النتائج

من الملاحظ في نتائج البحث عن Alice وجود عدة صيغ للكلمة، مثل:

Alice

Alice,

Alice.

Alice:

; Alice

ويحدث ذلك لأن WordCount الأساسي لا يقوم بتنظيف النص بشكل متقدم قبل حساب الكلمات.

لذلك فإن إزالة علامات الترقيم وتوحيد الحروف الكبيرة والصغيرة يمكن أن يؤدي إلى نتائج أكثر ملاءمة للتحليل النصي المتقدم.

وهذا يوضح أهمية مرحلة Data Cleaning في مشاريع Big Data، لأن جودة التحليل تعتمد جزئيًا على جودة البيانات وطريقة تجهيزها.

١٦. العلاقة بين HDFS و MapReduce و YARN

يوضح المشروع العلاقة بين المكونات الأساسية لنظام Hadoop.

HDFS

يستخدم لتخزين Dataset والنتائج بطريقة موزعة.

MapReduce

يستخدم لمعالجة البيانات وحساب عدد مرات ظهور الكلمات.

YARN

يستخدم لإدارة موارد النظام ومتابعة تنفيذ مهمة MapReduce.

١٧. أهم الأوامر المستخدمة

التحقق من Dataset

`ls -lh 11.txt`

قراءة بداية Dataset

`head -20 11.txt`

التحقق من HDFS

`hdfs dfs -ls -h /user/cloudera/books_alice`

تنفيذ WordCount

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-  
examples.jar wordcount /user/cloudera/books_alice  
/user/cloudera/output_alice
```

عرض النتائج

```
hdfs dfs -cat /user/cloudera/output_alice/part-r-00000 | head -n  
20
```

البحث عن Alice

```
hdfs dfs -cat /user/cloudera/output_alice/part-r-00000 | grep -w  
"Alice"
```

ترتيب أعلى ٢٠ كلمة

```
hdfs dfs -cat /user/cloudera/output_alice/part-r-00000 | sort -k2  
-nr | head -n 20
```

استخراج النتائج

```
hdfs dfs -getmerge /user/cloudera/output_alice  
alice_wordcount.txt
```

واجهة YARN

<http://localhost:8088>

١٨. أسئلة يمكن الإجابة عنها من المشروع

السؤال الأول: ما وظيفة HDFS؟

HDFS هو نظام الملفات الموزع المستخدم في Hadoop لتخزين البيانات بطريقة موزعة.

السؤال الثاني: ما وظيفة MapReduce؟

MapReduce يستخدم لمعالجة البيانات بصورة موزعة، ويتكون بشكل أساسي من مراحل Map و Shuffle و Reduce.

السؤال الثالث: ما وظيفة WordCount؟

يقوم WordCount بحساب عدد مرات ظهور كل كلمة في النص.

السؤال الرابع: ما وظيفة YARN؟

YARN مسؤول عن إدارة موارد Hadoop ومتابعة وتشغيل التطبيقات والمهام.

السؤال الخامس: أين توجد النتائج؟

توجد نتائج WordCount داخل:

user/cloudera/output_alice/

ومن أهم ملفات النتائج:

part-r-00000

السؤال السادس: ما فائدة alice_wordcount.txt؟

هو ملف محلي تم استخراج نتائج WordCount إليه من HDFS حتى يمكن قراءتها وتحليلها خارج HDFS.

السؤال السابع: لماذا ظهرت Alice و Alice, ككلمتين مختلفتين؟

لأن WordCount الأساسي يتعامل مع علامات الترقيم كجزء من النص ولا يقوم بتنظيف الكلمات قبل العد.

١٩. الخلاصة

تم في هذا المشروع تطبيق دورة متكاملة لمعالجة البيانات النصية باستخدام Hadoop.

بدأ المشروع باستخدام Dataset حقيقية وهي رواية Alice's Adventures in Wonderland، ثم تم فحص الملف والتأكد من محتواه.

بعد ذلك تم تخزين Dataset داخل HDFS في المسار:

user/cloudera/books_alice/

ثم تم تنفيذ برنامج WordCount باستخدام Hadoop MapReduce، ومتابعة تنفيذ المهمة باستخدام YARN.

بعد انتهاء المعالجة، تم استعراض النتائج والبحث عن كلمات محددة مثل Alice و Queen و Rabbit، بالإضافة إلى استخراج أكثر ٢٠ كلمة تكرارًا.

وأخيرًا تم استخراج نتائج Hadoop من HDFS إلى ملف Linux باسم:

alice_wordcount.txt

وبذلك تم تطبيق مجموعة من مفاهيم Big Data عمليًا، بما في ذلك HDFS و MapReduce و YARN و WordCount وتحليل النتائج.