

تحليل كتاب حقيقي باستخدام Hadoop MapReduce

Big Data Text Analytics with Hadoop MapReduce

1. مقدمة المشروع

يهدف هذا المشروع إلى تطبيق تقنيات معالجة البيانات الضخمة باستخدام Hadoop MapReduce من خلال تحليل نص كتاب حقيقي، واستخراج إحصائيات عن الكلمات الأكثر تكرارًا، بالإضافة إلى البحث عن كلمات وشخصيات وأماكن محددة داخل النص.

تم تطبيق خطوات المشروع باستخدام بيئة **Cloudera QuickStart VM**، والاستفادة من مكونات Hadoop ، وبالأخص:

- Linux للتعامل مع الملف وفحص البيانات.
- HDFS لتخزين البيانات داخل نظام الملفات الموزع.
- MapReduce لتنفيذ عملية حساب تكرار الكلمات.
- YARN لمتابعة وإدارة مهام Hadoop.
- أوامر Hadoop لتحليل النتائج واستخراج الكلمات المطلوبة.
- Linux لحفظ النتائج النهائية وتحضيرها للتحليل.

تم اختيار كتاب:

Pride and Prejudice

للكاتبة:

Jane Austen

وتم استخدام نسخة نصية حقيقية من مشروع Gutenberg / GITenberg بدلاً من الكتاب المستخدم في المثال الموجود في تعليمات المشروع.


2. الحصول على Dataset حقيقي

تم استخدام النسخة النصية من كتاب **Pride and Prejudice**، وتم حفظها محليًا داخل بيئة Linux باسم:

pride_prejudice.txt


وتم تحميل الكتاب باستخدام الأمر:

```
wget --no-check-certificate -O pride_prejudice.txt  
https://raw.githubusercontent.com/GITenberg/Pride-and-Prejudice_1342/master/1342-0.txt
```



بعد تحميل الملف تم التأكد من وجوده وحجمه باستخدام:

```
ls -lh pride_prejudice.txt
```



ويظهر في الناتج الملف pride_prejudice.txt

وكان حجم الملف:

724725 bytes أي ما يقارب: 708K

3. فحص البيانات في Linux

قبل نقل البيانات إلى HDFS ، تم فحص الملف محليًا للتأكد من أنه ملف نصي حقيقي وسليم.

3.1. عرض بداية الملف

تم استخدام:

```
head pride_prejudice.txt
```

```
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$ head pride_prejudice.txt  
The Project Gutenberg EBook of Pride and Prejudice, by Jane Austen  
  
This eBook is for the use of anyone anywhere at no cost and with  
almost no restrictions whatsoever. You may copy it, give it away or  
re-use it under the terms of the Project Gutenberg License included  
with this eBook or online at www.gutenberg.org  
  
Title: Pride and Prejudice  
[cloudera@quickstart ~]$ █
```

ثم تم عرض أول ٢٠ سطرًا بشكل أكثر وضوحًا:


```
head -20 pride_prejudice.txt
```

```
This command was run using /usr/lib/hadoop/hadoop-common-2.6.0-cdh5.13.0.jar  
[cloudera@quickstart ~]$ head -20 pride_prejudice.txt  
The Project Gutenberg EBook of Pride and Prejudice, by Jane Austen  
  
This eBook is for the use of anyone anywhere at no cost and with  
almost no restrictions whatsoever. You may copy it, give it away or  
re-use it under the terms of the Project Gutenberg License included  
with this eBook or online at www.gutenberg.org  
  
Title: Pride and Prejudice  
Author: Jane Austen  
Posting Date: August 26, 2008 [EBook #1342]  
Release Date: June, 1998  
Last Updated: March 10, 2018  
Language: English  
Character set encoding: UTF-8
```

3.2. حساب عدد الأسطر

تم استخدام:

```
wc -l pride_prejudice.txt
```



The screenshot shows a Cloudera VM desktop environment. A terminal window is open, displaying the following commands and output:

```
cloudera@quickstart:~$ wc -l pride_prejudice.txt
13427 pride_prejudice.txt
cloudera@quickstart:~$ wc -w pride_prejudice.txt
124592 pride_prejudice.txt
cloudera@quickstart:~$ tail -20 pride_prejudice.txt
Professor Michael S. Hart is the originator of the Project Gutenberg-tm
concept of a library of electronic works that could be freely shared
with anyone. For thirty years, he produced and distributed Project
Gutenberg-tm eBooks with only a loose network of volunteer support.

Project Gutenberg-tm eBooks are often created from several printed
editions, all of which are confirmed as Public Domain in the U.S.
unless a copyright notice is included. Thus, we do not necessarily
keep eBooks in compliance with any particular paper edition.

Most people start at our Web site which has the main PG search facility:
http://www.gutenberg.org

This Web site includes information about Project Gutenberg-tm,
including how to make donations to the Project Gutenberg Literary
```


3.3. حساب عدد الكلمات

تم استخدام:

```
wc -w pride_prejudice.txt
```

ويظهر في الناتج:

124592



The screenshot shows a Cloudera VM desktop environment. A terminal window is open, displaying the following commands and output:

```
cloudera@quickstart:~$ wc -l pride_prejudice.txt
13427 pride_prejudice.txt
cloudera@quickstart:~$ wc -w pride_prejudice.txt
124592 pride_prejudice.txt
cloudera@quickstart:~$ tail -20 pride_prejudice.txt
Professor Michael S. Hart is the originator of the Project Gutenberg-tm
concept of a library of electronic works that could be freely shared
with anyone. For thirty years, he produced and distributed Project
Gutenberg-tm eBooks with only a loose network of volunteer support.

Project Gutenberg-tm eBooks are often created from several printed
editions, all of which are confirmed as Public Domain in the U.S.
unless a copyright notice is included. Thus, we do not necessarily
keep eBooks in compliance with any particular paper edition.


Most people start at our Web site which has the main PG search facility:
http://www.gutenberg.org

This Web site includes information about Project Gutenberg-tm,
including how to make donations to the Project Gutenberg Literary
```

3.4. فحص نهاية الملف

للتأكد من أن الملف مكتمل حتى نهايته تم استخدام:

```
tail -20 pride_prejudice.txt
```



4. إنشاء مجلد المشروع في HDFS


بعد التأكد من صحة البيانات، تم إنشاء مجلد خاص بالمشروع داخل HDFS.

تم اعتماد المسار:

```
/bigdata/pride_prejudice
```

وتم إنشاء المجلد باستخدام:


```
sudo -u hdfs hdfs dfs -mkdir -p /bigdata/pride_prejudice/input
```



خطوة إضافية: ضبط صلاحيات مجلد المشروع

تم ضبط ملكية مجلد المشروع حتى يستطيع المستخدم cloudera التعامل مع ملفات المشروع وتنفيذ عمليات Hadoop المطلوبة:

```
sudo -u hdfs hdfs dfs -chown -R cloudera:cloudera /bigdata/pride_prejudice
```




سبب هذه الخطوة:

ضمان أن المستخدم الذي ينفذ المشروع يمتلك صلاحية القراءة والكتابة على مجلد المشروع ونتائجه داخل HDFS.

5. رفع البيانات من Linux إلى HDFS

بعد إنشاء مجلد الإدخال، تم رفع ملف الكتاب من نظام Linux إلى HDFS باستخدام:

```
hdfs dfs -put pride_prejudice.txt /bigdata/pride_prejudice/input/
```




وبذلك أصبح الكتاب متاحًا داخل HDFS في المسار:

/bigdata/pride_prejudice/input/pride_prejudice.txt

6. التحقق من وجود الملف داخل HDFS

تم التأكد من رفع الملف بنجاح باستخدام: `hdfs dfs -ls /bigdata/pride_prejudice/input`



ثم تم عرض الحجم بطريقة مقروءة:

`hdfs dfs -ls -h /bigdata/pride_prejudice/input`

```
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/pride_prejudice/input
Found 1 items
-rw-r--r-- 1 cloudera cloudera 707.7 K 2026-09-22 16:29 /bigdata/pride_prejudice/input/pride_prejudice.txt
[cloudera@quickstart ~]$
```

وكان حجم الملف داخل: HDFS 707.7 K

7. قراءة البيانات مباشرة من HDFS

للتأكد من إمكانية الوصول إلى الملف من داخل HDFS ، تم استخدام:

`hdfs dfs -cat /bigdata/pride_prejudice/input/pride_prejudice.txt | head -20`

```
ce/input/pride_prejudice.txt
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/input/pride_prejudice.txt | head -20
The Project Gutenberg EBook of Pride and Prejudice, by Jane Austen

This eBook is for the use of anyone anywhere at no cost and with
almost no restrictions whatsoever. You may copy it, give it away or
re-use it under the terms of the Project Gutenberg License included
with this eBook or online at www.gutenberg.org

Title: Pride and Prejudice
Author: Jane Austen
Posting Date: August 26, 2008 [EBook #1342]
Release Date: June, 1998
Last Updated: March 10, 2018
Language: English
Character set encoding: UTF-8
cat: Unable to write to output stream.
[cloudera@quickstart ~]$
```

وأظهر الأمر بداية الكتاب من داخل HDFS.

وهذه الخطوة مهمة لأنها تؤكد أن الملف لم يتم رفعه فقط، وإنما أصبح قابلاً للقراءة من نظام HDFS.

8. التحقق من حجم البيانات في HDFS

تم استخدام الأمر:

```
hdfs dfs -du -h /bigdata/pride_prejudice/input
```

```
cat: Unable to write to output stream.
[cloudera@quickstart ~]$ hdfs dfs -du -h /bigdata/pride_prejudice/input
707.7 K 707.7 K /bigdata/pride_prejudice/input/pride_prejudice.txt
```

وكانت النتيجة:

```
707.7 K 707.7 K /bigdata/pride_prejudice/input/pride_prejudice.txt
```

وبذلك تم التأكد من حجم الملف المخزن داخل HDFS.

9. تنفيذ Hadoop MapReduce WordCount


بعد تجهيز البيانات داخل HDFS ، تم تنفيذ برنامج **WordCount** باستخدام MapReduce.

تم استخدام Hadoop MapReduce Examples الموجود في النظام:

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
wordcount /bigdata/pride_prejudice/input /bigdata/pride_prejudice/output
```



ويتم التنفيذ بصورة عامة بالمراحل التالية:



10. التحقق من نتائج MapReduce

بعد انتهاء عملية WordCount ، تم فحص مجلد النتائج باستخدام:

```
hdfs dfs -ls -h /bigdata/pride_prejudice/output
```



```
cloudera@quickstart:~$ hdfs dfs -ls -h /bigdata/pride_prejudice/output
Found 2 items
-rw-r--r-- 1 cloudera cloudera 0 2026-09-22 16:35 /bigdata/pride_prejudice/output/part-r-00000
cloudera@quickstart:~$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000
head -20
#1342] 1
$5,000) 1
'As, 15 1
'Ah! 1
'Being 1
'Having 1
'Z 1
'Keep 1
'Lady 1
'Late 1
'Late 1
'Oh! 1
'This 1
'Tis 1
'Yes, 1
'had 1
'violently 1
'you 1
cat: Unable to write to output stream
cloudera@quickstart:~$
```

ويظهر في الناتج:

```
_SUCCESS
part-r-00000
```

وكان حجم الملف الناتج: 147.7 K

معنى الملفات _SUCCESS

يمثل علامة على اكتمال عملية MapReduce بنجاح.

part-r-00000

يحتوي على نتائج عملية Reduce ، وهي الكلمات التي تم حساب عدد مرات ظهورها داخل الكتاب.

11. قراءة نتائج WordCount

تم عرض أول ٢٠ نتيجة من ملف النتائج باستخدام:

```
hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | head -20
```

الصورة رقم (١٧) — عرض أول ٢٠ نتيجة من WordCount

```
[In Home] cloudera-quickstart-vm-5.1
Applications Places System cloudera@quickstart:~
File Edit View Search Terminal Help
cloudera@quickstart ~$
cloudera@quickstart ~$
cloudera@quickstart ~$
cloudera@quickstart ~$ hdfs dfs -ls -h /bigdata/pride_prejudice/output
Found 2 items
-rw-r--r- 1 cloudera cloudera 0 2026-09-22 16:35 /bigdata/pride_prejudice/output/part-r-000000
-rw-r--r- 1 cloudera cloudera 147.7 K 2026-09-22 16:35 /bigdata/pride_prejudice/output/part-r-000000
cloudera@quickstart ~$ hdfs dfs -ls -R /bigdata/pride_prejudice/output
-rw-r--r- 1 cloudera cloudera 0 2026-09-22 16:35 /bigdata/pride_prejudice/output/part-r-000000
-rw-r--r- 1 cloudera cloudera 151217 2026-09-22 16:35 /bigdata/pride_prejudice/output/part-r-000000
cloudera@quickstart ~$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-000000
I head -20
#1342] 1
$5,000) 1
'AS-IS' 1
'Ah! 1
'Bingley, 1
'Having 1
'I 1
'Keep 1
'Lady 1
'Latently, 1
'Lydia 1
'Mr. 1
'Oh! 1
'This 1
'Tis 1
'Yes, ' 1
'_She_ 1
'had 1
'violently 1
'you 1
cat: Unable to write to output stream
cloudera@quickstart ~$
```

ويظهر معها أول ٢٠ نتيجة من ملف part-r-000000.

ومن النتائج التي ظهرت:

```
#1342] 1
$5,000) 1
'AS-IS' 1
'Ah! 1
'Bingley, 1
'Having 1
'I 1
'Keep 1
'Lady 1
'Latently, 1
'Lydia 1
'Mr. 1
'Oh! 1
'This 1
'Tis 1
'Yes, ' 1
'_She_ 1
'had 1
'violently 1
'you 1
```

وتوضح هذه النتائج طبيعة WordCount الأساسي، حيث يتم التعامل مع الكلمات والرموز الموجودة في النص كما هي.

12. البحث عن كلمات وشخصيات وأماكن محددة

تم بعد ذلك استخدام نتائج WordCount للبحث عن كلمات مهمة مرتبطة بمحتوى الرواية.

12.1 Elizabeth

تم استخدام:

```
hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | grep -w
                        "Elizabeth"
```

A screenshot of a Cloudera Quickstart VM terminal window. The title bar shows "cloudera-quickstart vm 5.1...". The terminal output displays the results of an HDFS command:

```
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | grep -w "Elizabeth"
```

```
^C  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000  
| grep -w "Elizabeth"  
Elizabeth      398  
Elizabeth's    37  
Elizabeth's,   136  
Elizabeth,,    3  
Elizabeth-     1  
Elizabeth--and 1  
Elizabeth--there 1  
Elizabeth,,    28  
Elizabeth,,    1  
Elizabeth;     3  
Elizabeth;     21  
intelligence-Elizabeth 1  
"Elizabeth     1  
"Elizabeth     1  
[cloudera@quickstart ~]$
```

The terminal interface includes standard menu bars (File, Edit, View, Search, Terminal, Help) and a status bar at the bottom indicating the date and time as Wednesday, September 23, 4:24 PM.

ويظهر في الناتج السطر:

Elizabeth 398

بالإضافة إلى الصيغ الأخرى الموجودة في النتائج.

وكان التطابق المباشر:

Elizabeth = 398

مع وجود صيغ أخرى للكلمة بسبب علامات الترقيم أو اتصالها بكلمات أخرى.

12.2 Darcy

تم استخدام:

```
hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | grep -w "Darcy"
```

```
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-000000 | grep -w "Darcy"
Darcy! 1
Darcy! 215
Darcy! 7
Darcy! 3
Darcy's 41
Darcy's, 1
Darcy's," 1
Darcy's; 1
Darcy, 96
Darcy," 6
Darcy--that 1
Darcy, 21
Darcy," 5
Darcy: 1
Darcy--but 1
Darcy; 7
Darcy? 1
Darcy? 7
cloudera@quickstart ~$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-000000
```

ويظهر في الناتج:

Darcy 215

12.3 Jane

تم استخدام:

```
hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | grep -w "Jane"
```

```
Darcy?" 7
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000
| grep -w "Jane"
Jane 155
Jane! 3
Jane!" 2
Jane's " 26
Jane's " 1
Jane's? 71
Jane, " 4
Jane--from 1
Jane--his 1
Jane--one 1
Jane--which 1
Jane, 15
Jane: 1
Jane; 10
Jane? 1
"Jane, 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000
| grep -w "Bennet"
```

وكان التطابق المباشر:

Jane = 155

كما ظهرت صيغ أخرى مثل:

Jane!
Jane's
Jane,
Jane.
Jane;
Jane?
"Jane,

12.4 Bennet

تم استخدام:

```
hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | grep -w  
"Bennet"
```

```
"Jane, 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000
| grep -w "Bennet"
Bennet 168
Bennet! 1
Bennet!" 1
Bennet's 29
Bennet, 89
Bennet," 1
Bennet," 8
Bennet, 12
Bennet." --My 1
Bennet." 1
Bennet: 1
Bennet; 6
Bennet? 1
Bennet?" 3
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | grep -w "London"
```

وكان التطابق المباشر:

Bennet = 168

كما ظهرت صيغ أخرى مثل:

Bennet!
Bennet's
Bennet,

Bennet.
Bennet;
Bennet?
Bennet?"

12.5 London

تم استخدام:

```
hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | grep -w  
"London"
```

```
Bennet?"      3  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | grep -w "London"  
London      22  
London!     1  
London,     15  
London,"    2  
London--his 1  
London.     8  
London."    1  
London;     3  
London?"    2  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | sort -k2 -nr | h
```

وكان التطابق المباشر:

London = 22

كما ظهرت صيغ أخرى مثل:

London!
London,
London."
London--his
London.
London;
London?"

13. استخراج أعلى ٢٠ كلمة تكرارًا

تم استخراج أكثر ٢٠ كلمة تكرارًا باستخدام:

```
hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | sort -k2 -nr  
| head -20
```



```
File Edit View VM Tabs Help  
cloudera@quickstart:~  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-00000 | sort -k2 -nr | head -20  
the      4295  
of       4121  
and      3909  
a        3645  
for      3638  
as       3613  
was      3225  
I        3240  
not      3238  
his      3200  
her      3200  
he       3200  
his      3197  
the      3196  
at       3119  
with    3040  
in       3030  
you     2877  
it       2877  
[cloudera@quickstart ~]$
```

وكانت النتائج:

عدد مرات الظهور الكلمة الترتيب

1	the	4205
2	to	4121
3	of	3662
4	and	3309
5	a	1945
6	her	1858
7	in	1813
8	was	1795
9	I	1740
10	that	1419
11	not	1356
12	she	1306
13	be	1209
14	his	1167
15	had	1126
16	as	1119
17	with	1040
18	he	1038
19	for	1003
20	you	987

14. تحليل نتائج Top 20

توضح النتائج أن الكلمات الأكثر تكرارًا في النص هي في الغالب كلمات شائعة في اللغة الإنجليزية مثل:

the
to
of
and
a
her
in
was

ويرجع ذلك إلى أن عملية WordCount المستخدمة تقوم بحساب الكلمات كما تظهر في النص، دون تنفيذ مرحلة متقدمة لإزالة الكلمات الشائعة أو تنظيف علامات الترقيم.

كما تظهر كلمات مثل:

her
she
his
he

ضمن الكلمات الأعلى تكرارًا، وهو أمر مرتبط بطبيعة النص السردى واستخدام الضمائر أثناء رواية الأحداث والحوار بين الشخصيات.

ومن المهم ملاحظة أن هذا التحليل يمثل **WordCount** أساسيًا وليس تحليلًا لغويًا متقدمًا، ولذلك لا يمكن اعتبار الكلمات الأعلى تكرارًا بالضرورة أهم الكلمات من ناحية المعنى.

15. نقل نتائج HDFS إلى Linux

بعد الانتهاء من تحليل النتائج داخل HDFS ، تم نسخ النتائج إلى نظام Linux باستخدام الأمر:


```
hdfs dfs -getmerge /bigdata/pride_prejudice/output  
pride_prejudice_wordcount.txt
```



```
cloudera@quickstart:~$ hdfs dfs -getmerge /bigdata/pride_prejudice/yarn_demo pride_prejudice_yarn_wordcount.txt
cloudera@quickstart:~$ ls -lh pride_prejudice_yarn_wordcount.txt
-rw-r--r-- 1 cloudera cloudera 148K Sep 23 16:56 pride_prejudice_yarn_wordcount.txt
cloudera@quickstart:~$ head -20 pride_prejudice_yarn_wordcount.txt
#1342) 1
$5,000) 1
'AS-IS' 1
'Ahi' 1
'Bingley,' 1
'Having' 1
'I' 1
'Keep' 1
'Lady' 1
'Lately,' 1
'Lydia' 1
'Mr.' 1
'Oh!' 1
'This' 1
'Tis' 1
'Yes,' 1
'She' 1
'had' 1
'violently' 1
'you' 1
```

ثم تم التحقق من وجوده وحجمه باستخدام:

```
ls -lh pride_prejudice_wordcount.txt
```



```
cloudera@quickstart:~$ ls -lh pride_prejudice_wordcount.txt
-rw-r--r-- 1 cloudera cloudera 148K Sep 23 16:56 pride_prejudice_yarn_wordcount.txt
cloudera@quickstart:~$ head -20 pride_prejudice_yarn_wordcount.txt
#1342) 1
$5,000) 1
'AS-IS' 1
'Ahi' 1
'Bingley,' 1
'Having' 1
'I' 1
'Keep' 1
'Lady' 1
'Lately,' 1
'Lydia' 1
'Mr.' 1
'Oh!' 1
'This' 1
'Tis' 1
'Yes,' 1
'She' 1
'had' 1
'violently' 1
'you' 1
```

وكان حجمه: 148K

16. التحقق من الملف النهائي

تم عرض أول ٢٠ سطرًا من الملف النهائي باستخدام:

```
head -20 pride_prejudice_wordcount.txt
```



```
cloudera@quickstart:~$ hdfs dfs -getmerge /bigdata/pride_prejudice/yarn_demo pride_prejudice_yarn_wordcount.txt
cloudera@quickstart:~$ ls -lh pride_prejudice_yarn_wordcount.txt
-rw-r--r-- 1 cloudera cloudera 148K Sep 23 16:56 pride_prejudice_yarn_wordcount.txt
cloudera@quickstart:~$ head -20 pride_prejudice_yarn_wordcount.txt
#1342] 1
$5,000) 1
'AS-IS' 1
'Ah! 1
'Bingley, 1
'Having 1
'I 1
'Keep 1
'Lady 1
'Lately, 1
'Lydia 1
'Mr. 1
'Oh! 1
'This 1
'Tis 1
'Yes,' 1
'_She_ 1
'had 1
'violently 1
'you 1
cloudera@quickstart:~$
```

وظهرت النتائج:

```
#1342] 1
$5,000) 1
'AS-IS' 1
'Ah! 1
'Bingley, 1
'Having 1
'I 1
'Keep 1
'Lady 1
'Lately, 1
'Lydia 1
'Mr. 1
'Oh! 1
'This 1
'Tis 1
'Yes,' 1
'_She_ 1
'had 1
'violently 1
'you 1
```


وبذلك تم التأكد من أن نتائج WordCount تم نقلها بنجاح من HDFS إلى Linux.

17. متابعة المهمة باستخدام YARN

يُستخدم YARN في Hadoop لإدارة موارد النظام ومتابعة مهام المعالجة التي يتم تنفيذها.

تم استخدام واجهة YARN من خلال:

<http://localhost:8088>



وتوضح واجهة ResourceManager حالة Cluster والعدد والموارد المتاحة.

أثناء تنفيذ مهمة WordCount تم تسجيل التطبيق داخل YARN ، وكانت بيانات المهمة الفعلية كما يلي:

ID	User	Name	Application Type	Queue	StartTime	FinishTime	State	FinalStatus	RM
application_1790197245852_0001	cloudera	word count	MAPREDUCE	root-users.cloudera	Wed Sep 23 14:34:41.0700 2026	Wed Sep 23 14:35:00.0700 2026	FINISHED	SUCCEEDED	N/A

ونأتي هذه المرحلة ضمن Workflow المشروع لأنها توضح كيفية متابعة وإدارة مهمة MapReduce داخل بيئة Hadoop باستخدام YARN

18. التحقق من نتيجة تشغيل YARN

للتأكد من أن تشغيل WordCount الذي تمت متابعته بواسطة YARN أنتج نتيجة فعلية داخل HDFS ، تم استخدام مجلد نتائج منفصل للتوثيق:

/bigdata/pride_prejudice/yarn_demo

تم التحقق منه باستخدام:

hdfs dfs -ls -h /bigdata/pride_prejudice/yarn_demo

```
cat: Unable to write to output stream.
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/pride_prejudice/yarn_demo
Found 2 items
-rw-r--r-- 1 cloudera cloudera 0 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo/ SUCCESS
-rw-r--r-- 1 cloudera cloudera 147.7 K 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo/part-r-000000
[cloudera@quickstart ~]$ hdfs dfs -ls -R /bigdata/pride_prejudice/yarn_demo
-rw-r--r-- 1 cloudera cloudera 0 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo/ SUCCESS
-rw-r--r-- 1 cloudera cloudera 151217 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo/part-r-000000
```

ويظهر فيها:

_SUCCESS
part-r-00000

وحجم ملف النتائج: 147.7 K

ثم تم التحقق من جميع الملفات باستخدام:

```
hdfs dfs -ls -R /bigdata/pride_prejudice/yarn_demo
```

```
cat: Unable to write to output stream.
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/pride_prejudice/yarn_demo
Found 2 items
-rw-r--r-- 1 cloudera cloudera 0 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo/_SUCCESS
-rw-r--r-- 1 cloudera cloudera 147.7 K 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo/part-r-000000
[cloudera@quickstart ~]$ hdfs dfs -ls -R /bigdata/pride_prejudice/yarn_demo
-rw-r--r-- 1 cloudera cloudera 0 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo/_SUCCESS
-rw-r--r-- 1 cloudera cloudera 151217 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo/part-r-000000
```

ويظهر:

```
_SUCCESS
part-r-000000
```

وكان حجم:

151217 bytes

ثم تم عرض أول ٢٠ نتيجة:

```
hdfs dfs -cat /bigdata/pride_prejudice/yarn_demo/part-r-000000 | head -20
```

```
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/yarn_demo/part-r-000000 | head -20
#1342] 1
$5,000) 1
'AS-IS' 1
'Ah! 1
'Bingley, 1
'Having 1
'I 1
'Keep 1
'Lady 1
'Latently, 1
'Lydia 1
'Mr. 1
'Oh! 1
'This 1
'Tis 1
'Yes,' 1
'She 1
'had 1
'violently 1
'you 1
cat: Unable to write to output stream.
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/pride_prejudice/output/part-r-000000 | grep -w "Elizabe
```

19. البنية النهائية للمشروع

أصبحت بنية المشروع داخل HDFS كالتالي:

```
/bigdata
├── pride_prejudice
│   ├── input
│   └── pride_prejudice.txt
│       ├── output
│       │   ├── _SUCCESS
│       │   └── part-r-000000
│       └── yarn_demo
│           ├── _SUCCESS
│           └── part-r-000000
```

```

[cloudera@quickstart ~]$ hdfs dfs -ls -R /bigdata/pride_prejudice
drwxr-xr-x - cloudera cloudera 0 2026-09-22 16:29 /bigdata/pride_prejudice/input
-rw-r--r-- 1 cloudera cloudera 724725 2026-09-22 16:29 /bigdata/pride_prejudice/input/pride_p
udice.txt
drwxr-xr-x - cloudera cloudera 0 2026-09-22 16:35 /bigdata/pride_prejudice/output
-rw-r--r-- 1 cloudera cloudera 0 2026-09-22 16:35 /bigdata/pride_prejudice/output/_SUCCESS
-rw-r--r-- 1 cloudera cloudera 151217 2026-09-22 16:35 /bigdata/pride_prejudice/output/part-r-000000
drwxr-xr-x - cloudera cloudera 0 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo
-rw-r--r-- 1 cloudera cloudera 0 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo/_SUCCESS
-rw-r--r-- 1 cloudera cloudera 151217 2026-09-23 14:34 /bigdata/pride_prejudice/yarn_demo/part-r-000000

```

ويظهر معها المجلدات والملفات الموجودة داخل المشروع.

20. التحقق النهائي من نتيجة WordCount

تم التحقق من حجم النتيجة الأصلية باستخدام:

```
hdfs dfs -du -h /bigdata/pride_prejudice/output
```

```

[cloudera@quickstart ~]$ hdfs dfs -du -h /bigdata/pride_prejudice/output
0 /bigdata/pride_prejudice/output/_SUCCESS
147.7 K 147.7 K /bigdata/pride_prejudice/output/part-r-000000
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/pride_prejudice/output/_SUCCESS
-rw-r--r-- 1 cloudera cloudera 0 2026-09-22 16:35 /bigdata/pride_prejudice/output/_SUCCESS
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/pride_prejudice/output/part-r-000000
-rw-r--r-- 1 cloudera cloudera 147.7 K 2026-09-22 16:35 /bigdata/pride_prejudice/output/part-r-000000
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$

```

ثم تم التأكد من وجود علامة نجاح العملية:

```
hdfs dfs -ls /bigdata/pride_prejudice/output/_SUCCESS
```

```

[cloudera@quickstart ~]$ hdfs dfs -du -h /bigdata/pride_prejudice/output
0 /bigdata/pride_prejudice/output/_SUCCESS
147.7 K 147.7 K /bigdata/pride_prejudice/output/part-r-000000
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/pride_prejudice/output/_SUCCESS
-rw-r--r-- 1 cloudera cloudera 0 2026-09-22 16:35 /bigdata/pride_prejudice/output/_SUCCESS
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/pride_prejudice/output/part-r-000000
-rw-r--r-- 1 cloudera cloudera 147.7 K 2026-09-22 16:35 /bigdata/pride_prejudice/output/part-r-000000
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$

```

ثم تم التأكد من وجود ملف النتائج:

```
hdfs dfs -ls -h /bigdata/pride_prejudice/output/part-r-000000
```

```

[cloudera@quickstart ~]$ hdfs dfs -du -h /bigdata/pride_prejudice/output
0 /bigdata/pride_prejudice/output/_SUCCESS
147.7 K 147.7 K /bigdata/pride_prejudice/output/part-r-000000
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/pride_prejudice/output/_SUCCESS
-rw-r--r-- 1 cloudera cloudera 0 2026-09-22 16:35 /bigdata/pride_prejudice/output/_SUCCESS
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/pride_prejudice/output/part-r-000000
-rw-r--r-- 1 cloudera cloudera 147.7 K 2026-09-22 16:35 /bigdata/pride_prejudice/output/part-r-000000
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$

```

21. الخلاصة

تم في هذا المشروع تطبيق Workflow متكامل لتحليل كتاب حقيقي باستخدام Hadoop MapReduce. بدأ العمل بالحصول على كتاب حقيقي وهو **Pride and Prejudice**، ثم تم فحص البيانات محليًا والتأكد من حجمها وعدد أسطرها وكلماتها، وبعد ذلك تم إنشاء مجلد المشروع داخل HDFS ورفع الكتاب إليه. بعد تجهيز البيانات، تم استخدام Hadoop MapReduce لتنفيذ عملية WordCount وحساب تكرار الكلمات داخل الكتاب. ثم تم استعراض النتائج والبحث عن كلمات وشخصيات وأماكن محددة مثل:

Elizabeth
Darcy
Jane
Bennet
London

كما تم استخراج أعلى ٢٠ كلمة تكرارًا.

تم كذلك استخدام **YARN ResourceManager** لمتابعة تنفيذ مهمة WordCount، حيث ظهر التطبيق:

application_1790197245852_0001

وكان نوع التطبيق:

MAPREDUCE

وانتهت المهمة بالحالة:

FINISHED

وبالنتيجة النهائية:

SUCCEEDED

وفي النهاية تم نقل نتائج MapReduce من HDFS إلى Linux في ملف:

pride_prejudice_wordcount.txt

وبذلك تم تنفيذ المراحل الأساسية لتحليل نص حقيقي باستخدام:

Linux
↓
HDFS
↓
MapReduce
↓
YARN
↓
Results
↓
Analysis

ويُظهر المشروع عمليًا كيفية استخدام Hadoop في تخزين ومعالجة وتحليل بيانات نصية حقيقية ضمن بيئة Big Data.

