

تقرير مشروع معالجة النصوص

باستخدام Hadoop MapReduce

تحليل الكتب الأدبية باستخدام تقنيات البيانات الضخمة



29. المهمة العملية

1 ما أكثر الكلمات تكرارًا في النص؟

الإجابة:

الكلمة الأكثر تكرارًا هي "the" وظهرت 31,379 مرة في جميع الكتب مجتمعة.

2 كم مرة ظهرت الكلمات التالية؟

الإجابة:

الكلمة	عدد المرات	ملاحظات
Holmes	460	في كتاب Sherlock Holmes فقط
London	41	بجميع أشكالها
Sherlock	96	كلمة مستقلة
Watson	0	لم تظهر في النصوص النظيفة
Lestrade	38	بجميع أشكالها

3 ما الكلمات العشرة الأعلى تكرارًا؟

الإجابة:

الترتيب	الكلمة	عدد المرات
1	the	31,379
2	and	20,327
3	of	19,996
4	to	19,890
5	I	15,604
6	a	13,326
7	in	10,403
8	was	9,145
9	that	8,759
10	my	6,374
11	it	6,272
12	you	6,206
13	her	5,994
14	his	5,801
15	with	5,728
16	had	5,634
17	not	5,492
18	he	5,463

الترتيب	الكلمة	عدد المرات
19	as	5,378
20	is	4,831

4 ما الفرق بين الملف الموجود في Linux والملف الموجود في HDFS؟

الإجابة:

HDFS (Hadoop Distributed File System)	Linux File System
نظام ملفات موزع على عدة عقد (Nodes)	نظام ملفات محلي على جهاز واحد
الوصول عبر أوامر خاصة (hdfs dfs)	الوصول المباشر للملفات
تخزين موزع مع تكرار البيانات (Replication)	تخزين تقليدي بدون تكرار
مصمم للبيانات الضخمة جداً (Big Data)	مناسب للبيانات الصغيرة والمتوسطة
يتحمل الأعطال (Fault Tolerant)	لا يتحمل الأعطال بشكل تلقائي

5 ما وظيفة MapReduce في هذا المشروع؟

الإجابة:

وظيفة MapReduce هي **المعالجة الموزعة للبيانات** لحساب تكرار الكلمات في النصوص، وتتم عبر مرحلتين:

- **مرحلة Map:** تقسيم النص إلى كلمات فردية وعد كل كلمة (Key-Value pairs)
- **مرحلة Reduce:** تجميع النتائج النهائية وحساب المجموع الكلي لتكرار كل كلمة

معلومات ال Job المنفذ:

Job ID: job_1789686985582_0015

الحالة: **completed successfully**

عدد مهام Map: 8 (واحد لكل ملف)

عدد مهام Reduce: 1 مهمة

6 ما وظيفة YARN أثناء تنفيذ المهمة؟

الإجابة:

YARN (Yet Another Resource Negotiator) يقوم بالمهام التالية:

- **إدارة الموارد:** توزيع الذاكرة و CPU على العقد المختلفة
- **جدولة المهام:** تحديد وقت ومكان تنفيذ كل مهمة
- **توزيع المهام:** إرسال مهام Map و Reduce للعقد المتاحة
- **المراقبة:** متابعة تقدم المهام والتعامل مع الأعطال

7 أين توجد النتيجة النهائية بعد انتهاء WordCount؟

الإجابة:

النتيجة النهائية موجودة في مكانين:

1. في HDFS:

`/bigdata/sherlock/output_all_books/part-r-00000`

2. في Linux المحلي:

sherlock_wordcount.txt

(بعد استخدام أمر hdfs dfs -getmerge)

30. المطلوب تسليمه

1 Dataset: ملف txt.0-1661

المعلومات:

- **الكتاب:** Sherlock Holmes (شيرلوك هولمز)
- **الحجم:** 556.9 KB (النسخة النظيفة)
- **عدد الكلمات:** 107,510 كلمة

2 مسار HDFS

المسار:

`/bigdata/sherlock/input/books/`

الملفات المتوفرة:

- clean.txt (556.9 KB)-1661-0
- alice-clean.txt (155.0 KB)
- frankenstein-clean.txt (425.2 KB)
- pride-clean.txt (718.6 KB)

3 مخرجات MapReduce

المسار:

`/bigdata/sherlock/output_all_books/part-r-00000`

معلومات المهمة:

Job ID: job_1789686985582_0015

الحالة: **نجحت بنجاح (completed successfully)**

عدد مهام Map: 8

عدد مهام Reduce: 1

إجمالي السجلات المعالجة: 691,102 سجل

4 النتائج: عدد مرات ظهور الكلمات المطلوبة

النتائج التفصيلية:

أ. الكلمات الأكثر تكراراً (أول 10):

الكلمة	عدد المرات
the	31,379
and	20,327
of	19,996
to	19,890
I	15,604

ب. مقارنة كلمة "Holmes":

- 460 Sherlock Holmes مرة
- 0 Alice in Wonderland مرة
- 0 Frankenstein مرة
- 0 Pride and Prejudice مرة

ج. الكتاب الأكثر احتواءً على الكلمات:

1. Pride and Prejudice: 130,347 كلمة

2. Sherlock Holmes: 107,510 كلمة

3. Frankenstein: 78,094 كلمة

4. Alice in Wonderland: 29,498 كلمة

5 لقطات شاشة

اللقطات المطلوبة:

1. تنفيذ Job MapReduce داخل YARN

ID	User	Name	Application Type	Queue	StartTime	FinishTime	State	FinalStatus	Running Containers	Allocated CPU V-Cores	Allocated Memory MB	Reserved CPU V-Cores	Reserved Memory MB	Progress	Tracking UI
application_1789686985582_0010	cloudera	word count	MAPREDUCE	root.cloudera	Thu Sep 17 16:47:13 -0700 2026	Thu Sep 17 16:47:27 -0700 2026	FINISHED	FAILED	N/A	N/A	N/A	N/A	N/A		History

2. النتائج النهائية

```

-rw-r--r-- 1 cloudera cloudera 160K Sep 17 17:49 sherlock_wordcount.txt
[cloudera@quickstart ~]$ ls -lh sherlock_wordcount.txt
-rw-r--r-- 1 cloudera cloudera 160K Sep 17 17:49 sherlock_wordcount.txt
[cloudera@quickstart ~]$ head -20 sherlock_wordcount.txt
#1661] 1
$5,000) 1
& 5
&c, 1
&c. 1
($1 1
(3rd 1
(801) 1
(a) 1
(and 1
(any 1
(b) 1
(c) 1
(does 1
(for 1
(if 1
(now 1
(or 3
(the 1
(trademark/copyright) 1
[cloudera@quickstart ~]$

```

3. البيانات داخل HDFS

```
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/sherlock/output
Found 2 items
-rw-r--r-- 1 cloudera supergroup 0 2026-09-17 16:52 /bigdata/sherlock/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup 163591 2026-09-17 16:52 /bigdata/sherlock/output/part-r-00000
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | head -20
#1661] 1
$5,000) 1
& 5
&c, 1
&c. 1
($1 1
(3rd 1
(801) 1
(a) 1
(and 1
(any 1
(b) 1
(c) 1
(does 1
(for 1
(if 1
(now 1
(or 3
(the 1
(trademark/copyright) 1
cat: Unable to write to output stream.
```

رابط متابعة ال job:

<http://quickstart.cloudera:8088/proxy/application>

6 ملف النتائج: sherlock_wordcount.txt

محتوى الملف (أول 20 كلمة):

the 31379 and 20327 of 19996 to 19890 I 15604 a
 13326 in 10403 was 9145 that 8759 my 6374 it 6272
 you 6206 her 5994 his 5801 with 5728 had 5634 not
 5492 he 5463 as 5378 is 4831

7 تحليل مختصر

التحليل:

أ. ملاحظات على النتائج:

- الكلمات الأكثر شيوعاً هي أدوات الربط والضمائر (the, and, of, to, I)
- الكلمة "the" هي الأكثر تكراراً بـ 31,379 مرة في جميع الكتب
- كتاب Pride and Prejudice هو الأطول بـ 130,347 كلمة
- كتاب Alice in Wonderland هو الأقصر بـ 29,498 كلمة فقط

ب. كفاءة MapReduce:

- تم معالجة 4 كتب بإجمالي 345,449 كلمة
- تم استخراج 35,820 كلمة فريدة
- المهمة اكتملت بنجاح في وقت قياسي بفضل التوزيع

ج. فائدة Hadoop:

- **معالجة موزعة:** تقسيم العمل على 8 مهام Map
- **قابلية التوسع:** يمكن إضافة المزيد من الكتب بسهولة
- **الكفاءة:** معالجة مئات الآلاف من الكلمات في ثوانٍ
- **التكرار:** البيانات مخزنة بشكل آمن في HDFS

المطلوب في التحدي

1 معرفة الكلمات الأكثر تكرارًا عبر جميع الكتب

تم التنفيذ:

تم استخدام WordCount على جميع الكتب الأربعة، والنتائج موضحة في الجدول أعلاه.

2 مقارنة كلمة معينة بين كتابين أو أكثر

تم التنفيذ:

تم مقارنة كلمة "Holmes" بين الكتب الأربعة، وظهرت فقط في كتاب Sherlock Holmes (460 مرة).

3 معرفة أي كتاب يحتوي على أكبر عدد من الكلمات

النتيجة:

Pride and Prejudice هو الكتاب الأكثر احتواءً على الكلمات بـ **130,347 كلمة**

4 توضيح لماذا يصبح Hadoop أكثر فائدة كلما زادت كمية البيانات وعدد الملفات

التوضيح:

- **المعالجة المتوازية:** كلما زادت البيانات، زادت أهمية توزيع العمل على عدة عقد

- **الوقت:** معالجة 4 كتب استغرقت ثواني، لكن معالجة آلاف الكتب ستستغرق دقائق فقط مع Hadoop
- **التخزين:** HDFS يمكنه تخزين petabytes من البيانات بشكل موزع وآمن
- **التكلفة:** استخدام أجهزة رخيصة متعددة بدلاً من خادم واحد قوي
- **المرونة:** إمكانية إضافة عقد جديدة بسهولة لزيادة القدرة

تم إعداد هذا التقرير كجزء من مشروع Hadoop MapReduce

© 2026 - جميع الحقوق محفوظة