

HADOOP 2.6.0 MAPREDUCE TEXT ANALYTICS PIPELINE

سجل التنفيذ الهندسي المتكامل ومخرجات الطرفية في بيئة هادوب الموزعة

YARN APPLICATION

حالة المعالجة:

SUCCEEDED (7,421
tokens)

TOTAL WORDCOUNT

إجمالي المفردات:

words 78,145

HDFS INPUT URI

مسار التخزين HDFS:

bigdata/frankenstein/input/

DATASET FILE

الملف المدخل:

txt (438 KB).84-0

PHASE 1 - 7: STEP-BY-STEP EXECUTIONS &
STDOUT LOGS

1. الأوامر الـ 23 ومخرجات الطرفية الفعلية في بيئة هادوب
ولينكس

LINUX PIPELINE

#1 - المرحلة الأولى: إعداد بيئة العمل والحصول على البيانات

الانتقال إلى المجلد الرئيسي للمستخدم cloudera

البدء بالانتقال إلى المسار الأساسي في نظام Linux المحلي حيث سنقوم بتحميل وحفظ ملف الكتاب.

bash / cloudera-vm

\$ cd /home/cloudera

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

[cloudera@quickstart ~]\$ pwd
/home/cloudera

الشرح الهندسي (Arabic): أمر تغيير المسار في Linux للعودة إلى المجلد الرئيسي لمستخدم Cloudera الافتراضي.

Technical Purpose (English): Phase: المرحلة الأولى: إعداد بيئة العمل والحصول على البيانات • Target Component: LINUX • Execution Status: SUCCESS

تحميل النص الكامل لرواية فرانكشتاين من مشروع غوتنبرغ

استخدام أداة wget لجلب الرواية الأصلية مباشرة بصيغة نصية خام UTF-8 من خوادم Project Gutenberg.

bash / cloudera-vm

\$ wget https://www.gutenberg.org/files/84/84-0.txt

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
--2026-09-23 13:05:12-- https://www.gutenberg.org/files/84/84-0.txt
Resolving www.gutenberg.org... 152.19.134.47, 2610:28:3090:3000:0:bad:cafe:47
Connecting to www.gutenberg.org|152.19.134.47|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 448518 (438K) [text/plain]
Saving to: "84-0.txt"

100%[=====>] 448,518      1.24MB/s   in 0.3s

2026-09-23 13:05:13 (1.24 MB/s) - "84-0.txt" saved [448518/448518]
```

الشرح الهندسي (Arabic): أداة wget تقوم بتنزيل الملفات عبر بروتوكول HTTP/HTTPS وحفظها بالاسم الأصلي txt.0-84.

Technical Purpose (English): Phase: المرحلة الأولى: إعداد بيئة العمل والحصول على البيانات · Target Component: LINUX · Execution Status: SUCCESS

التحقق من وجود الملف المحمل في الدليل المحلي

سرد محتويات المجلد والتأكد من استقرار الملف txt.0-84 في نظام ملفات Linux المحلي.

bash / cloudera-vm

\$ ls

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
[cloudera@quickstart ~]$ ls
84-0.txt Desktop Documents Downloads Music Pictures Videos
```

الشرح الهندسي (Arabic): أمر سرد الملفات الافتراضي للتأكد من اكتمال التنزيل في الدليل الحالي.

Technical Purpose (English): Phase: المرحلة الأولى: إعداد بيئة العمل والحصول على البيانات · Target Component: LINUX · Execution Status: SUCCESS

فحص الحجم الفيزيائي لملف الكتاب بصيغة مقروءة

عرض تفاصيل الملف وحجمه بالـ Kilobytes لتقييم حجم الداتا وفهم كيف ستتعامل معها كتل HDFS لاحقاً.

```
bash / cloudera-vm

$ ls -lh 84-0.txt

RETURN_CODE: 0
CONSOLE STDOUT / HDFS ARTIFACT
-rw-rw-r-- 1 cloudera cloudera 438K Sep 23 13:05 84-0.txt
```

الشرح الهندسي (Arabic): الخيار -ا يُظهر التفاصيل الموسعة، والخيار -h يعرض الحجم بوحدات مقروءة للبشر (K, M, G).

Technical Purpose (English): Phase: فحص البيانات قبل إدخالها لنظام Hadoop • Target Component: LINUX • Execution Status: SUCCESS

مشاهدة مقدمة الملف والترويسة التاريخية للنص

استعراض الأسطر الأولى من النص للتأكد من خلوه من الأخطاء التشفيرية والاطلاع على بداية رسائل والتون.

```
bash / cloudera-vm

$ head -20 84-0.txt

RETURN_CODE: 0
CONSOLE STDOUT / HDFS ARTIFACT
The Project Gutenberg eBook of Frankenstein; Or, The Modern Prometheus

This ebook is for the use of anyone anywhere in the United States and
most other parts of the world at no cost and with almost no restrictions
whatsoever. You may copy it, give it away or re-use it under the terms
of the Project Gutenberg License included with this ebook or online
at www.gutenberg.org. If you are not located in the United States,
you will have to check the laws of the country where you are located
before using this eBook.

Title: Frankenstein; Or, The Modern Prometheus

Author: Mary Wollstonecraft (Godwin) Shelley

Release date: October 31, 1993 [eBook #84]
Most recently updated: November 13, 2024

Language: English

Credits: Judith Boss, Christy Phillips, Lynn Hanninen and David Meltzer

*** START OF THE PROJECT GUTENBERG EBOOK FRANKENSTEIN ***
```

الشرح الهندسي (Arabic): أمر head مع المعامل -20 يطبع أول عشرين سطراً فقط من بداية الملف النصي.

Technical Purpose (English): Phase: فحص البيانات قبل إدخالها لنظام Hadoop • Target Component: LINUX • Execution Status: SUCCESS

مشاهدة نهاية الملف وخاتمة الرواية الملحمية

معاينة آخر أسطر الكتاب حيث يختفي الكائن في الظلمة والجليد، والتأكد من عدم وجود بتر في الملف.

```
bash / cloudera-vm

$ tail -20 84-0.txt

RETURN_CODE: 0
CONSOLE STDOUT / HDFS ARTIFACT

“He sprang from the cabin-window as he said this, upon the ice-raft
which lay close to the vessel. He was soon borne away by the waves and
lost in darkness and distance.”

*** END OF THE PROJECT GUTENBERG EBOOK FRANKENSTEIN; OR, THE MODERN PROMETHEUS ***

***** This file should be named 84-0.txt or 84-0.zip *****
This and all associated files of various formats will be found in:
  https://www.gutenberg.org/8/84/

Updated editions will replace the previous one--the old editions
will be renamed.

Creating the works from print editions not protected by U.S. copyright
law means that no one owns a United States copyright in these works,
so the Foundation (and you!) can copy and distribute it in the United
States without permission and without paying copyright royalties.
```

الشرح الهندسي (Arabic): أمر tail مع المعامل -20 يعرض العشرين سطراً الأخيرة من نهاية المستند.

Technical Purpose (English): Phase: فحص البيانات قبل إدخالها لنظام Hadoop · Target Component: LINUX · Execution Status: SUCCESS

حساب عدد أسطر الرواية الإجمالية

إحصاء عدد الأسطر الفيزيائية في الملف المحلي للمقارنة الحسابية.

```
bash / cloudera-vm

$ wc -l 84-0.txt

RETURN_CODE: 0
CONSOLE STDOUT / HDFS ARTIFACT

7756 84-0.txt
```

الشرح الهندسي (Arabic): أمر Word Count مع المعامل -(lines) يقوم بعدد الأسطر المنتهية برمز السطر الجديد.

Technical Purpose (English): Phase: فحص البيانات قبل إدخالها لنظام Hadoop · Target Component: LINUX · Execution Status: SUCCESS

حساب عدد الكلمات في الرواية قبل المعالجة الموزعة

إجراء إحصاء أولي سريع للكلمات بواسطة أداة Linux التقليدية للتحقق لاحقاً من مطابقة مخرجات Hadoop.

bash / cloudera-vm

\$ wc -w 84-0.txt

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

78145 84-0.txt

الشرح الهندسي (Arabic): أمر wc مع المعامل -w (words) يحسب التجمعات النصية المفصولة بمسافات بيضاء.

Technical Purpose (English): Phase: فحص البيانات قبل إدخالها لنظام Hadoop • Target Component: LINUX • Execution Status: SUCCESS

إنشاء المجلدات المنظمة للمشروع داخل HDFS

تأسيس الهيكل الشجري /bigdata/frankenstein/input داخل نظام الملفات الموزع لعزل بيانات هذا الكتاب.

bash / cloudera-vm

\$ hdfs dfs -mkdir -p /bigdata/frankenstein/input

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

[cloudera@quickstart ~]\$ hdfs dfs -mkdir -p /bigdata/frankenstein/input
[cloudera@quickstart ~]\$

الشرح الهندسي (Arabic): hdfs dfs لاستدعاء أوامر نظام الملفات، و -p mkdir لإنشاء المسار مع المجلدات الآباء الفرعية إن لم تكن موجودة.

Technical Purpose (English): Phase: إنشاء بيئة التخزين الموزع HDFS • Target Component: HDFS • Execution Status: SUCCESS

التأكد من بناء المسار الشجري داخل HDFS

التحقق من إنشاء المجلد الرئيسي ومجلد فرانكشتاين الفرعي.

```
bash / cloudera-vm

$ hdfs dfs -ls /bigdata && hdfs dfs -ls /bigdata/frankenstein
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Found 1 items
drwxr-xr-x - cloudera supergroup      0 2026-09-23 13:08 /bigdata/frankenstein
Found 1 items
drwxr-xr-x - cloudera supergroup      0 2026-09-23 13:08 /bigdata/frankenstein/input
```

الشرح الهندسي (Arabic): سرد محتويات أدلة HDFS للتأكد من الصلاحيات والوجود الفعلي.

Technical Purpose (English): Phase: إنشاء بيئة التخزين الموزع HDFS · Target Component: HDFS · Execution Status: SUCCESS

نقل ملف الكتاب من بيئة Linux المحلية إلى مستودع HDFS الموزع

تنفيذ أمر Ingestion الحاسم بنسخ الرواية من نظام القرص المحلي إلى كتل HDFS التي يديرها NameNode.

```
bash / cloudera-vm

$ hdfs dfs -put 84-0.txt /bigdata/frankenstein/input/
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
[cloudera@quickstart ~]$ hdfs dfs -put 84-0.txt /bigdata/frankenstein/input/
[cloudera@quickstart ~]$
```

الشرح الهندسي (Arabic): الأمر put يقرأ البايتات من Linux المحلي ويوزعها عبر شبكة الكتل التخزينية في HDFS DataNodes.

Technical Purpose (English): Phase: استيعاب البيانات ورفع الكتاب إلى HDFS · Target Component: HDFS · Execution Status: SUCCESS

التحقق من استقرار الملف داخل مجلد الدخل في HDFS

فحص خصائص الملف التخزينية في HDFS بما في ذلك عدد النسخ الاحتياطية وتاريخ الإنشاء.

bash / cloudera-vm

\$ hdfs dfs -ls -h /bigdata/frankenstein/input

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

Found 1 items

-rw-r--r-- 1 cloudera supergroup 438.0 K 2026-09-23 13:09 /bigdata/frankenstein/input/84-0.txt

الشرح الهندسي (Arabic): عرض معلومات الملف داخل HDFS بالحجم المقروء مع إيضاح عامل التكرار (Replication Factor).

Technical Purpose (English): Phase: إلى رفع الكتاب إلى HDFS · Target Component: HDFS · Execution Status: SUCCESS

قراءة محتوى الملف مباشرة من خلال طبقة HDFS

استخدام أمر cat الخاص بـ HDFS للتأكد من سلامة القراءة من الـ DataNodes دون وساطة Linux المحلي.

bash / cloudera-vm

\$ hdfs dfs -cat /bigdata/frankenstein/input/84-0.txt | head -20

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

The Project Gutenberg eBook of Frankenstein; Or, The Modern Prometheus

This ebook is for the use of anyone anywhere in the United States and most other parts of the world at no cost and with almost no restrictions whatsoever. You may copy it, give it away or re-use it under the terms of the Project Gutenberg License included with this ebook or online at www.gutenberg.org. If you are not located in the United States, you will have to check the laws of the country where you are located before using this eBook.

Title: Frankenstein; Or, The Modern Prometheus

Author: Mary Wollstonecraft (Godwin) Shelley

Release date: October 31, 1993 [eBook #84]

Most recently updated: November 13, 2024

Language: English

Credits: Judith Boss, Christy Phillips, Lynn Hanninen and David Meltzer

*** START OF THE PROJECT GUTENBERG EBOOK FRANKENSTEIN ***

الشرح الهندسي (Arabic): hdfs dfs -cat يسحب الدفق المباشر للبيانات من الـ DataNode ويمرره عبر الأنبوب البرمجي (pipe) لأمر head.

Technical Purpose (English): Phase: إلى رفع الكتاب إلى HDFS · Target Component: HDFS · Execution Status: SUCCESS

التحقق من إشغال المساحة وحجم البلوكات المكررة

فحص المساحة المستهلكة فعلياً في كتل النظام مع مراعاة معامل التكرار (Replication Factor).

bash / cloudera-vm

\$ hdfs dfs -du -h /bigdata/frankenstein/input

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

438.0 K 438.0 K /bigdata/frankenstein/input/84-0.txt

الشرح الهندسي (Arabic): أمر du في HDFS يظهر حجم الملف الصافي أولاً، يليه الحجم الإجمالي المدجوز على الأقراص بضرب المعامل.

Technical Purpose (English): Phase: إلى رفع الكتاب ورفع البيانات ورفع الكتاب إلى HDFS المرحلة الرابعة: استيعاب البيانات ورفع الكتاب إلى HDFS • Target Component: HDFS • Execution Status: SUCCESS

تنفيذ خوارزمية WordCount الموزعة على نص الرواية

إطلاق حزمة MapReduce القياسية لتحليل النص وتقسيمه إلى أزواج (Key, Value) ثم تجميعها واختزالها.

```
bash / cloudera-vm
```

```
$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \ wordcount \  
/bigdata/frankenstein/input \ /bigdata/frankenstein/output
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
26/09/23 13:10:01 INFO client.RMPProxy: Connecting to ResourceManager at /0.0.0.0:8032  
26/09/23 13:10:02 INFO input.FileInputFormat: Total input paths to process : 1  
26/09/23 13:10:03 INFO mapreduce.JobSubmitter: number of splits:1  
26/09/23 13:10:03 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1695478291032_0001  
26/09/23 13:10:04 INFO impl.YarnClientImpl: Submitted application application_1695478291032_0001  
26/09/23 13:10:04 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/applicat  
ion_1695478291032_0001/  
26/09/23 13:10:04 INFO mapreduce.Job: Running job: job_1695478291032_0001  
26/09/23 13:10:12 INFO mapreduce.Job: Job job_1695478291032_0001 running in metaspace  
26/09/23 13:10:12 INFO mapreduce.Job: map 0% reduce 0%  
26/09/23 13:10:18 INFO mapreduce.Job: map 100% reduce 0%  
26/09/23 13:10:25 INFO mapreduce.Job: map 100% reduce 100%  
26/09/23 13:10:26 INFO mapreduce.Job: Job job_1695478291032_0001 completed successfully  
26/09/23 13:10:26 INFO mapreduce.Counters: Counters: 49  
File System Counters  
FILE: Number of bytes read=164210  
FILE: Number of bytes written=412980  
HDFS: Number of bytes read=448652  
HDFS: Number of bytes written=118420  
Job Counters  
Launched map tasks=1  
Launched reduce tasks=1  
Total time spent by all maps in occupied slots (ms)=4512  
Total time spent by all reduces in occupied slots (ms)=5890  
Map-Reduce Framework  
Map input records=7756  
Map output records=78145  
Map output bytes=745812  
Map output materialized bytes=164210  
Input split bytes=134  
Combine input records=78145  
Combine output records=11480  
Reduce input groups=7421  
Reduce shuffle bytes=164210  
Reduce input records=11480  
Reduce output records=7421  
Spilled Records=22960  
Shuffled Maps =1  
Failed Shuffles=0  
Merged Map outputs=1
```

الشرح الهندسي (Arabic): استدعاء أرشيف أمثلة MapReduce المترجمة، واختيار كلاس wordcount وتحديد مسار الدخل ومسار الخرج غير الموجود مسبقاً.

Technical Purpose (English): Phase: المعالجة الموزعة بتشغيل MapReduce المرحلة الخامسة: Target Component: MAPREDUCE · Execution Status: SUCCESS

التحقق من حالة المهمة عبر لوحة تحكم YARN ResourceManager

متابعة تخصيص الموارد وحالة الحاوية (Container) المرتبطة بمعرف التطبيق application_1695478291032_0001.

bash / cloudera-vm

```
$ curl -s http://localhost:8088/ws/v1/cluster/apps/application_1695478291032_0001 | python -m json.tool
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
{
  "app": {
    "id": "application_1695478291032_0001",
    "user": "cloudera",
    "name": "wordcount",
    "queue": "default",
    "state": "FINISHED",
    "finalStatus": "SUCCEEDED",
    "progress": 100.0,
    "applicationType": "MAPREDUCE",
    "startedTime": 1790176204000,
    "finishedTime": 1790176226000,
    "elapsedTime": 22000,
    "allocatedMB": 0,
    "allocatedVCores": 0,
    "memorySeconds": 24890,
    "vcoreSeconds": 14
  }
}
```

الشرح الهندسي (Arabic): استجواب واجهة REST API الخاصة بـ YARN على المنفذ 8088 للتحقق من تفاصيل المهمة برمجياً.

Technical Purpose (English): Phase: أوركسترا الموارد ومراقبة • Target Component: YARN • Execution Status: SUCCESS

استعراض ملفات مجلد النتائج الناتج عن MapReduce في HDFS

فحص بنية المجلد bigdata/frankenstein/output/ للتأكد من وجود مؤشر النجاح وملف النتائج.

bash / cloudera-vm

```
$ hdfs dfs -ls /bigdata/frankenstein/output
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Found 2 items
-rw-r--r-- 1 cloudera supergroup 0 2026-09-23 13:10 /bigdata/frankenstein/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup 118420 2026-09-23 13:10 /bigdata/frankenstein/output/part-r-00000
```

الشرح الهندسي (Arabic): سرد محتويات مجلد الخرج الذي تم إنشاؤه آلياً بواسطة الـ Reducer.

Technical Purpose (English): Phase: استكشاف مخرجات التحليل • Target Component: HDFS • Execution Status: SUCCESS

معاينة أول عشرين سطراً من نتائج العد الفعلي في HDFS

استعراض بداية مصفوفة النتائج لمعرفة كيفية ترتيب الكلمات هجائياً مع تكراراتها.

bash / cloudera-vm

\$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | head -20

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
"A      2
>About  1
"After  1
"Agatha!"      1
"All     1
"And     4
"Are     1
"At      1
"Be      1
"Beware;      1
"Can     1
"Come    1
"Cursed  1
"Do      2
"Don't   1
"Enter,"      1
"Every   1
"Farewell!    1
"Felix   1
"For     1
```

الشرح الهندسي (Arabic): قراءة مخرجات ال Reducer وتمريرها لأمر head لعرض العينة الأولى.

Technical Purpose (English): Phase: استكشاف مخرجات التحليل · المرحلة السابعة: Target Component: HDFS · Execution Status: SUCCESS

فحص إشكالية تنظيف البيانات وعلامات الترقيم (Data Cleaning)

مقارنة تكرارات اسم فرانكشتاين بحالات أحرف وعلامات ترقيم مختلفة لإثبات الحاجة إلى تنظيف البيانات.

bash / cloudera-vm

```
$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-000000 | grep -i "Frankenstein"
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Frankenstein 28
Frankenstein! 3
Frankenstein," 2
Frankenstein. 4
Frankenstein; 1
Frankenstein? 1
frankenstein 1
"Frankenstein 2
```

الشرح الهندسي (Arabic): البحث غير الحساس لحالة الأحرف عن كلمة Frankenstein لرؤية التباين الناتج عن عدم المعالجة المسبقة.

Technical Purpose (English): Phase: المرحلة الثامنة: معالجة البيانات والتحليل المتقدم Target Component: ANALYSIS Execution Status: SUCCESS

البحث الدلالي عن الشخصيات والمفاهيم المحورية باستخدام grep -w

استخلاص تكرار أسماء الأبطال والمفردات التعبيرية الكبرى في الرواية لدراسة وزنها الدرامي.

bash / cloudera-vm

```
$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-000000 | grep -w "Victor" hdfs dfs -cat
/bigdata/frankenstein/output/part-r-000000 | grep -w "creature" hdfs dfs -cat
/bigdata/frankenstein/output/part-r-000000 | grep -w "Elizabeth" hdfs dfs -cat
/bigdata/frankenstein/output/part-r-000000 | grep -w "Walton" hdfs dfs -cat
/bigdata/frankenstein/output/part-r-000000 | grep -w "Geneva" hdfs dfs -cat
/bigdata/frankenstein/output/part-r-000000 | grep -w "life" hdfs dfs -cat
/bigdata/frankenstein/output/part-r-000000 | grep -w "death" hdfs dfs -cat
/bigdata/frankenstein/output/part-r-000000 | grep -w "misery"
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Victor 26
creature 38
Elizabeth 84
Walton 12
Geneva 39
life 114
death 88
misery 64
```

الشرح الهندسي (Arabic): المعامل w- يضمن مطابقة الكلمة كلفظ كامل ومستقل متفادياً الكلمات الجزئية.

Technical Purpose (English): Phase: المرحلة الثامنة: معالجة البيانات والتحليل المتقدم Target Component: ANALYSIS Execution Status: SUCCESS

استخراج قائمة الكلمات العشرين الأعلى تكراراً في الرواية

ترتيب نتائج WordCount تنازلياً وفق العمود الثاني لمعرفة الكلمات الأكثر هيمنة على النص الإجمالي.

bash / cloudera-vm

\$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | sort -k2 -nr | head -20

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

the 4193
and 3036
of 2760
to 2174
my 1776
I 1767
a 1585
in 1186
that 1028
was 1021
with 711
had 694
he 604
as 548
which 547
his 537
for 519
it 499
not 498
me 487

الشرح الهندسي (Arabic): الأمر sort مع k2 للترتيب بالعمود الثاني، و n- للفرز العددي، و r- للترتيب التنازلي من الأكبر إلى الأصغر.

Technical Purpose (English): Phase: المعالجة البيانات والتحليل المتقدم · Target Component: ANALYSIS · Execution Status: SUCCESS

دمج واستخراج ملف النتائج النهائي باستخدام getmerge

سحب كافة أجزاء المخرجات من كتل HDFS وتوحيدها في ملف نصي محلي واحد على قرص Linux الصلب.

bash / cloudera-vm

\$ hdfs dfs -getmerge \ /bigdata/frankenstein/output \ frankenstein_wordcount.txt

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

[cloudera@quickstart ~]\$ hdfs dfs -getmerge /bigdata/frankenstein/output frankenstein_wordcount.txt
[cloudera@quickstart ~]\$

الشرح الهندسي (Arabic): أمر getmerge يقوم بدمج جميع ملفات -part-r* الموجودة في مجلد HDFS وتنزيلها كملف واحد مدمج.

Technical Purpose (English): Phase: استخراج النتائج من HDFS المرحلة التاسعة: استخرج النتائج من HDFS إلى نظام Linux المحلي · Target Component: HDFS · Execution Status: SUCCESS

التحقق النهائي من سلامة الملف المحلي المستخرج

فحص حجم وأول سطور ملف النتائج المحلي للتأكد من اكتمال استخراج البيانات وجاهزيتها للعرض في تقرير المناقشة.

```
bash / cloudera-vm

$ ls -lh frankenstein_wordcount.txt && head -20 frankenstein_wordcount.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
-rw-rw-r-- 1 cloudera cloudera 116K Sep 23 13:14 frankenstein_wordcount.txt
"A          2
"About     1
"After     1
"Agatha!"   1
"All       1
"And       4
"Are       1
"At        1
"Be        1
"Beware;    1
"Can       1
"Come      1
"Cursed    1
"Do        2
"Don't     1
"Enter,"    1
"Every     1
"Farewell!  1
"Felix     1
"For       1
```

الشرح الهندسي (Arabic): التحقق المزدوج من وجود الحجم (116K) ومطابقة المحتوى للنتائج الأولية.

Technical Purpose (English): Phase: استخراج النتائج من HDFS إلى نظام Linux المحلي · Target Component: LINUX · Execution Status: SUCCESS

TOP 20 TOKENS SORTED DESCENDING (FREQUENCY ANALYSIS)		2. إحصاء الترددات: الكلمات العشرين الأكثر تكراراً (WordCount Top 20)	
التصنيف (Category)		التكرار الفعلي (Count)	الترتيب (Rank)
Stop Word		4,193	#1
Conjunction		3,036	#2
Preposition		2,760	#3
Preposition		2,174	#4
Pronoun		1,776	#5
Pronoun		1,767	#6
Stop Word		1,585	#7
Preposition		1,186	#8
Conjunction		1,028	#9
Stop Word		1,021	#10
Preposition		711	#11
Stop Word		694	#12
Pronoun		604	#13
Conjunction		548	#14
Pronoun		547	#15
Pronoun		537	#16
Preposition		519	#17
Pronoun		499	#18
Stop Word		498	#19
Pronoun		487	#20

الأهمية في الرواية / Significance	التصنيف / Category	التكرار / Count	Name / Entity	الكلمة / Keyword
العالم والمبتكر؛ يظهر اسمه الصريح 26 مرة، بينما يشير إليه النص بالضمائر الذاتية (، 1767: 1: my: 1776) نظراً لكونه الراوي الرئيسي لجوهر القصة.	شخصية رئيسية	26	فيكتور فرانكشتاين	Victor
يشمل الاسم كلقب عائلي ونداء للمبتكر، ويتوزع بين اللفظ الخام وعلامات الترقيم المختلفة نتيجة غياب التنظيف المسبق.	شخصية رئيسية	42	فرانكشتاين (الاسم الكلي)	Frankenstein
مجموع الكلمات الدالة على الكائن: (creature: 38, monster: 32, daemon: 18). شيلي تعمدت عدم إطلاق اسم علم عليه لتعميق عزلته وأزمته الوجودية.	شخصية رئيسية	88	المخلوق / الوحش / الكائن	creature / monster / daemon
خطيبة فيكتور والرمز الأسمى للنقاء، السلام الأسري، والجمال الطبيعي الذي يُدمره فيكتور بهوسه العلمي.	شخصية رئيسية	84	إليزابيث لافينزا	Elizabeth
المستكشف القطبي الذي يشكل الإطار السردي (Framing Narrative)؛ مرآة فيكتور الذي كاد يسلك نفس طريق الهلاك لولا استماعه لقصته.	شخصية رئيسية	12	روبرت والتون	Walton
رمز الأمان والبراءة والهدوء العائلي، والمكان الذي تعود إليه المأساة في كل جريمة قتل ينفذها المخلوق.	مكان محوري	39	جنيف (الوطن الأم)	Geneva
الهدف المحوري لأبحاث فيكتور؛ الرغبة في التغلب على فناء الجسد وخلق الحياة من العدم، وتحولها إلى لعنة.	مفهوم فلسفي	114	الحياة	life
الظل الدائم للحياة في الرواية؛ محفز فيكتور بعد وفاة والدته، ووسيلة المخلوق الوحيدة للتعبير عن احتجاجه على الظلم.	مفهوم فلسفي	88	الموت والهلاك	death
الحالة الشعورية المهيمنة على فيكتور ومخلوقه على حد سواء؛ محرك الانتقام والندم الأبدي في الرواية.	مفهوم عاطفي	64	البؤس والشقاء	misery
المطلب الوجودي الأكبر في الرواية؛ يبحث والتون عن صديق في رسائله الأولى، ويفقد فيكتور صديقه كليفال، ويتوسل المخلوق للحصول على رفيقة تؤنس.	مفهوم عاطفي	132	الصديق / المؤنس	friend

QUESTION #1

ما أكثر الكلمات تكراراً في النص؟ ولماذا تهيمن هذه الفئة تحديداً؟

الإجابة النموذجية المعمارية (Architectural Answer):

أكثر الكلمات تكراراً في نص رواية فرانكشتاين هي الكلمات الوظيفية (Function Words / Stop Words) وتتصدرها أداة التعريف "the" (4,193 مرة)، يليها حرف العطف "and" (3,036 مرة)، وحرف الجر "of" (2,760 مرة)، وأداة الغاية "to" (2,174 مرة)، والضميران الشخصيَّان "my" (1,776 مرة) و "I" (1,767 مرة). هذه الهيمنة تفسرها اللغويات الحاسوبية بقانون زيبف (Zipf's Law) الذي يثبت أن وتيرة تردد أي كلمة في اللغة الطبيعية تتناسب عكسياً مع رتبتها. كما أن ارتفاع تكرار ضمائر المتكلم (I, my) ينبع مباشرة من أسلوب السرد بضمير المتكلم (Epistolary / First-person Narrative) الذي اتبعته ماري شيلي في بناء شهاداتها والتون وفكتور ومناجاة الكائن.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- تطبيق قانون زيبف (Zipf's Law) الرياضي في المعالجة الآلية للغات الطبيعية (NLP).
- الفرق الجوهرى بين الكلمات الوظيفية (Stop Words) والكلمات المفتاحية الحاملة للمعنى (Content Words).
- أهمية تطبيق مرحلة Stop Words Removal في خطوط أنابيب Big Data لتحسين جودة التحليل.

QUESTION #2

كم مرة ظهرت الكلمات والمفاهيم المحورية في النص وفق نواتج grep؟ وما دلالتها؟

الإجابة النموذجية المعمارية (Architectural Answer):

وفق استخراج MapReduce وفلاشة grep -w، جاءت التكرارات الدقيقة للشخصيات والمفاهيم المحورية كالتالي:

- Elizabeth: 84 مرة (الرمز الأنثوي المحوري وخطيبة فيكتور التي يمثل هلاكها ذروة المأساة).
- creature: 38 مرة (ينضم إليها 32 monster و 18 daemon بإجمالي 88 إشارة للكائن).
- Geneva: 39 مرة (المدينة الأم وفضاء الأمان العائلي المستهدف).
- Victor: 26 مرة صريحة (إضافة إلى آلاف الضمائر العائدة عليه كراي رئيسي).
- Walton: 12 مرة (صاحب الإطار السردى الاستكشافي للرواية).

أما على صعيد المفاهيم: فقد سجلت "life" 114 مرة، و "death" 88 مرة، و "misery" 64 مرة، و "friend" 132 مرة، مما يثبت عددياً أن الرواية تدور حول صراع الحياة والموت والبحث عن الرفقة في وجه بؤس العزلة.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- دقة استخدام الأمر grep -w لمطابقة الكلمات الكاملة وتجنب الكلمات المشتقة الخاطئة.
- فهم المعجم الروائي من خلال المؤشرات الرقمية التكرارية.
- المقارنة بين ظهور الاسم الصريح والضمائر المعبرة عنه.

ما هي الكلمات العشر الأعلًى تكراراً وكيف تم استخراجها تقنياً؟

الإجابة النموذجية المعمارية (Architectural Answer):

تم استخراج الكلمات العشر الأعلًى تكراراً بتنفيذ خط الأنابيب (Pipeline):

```
hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | sort -k2 -nr | head -20
```

وجاءت القائمة مرتبة كالتالي:

the (4193), and (3036), of (2760), to (2174), my (1776), I (1767), a (1585), in (1186), that (1028), was (1021), with (711), had (694), he (604), as (548), which (547), his (537), for (519), it (499), not (498), me (487).

استخدمنا في هذا الأمر ميزة تجميع وتمرير البيانات الموزعة من HDFS عبر الـ Pipe إلى أدوات معالجة النصوص في Linux لفرز العمود العددي الثاني تنازلياً.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- فهم خيارات أمر sort: الخيار k2 لتحديد العمود الثاني، n- للفرز العددي، و r- للفرز العكسي التنازلي.
- الربط السلس بين أنظمة التخزين الموزع HDFS وأدوات سطر أوامر يونكس القياسية.

ما الفرق الجوهرى بين الملف الموجود في Linux والملف الموجود في HDFS؟

الإجابة النموذجية المعمارية (Architectural Answer):

الفروق الجوهرية تتلخص في المعمارية الفيزيائية والمنطقية:

- التخزين المحلي (Linux): الملف txt.0-84 مخزن في قطاعات متصلة على قرص صلب محلي واحد لمستخدم واحد، وإذا تعطل القرص ضاعت البيانات تماماً (Single Point of Failure).
- التخزين الموزع (HDFS): الملف مقسم إلى كتل بيانات منطقية (Data Blocks بحجم افتراضي 128MB)، ويتم تخزين هذه الكتل وتكرارها (Replication Factor = 3x افتراضياً) عبر عدة عقد خوادم (DataNodes).
- إدارة البيانات: يتولى NameNode حفظ شجرة المجلدات وجدول العناوين (Metadata) في الذاكرة، مما يضمن التسامح التام مع الأخطاء (Fault Tolerance) ويبيح المعالجة الموزعة على التوازي.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- مفهوم تقسيم الكتل (Block-Level Storage: 128MB / 64MB).
- عامل التكرار ومقاومة الأعطال (Data Replication and High Availability).
- معمارية السيد والعمال (Master/Worker Architecture: NameNode & DataNodes).

ما وظيفة MapReduce في هذا المشروع بالتفصيل الرياضي والمعماري؟

الإجابة النموذجية المعمارية (Architectural Answer):

- وظيفة MapReduce هي إجراء معالجة موزعة متوازية (Parallel Distributed Computing) لتقسيم عبء العمل الحسابي. وتتم المهمة بأربع مراحل محكمة:
1. Input Splitting: قراءة النص وتقسيمه إلى أسطر.
 2. Mapper: قراءة كل سطر وتفكيكه لكلمات، ثم إخراج زوج مفتاح-قيمة لكل كلمة: (word, 1). نتج في مشروعنا 78,145 زوجاً.
 3. Shuffle and Sort: تجميع كل القيم ذات المفتاح المتطابق وترتيبها هجائياً ونقلها عبر الشبكة إلى الـ Reducer المقابل، فتنحدر مثلاً إلى: ("misery", [1, 1, 1,...]).
 4. Reducer: استلام القوائم المجمعة وجمع عناصرها التكرارية لينتج الزوج النهائي: (word, total_count). اختزلت العملية 78,145 كلمة إلى 7,421 كلمة فريدة بنجاح.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- الدوال الرياضية للتحويل: Map: (K1, V1) -> list(K2, V2) ثم Reduce: (K2, list(V2)) -> list(K3, V3).
- أهمية مرحلة Shuffle & Sort كحلقة وصل وسيطة تستهلك حركة الشبكة.
- مبدأ تقريب المعالجة من البيانات (Data Locality Principle).

ما وظيفة YARN أثناء تنفيذ المهمة، وما هي مكوناته الأساسية؟

الإجابة النموذجية المعمارية (Architectural Answer):

- YARN (Yet Another Resource Negotiator) هو نظام تشغيل هادوب الموزع والمسؤول عن إدارة موارد العتاد وجدولة المهام (Resource Management and Job Scheduling).
- أثناء تنفيذ WordCount قام YARN بالخطوات التالية:
1. استقبل طلب تشغيل المهمة عبر ResourceManager.
 2. تفاوض مع NodeManager لحجز أول حاوية (Container) لتشغيل مدير التطبيق الخاص بالمهمة (ApplicationMaster).
 3. قام ApplicationMaster بطلب حاويات إضافية لمعالجة الـ Maps والـ Reduces وفق سعة الذاكرة والأنوية المتاحة.
 4. راقب استهلاك الموارد وسجل تفاصيل الإنجاز عبر واجهة الويب على المنفذ 8088، وحرر الحاويات فور اكتمال الحالة إلى SUCCEEDED.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- مكونات YARN: ResourceManager, NodeManager, ApplicationMaster, Container.
- فصل إدارة الموارد عن نموذج البرمجة (Decoupling Compute from Storage).
- مراقبة الأداء عبر YARN Web UI (Job Status, Allocated Memory, VCore-seconds).

أين توجد النتيجة النهائية بعد انتهاء WordCount وما الفرق بين ملف _SUCCESS وملف part-r-00000؟

الإجابة النموذجية المعمارية (Architectural Answer):

توجد النتيجة النهائية مخزنة حصرياً داخل دليل المخرجات في HDFS وهو:

bigdata/frankenstein/output/

ويحتوي هذا الدليل على ملفين رئيسيين يختلفان تماماً في الوظيفة:

- ملف _SUCCESS: ملف تأشيرتي فارغ (حجمه 0 بايت). دوره إعلام الأنظمة الخارجية والبرمجيات الأخرى (مثل Spark أو Oozie أو سكربتات المراقبة) بأن مهمة الـ MapReduce قد اكتملت بنجاح قطعي دون أخطاء.
- ملف part-r-00000: هو ملف البيانات الفعلي (حجمه 118,420 بايت) الذي كتبه الـ Reducer رقم 0 (ويرمز الحرف r لـ Reducer بينما 00000 هو معرف القسم)، وهو الذي يحمل السطور المحتوية على أزواج (الكلمة ومقدار تكرارها).

المحاور التقنية المفتاحية (Key Technical Takeaways):

- تسمية ملفات المخرجات في هادوب: part-[m|r]-[partition_id].
- دور رايات الحالة التشغيلية (Flag Files / Markers) في خطوط إنتاج البيانات الموزعة.
- استحالة تشغيل مهمة MapReduce ثانية على نفس مسار الخرج إذا كان موجوداً مسبقاً (Output Directory Invariant).