

وزارة التعليم العالي والبحث العلمي

الجامعة الماليزية الدولية - محافظة إاب

كلية الحاسبات وتقنية المعلومات - قسم الـ IT

مقرر: معالجة البيانات الضخمة (المستوى الرابع)

مقدم التقرير: محمد غازي الحجري

إشراف أستاذ المقرر: د. رمزي البازل


الفصل الدراسي: الأول - 2026م

الخلاصة التنفيذية (Executive Summary) 📌

يستعرض هذا التقرير التطبيق العملي لمفاهيم البيانات الضخمة من خلال تنفيذ دورة متكاملة لمعالجة وتحليل كتاب نمي باللغة الإنجليزية (مغامرات شيرلوك هولمز) بحجم يتجاوز 232 كيلوبايت. تم الاعتماد على بيئة (Cloudera QuickStart VM)، حيث شملت التجربة جلب البيانات، تخزينها عبر نظام HDFS الموزع، ثم برمجتها حسابياً باستخدام خوارزمية WordCount ضمن إطار MapReduce، وصولاً إلى استخراج المؤشرات الإحصائية باستخدام أدوات نظام Linux.

المرحلة الأولى: التجهيز وحقن البيانات (Data Preparation & Ingestion) 🛠️

بدأت أولى خطوات العمل بالحصول على البيانات الخام من مصدرها (Project Gutenberg) عبر أوامر التنزيل الشبكي في نظام لينكس (wget). ولضمان موثوقية العمل، تم التحقق من هيكلية الملف (txt.0-1661) وحجمه باستخدام دوال الاستكشاف مثل head و wc. لتهيئة التخزين الموزع، تم إيقاف حالة الأمان (Safe Mode) في HDFS، وبناء شجرة مجلدات مخصصة (bigdata/sherlock/input/). بعد ذلك، تم حقن البيانات من النظام المحلي إلى بيئة هادوب باستخدام أمر الرفع put، ليتم تجزئتها وحفظها كتلة تخزينية موزعة.




شرح توضيحي (1): واجهة سطر الأوامر توضح نجاح عملية رفع الملف النصي إلى مسارات HDFS والتأكد من حجم الكتلة التخزينية.

⚙️ المرحلة الثانية: المعالجة الحسابية (MapReduce Processing)

تمثل هذه المرحلة قلب نظام هادوب، حيث تم توزيع الحزمة البرمجية `hadoop-mapreduce-examples.jar` لمعالجة النصوص الموزعة. ولتخطي عقبات الموارد المحدودة في الأجهزة الافتراضية والتي قد تسبب تعطل حاويات YARN، تم ضبط المعالجة لتعمل ضمن الإطار المحلي (local framework). مرت البيانات بدورة الخوارزمية القياسية:

- **1. التعيين (Map):** تفتت الأسطر إلى كلمات مفردة وإعطاء كل كلمة قيمة مبدئية (1).
- **2. الخلط (Shuffle):** تجميع المفاتيح المتطابقة من مختلف العقد.

• 3. التخفيض (Reduce): جمع القيم وإخراج المجموع النهائي لكل مفردة.




شرح توضيحي (2): تقدم سير عملية MapReduce واكتمال مرحلتي الخرائط والتخفيض بنسبة 100% بنجاح تام.

📁 المرحلة الثالثة: هيكلية المخرجات (Output Architecture)

عند انتهاء المهام الحسابية، قام النظام آلياً بتوليد دليل المخرجات `bigdata/sherlock/output/`. باختبار محتويات هذا الدليل، تم رصد ملفين أساسيين:


- **ملف SUCCESS_:** وهو مؤشر برمجي فارغ يؤكد خلو العملية من الأخطاء.
- **ملف part-r-00000:** وهو مستودع النتائج النهائي الذي يضم القاموس الكامل لكلمات الكتاب وتكراراتها.



شرح توضيحي (3): فحص مجلد المخرجات داخل نظام HDFS وظهور ملف النتائج وحجمه التخزيني.

المرحلة الرابعة: التحليل الإحصائي (Statistical Analysis)


للاقتقال من مرحلة "معالجة البيانات" إلى "تحليل البيانات"، تم دمج قدرات HDFS مع أدوات لينكس. تم استخدام أمر الفرز الرياضي التنازلي `sort -k2 -n -r` على ملف المخرجات لاستخراج قائمة بأعلى الكلمات تردداً في النص. أظهرت النتائج أن الكلمات الوظيفية وحروف الجر (مثل: the, and, to) تتصدر القائمة، وهو ما يتوافق مع خصائص النصوص غير المهيكلية.



شرح توضيحي (4): ترتيب النتائج إحصائياً وتنظيماً لاستخراج أعلى 20 كلمة تكراراً في الرواية.

🎯 المرحلة الخامسة: التنقيب الموجه عن البيانات (Targeted Data Mining)

لاختبار كفاءة الفهرس الذي بناه النظام، قمنا بإجراء استعلام مخصص للبحث عن الشخصية الرئيسية في الرواية. باستخدام أداة `grep -w`، تم البحث عن اسم "Holmes" داخل ملف المخرجات الضخم. أثبتت النتيجة قدرة النظام على استرجاع المعلومات بدقة وبسرعة فائقة دون الحاجة لإعادة مسح الملف الأصلي.



شرح توضيحي (5): التنقيب عن اسم الشخصية الرئيسية "Holmes" واسترجاع عدد مرات ظهورها الدقيق في النص.

الاستنتاجات (Conclusions) 💡

أثبتت هذه التجربة فعالية منظومة Hadoop في إدارة دورة حياة البيانات بالكامل. نجحنا في دمج أدوات موجه الأوامر للحصول على البيانات وتنظيفها، واستخدام HDFS لتخزينها بأمان، وتطبيق MapReduce لمعالجتها رغم قيود الذاكرة. يجسد هذا المشروع فهماً عملياً متقدماً لكيفية تحويل البيانات الضخمة الخام إلى معلومات ذات قيمة تحليلية.