

الجمهورية اليمنية

الجامعة الماليزية الدولية - فرع إب

كلية الحاسوب وتكنولوجيا المعلومات

قسم تقنية المعلومات (IT) - المستوى الرابع

إعداد الطالب: وليد أحمد قايد صالح ناجي العبادي

إشراف الدكتور: رمزي البازل

التحليل الإحصائي الموزع للبيانات غير المهيكلة باستخدام منظومة Hadoop HDFS & MapReduce

دراسة حالة: تحليل نصوص رواية "أرض كُرسْتَالِس"

1. المقدمة وأهداف المشروع (Project Idea, Goals & Conceptualization)

يهدف هذا المشروع الجامعي والتطبيقي العملي إلى الربط التكاملي المتقدم بين المفاهيم النظرية والتطبيق العملي لتقنيات البيانات الضخمة (Big Data Architecture)، من خلال دمج البيئات التشغيلية وأطر العمل الموزعة (Hadoop, Linux, HDFS, MapReduce, YARN) في تطبيق موحد على بيانات حقيقية غير مهيكلة (Unstructured Data) متمثلة في نص رواية "أرض كُرسْتَالِس" بحجم (232 كيلوبايت) باستخدام بيئة العمل الافتراضية Cloudera QuickStart VM (توزيعة 5.13 CDH). يتتبع العمل مسار تحول البيانات عبر كافة مراحل دورة حياتها الرقمية؛ بدءاً من التهيئة والتأكد من الجودة، مروراً بالتخزين الموزع والمعالجة الحاسوبية الإحصائية، وصولاً إلى استخراج المعرفة والاستكشاف الإحصائي وصياغة الرؤى الأكاديمية والميدانية المكتملة.

2. فحص البيانات وتهيئة التخزين الموزع (& Validation, Organization)

(Ingestion - HDFS Setup)


أولاً: مرحلة التحقق والتحليل المبدئي (Data Validation)

تم التأكد المبدئي من سلامة الملف النصي الخام للرواية (waleed_cearsthales.txt) داخل نظام تشغيل Linux المضيف قبل البدء بعمليات الإدخال والتخزين، حيث شملت عملية التحقق قياس الحجم الظاهري والتدقيق في عدد الأسطر وجودة الترميز النصي (UTF-8) لضمان خلو البيانات من الأخطاء العشوائية قبل إرسالها إلى عقد النظام الموزع.

ثانياً: مرحلة التنظيم والاستيعاب الموزع (Organization & Ingestion)

خلال التهيئة والتخزين الموزع، تم إعداد وتأمين استقرار بيئة هادوب عبر الإجراءات التقنية التالية:

- الخروج من وضع الأمان (Safe Mode) لتمكين كتابة وتحديث البيانات: `sudo -u hdfs hdfs dfsadmin -safemode leave`
 - إنشاء شجرة الأدلة المسارية الموزعة: `hdfs dfs -mkdir -p /bigdata/crystalis/input`
 - رفع الملف وتخزينه الموزع: `hdfs dfs -put ~/Desktop/waleed_cearsthales.txt /bigdata/crystalis/input`
- استقر الملف ككتلة تخزينية موزعة بحجم دقيق قدره 236,602 بايت.



الشكل (1): لقطة شاشة توثق تنفيذ أوامر رفع الملف النصي للرواية واستقراره بنجاح داخل مسارات HDFS مع التحقق من حجم الكتلة التخزينية.

3. مرحلة المعالجة الحسابية الموزعة والتنسيق الشبكي (Distributed MapReduce Processing & Orchestration)


تضمنت هذه المرحلة تشغيل الحزمة البرمجية القياسية `hadoop-mapreduce-examples.jar` لتطبيق وتنفيذ خوارزمية عد الكلمات (WordCount) على كامل النص الكلي للرواية.

التنسيق وتجاوز عقبة الذاكرة (Orchestration Bypass):

نظراً للقيود الحرجة الخاصة بالذاكرة الوهمية (Virtual Memory Overhead) واستهلاك الموارد المتاحة لحاويات YARN ضمن البيئة الافتراضية المحدودة، تم اتباع حل هندسي مخصص يعتمد على تفعيل النمط المحلي (Local Framework Execution) لإطار العمل. تضمن هذا الاختيار الفني تجاوز أخطاء تجاوز السعة

وتجنب فشل الحاويات وتفادي ظاهرة رمادية رمز الخروج (Container Exit Code Invalid)؛ مما يضمن استقرار تنفيذ المهمة وتدفق العمليات الحسابية بسلاسة دون أخطاء. تتكون العملية الحسابية للخوارزمية من ثلاث مراحل معمارية متتالية:

- **مرحلة الخرائط (Mapper Stage):** تقطيع السطور النصية إلى كلمات منفصلة وتحويلها لأزواج مفاتيح وقيم على شكل `<Word, 1>`.
- **مرحلة الخلط والفرز (Shuffle & Sort Stage):** تجميع وتصنيف المفاتيح المتطابقة وتنظيم ترتيبها الشبكي لتمريرها بفاعلية لنقاط الـ Reducers.
- **مرحلة التخفيض (Reducer Stage):** جمع كافة القيم التكرارية المصاحبة لكل مفتاح حسابياً لإنتاج المجموع الكلي النهائي لكل كلمة فريدة بصيغة `<Word, Total_Count>`.



الشكل (2): لقطة شاشة توثق احتمال مهام Map و Reduce بنسبة 100% بنجاح ودون أخطاء تجاوز الذاكرة.

4. التحليل الإحصائي وعدادات الأداء الفنية (& Job Counters Analysis Metrics)

سجلت عدادات هادوب (Hadoop Job Counters) المخرجات الإحصائية التقنية التالية المعروضة في الجدول والقائمة التفصيلية أدناه:

المؤشر الفني / العداد (Hadoop Job Counter)	القيمة المسجلة
حجم البيانات الإجمالية المقروءة	236,602 بايت
إجمالي الأسطر النصية المدخلة (Map input) (records)	4,728 سطرًا
إجمالي الكلمات المعالجة في الرواية (Map) (output records)	27,232 كلمة
الكلمات الفريدة غير المكررة الناتجة (Reduce) (output records)	8,003 كلمة فريدة
حجم ملف النتائج المكتوب في HDFS	103,357 بايت

تحليل دلالة المؤشرات والعدادات:


- **حجم البيانات المقروءة (236,602 بايت):** يعكس التدفق الكامل للبيانات الخام المقروءة من HDFS إلى الـ Mappers.
- **إجمالي السطور المدخلة (4,728 سطرًا):** يمثل عدد الأسطر التي تم تقليصها وتقطيعها بواسطة الـ LineRecordReader.
- **إجمالي الكلمات المعالجة (27,232 كلمة):** الحجم الكلي للمفردات والرموز التي تم توليد أزواج مفاتيح لها خلال مرحلة الخرائط.
- **الكلمات الفريدة الناتجة (8,003 كلمة فريدة):** الحجم النهائي للقاموس اللغوي للرواية عقب دمج التكرارات في مرحلة الـ Reduce بنسبة ضغط لغوي وتجميع نمطي عالية.
- **حجم ملف النتائج (103,357 بايت):** الحجم الصافي للملف المخرّج النهائي المكتوب والمحفوظ في نظام الملفات الموزع.

5. استعراض المخرجات ومستودع البيانات (Output Generation & Repository)

عقب اكتمال المعالجة بنجاح، تولد مجلد المخرجات المستهدف `bigdata/crystalis/output/`

داخل نظام HDFS محتويًا على العناصر التوثيقية التالية:

- **ملف التأكيد (SUCCESS_):** ملف فارغ بحجم (0 بايت) يعمل كمؤشر توثيقي على اكتمال وتنفيذ المعالجة دون أخطاء.
- **مستودع النتائج الموزعة الرئيسي (part-r-00000):** الجدول الإحصائي النهائي المحتوي على كافة الكلمات الفريدة وتكراراتها بحجم دقيق قدره 103,357 بايت.



الشكل (3): لقطة شاشة لمجلد المخرجات تظهر ملف النجاح وملف النتائج الموزعة وحجمه الفعلي.

6. فرز وتصنيف الكلمات الأكثر تكراراً (Data Analytics & Sorting)

لغرض استكشاف الخصائص الإحصائية واستخراج المفردات الأكثر تكراراً، تم تنفيذ أمر الفرز التنازلي عبر الشاشة الطرفية:


```
hdfs dfs -cat /bigdata/crystalis/output/part-r-00000 | sort -k2 -n  
-r | head -n 15
```

ملاحظة أكاديمية وفنية هامة:

"على الرغم من أن شاشة الطرفية (Terminal) في نظام CentOS لا تدعم العرض المتصل للحروف العربية (BiDi Shaping) مما يجعل الكلمات تبدو متفرقة ظاهرياً، إلا أن محرك Java ومنظومة Hadoop قاما بمعالجة النصوص والكلمات العربية بترميز UTF-8 بشكل سليم ودقيق تماماً داخل التخزين"

أظهرت النتائج الإحصائية أن أدوات الربط وحروف الجر الأكثر تكراراً في النص هي:

المفردة / الكلمة	عدد التكرارات (التردد)
من	518 مرة
أن	275 مرة
على	215 مرة



الشكل (4): لقطة شاشة توضح تطبيق أمر الفرز التنازلي لاستخراج الكلمات ذات التردد العالي في سرد الرواية.

7. الاستعلام المستهدف وفهرسة أسماء الأعلام (& Targeted Querying)

(Data Extraction)

تم تطبيق الاستعلام الموجه باستخدام أداة البحث المتقدمة grep على ملف النتائج المستخرج للبحث الفوري عن اسم المؤلف والشخصية المحورية "وليد":

grep "وليد" ~/Desktop/results.txt

أثبتت النتيجة قدرة منظومة Hadoop على بناء فهرس عكسي (Inverted Index) محكم يتيح الاسترجاع الفوري والبحث الدقيق عن أي مفردة ضمن البيانات النصية غير المهيكلية.

إجابات أسئلة المناقشة المعتمدة في المنهج:

- **س1: ما هي الكلمة الأكثر تكراراً في النص؟**

ج1: الكلمة الأكثر تكراراً هي حرف الجر "من" بواقع 518 تكراراً.

- **س2: كم عدد تكرارات الكلمة المفتاحية المسندة إليك (وليد)؟**

ج2: أظهر الاستعلام الموجه باستخدام grep أن كلمة "وليد" تكررت 77 مرة بحالتها المجردة،

بالإضافة إلى ورودها في صيغ مركبة أخرى مثل "وليد—" (مرة واحدة) و"وليد:" (مرة واحدة)

و"وليد؟" (مرة واحدة).

- **س3: ما هي الكلمات التي تقع ضمن قائمة أعلى 10 إلى 20 كلمة تكراراً؟**

ج3: تشمل القائمة حروف الجر وأدوات العطف والربط الرئيسية مثل: "من" (518)، "أن" (275)،

"على" (215)، "في" (506)، بالإضافة إلى العلامات والرموز النصية والروابط الكلامية ذات التردد

العالي.

- **س4: ما الفرق بين الملف المقروء من Linux والملف المخزن في HDFS؟**

ج4: الملف في Linux هو ملف نمي تقليدي مخزن محلياً على قرص صلب واحد وتتعامل معه

النواة بشكل متسلسل، بينما الملف في HDFS يتم تقسيمه إلى كتل تخزينية موزعة (Blocks)

وموزعة على عقد متعددة مع تطبيق ميزات التكرار والتحمل للأخطاء (Fault Tolerance).

- **س5: ما هي وظيفة MapReduce في المشروعات؟**

ج5: يوفر MapReduce إطار معالجة برمجية موزعة ومتوازية للبيانات الضخمة عن طريق تقسيم

المهام الكبيرة إلى مهام خريطة (Map) مجزأة ثم تجميع وتخفيض المخرجات (Reduce) للوصول

للنتائج النهائية بكفاءة وسرعة عالية.

- **س6: ما هي وظيفة YARN في بيئة Hadoop؟**

ج6: يعمل YARN كممدار ومجدول لموارد المنظومة (Resource Manager) حيث يخصص الذاكرة

والمعالج للحاويات (Containers) ويدير جدول المهام وتنفيذ التطبيقات الموزعة على عقد

المجموع.

س7: أين تم حفظ وتوليد النتيجة النهائية للمشروع؟

ج7: تم حفظ النتيجة النهائية داخل HDFS في المجلد `bigdata/crystalis/output/` وتحديداً داخل

الملف الموزع الرئيسي `part-r-00000`.