

Big Data Text Analytics with Hadoop MapReduce

اسم الطالب: ضياء الدين العصواني

الموضوع: مشروع عملي متكامل - تحليل كتاب Alice's Adventures in Wonderland

الملف المعالج: pg11.txt (Project Gutenberg)

البيئة المستهدفة: Cloudera QuickStart VM (Hadoop / HDFS / YARN)

1. دورة البيانات والمخطط العام للمشروع (Data Pipeline)




2. المرحلة الأولى: استكشاف وفحص البيانات محلياً (Linux)

تم استكشاف ملف القصة الخاص بالتجربة (pg11.txt) ومعرفة الحجم وعدد الأسطر والكلمات قبل الرفع لنظام HDFS:

```
cd /home/cloudera
ls -lh pg11.txt
head -n 20 pg11.txt
wc -l pg11.txt
wc -w pg11.txt
```

المخرجات النصية المأخوذة من الشاشة:

```
-rw----- 1 cloudera cloudera 171K Sep 23 11:35 pg11.txt
The Project Gutenberg eBook of Alice's Adventures in Wonderland
3762 pg11.txt
29569 pg11.txt
```



```
My Computer cloudera-quickstart
[cloudera@quickstart ~]$ cd /home/cloudera
[cloudera@quickstart ~]$ wget https://www.gutenberg.org/cache/epub/11/pg11.txt
--2026-09-23 11:41:28-- https://www.gutenberg.org/cache/epub/11/pg11.txt
Resolving www.gutenberg.org... failed: Temporary failure in name resolution.
wget: unable to resolve host address "www.gutenberg.org"
[cloudera@quickstart ~]$ ls -lh pg11.txt
-rw----- 1 cloudera cloudera 171K Sep 23 11:35 pg11.txt
[cloudera@quickstart ~]$ head -n 20 pg11.txt
The Project Gutenberg eBook of Alice's Adventures in Wonderland

This eBook is for the use of anyone anywhere in the United States and
most other parts of the world at no cost and with almost no restrictions
whatsoever. You may copy it, give it away or re-use it under the terms
of the Project Gutenberg License included with this eBook or online
at www.gutenberg.org. If you are not located in the United States,
you will have to check the laws of the country where you are located
before using this eBook.

Title: Alice's Adventures in Wonderland

Author: Lewis Carroll

Release date: June 27, 2008 [eBook #11]
Most recently updated: June 26, 2025

Language: English
[cloudera@quickstart ~]$ wc -l pg11.txt
3762 pg11.txt
[cloudera@quickstart ~]$ wc -w pg11.txt
29569 pg11.txt
[cloudera@quickstart ~]$
```

3. المرحلة الثانية والثالثة: إنشاء مساحة HDFS ورفع البيانات

تم إنشاء مجلد المعالجة الخاص بالمشروع داخل نظام HDFS ونقل ملف القصة إليه والتأكد من مطابقة الحجم:

```
hdfs dfs -mkdir -p /bigdata/alice/input
hdfs dfs -put pg11.txt /bigdata/alice/input/
hdfs dfs -ls -h /bigdata/alice/input
hdfs dfs -du -h /bigdata/alice/input
```

المخرجات النصية المأخوذة من الشاشة:

```
Found 1 items
-rw-r--r-- 1 cloudera supergroup 170.2 K 2026-09-23 11:47
/bigdata/alice/input/pg11.txt
```

```
Title: Alice's Adventures in Wonderland
Author: Lewis Carroll

Release date: June 27, 2008 [eBook #11]
Most recently updated: June 26, 2025

Language: English
[cloudera@quickstart ~]$ wc -l pg11.txt
3762 pg11.txt
[cloudera@quickstart ~]$ wc -w pg11.txt
29569 pg11.txt
[cloudera@quickstart ~]$ hdfs dfs -mkdir -p /bigdata/alice/input
[cloudera@quickstart ~]$ hdfs dfs -put pg11.txt /bigdata/alice/input/
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/alice/input
Found 1 items
-rw-r--r-- 1 cloudera supergroup 170.2 K 2026-09-23 11:47 /bigdata/alice/in
put/pg11.txt
[cloudera@quickstart ~]$ hdfs dfs -rm -r /bigdata/alice/output
rm: `/bigdata/alice/output': No such file or directory
[cloudera@quickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-exa
26/09/23 11:51:30 INFO client.RMPProxy: Connecting to ResourceManager at quickstart
26/09/23 11:51:35 INFO input.FileInputFormat: Total input paths to process : 1
26/09/23 11:51:36 INFO mapreduce.JobSubmitter: number of splits:1
26/09/23 11:51:38 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_17
89676476175 0008
26/09/23 11:51:39 INFO impl.YarnClientImpl: Submitted application application_17
```


4. المرحلة الرابعة والخامسة: تشغيل تطبيق MapReduce ومراقبته عبر YARN

تم إرسال مهمة المعالجة الموزعة WordCount ومتابعة المؤشرات الحسابية والإحصائية في مرحلتي Mapper و Reducer:

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
```

المخرجات النصية المأخوذة من الشاشة:

```
File Input Format Counters: Bytes Read=348622
File Output Format Counters: Bytes Written=61904
Combine input records=59138
Combine output records=11946
Reduce input groups=5973
Reduce output records=5973
```



5. المرحلة السادسة والسابعة: استكشاف النتائج والتحليل النهائي

تم عرض محتويات الملف النهائي part-r-00000 واستعراض تكرار الكلمات المستخرجة من نظام HDFS:

```
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | head -n 20
```

المخرجات النصية المأخوذة من الشاشة:

```
#11] 2
#516, 2
$5,000) 2
($1 2
(862) 2
(Alice 8
(And, 2
(As 2
(Before 2
(Dinah 2
(For, 2
(He 2
(If 2
(In 2
(It 2
(Sounds 2
(The 6
(We 2
(Which 4
(with 2
```

```
cloudera@quickstart:~  
File Edit View Search Terminal Help  
Bytes Written=61904  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/  
-n 20  
#11]      2  
#516,     2  
$5,000)   2  
($1       2  
(862)     2  
(Alice    8  
(And,     2  
(As        2  
(Before    2  
(Dinah     2  
(For,      2  
(He        2  
(If        2  
(In        2  
(It        2  
(Sounds    2  
(The       6  
(We        2  
(Which     4  
(_with     2  
[cloudera@quickstart ~]$
```

6. حل الأسئلة العملية والتحليلية للمشروع (قسم 29 من الملزمة)

السؤال الأول: ما أكثر الكلمات تكراراً في النص؟

تظهر أدوات التعريف وحروف الجر والقواعد مثل (the, and, of, to, a, in) كأعلى الكلمات تكراراً عند ترتيب نتائج التحليل بواسطة الأمر `sort -k2 -nr`.

السؤال الثاني: ما هي المؤشرات والأرقام الإحصائية المستخرجة من معالجة ملف التجربة (pg11.txt)؟

استناداً إلى سجلات التنفيذ الفعلية الظاهرة في الشاشات:

المؤشر الإحصائي (Counter Metric)	القيمة المخرجة (Value)
إجمالي الكلمات الفريدة (Reduce output records)	5,973 كلمة فريدة
حجم البيانات المقروءة (Bytes Read)	348,622 بايت
حجم ملف النتائج في HDFS (Bytes Written)	61,904 بايت
إجمالي السجلات المدخلة للـ Combiner	59,138 سجل

السؤال الثالث: ما الكلمات العشرون الأعلى تكراراً؟ وكيف تستخرج؟

تستخرج بدمج أمر HDFS مع أداة الترتيب في Linux:

```
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | sort -k2 -nr | head -20
```

السؤال الرابع: ما الفرق بين الملف الموجود في Linux والملف الموجود في HDFS؟

الملف المحلي في Linux يخزن بقرص صلب محلي واحد وتعتمد معالجته على معالج واحد، بينما في HDFS يُقسم الملف إلى كتل (Blocks) موزعة ومكررة (Replicated) عبر الخوادم لتتيح المعالجة الموازية وتفاذي ضياع البيانات.

السؤال الخامس: ما وظيفة MapReduce في هذا المشروع؟

هي أداة البرمجة والمعالجة الموزعة؛ تتولى مرحلة **Mapper** تحويل النص إلى أزواج `Word, >` 1، ومرحلة **Shuffle** لتجميع الكلمات، ومرحلة **Reducer** لحساب إجمالي تكرار كل كلمة `<Word, Count>`.

السؤال السادس: ما وظيفة YARN أثناء تنفيذ المهمة؟

هو مدير الموارد (Resource Manager) والجدولة؛ يقوم بتخصيص الذاكرة والمعالجات (Containers) المطلوبة لتشغيل وتنفيذ مهام الـ Map والـ Reduce ومتابعة حالتها عبر البورت 8088.

السؤال السابع: أين توجد النتيجة النهائية بعد انتهاء WordCount؟ وكيف تُستخرج للـ Linux؟

توجد داخل نظام HDFS بداخل الملف part-r-00000 بداخل مجلد المخرجات، ويتم استخراجها ونقلها إلى نظام Linux عبر الأمر:

```
hdfs dfs -getmerge /bigdata/alice/output alice_wordcount.txt
```

7. الخلاصة النهائية: مراحل دورة حياة البيانات في Hadoop (Lifecycle)

1. **Acquisition**: الحصول على البيانات الحقيقية لقصة Alice's Adventures in Wonderland.

2. **Validation**: فحص البيانات محلياً والتأكد من حجمها (171K) وعدد أسطرها (3,762 سطر).

3. **Organization**: إنشاء دليل ومساحة منظمة داخل HDFS تحت المسار
bigdata/alice/input/

4. **Ingestion**: رفع البيانات من نظام Linux إلى HDFS باستخدام الأمر put.

5. **Processing**: تشغيل تطبيق MapReduce لمعالجة النص وحساب تكرار الكلمات.

6. **Orchestration**: إدارة وتوزيع الموارد وجدولة المهمة عبر محرك YARN.

7. **Analysis**: تحليل النتائج المخرجة وتقييم الكلمات الفريدة (5,973 كلمة).

8. **Extraction**: استخراج النتائج النهائية وتجميعها إلى ملف Linux عبر الأمر getmerge.