

تقرير تنفيذ معالجة نصية باستخدام HDFS و Hadoop و MapReduce

1. بيانات التقرير

موضوع التقرير: رفع نص «إعلان استقلال الولايات المتحدة الأمريكية» إلى HDFS وتنفيذ مهمة WordCount ثم استخراج النتائج وتحليلها.

مصدر البيانات: الملف النصي `txt.0-1661` المرفق ضمن الحزمة.

الأدلة المرفقة: 15 لقطة شاشة توثق مراحل التنفيذ من فحص البيانات الأولي حتى استخراج أفضل 20 كلمة والبحث عن كلمات محددة.

تاريخ إعداد التقرير: 24 سبتمبر 2026.

2. الملخص التنفيذي

يوثق هذا التقرير تجربة عملية لمعالجة ملف نصي تاريخي باستخدام منظومة Hadoop. بدأت العملية بالحصول على الملف وفحص محتواه قبل إدخاله إلى Hadoop، ثم إنشاء مساحة عمل داخل HDFS ورفع الملف إليها. بعد ذلك جرى التحقق من وجود الملف وحجمه وقراءة محتواه مباشرة من HDFS، ثم تشغيل مهمة WordCount لمقابلة كل كلمة بعدد مرات ظهورها. كما توثق اللقطات مراقبة المهمة عبر YARN، واستخراج ملفات النتائج من HDFS، وقراءة النتائج واستكشافها، إلى جانب البحث عن كلمات محددة واستخراج أفضل 20 كلمة.

تُظهر البيانات أن الملف هو الإصدار النصي من أول كتاب إلكتروني في مشروع Project Gutenberg، ويتضمن مقدمة وملاحظات المحررين ونص إعلان الاستقلال. وبحسب الفحص المباشر للملف، يبلغ حجمه **10,954 بايت**، ويتكون من **228 سطرًا** و **1,759 كلمة** وفق عدّادات النظام النصية. ويجب فهم هذه الأرقام باعتبارها مؤشرات على الملف الخام؛ أما ناتج WordCount فيتأثر بطريقة تقسيم الكلمات وتنظيفها المستخدمة في المهمة.

3. وصف البيانات المصدر

الملف `txt.0-1661` يحمل العنوان:

THE DECLARATION OF INDEPENDENCE OF THE UNITED STATES OF AMERICA

ويحتوي على عناصر تمهيدية من مشروع Gutenberg، وملاحظات المحررين، ثم نص إعلان الاستقلال الصادر في 4 يوليو 1776، وينتهي بعلامة نهاية الكتاب الإلكتروني. ويشير النص إلى أن هذا الملف يمثل الكتاب الإلكتروني الأول في مجموعة Project Gutenberg، مع وجود ملاحظات تاريخية حول طريقة إنتاج النصوص الإلكترونية في السبعينيات.

مؤشرات الملف

المؤشر	القيمة
اسم الملف	txt.1661-0
عدد الأسطر	228
عدد الكلمات وفق WC	1,759
الحجم بالبايت	10,954
نوع البيانات	نص عادي Plain Text
طبيعة المعالجة	تخزين موزع ثم عدّ تكرار الكلمات

4. تسلسل التنفيذ

4.1 الحصول على البيانات وفحصها قبل Hadoop

تم أولاً تجهيز الملف النصي واستخدام أوامر القراءة والفحص للتحقق من سلامة المحتوى قبل رفعه إلى HDFS. وتُظهر اللقطات أن البيانات عبارة عن نص مقروء يتضمن مقدمة الكتاب والنص التاريخي، كما تم إجراء فحص إضافي للبيانات قبل إدخالها إلى Hadoop.

النتيجة: توفر ملف نصي صالح للمعالجة، مع إمكانية قراءة محتواه محليًا والتحقق من عدم كونه ملفًا فارغًا أو تالفًا.

4.2 إنشاء مساحة المشروع داخل HDFS

تم إنشاء المسار المخصص للمشروع داخل HDFS، ثم رفع ملف الكتاب إلى هذا المسار. إنشاء مسار مستقل يساعد على فصل ملفات الإدخال عن ملفات النتائج، ويجعل أوامر القراءة والتشغيل والاستخراج أكثر وضوحًا.

النتيجة: أصبح هناك مسار عمل داخل HDFS مخصص لملف الإدخال ونتائج المهمة.

4.3 التحقق من الرفع والحجم والقراءة

بعد الرفع، تم التأكد من وصول الملف إلى HDFS، والتحقق من حجمه، ثم قراءة البيانات مباشرة من المسار الموزع. هذه الخطوات مهمة للتأكد من أن الملف الذي ستعالجه مهمة WordCount هو الملف المقصود فعليًا، وأن عملية الرفع لم تنتج ملفًا ناقصًا أو مسارًا خاطئًا.

النتيجة: تم التحقق من وجود الملف في HDFS وإمكانية قراءة محتواه من المسار الموزع.

4.4 تشغيل WordCount

تم تشغيل مهمة WordCount على ملف الكتاب. تقوم هذه المهمة عادةً بمرحلة **Map** لإنتاج أزواج من الشكل (الكلمة , 1) ، ثم مرحلة **Shuffle/Sort** لتجميع المفاتيح المتشابهة، ثم مرحلة **Reduce** لجمع القيم وإنتاج (الكلمة , عدد التكرارات) .

تمت مراقبة تقدم المهمة باستخدام YARN، بما في ذلك حالة التطبيق ومعلومات التشغيل الظاهرة في واجهة المراقبة.

النتيجة: اكتملت مهمة العد وأنشئت ملفات النتائج داخل مجلد الإخراج في HDFS.

4.5 استخراج النتائج واستكشافها

بعد اكتمال المهمة، تم استخراج النتائج من HDFS وقراءتها. كما تم استكشاف النتائج والبحث عن كلمات محددة، ثم ترتيب أو عرض أعلى الكلمات تكرارًا لاستخراج أفضل 20 كلمة بحسب ناتج المهمة.

النتيجة: أصبحت مخرجات WordCount قابلة للقراءة والتحليل، مع توفير مؤشرات أولية عن أكثر الكلمات تكرارًا في النص.

5. ملخص النتائج الفنية

المرحلة	الإجراء	دليل التحقق
1	الحصول على البيانات	وجود ملف txt.0-1661 وظهور محتواه
2	الفحص الأولي	قراءة النص وفحصه قبل الإدخال
3	إنشاء مساحة HDFS	ظهور مسار المشروع داخل HDFS
4	رفع الملف	ظهور الملف في المسار المخصص
5	التحقق	فحص الوصول والحجم والقراءة المباشرة
6	المعالجة	تشغيل WordCount وظهور سجلات المهمة
7	المراقبة	ظهور المهمة في YARN ومتابعة حالتها
8	النتائج	استخراج مخرجات المهمة من HDFS
9	التحليل	استكشاف النتائج والبحث عن كلمات واستخراج أفضل 20 كلمة

6. ملاحظات منهجية على تفسير WordCount

يعتمد الناتج النهائي على منطق الـ Mapper المستخدم في المهمة. فإذا كان التقسيم يعتمد على الفراغات فقط، فقد تظهر علامات الترقيم أو اختلافات حالة الأحرف كعناصر منفصلة؛ فمثلاً قد تُعامل **The** و **the** ككلمتين مختلفتين، وقد تُحتسب كلمة ملتصقة بفاصلة كعنصر مستقل. لذلك فإن قائمة أفضل 20 كلمة تعكس **سياسة تنظيف وتقسيم البيانات** بقدر ما تعكس تكرار الكلمات في النص.

ولرفع جودة التحليل، يمكن في تشغيل لاحق توحيد حالة الأحرف، إزالة علامات الترقيم، استبعاد الكلمات الشائعة، ومعالجة صيغ الجمع والاختلافات الإملائية عند الحاجة. أما التنفيذ الموثق في هذا التقرير فيثبت دورة العمل الأساسية: إدخال البيانات إلى HDFS، تشغيل MapReduce، والتحقق من النتائج واستخراجها.

7. الخلاصة

تم توثيق دورة تنفيذ كاملة لمعالجة ملف نصي باستخدام Hadoop، بدءاً من فحص البيانات المصدرية ووصولاً إلى استخراج نتائج WordCount وتحليلها. وتؤكد اللقطات المرفقة تحقق المراحل الأساسية: تجهيز الملف، إنشاء مساحة HDFS، رفع البيانات، التحقق من الحجم والوصول، تشغيل المهمة، مراقبتها عبر YARN، ثم استخراج النتائج والبحث فيها.

وبناءً على الأدلة المتاحة، فإن التنفيذ يحقق الهدف العملي من التجربة، وهو تطبيق معالجة موزعة على نص حقيقي والتحقق من مخرجات العد. وتبقى دقة ترتيب الكلمات الأكثر تكراراً مرتبطة بالتنفيذ التفصيلي لبرنامج WordCount وقواعد تنظيف النص المستخدمة داخله.

8. سجل لقطات الشاشة والتنفيذ

أدرجت جميع اللقطات المرفقة دون حذف، وبترتيب تنفيذي منطقي من تجهيز البيانات إلى تحليل النتائج. كل لقطة تمثل دليلاً بصرياً مستقلاً على المرحلة الموضحة أسفلها.

اللقطة 1 – المرحلة الأولى: الحصول على البيانات

توضح بدء مرحلة تجهيز البيانات والحصول على الملف النصي المراد إدخاله إلى بيئة Hadoop.

```
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$ cd /home/cloudera  
[cloudera@quickstart ~]$ ls -lh 1661-0.txt  
-rwxrw-rw- 1 cloudera cloudera 11K Sep 23 10:42 1661-0.txt  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$
```

```
cd /home/cloudera
```

4. المرحلة الأولى: الحصول على البيانات

قل إلى مجلد المستخدم:

يتم تحميل الكتاب:

اللقطة 2 — فحص البيانات قبل إدخالها إلى Hadoop

توضح قراءة وفحص المحتوى قبل الرفع، بما يساعد على التحقق من أن ملف الإدخال يحتوي على النص المتوقع.

```
[cloudera@quickstart ~]$ ls -lh 1661-0.txt
-rwxrwx-rw- 1 cloudera cloudera 11K Sep 23 10:42 1661-0.txt
[cloudera@quickstart ~]$ head 1661-0.txt
*** START OF THE PROJECT GUTENBERG EBOOK 1 ***

The United States Declaration of Independence was the first E-text
released by Project Gutenberg, early in 1971. The title was stored
in an emailed instruction set which required a tape or diskpack be
hand mounted for retrieval. The disk pack was the size of a large
cake in a cake carrier, cost $1500, and contained 5 megabytes, of
which this file took 1-2%. Two tape backups were kept plus one on
paper tape. The 10,000 files we hope to have online by the end of
[cloudera@quickstart ~]$ head -20 1661-0.txt
*** START OF THE PROJECT GUTENBERG EBOOK 1 ***

The United States Declaration of Independence was the first E-text
released by Project Gutenberg, early in 1971. The title was stored
in an emailed instruction set which required a tape or diskpack be
hand mounted for retrieval. The disk pack was the size of a large
cake in a cake carrier, cost $1500, and contained 5 megabytes, of
which this file took 1-2%. Two tape backups were kept plus one on
paper tape. The 10,000 files we hope to have online by the end of
2001 should take about 1-2% of a comparably priced drive in 2001.

This file was never copyrighted, Shareware, etc., and is thus for
all to use and copy in any manner they choose. Please feel free to
make your own edition using this as a base.

In my research for creating this transcription of our first Etext,
I have come across enough discrepancies [even within that official
documentation provided by the United States] to conclude that even
"facsimiles" of the Declaration of Independence are nary identical
[cloudera@quickstart ~]$
```

5. فحص البيانات قبل إدخالها إلى Hadoop

قبل استخدام أي Dataset، من المهم التأكد من أنها موجودة وأن محتواها صحيح.

معرفة حجم الملف

```
ls -lh 1661-0.txt
```

هذا يعرض حجم الملف بطريقة سهلة للقراءة.

مشاهدة بداية الملف

```
head 1661-0.txt
```

يمكن استخدام عدد أكبر من الأسطر:

```
head -20 1661-0.txt
```

هذا يساعدنا على معرفة شكل البيانات في بداية الملف.

اللقطة 3 — فحص إضافي للبيانات

توضح خطوة فحص إضافية للملف ومخرجات القراءة أو الأوامر المرتبطة به قبل بدء المعالجة الموزعة.

```
all to use and copy in any manner they choose. Please feel free to
make your own edition using this as a base.

In my research for creating this transcription of our first Etext,
I have come across enough discrepancies [even within that official
documentation provided by the United States] to conclude that even
"facsimiles" of the Declaration of Independence are nary identical
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ tail 1661-0.txt
the State of Great Britain, is and ought to be totally dissolved; and
that as Free and Independent States, they have full Power to levy War,
conclude Peace, contract Alliances, establish Commerce, and to do all
other Acts and Things which Independent States may of right do. And for
the support of this Declaration, with a firm reliance on the Protection
of Divine Providence, we mutually pledge to each other our Lives, our
Fortunes and our sacred Honor.

*** END OF THE PROJECT GUTENBERG EBOOK 1 ***
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ wc -l 1661-0.txt
228 1661-0.txt
[cloudera@quickstart ~]$ wc -w 1661-0.txt
1759 1661-0.txt
[cloudera@quickstart ~]$
```

مشاهدة نهاية الملف

```
tail 1661-0.txt
```

أو:

```
tail -20 1661-0.txt
```

معرفة عدد الأسطر

```
wc -l 1661-0.txt
```

معرفة عدد الكلمات

```
wc -w 1661-0.txt
```

يمكن استخدام هذه الأوامر لمعرفة حجم البيانات قبل إدخالها في نظام Hadoop.

اللقطة 4 — التأكد من وصول الملف

توضح التحقق من وجود الملف في الموضع المتوقع وإمكانية الوصول إليه.

نَفَذَ:

يجب أن يظهر:

يمكن أيضًا استخدام:

```
*new file (~/Desktop/untitled folder) - aedit
```

توضيح إنشاء المسار أو مساحة العمل التي ستحتوى على بيانات المشروع داخل نظام الملفات الموزع HDFS.

رة الثانية تعلمنا أن HDFS يحتاج إلى تنظيم للبيانات داخل مجلدات. سننشئ مجلدًا خاصًا بهذا المشروع.

لَآئِن:

باستخدام:

```
*new file (~/Desktop/untitled folder) - gedit
```

توضح نقل ملف الكتاب من البيئة المحلية إلى مسار الإدخال داخل HDFS.

يُدّ حالياً في: `home/cloudera/1661-0.txt/`

ملفات المحلي Linux الذي تعلمناه في المحاضرة الثانية. نحتاج الآن إلى إدخاله إلى HDFS.

أد من فصل الملف الى HDFS

```
cloudera@quickstart:~
```

اللقطة 7 – التحقق من حجم البيانات داخل HDFS

توضح استخدام أوامر التحقق من حجم الملف أو البيانات بعد الرفع إلى HDFS.

```
released by Project Gutenberg, early in 1971. The title was stored in an emailed instruction set which required a tape or diskpack be hand mounted for retrieval. The disk pack was the size of a large cake in a cake carrier, cost $1500, and contained 5 megabytes, of which this file took 1-2%. Two tape backups were kept plus one on paper tape. The 10,000 files we hope to have online by the end of 2001 should take about 1-2% of a comparably priced drive in 2001.
```

This file was never copyrighted, Shareware, etc., and is thus free for all to use and copy in any manner they choose. Please feel free to make your own edition using this as a base.

In my research for creating this transcription of our first Etext, I have come across enough discrepancies [even within that official documentation provided by the United States] to conclude that even "facsimiles" of the Declaration of Independence are nary identical

```
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$ hdfs dfs -du -h /bigdata/sherlock/input  
10.7 K 10.7 K /bigdata/sherlock/input/1661-0.txt  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$
```

10. التحقق من حجم البيانات داخل HDFS

نقد:

```
hdfs dfs -du -h /bigdata/sherlock/input
```

سيظهر حجم الملف الموجود داخل HDFS.

اللقطة 8 – قراءة البيانات مباشرة من HDFS

توضح قراءة محتوى الملف من المسار الموزع مباشرة للتأكد من سلامة الإدخال قبل تشغيل المهمة.

```
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/input/1661-0.txt | head -20  
*** START OF THE PROJECT GUTENBERG EBOOK 1 ***
```

The United States Declaration of Independence was the first E-text released by Project Gutenberg, early in 1971. The title was stored in an emailed instruction set which required a tape or diskpack be hand mounted for retrieval. The disk pack was the size of a large cake in a cake carrier, cost \$1500, and contained 5 megabytes, of which this file took 1-2%. Two tape backups were kept plus one on paper tape. The 10,000 files we hope to have online by the end of 2001 should take about 1-2% of a comparably priced drive in 2001.

This file was never copyrighted, Shareware, etc., and is thus free for all to use and copy in any manner they choose. Please feel free to make your own edition using this as a base.

In my research for creating this transcription of our first Etext, I have come across enough discrepancies [even within that official documentation provided by the United States] to conclude that even "facsimiles" of the Declaration of Independence are nary identical

```
[cloudera@quickstart ~]$
```

علمنا أن `cat` العادية تتعامل مع Linux. أما هنا فنستخدم:

```
hdfs dfs -cat /bigdata/sherlock/input/1661-0.txt | head -20
```

من HDFS. وهكذا نربط ما تعلمناه سابقاً:

اللقطة 9 – تشغيل WordCount

توضح إطلاق مهمة WordCount لمعالجة النص وحساب عدد مرات ظهور الكلمات.


```
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
> wordcount \
> /bigdata/sherlock/input \
> /bigdata/sherlock/output
26/09/23 13:16:28 INFO client.RMProxy: Connecting to ResourceManager at
26/09/23 13:16:29 INFO input.FileInputFormat: Total input paths to process
26/09/23 13:16:29 WARN hdfs.DFSClient: Caught exception
java.lang.InterruptedException
    at java.lang.Object.wait(Native Method)
    at java.lang.Thread.join(Thread.java:1281)
    at java.lang.Thread.join(Thread.java:1355)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.closeResponse
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.endBlock
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.run(DFSOutputStream.java:894)
26/09/23 13:16:29 WARN hdfs.DFSClient: Caught exception
java.lang.InterruptedException
    at java.lang.Object.wait(Native Method)
    at java.lang.Thread.join(Thread.java:1281)
    at java.lang.Thread.join(Thread.java:1355)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.closeResponse
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.endBlock
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.run(DFSOutputStream.java:894)
26/09/23 13:16:29 INFO mapreduce.JobSubmitter: number of splits:1
26/09/23 13:16:29 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1787780516262_0010
26/09/23 13:16:30 INFO impl.YarnClientImpl: Submitted application application_1787780516262_0010
26/09/23 13:16:30 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/application_1787780516262_0010/
26/09/23 13:16:30 INFO mapreduce.Job: Running job: job_1787780516262_0010
26/09/23 13:16:42 INFO mapreduce.Job: Job job_1787780516262_0010 running in uber mode : false
```

المرحلة الخامسة: تشغيل WordCount

نقوم الآن بتشغيل البرنامج WordCount الجاهز الموجود ضمن أمثلة Hadoop. نفذ:

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
wordcount \
/bigdata/sherlock/input \
/bigdata/sherlock/output
```

Hadoop الآن العملية على البيانات الموجودة داخل:

اللقطة 10 — مراقبة العملية باستخدام YARN


توضح متابعة التطبيق أثناء التنفيذ باستخدام واجهة أو أوامر YARN، بما يدعم التحقق من حالة المهمة.

The screenshot shows the Cloudera Manager web interface in a Firefox browser. The main view is the 'All Applications' page, which displays a table of running applications. The table has columns for Application ID, User, Name, Application Type, and Status. The application 'application_1787780516262_0010' is shown as 'Running / Finished'. The interface also includes a sidebar with navigation links for Cluster, Nodes, Applications, and Tools. A modal window is open, showing details for the selected application, including its ID and status.

اللقطة 11 — استخراج النتائج من HDFS

توضح الوصول إلى مخرجات المهمة واستخراجها أو نسخها من مجلد النتائج داخل HDFS.



```
> sherl
[cloudera@quickstart ~]$ dfs -getmerge \
> /bigdata/sherlock/output \
>
bash: dfs: command not found
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hdfs dfs -getmerge \
> /bigdata/sherlock/output \
> sherlock_wordcount.txt
[cloudera@quickstart ~]$ ls -lh sherlock_wordcount.txt
-rw-r--r-- 1 cloudera cloudera 8.2K Sep 23 13:36 sherlock_wordcount.txt
[cloudera@quickstart ~]$ head -20 sherlock_wordcount.txt
#1 1
#2 1
#9. 1
$1500, 1
& 1
*** 6
- 1
--Such 1
1 2
1-2% 1
1-2% 1
10,000 1
1776 1
1970's 1
1971, 1
1971. 1
2001 1
2001. 1
2005: 1
2025: 1
[cloudera@quickstart ~]$
```



اللقطة 12 — قراءة نتائج WordCount

توضح قراءة الملفات الناتجة بعد اكتمال مهمة العد.

```
File Input Format Counters
  Bytes Read=10954
File Output Format Counters
  Bytes Written=8305
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/sherlock/output
Found 2 items
-rw-r--r-- 1 cloudera cloudera 0 2026-09-23 13:17 /bigdata/sherlock/output/part-r-000000
-rw-r--r-- 1 cloudera cloudera 8305 2026-09-23 13:17 /bigdata/sherlock/output/part-r-000001
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-000001 | head -20
#1 1
#2 1
#9. 1
$1500, 1
& 1
*** 6
- 1
--Such 1
1 2
1-2% 1
1-2% 1
10,000 1
1776 1
1970's 1
1971, 1
1971. 1
2001 1
2001. 1
2005: 1
2025: 1
[cloudera@quickstart ~]$
```



اللقطة 13 — استكشاف النتائج

توضح استعراض النتائج وفحص القيم الناتجة عن عملية العد.

17. المرحلة السادسة: استكشاف النتائج

بعد انتهاء المهمة نفذ:

```
hdfs dfs -ls /bigdata/sherlock/output
```

قد يظهر:

```
_SUCCESS  
part-r-00000
```

18. ما هو _SUCCESS؟

```
cloudera@quickstart ~]$  
cloudera@quickstart ~]$  
cloudera@quickstart ~]$  
cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/sherlock/output  
Found 2 items  
rw-r--r-- 1 cloudera cloudera      0 2026-09-23 13:17 /bigdata/sherlock/output/_SUCCESS  
rw-r--r-- 1 cloudera cloudera 8305 2026-09-23 13:17 /bigdata/sherlock/output/part-r-00000  
cloudera@quickstart ~]$
```

اللقطة 14 – البحث عن كلمات محددة

توضح تنفيذ بحث موجه عن كلمات معينة داخل النتائج للتحقق من تكرارها أو الوصول إليها.

```
1  
#2 1  
#9 1  
$1500, 1  
& 1  
*** 6  
- 1  
--Such 1  
1 2  
1-2% 1  
1-2% 1  
10,000 1  
1776 1  
1970's 1  
1971, 1  
1971. 1  
2001 1  
2001. 1  
2005: 1  
2025: 1  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Holmes"  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Watson"  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Sherlock"  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "and"  
and 60  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "of"  
of 99  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "the"  
the 99  
[cloudera@quickstart ~]$
```

رحلة السابعة: البحث عن كلمات معينة

داخل نتائج Hadoop باستخدام grep. مثل:

```
hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Holmes"
```

اللقطة 15 – استخراج أفضل 20 كلمة

توضح استخراج أو عرض أعلى 20 كلمة بحسب عدد مرات الظهور في مخرجات WordCount.



9. مرفقات المصدر

يتضمن أرشيف التسليم ملف البيانات الأصلي txt.0-1661 وجميع لقطات الشاشة الخمس عشرة المستخدمة في هذا التقرير. ويُستحسن الاحتفاظ بالأرشيف الأصلي إلى جانب التقرير للحفاظ على إمكانية مراجعة الأدلة بحالتها الأصلية.

نهاية التقرير