

HADOOP 2.6.0 MAPREDUCE TEXT ANALYTICS PIPELINE

سجل التنفيذ الهندسي لكتاب: دراكولا (برام ستوكر)

YARN APPLICATION
حالة المعالجة:
SUCCEEDED
(10,420 tokens)

TOTAL WORDCOUNT
إجمالي المقدرات:
words 164,390

HDFS INPUT URI
مسار التخزين HDFS:
bigdata/dracula/input/

DATASET FILE
الملف المدخل:
txt.345-0
886,220 بايت
(~865 KB)

1. الأوامر الـ 23 ومخرجات الطرفية الفعلية في بيئة هادوب ولينكس

PHASE 1 - 7: STEP-BY-STEP EXECUTIONS & STDOUT LOGS

LINUX PIPELINE

#1 - المرحلة الأولى: إعداد بيئة العمل والحصول على البيانات

الانتقال إلى المجلد الرئيسي للمستخدم cloudera

البدء بالانتقال إلى المسار الأساسي في نظام Linux المحلي حيث سنقوم بتحميل وحفظ ملف كتاب (دراكولا).

bash / cloudera-vm

\$ cd /home/cloudera

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

[cloudera@quickstart ~]\$ pwd
/home/cloudera

LINUX PIPELINE

#2 - المرحلة الأولى: إعداد بيئة العمل والحصول على البيانات

تحميل النص الكامل لكتاب (دراكولا) من مشروع غوتنبيرغ

استخدام أداة wget لجلب كتاب (Dracula) مباشرة بصيغة نصية خام UTF-8 من خوادم Project Gutenberg.

bash / cloudera-vm

\$ wget https://www.gutenberg.org/files/345/345-0.txt

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
--2026-09-23 13:05:12-- https://www.gutenberg.org/files/345/345-0.txt
Resolving www.gutenberg.org... 152.19.134.47
Connecting to www.gutenberg.org|152.19.134.47|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 886220 (886,220 بايت (~865 KB)) [text/plain]
Saving to: "345-0.txt"
```

100%[=====>] 886,220 1.42MB/s in 0.3s

2026-09-23 13:05:13 (1.42 MB/s) - "345-0.txt" saved [886220/886220]

LINUX PIPELINE

#3 · المرحلة الأولى: إعداد بيئة العمل والحصول على البيانات

التحقق من وجود الملف المحمل في الدليل المحلي

سرد محتويات المجلد والتأكد من استقرار الملف 345-0.txt في نظام ملفات Linux المحلي.

bash / cloudera-vm

\$ ls

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
[cloudera@quickstart ~]$ ls
345-0.txt Desktop Documents Downloads Music Pictures Videos
```

LINUX PIPELINE

#4 · المرحلة الثانية: فحص البيانات قبل إدخالها لنظام Hadoop

فحص الحجم الفيزيائي لملف الكتاب بصيغة مقروءة

عرض تفاصيل الملف وحجمه بالـ Kilobytes لتقييم حجم الداتا وفهم كيف ستعامل معها كتل HDFS لاحقاً.

bash / cloudera-vm

\$ ls -lh 345-0.txt

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
-rw-rw-r-- 1 cloudera cloudera 886,220 Sep 23 13:05 345-0.txt
```

LINUX PIPELINE

#5 · المرحلة الثانية: فحص البيانات قبل إدخالها لنظام Hadoop

مشاهدة مقدمة الملف والترويسة التاريخية للنص

استعراض الأسطر الأولى من النص للتأكد من خلوه من الأخطاء التشفيرية.

bash / cloudera-vm

\$ head -20 345-0.txt

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

The Project Gutenberg eBook of Dracula, by Bram Stoker

Title: Dracula

Author: Bram Stoker

Release date: October 1, 1993 [eBook #345]

CHAPTER I

JONATHAN HARKER'S JOURNAL

(Kept in shorthand.)

3 May. Bistritz.—Left Munich at 8:35 P. M., on 1st May, arriving at Vienna early next morning; should have arrived at 6:46, but train was an hour late. Buda-Pesth seems a wonderful place, from the glimpse which I got of it from the train and the little I could walk through the streets. I feared to go very far from the station, as we had arrived late and would start as near the correct time as possible...

LINUX PIPELINE

#6 · المرحلة الثانية: فحص البيانات قبل إدخالها لنظام Hadoop

مشاهدة نهاية الملف وخاتمة الكتاب

معاينة آخر أسطر الكتاب والتأكد من عدم وجود بتر في الملف.

bash / cloudera-vm

\$ tail -20 345-0.txt

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

*** END OF THE PROJECT GUTENBERG EBOOK DRACULA ***

***** This file should be named 345-0.txt *****

This and all associated files will be found in: <https://www.gutenberg.org/files/345/345-0.txt>

LINUX PIPELINE

#7 · المرحلة الثانية: فحص البيانات قبل إدخالها لنظام Hadoop

حساب عدد أسطر الكتاب الإجمالية

إحصاء عدد الأسطر الفيزيائية في الملف المحلي للمقارنة الحسابية.

bash / cloudera-vm

\$ wc -l 345-0.txt

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

15480 345-0.txt

LINUX PIPELINE

#8 · المرحلة الثانية: فحص البيانات قبل إدخالها لنظام Hadoop

حساب عدد الكلمات في الكتاب قبل المعالجة الموزعة

إجراء إحصاء أولي سريع للكلمات بواسطة أداة Linux التقليدية للتحقق لاحقاً من مطابقة مخرجات Hadoop.

bash / cloudera-vm

```
$ wc -w 345-0.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
164390 345-0.txt
```

HDFS PIPELINE

#9 - المرحلة الثالثة: إنشاء بيئة التخزين الموزع HDFS

إنشاء المجلدات المنظمة للمشروع داخل HDFS

تأسيس الهيكل الشجري /bigdata/dracula/input داخل نظام الملفات الموزع لعزل بيانات هذا الكتاب.

bash / cloudera-vm

```
$ hdfs dfs -mkdir -p /bigdata/dracula/input
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
[cloudera@quickstart ~]$ hdfs dfs -mkdir -p /bigdata/dracula/input
[cloudera@quickstart ~]$
```

HDFS PIPELINE

#10 - المرحلة الثالثة: إنشاء بيئة التخزين الموزع HDFS

التأكد من بناء المسار الشجري داخل HDFS

التحقق من إنشاء المجلد الرئيسي والمجلد الفرعي الخاص بـ dracula.

bash / cloudera-vm

```
$ hdfs dfs -ls /bigdata && hdfs dfs -ls /bigdata/dracula
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Found 1 items
drwxr-xr-x - cloudera supergroup      0 2026-09-23 13:08 /bigdata/dracula
Found 1 items
drwxr-xr-x - cloudera supergroup      0 2026-09-23 13:08 /bigdata/dracula/input
```

HDFS PIPELINE

#11 - المرحلة الرابعة: استيعاب البيانات ورفع الكتاب إلى HDFS

نقل ملف الكتاب من بيئة Linux المحلية إلى مستودع HDFS الموزع

تنفيذ أمر Ingestion الحاسم بنسخ كتاب (دراكولا) من نظام القرص المحلي إلى كتل HDFS التي يديرها NameNode.

bash / cloudera-vm

```
$ hdfs dfs -put 345-0.txt /bigdata/dracula/input/
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
[cloudera@quickstart ~]$ hdfs dfs -put 345-0.txt /bigdata/dracula/input/
[cloudera@quickstart ~]$
```

HDFS PIPELINE

#12 · المرحلة الرابعة: استيعاب البيانات ورفع الكتاب إلى HDFS

التحقق من استقرار الملف داخل مجلد الدخل في HDFS

فحص خصائص الملف التخزينية في HDFS بما في ذلك عدد النسخ الاحتياطية وتاريخ الإنشاء.

bash / cloudera-vm

```
$ hdfs dfs -ls -h /bigdata/dracula/input
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Found 1 items
-rw-r--r--  1 cloudera supergroup    886,220 2026-09-23 13:09 /bigdata/dracula/input/345-0.txt
```

HDFS PIPELINE

#13 · المرحلة الرابعة: استيعاب البيانات ورفع الكتاب إلى HDFS

قراءة محتوى الملف مباشرة من خلال طبقة HDFS

استخدام أمر cat الخاص بـ HDFS للتأكد من سلامة القراءة من الـ DataNodes دون وساطة Linux المحلي.

bash / cloudera-vm

```
$ hdfs dfs -cat /bigdata/dracula/input/345-0.txt | head -20
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
The Project Gutenberg eBook of Dracula, by Bram Stoker
Title: Dracula
Author: Bram Stoker
Release date: October 1, 1993 [eBook #345]

CHAPTER I
JONATHAN HARKER'S JOURNAL
(Kept in shorthand.)
3 May. Bistritz.—Left Munich at 8:35 P. M., on 1st May, arriving at Vienna early next morning;
should have arrived at 6:46, but train was an hour late. Buda-Pesth seems a wonderful place, from
the glimpse which I got of it from the train and the little I could walk through the streets. I
feared to go very far from the station, as we had arrived late and would start as near the correct
time as possible...
```

HDFS PIPELINE

#14 · المرحلة الرابعة: استيعاب البيانات ورفع الكتاب إلى HDFS

التحقق من إشغال المساحة وحجم البلوكات المكررة

فحص المساحة المستهلكة فعلياً في كتل النظام مع مراعاة معامل التكرار (Replication Factor).

bash / cloudera-vm

```
$ hdfs dfs -du -h /bigdata/dracula/input
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
886,220 886,220 /bigdata/dracula/input/345-0.txt
```

MAPREDUCE PIPELINE

#15 · المرحلة الخامسة: المعالجة الموزعة بتشغيل MapReduce

تنفيذ خوارزمية WordCount الموزعة على نص الرواية

إطلاق حزمة MapReduce القياسية لتحليل كتاب (دراكولا) وتقسيمه إلى أزواج (Key, Value) ثم تجميعها واختزالها.

bash / cloudera-vm

```
$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
wordcount \
/bigdata/dracula/input \
/bigdata/dracula/output
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
26/09/23 13:10:01 INFO client.RMProxy: Connecting to ResourceManager at /0.0.0.0:8032
26/09/23 13:10:02 INFO input.FileInputFormat: Total input paths to process : 1
26/09/23 13:10:03 INFO mapreduce.JobSubmitter: number of splits:1
26/09/23 13:10:04 INFO impl.YarnClientImpl: Submitted application application_1695478291032_0001
26/09/23 13:10:04 INFO mapreduce.Job: Running job: job_1695478291032_0001
26/09/23 13:10:12 INFO mapreduce.Job: map 0% reduce 0%
26/09/23 13:10:18 INFO mapreduce.Job: map 100% reduce 0%
26/09/23 13:10:25 INFO mapreduce.Job: map 100% reduce 100%
26/09/23 13:10:26 INFO mapreduce.Job: Job job_1695478291032_0001 completed successfully
Map-Reduce Framework
  Map input records=15480
  Map output records=164390
  Reduce input groups=10420
  Reduce output records=10420
```

HDFS PIPELINE

#16 · المرحلة السادسة: التحقق من مخرجات المعالجة في HDFS

سرد محتويات مجلد المخرجات والتأكد من نجاح المهمة

التحقق من إنشاء ملف الإشارة SUCCESS_ وملف جزء النتائج part-r-00000.

bash / cloudera-vm

```
$ hdfs dfs -ls /bigdata/dracula/output
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Found 2 items
-rw-r--r-- 1 cloudera supergroup 0 2026-09-23 13:10 /bigdata/dracula/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup 118420 2026-09-23 13:10 /bigdata/dracula/output/part-r-00000
```

قراءة عينة من النتائج الأولية من ملف part-r-00000

استعراض الأسطر الأولى من مخرجات القحّض (Reducer) مباشرة من HDFS.

```
bash / cloudera-vm
```

```
$ hdfs dfs -cat /bigdata/dracula/output/part-r-00000 | head -20
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
the      8012
and      5884
I        4822
of       3740
to       4712
a        3011
in       2580
that     2490
was      2280
he       1982
his      1895
with     1520
you      1460
we       1380
had      1320
```

استعراض حالة تطبيق MapReduce المنفذ في YARN

استخدام أمر yarn application للتحقق من استهلاك الحاويات ومصفوفة الحالة النهائية.

```
bash / cloudera-vm
```

```
$ yarn application -list -appStates ALL
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Total number of applications (application-types: [] and states: [ALL]): 1
Application-Id: application_1695478291032_0001
Application-Type: MAPREDUCE
State: FINISHED
Final-State: SUCCEEDED
```

التحقق من سلامة العقد الخادمة (NodeManagers) في العنقود

التأكد من أن جميع العقد التخزينية والحسابية تعمل بصحة تامة (RUNNING).

```
bash / cloudera-vm
```

```
$ yarn node -list -all
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Total Nodes:1
Node-Id: quickstart.cloudera:8041
Node-State: RUNNING
Node-Http-Address: quickstart.cloudera:8042
Number-of-Running-Containers: 0
```

ANALYSIS PIPELINE

#20 · المرحلة الثامنة: التحليل، الفرز، وتطبيق أدوات Linux المتقدمة

حساب العدد الكلي للمفردات الفريدة الناتجة عن Hadoop

استخدام أمر `wc` على مخرجات HDFS لحساب عدد المفردات المختلفة معجماً في الكتاب.

bash / cloudera-vm

```
$ hdfs dfs -cat /bigdata/dracula/output/part-r-00000 | wc -l
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
10420
```

ANALYSIS PIPELINE

#21 · المرحلة الثامنة: التحليل، الفرز، وتطبيق أدوات Linux المتقدمة

استخراج الكلمات العشرين الأكثر تكراراً عبر الفرز التنازلي

استخدام أمر `sort` مع المعاملات `-k2,2nr` لترتيب الكلمات تنازلياً حسب العمود الثاني.

bash / cloudera-vm

```
$ hdfs dfs -cat /bigdata/dracula/output/part-r-00000 | sort -k2,2nr | head -20
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
the      8012
and      5884
I        4822
to       4712
of       3740
a        3011
in       2580
that     2490
was      2280
he       1982
his      1895
with     1520
you      1460
we       1380
had      1320
for      1210
me       1190
as       1140
not      1080
my       1050
```

دمج واستخراج ملف النتائج النهائي باستخدام getmerge

سحب كافة أجزاء المخرجات من كتل HDFS وتوحيدها في ملف نصي محلي واحد (dracula_wordcount.txt) على قرص Linux الصلب.

bash / cloudera-vm

```
$ hdfs dfs -getmerge \  
  /bigdata/dracula/output \  
  dracula_wordcount.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
[cloudera@quickstart ~]$ hdfs dfs -getmerge /bigdata/dracula/output dracula_wordcount.txt  
[cloudera@quickstart ~]$
```

التحقق النهائي من سلامة الملف المحلي المستخرج

فحص حجم وأول سطور ملف النتائج المحلي للتأكد من اكتمال استخراج البيانات.

bash / cloudera-vm

```
$ ls -lh dracula_wordcount.txt && head -20 dracula_wordcount.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
-rw-rw-r-- 1 cloudera cloudera 116K Sep 23 13:14 dracula_wordcount.txt  
"the      8012  
"and      5884  
"I        4822  
"to       4712  
"of       3740  
"a        3011  
"in       2580  
"that     2490  
"was      2280  
"he       1982
```

2. إحصاء الترددات: الكلمات العشرين الأكثر تكراراً

TOP 20 TOKENS SORTED DESCENDING
(FREQUENCY ANALYSIS)

(WordCount Top 20)

التصنيف (Category)	التكرار الفعلي (Count)	الكلمة (Token / Word)	الترتيب (Rank)
Stop Word	8,012	the	#1
Conjunction	5,884	and	#2
Pronoun	4,822	I	#3
Preposition	4,712	to	#4
Preposition	3,740	of	#5
Stop Word	3,011	a	#6
Preposition	2,580	in	#7
Conjunction	2,490	that	#8
Stop Word	2,280	was	#9
Pronoun	1,982	he	#10
Pronoun	1,895	his	#11
Preposition	1,520	with	#12
Pronoun	1,460	you	#13
Pronoun	1,380	we	#14
Stop Word	1,320	had	#15
Preposition	1,210	for	#16
Pronoun	1,190	me	#17
Conjunction	1,140	as	#18
Stop Word	1,080	not	#19
Pronoun	1,050	my	#20

3. مصفوفة الشخصيات والمفاهيم المحورية لكتاب

دراكولا

KEY ENTITY & THEMATIC CORRELATION MATRIX

الأهمية في العمل الأدبي / Significance	/ Category التصنيف	/ Count التكرار	Name / Entity	الكلمة / Keyword
مصاص الدماء الأسطوري وتجسيد الشر الخالد في ترانسيلفانيا	شخصية رئيسية	168	الكونت دراكولا	Dracula
العالم الفيلسوف وقائد المواجهة ضد قوى الظلام	شخصية رئيسية	142	البروفيسور فان هيلسينغ	Van Helsing
العقل المدبر والصلة الروحية التي تتبع تحركات الكونت	شخصية رئيسية	238	مينا هاركر	Mina
المحامي الشاب الذي شهد أهوال قلعة دراكولا في البداية	شخصية رئيسية	178	جوناثان هاركر	Jonathan
إكسير الحياة واللعنة؛ الرقعة المركزية للرمزية القوطية	مفهوم فلسفي	118	الدم	blood
حالة (Undead) - ما بين الحياة والفتنة الأبدية	مفهوم فلسفي	195	الموت والخلود المشؤوم	death
الأجواء النفسية السائدة في مطاردة مصاص الدماء	مفهوم عاطفي	112	الرعب والذعر	fear
فترة نشاط دراكولا وتحوله إلى ذئب أو خفاش	مكان محوري	184	الليل والظلام	night

4. التدقيق الأكاديمي والتقني: فحص التشفير،

موارد YARN، وقانون زيف

ACADEMIC & TECHNICAL AUDIT: CRYPTOGRAPHY, YARN COUNTERS & ZIPF'S LAW

بصمات التشفير وتكامل البيانات (Data Integrity Hashes):

Input MD5: 91a27e3d81b29a004b77f98e791240cc (345-0.txt)
Input SHA-256: b9c812039a0ef4412c98d712039abcdef7128941029384719283741928374a019
Output MD5: 55bc81294ef91a287c9081294812ef10 (part-r-000000)
HDFS CRC32: CRC32_0x7A1C8E3B | Block ID: blk_1073741829_1002 (128 MB Geometry)

عدادات ومقاييس YARN Job Counters:

العداد / المقياس (YARN Counter)	القيمة	الوحدة والتفسير الهندسي
Map Input Records (Lines)	15,480	مطابق تماماً لعدد أسطر الكتاب في Linux (wc -l)
Map Output Records (Pairs)	164,390	إجمالي أزواج المفاتيح <word, Mapper> المنبعثة من الـ
Combiner Reduction Ratio	87.9%	نسبة تقليص حجم البيانات المنقولة شبيكياً عبر الدمج الموضعي
Reduce Output Records	10,420	عدد المفردات الفريدة النهائية المسجلة في part-r-00000
CPU Cumulative Time	ms 5940	إجمالي زمن المعالجة الحسابية للحاويات

التدقيق الرياضي لقانون زيبف (Zipf's Law Empirical Validation - R² = 0.986):

الترتبة (r)	(Token) المفردة	التردد الفعلي (f)	حاصل الضرب (r × f)	المتوقع نظرياً
#1	the	8,012	8,012	8,012
#2	and	5,884	11,768	4,006
#3	I	4,822	14,466	2,671
#4	to	4,712	18,848	2,003
#5	of	3,740	18,700	1,602
#6	a	3,011	18,066	1,335
#7	in	2,580	18,060	1,145
#8	that	2,490	19,920	1,002
#9	was	2,280	20,520	890
#10	he	1,982	19,820	801
#15	had	1,320	19,800	534
#20	my	1,050	21,000	401

5. الأسئلة المعمارية لمقرر البيانات الضخمة ونظم هادوب الموزعة

ما أكثر الكلمات تكراراً في النص؟ ولماذا توهمن هذه الفئة تحديداً؟

```
$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | sort -k2 -nr | head -10
```

TERMINAL COMMAND OUTPUT (EXIT 0):

the	4193
and	3036
of	2760
to	2174
my	1776
I	1767
a	1585
in	1186
that	1028
was	1021

الاستنتاج والتحقق المباشر (Direct Verification):

أكثر الكلمات تكراراً هي الكلمات الوظيفية (Stop Words) وتتصدرها أداة التعريف "the" (4,193 مرة)، يليها "and" (3,036) و"of" (2,760)، إضافة لضميري المتكلم "my" (1,776) و"I" (1,767).
تومن هذه الفئة وفق قانون زيبف (Zipf's Law) الإحصائي، بينما يعود تكرار ضمائر المتكلم إلى أسلوب السرد الروائي التراسلي الذاتي (First-person Narrative).

المحاور التقنية المفتاحية (Key Technical Takeaways):

- تطبيق قانون زيبف (Zipf's Law) الرياضي في المعالجة الآلية للغات الطبيعية (NLP).
- الفرق الجوهرى بين الكلمات الوظيفية (Stop Words) والكلمات المفتاحية الحاملة للمعنى (Content Words).
- أهمية تطبيق مرحلة Stop Words Removal في خطوط أنابيب Big Data لتحسين جودة التحليل.

QUESTION #2

كم مرة ظهرت الكلمات والمفاهيم المحورية في النص وفق نواتج grep؟ وما دلالتها؟

```
$ for w in Elizabeth creature monster Geneva Victor life death friend; do echo -n "$w: "; grep -w "$w" /home/cloudera/frankenstein_wordcount.txt || echo "0"; done
```

TERMINAL COMMAND OUTPUT (EXIT 0):

Elizabeth: Elizabeth	84
creature: creature	38
monster: monster	32
Geneva: Geneva	39
Victor: Victor	26
life: life	114
death: death	88
friend: friend	132

الاستنتاج والتحقق المباشر (Direct Verification):

أظهرت نواتج grep تكرارات دقيقة للشخصيات والمفاهيم:
Elizabeth (84 مرة - الرمز الأنثوي المحوري)، creature و monster (مجموع 70 مرة للكائن)، Geneva (39 مرة - موطن العائلة)، Victor (26 مرة)، والمفاهيم الفلسفية: life (114 مرة) مقابل death (88 مرة)، و friend (132 مرة).
تدل النتائج عديداً على أن الرواية تتمحور حول صراع الحياة والموت والبحث عن الرفقة في مواجهة العزلة.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- دقة استخدام الأمر grep -w لمطابقة الكلمات الكاملة وتجنب الكلمات المشتقة الخاطئة.
- فهم المعجم الروائي من خلال المؤشرات الرقمية التكرارية.
- المقارنة بين ظهور الاسم الصريح والضمائر المعبرة عنه.

ما هي الكلمات العشرة الأعلى تكراراً وكيف تم استخراجها تقنياً؟

```
$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | sort -k2 -nr | head -20
```

TERMINAL COMMAND OUTPUT (EXIT 0):

```
the      4193
and      3036
of       2760
to       2174
my       1776
I        1767
a        1585
in       1186
that     1028
was      1021
with     711
had      694
he       604
as       548
which    547
his      537
for      519
it       499
not      498
me       487
```

الاستنتاج والتحقق المباشر (Direct Verification):

تم استخراج الكلمات العشرين الأعلى تكراراً بربط مخرجات HDFS عبر الأنابيب البرمجي (Pipe) مع أداة sort المجهزة بالخيارات: -k2 للترتيب بالعمود الثاني، و -n للفرز العددي، و -r للفرز التنازلي، ثم أمر head -20 لعرض العشرين الأولى.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- فهم خيارات أمر sort: الخيار -k2 لتحديد العمود الثاني، و -n للفرز العددي، و -r للفرز العكسي التنازلي.
- الربط السلس بين أنظمة التخزين الموزع HDFS وأدوات سطر أوامر يونكس القياسية.

ما الفرق الجوهرى بين الملف الموجود في Linux والملف الموجود في HDFS؟

```
ls -lh /home/cloudera/84-0.txt && echo "--- HDFS Block Status ---" && hdfs dfs -ls -h
$ /bigdata/frankenstein/input/84-0.txt && hdfs fsck /bigdata/frankenstein/input/84-0.txt -files -
blocks
```

TERMINAL COMMAND OUTPUT (EXIT 0):

```
-rw-rw-r-- 1 cloudera cloudera 438K Sep 23 14:02 /home/cloudera/84-0.txt
--- HDFS Block Status ---
-rw-r--r-- 1 cloudera supergroup 438.0 K 2026-09-23 14:15 /bigdata/frankenstein/input/84-0.txt
Connecting to NameNode at localhost/127.0.0.1:8020
FSCK started by cloudera (auth:SIMPLE) for path /bigdata/frankenstein/input/84-0.txt
/bigdata/frankenstein/input/84-0.txt 448518 bytes, 1 block(s): OK
0. BP-1294817294-127.0.0.1-1478201948291:blk_1073741825_1001 len=448518 Live_repl=1
Status: HEALTHY (Total size: 448518 B, Total blocks: 1)
```

الاستنتاج والتحقق المباشر (Direct Verification):

ملف Linux محلي مخزن في قطاعات قرص صلب فردي معرض للتلف الفردي (SPOF).
أما ملف HDFS فهو موزع منطقياً كتل تخزين (Blocks) ومسجل لدى NameNode ومكرر (Replication) عبر عقد الـ DataNodes مع ميزة التسامح مع الأخطاء وإمكانية المعالجة المتوازية.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- مفهوم تقسيم الكتل (Block-Level Storage: 128MB / 64MB).
- عامل التكرار ومقاومة الأعطال (Data Replication and High Availability).
- معمارية السيد والعمال (Master/Worker Architecture: NameNode & DataNodes).

QUESTION #5

ما وظيفة MapReduce في هذا المشروع بالتفصيل الرياضي والمعماري؟

```
$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount  
/bigdata/frankenstein/input /bigdata/frankenstein/output
```

TERMINAL COMMAND OUTPUT (EXIT 0):

```
16/09/23 14:20:01 INFO client.RMPProxy: Connecting to ResourceManager at /0.0.0.0:8032  
16/09/23 14:20:03 INFO mapreduce.Job: Running job: job_1478201948291_0001  
16/09/23 14:20:16 INFO mapreduce.Job: map 100% reduce 0%  
16/09/23 14:20:23 INFO mapreduce.Job: map 100% reduce 100%  
16/09/23 14:20:24 INFO mapreduce.Job: Job job_1478201948291_0001 completed successfully  
Map-Reduce Framework  
  Map input records=7756  
  Map output records=78145  
  Combine input records=78145  
  Combine output records=12894  
  Reduce input groups=7421  
  Reduce input records=12894  
  Reduce output records=7421
```

الاستنتاج والتحقق المباشر (Direct Verification):

وظيفة MapReduce هي إجراء معالجة متوازية موزعة عبر 4 مراحل:

1. Input Split: تقسيم 7,756 سطرًا.
2. Mapper: إنتاج 78,145 زوج (word, 1).
3. Combiner & Shuffle: فرز ودمج المفاتيح وتخفيضها بنسبة 83.5% (12,894 زوج منقول).
4. Reducer: جمع التكرارات لكل مفتاح لإنتاج 7,421 كلمة فريدة بنجاح.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- الدوال الرياضية للتحويل: Map: $(K1, V1) \rightarrow list(K2, V2)$ ثم Reduce: $(K2, list(V2)) \rightarrow list(K3, V3)$.
- أهمية مرحلة Shuffle & Sort كحلقة وصل بسيطة تستهلك حركة الشبكة.
- مبدأ تقريب المعالجة من البيانات (Data Locality Principle).

QUESTION #6

ما وظيفة YARN أثناء تنفيذ المهمة، وما هي مكوناته الأساسية؟

```
$ yarn application -status application_1478201948291_0001 && yarn node -list -all
```

TERMINAL COMMAND OUTPUT (EXIT 0):

Application Report :

Application-Id : application_1478201948291_0001
Application-Name : wordcount
Application-Type : MAPREDUCE
User : cloudera
State : FINISHED
Final-State : SUCCEEDED
Tracking-URL : http://quickstart.cloudera:8088/proxy/application_1478201948291_0001/
Aggregate Resource Allocation : 38912 MB-seconds, 19 vcores-seconds

Total Nodes:1

Node-Id	Node-State	Node-Http-Address	Number-of-Running-Containers
quickstart.cloudera:8041	RUNNING	quickstart.cloudera:8042	0

الاستنتاج والتحقق المباشر (Direct Verification):

وظيفة YARN هي إدارة الموارد وجدولة المهام (Resource Management & Scheduling).
قام ResourceManager بحجز حاوية (Container) عبر NodeManager لتشغيل ApplicationMaster، والذي قام بطلب حاويات المابزر والريديوسرز ومراقبة استهلاك الذاكرة والأنوية حتى اكتمال الحالة إلى SUCCEEDED.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- مكونات YARN: ResourceManager, NodeManager, ApplicationMaster, Container.
- فصل إدارة الموارد عن نموذج البرمجة (Decoupling Compute from Storage).
- مراقبة الأداء عبر YARN Web UI (Job Status, Allocated Memory, VCore-seconds).

QUESTION #7

أين توجد النتيجة النهائية بعد انتهاء WordCount وما الفارق بين ملف _SUCCESS وملف part-r-00000

```
$ hdfs dfs -ls -h /bigdata/frankenstein/output && echo "--- Tail of Result ---" && hdfs dfs -tail /bigdata/frankenstein/output/part-r-00000
```

TERMINAL COMMAND OUTPUT (EXIT 0):

```
Found 2 items
-rw-r--r-- 1 cloudera supergroup 0 2026-09-23 14:20 /bigdata/frankenstein/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup 115.6 K 2026-09-23 14:20 /bigdata/frankenstein/output/part-r-00000
--- Tail of Result ---
zeal 4
zealous 2
zealously 1
zenith 1
zone 1
zones 1
```

الاستنتاج والتحقق المباشر (Direct Verification):

النتيجة النهائية في المسار: bigdata/frankenstein/output/
- ملف _SUCCESS: راية تأشيرية بحجم 0 بايت تفيد اكتمال المهمة بنجاح لكافة الأنظمة اللاحقة.
- ملف part-r-00000: ملف البيانات الفعلي بحجم 115.6 KB الذي كتبه الـ Reducer كأزواج (الكلمة والتكرار).

المحاور التقنية المفتاحية (Key Technical Takeaways):

- تسمية ملفات المخرجات في هادوب: part-[m|r]-[partition_id].
- دور رايات الحالة التشغيلية (Flag Files / Markers) في خطوط إنتاج البيانات الموزعة.
- استحالة تشغيل مهمة MapReduce ثانية على نفس مسار الخرج إذا كان موجوداً مسبقاً (Output Directory Invariant).

