

Big Data Text Analytics with Hadoop MapReduce

تحليل كتاب حقيقي باستخدام المعالجة الموزعة

اسم الطالب	صادق الحداد
المقرر	Big Data / Hadoop
البيئة	Cloudera QuickStart VM
مجموعة البيانات	1661-0.txt — The Adventures of Sherlock Holmes
التاريخ	24-09-2026

دورة البيانات

REAL DATA → Linux → HDFS → MapReduce / YARN → Analysis → Linux

ملخص تنفيذي

Hadoop باستخدام The Adventures of Sherlock Holmes يطبق هذا التقرير مشروعاً متكاملًا لتحليل نص كتاب Linux، ثم فحصه في نظام، Project Gutenberg يبدأ العمل بالحصول على ملف نصي حقيقي من MapReduce. ومتابعة التنفيذ بواسطة WordCount، ورفعته إلى النظام الموزع، وتشغيل، HDFS، وتنظيم مساحة له داخل وتحليلها Linux وأخيراً استخراج النتائج إلى YARN.

فاليانات تبدأ كملف محلي، ثم Hadoop الهدف ليس عدّ الكلمات فقط، بل توضيح العلاقة العملية بين مكونات YARN بينما يتولى Mapper وShuffle وReducer عبر مراحل MapReduce ويعالجها، HDFS تصبح مدخلاً في إدارة الموارد التنفيذ.

أهداف المشروع 1.

- حقيقية قابلة للتحليل Dataset الحصول على
- Hadoop التحقق من وجود الملف وحجمه ومحتواه قبل إدخاله إلى
- ورفع البيانات إليها HDFS إنشاء بنية منظمة داخل
- MapReduce على كتاب كامل باستخدام WordCount تشغيل
- Map وReduce في إدارة التطبيق ومراحل YARN فهم دور
- استخراج النتائج والإجابة عن أسئلة تحليلية مبنية على البيانات

وصف البيانات ومصدرها 2.

وهو متاح من Arthur Conan Doyle للكاتب The Adventures of Sherlock Holmes الكتاب المستخدم هو وُحفظ نسخة العمل، txt. تحت الرقم 1661. يتم التعامل معه كملف نصي باسم 0-1661 Project Gutenberg HDFS قبل رفعها إلى /home/cloudera المحلية داخل

```
Dataset: 1661-0.txt
Source: https://www.gutenberg.org/files/1661/1661-0.txt
Local path: /home/cloudera/1661-0.txt
```

المرحلة الأولى – الحصول على البيانات والتحقق منها 3.

تبدأ العملية بالانتقال إلى مجلد المستخدم، ثم تنزيل الكتاب، ثم تنفيذ فحوص أولية للتأكد من أن الملف موجود وأن بدايته ونهايته تبدو صحيحتين

```
cd /home/cloudera
wget https://www.gutenberg.org/files/1661/1661-0.txt
ls -lh 1661-0.txt
head -20 1661-0.txt
tail -20 1661-0.txt
wc -l 1661-0.txt
wc -w 1661-0.txt
```

؛ فهي تمنع إدخال ملف ناقص أو فارغ إلى النظام الموزع، وتوفر Validation مرحلة wc وtail وhead وls تُعد أوامر خط أساس للمقارنة بعد تنفيذ التحليل

HDFS المرحلة الثانية – تنظيم مساحة المشروع داخل 4.

إلى بنية مجلدات واضحة تفصل مدخلات المشروع عن مخرجاته. لذلك نستخدم مجلدًا باسم HDFS يحتاج للكتاب input مع مجلد، /bigdata داخل sherlock

```
hdfs dfs -mkdir -p /bigdata/sherlock/input
hdfs dfs -ls /bigdata
hdfs dfs -ls /bigdata/sherlock
```

HDFS المرحلة الثالثة – رفع الكتاب وقراءة البيانات من 5.

```
hdfs dfs -put 1661-0.txt /bigdata/sherlock/input/
hdfs dfs -ls -h /bigdata/sherlock/input
hdfs dfs -cat /bigdata/sherlock/input/1661-0.txt | head -20
hdfs dfs -du -h /bigdata/sherlock/input
```

الفرق بينهما أن HDFS ونسخة داخل Linux توجد نسختان منطقيتان من البيانات: نسخة محلية في put بعد تنفيذ Replication و Blocks يخزن البيانات ضمن بنية موزعة تعتمد على HDFS يمثل نظام ملفات محلياً، بينما Linux.

WordCount المرحلة الرابعة – تشغيل 6.

ويضع input يقرأ البرنامج الملفات من Hadoop MapReduce الجاهز ضمن WordCount يستخدم المشروع مثال موجوداً مسبقاً عند تشغيل المهمة لأول مرة output يجب ألا يكون مجلد. output ناتج العد في

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount \
/bigdata/sherlock/input \
/bigdata/sherlock/output
```

في هذا المشروع؟ MapReduce كيف تعمل 7.

Input	Mapper	Shuffle	Reducer	Output
مجموع كل Reducer القيم المتشابهة، وبحسب Shuffle كل كلمة إلى زوج (الكلمة، 1)، ثم يجمع Mapper يحوّل مجموعة. النتيجة النهائية تكون أسطراً من الشكل: الكلمة عدد مرات الظهور				

```
hello hadoop hello big data
```

```
Mapper: hello 1 | hadoop 1 | hello 1 | big 1 | data 1
Shuffle: hello → [1,1]   hadoop → [1]   big → [1]   data → [1]
Reducer: hello 2   hadoop 1   big 1   data 1
```

YARN المرحلة الخامسة – مراقبة التنفيذ بواسطة 8.

يمكن فتح واجهة WordCount بعد تشغيل Hadoop. هو طبقة إدارة الموارد والتطبيقات في YARN وحالة المهمة ووقت البداية والنهاية ومراحل Application ID من العنوان التالي ومراجعة ResourceManager Map و Reduce.

```
http://localhost:8088
```

- تعني أن التطبيق ما زال قيد التنفيذ Running
- تعني انتهاء المهمة بنجاح أو بفشل مع وجود حالة توضح السبب Finished
- تعرضان تقدم المرحلتين الأساسيتين للمهمة Map و Reduce

المرحلة السادسة – استكشاف النتائج 9.

```
hdfs dfs -ls /bigdata/sherlock/output
hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | head -20
```

part-r- إلى أن المهمة اكتملت بنجاح، لكنه ليس ملف النتائج التحليلية. الملف المهم هو SUCCESS_ يشير الملف 00000، حيث توجد أزواج الكلمات وأعدادها،

تنظيف البيانات وحدوده 10.

كقيم مختلفة. Holmes و Holmes الأساسي على النص كما هو، ولذلك قد يتعامل مع WordCount يعتمد مثل توحيد حالة الحروف وإزالة علامات الترقيم قبل تنفيذ تحليل متقدم. Data Cleaning، هذه النتيجة تبرز أهمية كما هو، مع توثيق هذا القيد ضمن الاستنتاجات WordCount في هذا المشروع نستخدم

البحث عن كلمات وشخصيات محددة 11.

```
hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | grep -w "Holmes"
hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | grep -w "Watson"
hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | grep -w "Sherlock"
hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | grep -w "London"
hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | grep -w "Lestrade"
```

الكلمة	طريقة الحصول على العدد	النتيجة الفعلية
Holmes	grep -w "Holmes"	Terminal تُملأ من مخرجات
Watson	grep -w "Watson"	Terminal تُملأ من مخرجات
Sherlock	grep -w "Sherlock"	Terminal تُملأ من مخرجات
London	grep -w "London"	Terminal تُملأ من مخرجات
Lestrade	grep -w "Lestrade"	Terminal تُملأ من مخرجات

استخراج أعلى 20 كلمة 12.

```
hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | sort -k2 -nr | head -20
```

لترتيبها تنازلياً. بذلك Linux في sort لإنتاج النتائج الأساسية، ثم نستخدم أداة Hadoop نستخدم هذه الخطوة يتحول الناتج الخام إلى قائمة قابلة للقراءة والتحليل

Linux المرحلة السابعة – استخراج النتائج إلى 13.

```
hdfs dfs -getmerge /bigdata/sherlock/output sherlock_wordcount.txt
ls -lh sherlock_wordcount.txt
head -20 sherlock_wordcount.txt
```

ويمكن sherlock_wordcount.txt تصبح نسخة النتائج متاحة في نظام الملفات المحلي باسم getmerge بعد استخدامها في التحليل أو تسليمها مع التقرير

إجابات الأسئلة السبعة 14.

السؤال	الإجابة
1. ما أكثر الكلمات تكراراً؟	وتكون ، sort -k2 -nr head -20 يتم تحديدها من أمر الكلمة صاحبة أعلى قيمة في العمود الثاني هي الأكثر تكراراً.
2. كم مرة ظهرت الكلمات المحددة؟	Sherlock و Watson و Holmes يُستخرج العدد لكل من part-r- من ملف grep باستخدام Lestrade و London و 00000.
3. ما الكلمات العشرة الأعلى؟	بعد قراءة مخرجات sort -k2 -nr head -20 ينتجها أمر

	WordCount من HDFS.
4. ما الفرق بين Linux وHDFS؟	بينما، /home/cloudera، يخزن النسخة المحلية في Linux يخزن نسخة موزعة داخل HDFS Replication و Blocks مع إدارة /bigdata/sherlock/input
5. ما وظيفة MapReduce؟	تحويل الكلمات إلى أزواج، تجميع القيم المتشابهة، ثم جمعها لإنتاج عدد ظهور كل كلمة
6. ما وظيفة YARN؟	وجدولة التطبيق ومتابعة حالته cluster إدارة موارد Map و Reduce ومراحل
7. أين توجد النتيجة النهائية؟	وبعد، /bigdata/sherlock/output/part-r-00000 أولاً داخل باسم Linux في ملف getmerge sherlock_wordcount.txt.

لقطات الشاشة المطلوبة للتسليم 15.

تُرفق لقطات الشاشة من بيئة التنفيذ الفعلية، ولا تُستبدل بنتائج تقديرية. المطلوب أربع لقطات أساسية

رقم	المطلوب	الدليل المطلوب
01	HDFS البيانات داخل	hdfs dfs -ls -h /bigdata/sherlock/input
02	MapReduce Job تنفيذ	Map وظهور اكتمال hadoop jar أمر و Reduce
03	YARN واجهة	في Application http://localhost:8088
04	النتائج	part-r-00000 من head و hdfs dfs -ls output

التسليم والاستنتاج 16.

ومخرجات، HDFS /bigdata/sherlock/input ومسار، باسم Dataset 0-1661 يتكون التسليم النهائي من
وجداول الكلمات، sherlock_wordcount.txt وملف النتائج المحلي، /bigdata/sherlock/output في MapReduce
المطلوبة، وأربع لقطات شاشة، وهذا التقرير

لا يقتصر على تنفيذ أمر واحد، بل يقدم دورة متكاملة لإدارة البيانات: الحصول عليها، Hadoop يوضح المشروع أن
التحقق منها، تنظيمها، إدخالها، معالجتها، مراقبة تنفيذها، تحليلها، ثم استخراجها. كما يوضح أن جودة التحليل تعتمد
على جودة النص الخام وعلى مقدار تنظيفه قبل العد