

Hadoop MapReduce مشروع عملي متكامل: تحليل كتاب حقيقي باستخدام

Big Data Text Analytics — The Adventures of Sherlock Holmes — Arthur Conan Doyle

الطالب: Salah | البيئة: Cloudera QuickStart VM 5.13 على VMware | الإدخال: `bigdata/salah/input/`
الإخراج: `bigdata/salah/output/`

(1) فكرة المشروع ودورة البيانات

جمع كل مفاهيم المقرر (Hadoop و HDFS و MapReduce و YARN و Linux) في مشروع واحد على بيانات حقيقية من Project Gutenberg. الدورة: تحميل الكتاب في Linux وفحصه، ثم تنظيم مساحة في HDFS ورفع الكتاب إليها، ثم تشغيل WordCount تحت إدارة YARN، ثم تحليل النتائج والبحث عن الشخصيات، ثم استخراج النتائج إلى Linux عبر `getmerge`.

(2) الحصول على البيانات وفحصها في Linux

```
cd  
/home/cloudera
```

```
cp  
omran.txt salah.txt (نسخة  
Salah العمل باسم  
من  
كتاب Gutenberg  
رقم  
1661)
```

ناتج التنفيذ الفعلي (من الطالب): الملف `salah.txt` حجم 594K بعدد 12306 أسطر و 107522 كلمة، وبدايته عنوان الكتاب **The Adventures of Sherlock Holmes** للمؤلف **Arthur Conan Doyle**.

```
ls  
-lh salah.txt => -rw-r--r-- 1 cloudera cloudera 594K Sep 23 15:56  
/home/cloudera/salah.txt
```

```
wc  
-l salah.txt => 12306 | wc -w salah.txt => 107522
```

(3) مساحة المشروع في HDFS ورفع الكتاب


```
hadoop  
fs -mkdir -p /bigdata/salah/input
```

```
hadoop
fs -put salah.txt /bigdata/salah/input/
```

نتيجة التنفيذ الفعلي: الملف موجود في **HDFS** بحجم **607504** بايت (**593.3K**) في المسار
.bigdata/salah/input/salah.txt/

```
hadoop
fs -ls -R /bigdata/salah => input + input/salah.txt (607504)
```

```
hadoop
fs -du -h /bigdata/salah/input/salah.txt => 593.3 K
```




صورة 1: فحص الملف المحلي وفحص HDFS باسم Salah


(4) تشغيل WordCount بتقنية MapReduce

```
hadoop
jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount
/bigdata/salah/input /bigdata/salah/output
```

نتيجة التنفيذ الفعلي للمهمة **job_1790119089946_0003**: التقدم **map 0%** ثم **map 100%** ثم **map 100%**
reduce 100% ثم **Job completed successfully**. العدادات: **Map input records = 12306**، **Map output records = 107562**، **Bytes Written = 607504**، **Bytes Read = 15187**، **163591**.




صورة 2: بدء المهمة job_0003 والتقدم حتى النجاح



صورة 3: عدادات المهمة ونجاحها

(5) مراقبة المهمة عبر YARN

واجهة YARN على `quickstart.cloudera:8088` تعرض مهام **MAPREDUCE** بحالة **FINISHED** و**SUCCEEDED**، ومنها مهمة هذا المشروع `application_1790119089946_0003` باسم `word count`.




صورة 4: واجهة YARN تعرض المهام ناجحة

(6) استكشاف نتائج WordCount

مجلد الإخراج `bigdata/salah/output/` يحتوي ملف `_SUCCESS` (دليل نجاح المهمة) وملف `part-r-00000` (النتائج الفعلية بحجم 163591 بايت بتاريخ 2026-09-23 16:01).

```
hadoop
fs -ls /bigdata/salah/output => _SUCCESS (0) + part-r-00000
(163591)
```

```
hadoop
fs -cat /bigdata/salah/output/part-r-00000 | head -20
```




صورة 5: محتويات مجلد الإخراج وعينة النتائج


7 البحث عن الشخصيات والأماكن

نتائج **grep** الفعلية: **Holmes** الدقيقة 198 ومع مشتقات الترقيم (**Holmes**, بعدد 126 و**Holmes**. بعدد 78) الإجمالي نحو 461. و**Watson** الدقيقة 4 ومع المشتقات نحو 81. و**Sherlock** بعدد 96. و**Lestrade** بعدد 21 والإجمالي نحو 38. و**London** بعدد 20 والإجمالي نحو 41. الاستنتاج: **Holmes** يتصدر بفارق كبير عن **Watson**. وملاحظة الجودة: **WordCount** الخام لا يوحد الحالة ولا يزيل الترقيم، وهذا درس **Data Cleaning**.

الكلمة	الدقيقة	الإجمالي مع الترقيم
Holmes	198	~461
Watson	4	~81
Sherlock	96	~97
Lestrade	21	~38
London	20	~41



صورة 6: نتائج البحث عن Holmes و Watson و Sherlock



صورة 7: نتائج البحث عن London و Lestrade

(8) أعلى 20 كلمة واستخراج النتائج

الأعلى تكراراً هي كلمات وظيفية: **the** بعدد 5412 و **and** بعدد 2794 و **of** بعدد 2724 و **to** بعدد 2702 و **a** بعدد 2575 و **is** بعدد 2533، ثم **in** و **that** و **was** و **his** و **you** و **he** و **my** و **have** و **with** و **as** و **which**. ثم استخرجنا النتائج عبر **getmerge** إلى ملف محلي **salah_wordcount.txt** بحجم 160K بتاريخ 16:06.


#	الكلمة	التكرار
1	the	5412
2	and	2794
3	of	2724
4	to	2702
5	a	2575
6	I	2533
7	in	1706
8	that	1557
9	was	1361
10	his	1096
11	is	1073
12	you	1034
13	he	1014
14	it	977
15	my	901
16	have	894
17	with	843
18	had	807
19	as	776
20	which	753

hadoop

fs -cat /bigdata/salah/output/part-r-00000 | sort -k2 -nr | head -20

hadoop

fs -getmerge /bigdata/salah/output salah_wordcount.txt => 160K



صورة 8: أعلى 20 كلمة واستخراج النتائج

9 أجوبة الأسئلة السبعة

الأول: الأكثر تكرارا **the** و **and** و **of**. الثاني: **Holmes** نحو 461 و **Watson** نحو 81 و **Sherlock** نحو 97 و **Lestrade** نحو 38 و **London** نحو 41. الثالث: قائمة العشرين في القسم السابق. الرابع: ملف **Linux** نسخة مفردة على قرص واحد، وملف **HDFS** مقسم إلى **Blocks** وموزع مع **Replication**. الخامس: وظيفة **MapReduce** هي عد الكلمات عبر **Mapper** ثم **Shuffle** ثم **Reducer**. السادس: وظيفة **YARN** هي إدارة الموارد وتشغيل المهمة **application_1790119089946_0003** ومراقبتها. السابع: النتيجة النهائية في **bigdata/salah/output/part-r-00000** ونسخة محلية **salah_wordcount.txt**.

الكلمة	الدقيقة	الإجمالي مع الترتيم
Holmes	198	~461
Watson	4	~81
Sherlock	96	~97
Lestrade	21	~38
London	20	~41

(10) المطلوب تسليمه

تم تسليم: ملف **Dataset** وهو **salah.txt**، ومسار **HDFS** وهو **bigdata/salah/input/**، ومخرجات **MapReduce** وهي **bigdata/salah/output/**، وجدول الكلمات المطلوبة، ولقطات الشاشة وهي الصور الثماني داخل هذا التقرير، وملف النتائج **salah_wordcount.txt**، وهذا التحليل المختصر.

(11) سلامة العقدة

فحص **dfsadmin** أظهر عقدة حية واحدة بحالة **Normal** بسعة **54.51GB** وصفر **Blocks** تالفة أو مفقودة، وفحص **yarn** أظهر عقدة واحدة بحالة **RUNNING**، أي أن العقدة الوحيدة سليمة وتخدم **HDFS** و **YARN**.