

مشروع Hadoop و MapReduce

تحليل كتاب نصي باستخدام HDFS و MapReduce و YARN

الكتاب: The Adventures of Sherlock Holmes

المؤلف: Arthur Conan Doyle

المقرر: Big Data / Hadoop

البيئة: Cloudera QuickStart VM 5.13.0

صلاح محمد امين الشعبي

فهرس المحتويات

1. المقدمة والأهداف
2. وصف Dataset
3. بيئة التنفيذ
4. الخطوات التنفيذية والنتائج
5. الإجابة عن أسئلة المشروع
6. التحدي المتقدم — تحليل متعدد الكتب
7. المناقشة والخاتمة
8. المراجع
9. لقطات الشاشة من التنفيذ الحقيقي

1. المقدمة والأهداف

يهدف هذا المشروع إلى تطبيق دورة البيانات الكاملة داخل بيئة Hadoop: تحميل كتاب نصي حقيقي إلى Linux، فحصه، رفعه إلى نظام الملفات الموزع HDFS، ثم تشغيل برنامج WordCount باستخدام إطار العمل MapReduce لإحصاء تكرار الكلمات، مع متابعة المهمة عبر YARN، وأخيراً استخراج النتائج وتحليلها.

الهدف: إثبات الفهم العملي لعلاقة المكونات الثلاثة الأساسية:

المكوّن	السؤال الذي يجب عنه
---------	---------------------

أين نخزن البيانات؟	HDFS
كيف نعالج البيانات؟	MapReduce
كيف ندير موارد التشغيل؟	YARN

2. وصف Dataset

البيان	القيمة
اسم الكتاب	The Adventures of Sherlock Holmes
المؤلف	Arthur Conan Doyle
المصدر	Project Gutenberg - eBook #1661
اسم الملف	sherlock.txt
حجم الملف	KB (607,504 bytes) 594
عدد الأسطر	12,306
عدد الكلمات	107,562

ملاحظة: بسبب حجب نطاق www.gutenberg.org على شبكة الجامعة، تم التحميل عبر IP المباشر للموقع مع تمرير اسم النطاق في Header، وظهرت رسالة OK 200 بنجاح:

```
wget --no-check-certificate --header='Host: www.gutenberg.org' \
https://152.19.134.47/files/1661/1661-0.txt -O sherlock.txt
```

```
--2026-09-23 06:52:29-- https://152.19.134.47/files/1661/1661-0.txt
HTTP request sent, awaiting response... 200 OK
Length: 607504 (593K) [text/plain]
sherlock.txt saved [607504/607504]
```

3. بيئة التنفيذ

المكوّن	التفصيل
نظام التشغيل	Cloudera QuickStart VM Linux (CentOS 6) 5.13.0
Versión Hadoop	Hadoop 2.6.0-cdh5.13.0
Vmware	VMware Workstation 16.2
IP الآلة	(NAT) 192.168.96.130
اسم المضيف	quickstart.cloudera
المستخدم	Cloudera

3.1 التأكد من تشغيل خدمات Hadoop

```
ps aux | grep -E "NameNode|DataNode|ResourceManager|NodeManager" |
grep -v grep

hdfs 2835 ... org.apache.hadoop.hdfs.server.namenode.NameNode
hdfs 2887 ... org.apache.hadoop.hdfs.server.datanode.DataNode
hdfs 2972 ...
org.apache.hadoop.hdfs.server.namenode.SecondaryNameNode
```

4. الخطوات التنفيذية والنتائج

4.1 المرحلة الأولى: التحميل والفحص في Linux

```
$ ls -lh sherlock.txt
-rw-rw-r-- 1 cloudera cloudera 594K Oct 10 2023 sherlock.txt

$ head -20 sherlock.txt
The Project Gutenberg eBook of The Adventures of Sherlock Holmes,
by Arthur Conan Doyle
...

$ wc -l sherlock.txt
12306 sherlock.txt

$ wc -w sherlock.txt
107562 sherlock.txt
```

4.2 المرحلة الثانية: إنشاء مجلد HDFS والرفع

```
$ sudo -u hdfs hdfs dfs -mkdir -p /bigdata/sherlock/input
$ sudo -u hdfs hdfs dfs -chmod -R 777 /bigdata

$ hdfs dfs -put sherlock.txt /bigdata/sherlock/input/

$ hdfs dfs -ls -h /bigdata/sherlock/input/
-rw-r--r-- 1 cloudera supergroup 593.3 K ...
/bigdata/sherlock/input/sherlock.txt
```

4.3 المرحلة الثالثة: القراءة من HDFS

```
$ hdfs dfs -cat /bigdata/sherlock/input/sherlock.txt | head -10
The Project Gutenberg eBook of The Adventures of Sherlock Holmes,
by Arthur Conan Doyle
...

$ hdfs dfs -du -h /bigdata/sherlock/input
593.3 K 593.3 K /bigdata/sherlock/input/sherlock.txt
```

النسخة المحلية	/home/cloudera/sherlock.txt
نسخة HDFS	/bigdata/sherlock/input/sherlock.txt

4.4 المرحلة الرابعة: فحص Replication و Blocks

```
$ hdfs fsck /bigdata/sherlock/input/sherlock.txt -files -blocks

/bigdata/sherlock/input/sherlock.txt 607504 bytes, 1 block(s): OK
0. BP-333635372-127.0.0.1-1508779710286:blk_1073743332_2518
len=607504 Live_repl=1

Status: HEALTHY
Total blocks (validated): 1 (avg. block size 607504 B)
Corrupt blocks: 0
Missing replicas: 0 (0.0%)
Number of data-nodes: 1

$ hdfs dfs -stat %r /bigdata/sherlock/input/sherlock.txt
1
```

البيان	القيمة
عدد Blocks	1 (الملف أصغر من حجم Block الافتراضي 128MB)
Block ID	blk_1073743332_2518
Replication Factor	1 (عقدة واحدة في QuickStart)
الحالة	HEALTHY

4.5 المرحلة الخامسة: تشغيل WordCount (MapReduce)

```
$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
    wordcount /bigdata/sherlock/input /bigdata/sherlock/output

map 0% reduce 0%
map 67% reduce 0%
map 100% reduce 0%
map 100% reduce 71%
map 100% reduce 100%

Job job_1790183608540_0001 completed successfully
```

المؤشر	القيمة
Job ID	job_1790183608540_0001
Application ID	application_1790183608540_0001
Map input records	12,306 (عدد أسطر الكتاب)
Map output records	107,562 (عدد الكلمات)

15,187 (كلمة مميزة)	Reduce input groups
15,187	Reduce output records
0	Failed Shuffles
607,504 (حجم الكتاب بالضبط)	Input Bytes Read

4.6 المرحلة السادسة: متابعة المهمة عبر YARN

```
$ yarn application -list -appStates FINISHED
```

Application-Id	Name	Type	State
Final-State Progress			
application_1790183608540_0001	word count	MAPREDUCE	FINISHED
SUCCEEDED	100%		

4.7 المرحلة السابعة: قراءة النتائج

```
$ hdfs dfs -ls /bigdata/sherlock/output
-rw-r--r-- 1 cloudera supergroup 0 _SUCCESS
-rw-r--r-- 1 cloudera supergroup 163591 part-r-000000

$ hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | head -20
#1661] 1
$5,000) 1
& 5
&c, 1
...
```

SUCCESS انتهاء المهمة بنجاح.
ملف **part-r-000000** هو ملف النتائج الفعلية الذي أخرجه Reducer.

4.8 المرحلة الثامنة: البحث عن كلمات محددة

```
$ hdfs dfs -cat .../part-r-000000 | grep -w "Sherlock" → Sherlock
96
$ hdfs dfs -cat .../part-r-000000 | grep -w "Holmes" → Holmes
198
$ hdfs dfs -cat .../part-r-000000 | grep -w "Watson" → Watson
4
$ hdfs dfs -cat .../part-r-000000 | grep -w "London" → London
20
$ hdfs dfs -cat .../part-r-000000 | grep -w "Lestrade" → Lestrade
21
```

الترتيب	الكلمة	عدد مرات الظهور (كلمة كاملة)
1	Holmes	198
2	Sherlock	96
3	Lestrade	21
4	London	20
5	Watson	4

ملاحظة: تظهر أيضاً صور أخرى لكلمة Lestrade مع علامات ترقيم: (8) Lestrade, و (3) Lestrade. و (2) Lestrade! — المجموع الكلي 37 مرة.

ملاحظة مهمة: كلمة "Holmes" ظهرت أيضاً بأشكال أخرى مثل Holmes, (126 مرة) و Holmes. (78 مرة) و 'Holmes' (17 مرة) — لأن WordCount الجاهز لا يزيل علامات الترقيم، فيتوزع العد على عدة مدخلات. البحث بـ `grep -w` يعطي العدد الدقيق لكلمة كاملة فقط.

4.9 المرحلة التاسعة: أفضل 20 كلمة تكراراً

```
$ hdfs dfs -cat .../part-r-00000 | sort -k2 -nr | head -20
```

#	الكلمة	العدد
1	The	5412
2	And	2794
3	Of	2724

2702	To	4
2575	A	5
2533	I	6
1706	In	7
1557	That	8
1361	was	9
1096	his	10
1073	is	11
1034	you	12
1014	he	13
977	it	14
901	my	15
894	have	16

843	with	17
807	had	18
776	as	19
753	which	20

4.10 المرحلة العاشرة: استخراج النتائج إلى Linux

```
$ hdfs dfs -getmerge /bigdata/sherlock/output sherlock_wordcount.txt
$ ls -lh sherlock_wordcount.txt
-rw-r--r-- 1 cloudera cloudera 160K Sep 23 12:05
sherlock_wordcount.txt
$ wc -l sherlock_wordcount.txt
15187 sherlock_wordcount.txt
```

HDFS: /bigdata/sherlock/output/part-r-000000
النتيجة النهائية في
Linux:
/home/cloudera/sherlock_wordcount.txt

5. الإجابة عن أسئلة المشروع

س1: ما أكثر الكلمات تكراراً؟

الكلمة "the" بمقدار 5412 مرة، تليها "and" بـ 2794 و "of" بـ 2724.

س2: كم مرة ظهرت الكلمات المختارة؟

العدد	الكلمة
198	Holmes
96	Sherlock

21	Lestrade
20	London
4	Watson

الترتيب: Holmes أكثر بوضوح من Watson (198 مقابل 4). كلمة London ظهرت 20 مرة — وهذا منطقي لأن أحداث الكتاب تدور في لندن. كلمة Lestrade (المحقق) ظهرت 21 مرة، أكثر من Watson نفسه!

س3: ما الكلمات العشرة الأعلى تكراراً؟

انظر الجدول في القسم 4.9 — جميعها كلمات شائعة (stop words) مثل the, and, of, to لأن البرنامج يحسب كل الكلمات دون استثناء.

س4: ما الفرق بين ملف Linux وملف HDFS؟

ملف Linux موجود في نظام الملفات المحلي على الآلة الافتراضية، بينما ملف HDFS موجود في نظام Hadoop الموزع. الأمر put ينسخ من Linux إلى HDFS، والأمر getmerge يعيد النتائج من HDFS إلى Linux.

س5: ما وظيفة MapReduce؟

يعالج البيانات على مرحلتين: **Mapper** يحوّل كل كلمة إلى زوج (كلمة، 1)، ثم **Shuffle** يجمع القيم المتشابهة، ثم **Reducer** يجمعها ويخرج العدد النهائي لكل كلمة.

س6: ما وظيفة YARN؟

يدير موارد التشغيل وجدولة المهام وتتبع حالتها — لا يخزن البيانات ولا ينفذ خوارزمية العد. أظهر لنا أن المهمة application_1790183608540_0001 انتهت بحالة SUCCEEDED بنسبة 100%.

س7: أين توجد النتيجة النهائية؟

داخل HDFS: /bigdata/sherlock/output/part-r-000000 وبعد 160KB / 15187) getmerge: /home/cloudera/sherlock_wordcount.txt (سطر)

6. التحدي المتقدم – تحليل متعدد الكتب

لإثبات فائدة Hadoop مع تعدد الملفات، تم تنفيذ WordCount على كتابين مختلفين في نفس المهمة الواحدة:

الكتاب	الرابط	الحجم
Pride and Prejudice (#1342)	gutenberg.org/files/1342/1342-0.txt	721 KB
Alice's Adventures in Wonderland (#11)	gutenberg.org/files/11/11-0.txt	148 KB

6.1 الرفع إلى HDFS

```
$ hdfs dfs -put pride.txt alice.txt /bigdata/books/input/
$ hdfs dfs -ls -h /bigdata/books/input/
-rw-r--r-- 1 cloudera supergroup 721 K ... pride.txt
-rw-r--r-- 1 cloudera supergroup 148 K ... alice.txt
```

6.2 تشغيل WordCount على الملفين معاً

```
$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
    wordcount /bigdata/books/input /bigdata/books/output
Total input paths to process : 2
number of splits: 2
map 0% reduce 0%
map 67% reduce 0%
map 100% reduce 0%
map 100% reduce 100%
Job job_1790183608540_0002 completed successfully
```

المؤشر	قيمة كتاب واحد (Sherlock)	قيمة كتابين (Challenge)
Job ID	job_1790183608540_0001	job_1790183608540_0002

عدد Input Splits	1	2
Map input (أسطر)	12,306	17,921
Map output records (كلمات)	107,562	153,921
Reduce output records (كلمة مميزة)	15,187	17,115
Input Bytes Read	607,504	889,237
Output Bytes Written	163,591	190,149
Launched map tasks	1	2

ملاحظة مهمة: خوارزمية Hadoop أنتجت **2 map tasks** — واحد لكل ملف — ثم دمجت النتائج في Reducer واحد. هذا بالضبط فكرة المعالجة الموزعة: كل ملف يُعالج بالتوازي ثم تُدمج النتائج.

6.3 أفضل 20 كلمة عبر الكتابين معاً

\$ hdfs dfs -cat /bigdata/books/output/part-r-00000 sort -k2 -nr head -20			
#	الكلمة	العدد (كتابين)	العدد (Sherlock فقط)
1	The	5855	5412

2702	4909	To	2
2724	4281	Of	3
2794	4093	And	4
2575	2576	A	5
1706	2211	In	6
1361	2141	was	7
—	2109	her	8
2533	2013	I	9
—	1826	she	10

6.4 استخراج النتائج

```
$ hdfs dfs -getmerge /bigdata/books/output books_wordcount.txt
$ ls -lh books_wordcount.txt
-rw-r--r-- 1 cloudera cloudera 186K Sep 24 00:36 books_wordcount.txt
```

لماذا Hadoop

1. كل ملف يُعالج في Map task مستقل بالتوازي.
2. يُكفي أمر واحد wordcount لمعالجة أي عدد من الملفات.
3. لو زادت الكتب إلى 1000 كتاب، يوزع Hadoop العمل على عدة عقد تلقائياً.

7. المناقشة

أظهرت النتائج أن كلمة "the" تتكرر 5412 مرة في كتاب شيرلوك أي حوالي 5% من إجمالي الكلمات (107562) — وهذا متسق مع النصوص الإنجليزية حيث تشكل الكلمات الشائعة النسبة الأكبر.

لاحظنا أن كلمة "Holmes" ككلمة كاملة ظهرت 198 مرة، لكن مع إضافة علامات الترقيم (Holmes, = 126, Holmes. = 78, Holmes' = 17) يصل المجموع إلى أكثر من 400. هذا يوضح قيد WordCount الجاهز في عدم تنظيف النص تلقائياً (Data Cleaning).

عند إضافة كتاب Pride and Prejudice، ارتفعت كلمة "to" من 2702 إلى 4909 — لاحظنا زيادة بنسبة 82% لأن لغة أوستن تعتمد أكثر على حروف الجر. بينما كلمة "I" قلت نسبياً بسبب انتقال التوازن اللغوي بين الكتابين.

التحدي المتقدم أثبت أن Hadoop يعالج ملفات متعددة بأمر واحد، وأن الـ Map tasks تُوزَّع تلقائياً حسب عدد الملفات — وهذا جوهر المعالجة الموزعة.

8. الخاتمة

نجح المشروع في تطبيق دورة البيانات الكاملة: من التحميل في Linux، إلى الفحص والتخزين في HDFS، إلى المعالجة بـ MapReduce، إلى إدارة الموارد بـ YARN، وصولاً إلى استخراج النتائج وتحليلها. أثبت المشروع فهم العلاقة بين المكونات الثلاثة الأساسية في Hadoop وتطبيقها عملياً على نص حقيقي من Project Gutenberg. وأكمل التحدي المتقدم بمعالجة كتابين في مهمة واحدة، مبرهنًا فائدة Hadoop مع تعدد الملفات.

9. لقطات الشاشة من التنفيذ الحقيقي

لقطة 1: فحص الكتاب في Linux (wc / head / tail)

```
File Edit View Search Terminal Help
12306 sherlock.txt
[cloudera@quickstart ~]$ wc -w sherlock.txt
107562 sherlock.txt
[cloudera@quickstart ~]$ head -20 sherlock.txt
The Project Gutenberg eBook of The Adventures of Sherlock Holmes,
by Arthur Conan Doyle

This eBook is for the use of anyone anywhere in the United States and
most other parts of the world at no cost and with almost no restrictions
whatsoever. You may copy it, give it away or re-use it under the terms
of the Project Gutenberg License included with this eBook or online at
www.gutenberg.org. If you are not located in the United States, you
will have to check the laws of the country where you are located before
using this eBook.

Title: The Adventures of Sherlock Holmes

Author: Arthur Conan Doyle

Release Date: November 29, 2002 [eBook #1661]
[Most recently updated: October 10, 2023]

Language: English

[cloudera@quickstart ~]$ tail -20 sherlock.txt
Gutenberg™ concept of a library of electronic works that could be
freely shared with anyone. For forty years, he produced and
distributed Project Gutenberg™ eBooks with only a loose network of
volunteer support.

Project Gutenberg™ eBooks are often created from several printed
editions, all of which are confirmed as not protected by copyright in
the U.S. unless a copyright notice is included. Thus, we do not
necessarily keep eBooks in compliance with any particular paper
edition.


Most people start at our website which has the main PG search
facility: www.gutenberg.org.

This website includes information about Project Gutenberg™,
including how to make donations to the Project Gutenberg Literary
Archive Foundation, how to help produce our new eBooks, and how to
subscribe to our email newsletter to hear about new eBooks.

[cloudera@quickstart ~]$ █
```

شكل 1: أوامر wc -l (12306 سطر) و wc -w (107562 كلمة) و head -20 و tail -20 على ملف sherlock.txt

لقطة 2: البيانات داخل HDFS + القراءة + فحص Blocks



```
و hdfs dfs -du -h و hdfs dfs -cat | head و hdfs dfs -ls -h (593.3K) : شكل 2
blk_1073743332_2518, واحد HEALTHY, Block الحالة — hdfs fsck -files -blocks
Live repl=1
```

لقطة 3: نتائج WordCount وملفات الإخراج

All Applications

192.168.96.130:8088/cluster

Hue

Hadoop

HBase

Impala

Spark

Solr

Oozie

Cloudera Manager

Getting Started

All Applications

Cluster

About

Nodes

Applications

NEW

NEW_SAVING

SUBMITTED

ACCEPTED

RUNNING

FINISHED

FAILED

KILLED

Scheduler

Tools

Cluster Metrics

Apps Submitted	Apps Pending	Apps Running	Apps Completed	Containers Running	Memory Used	Memory Total	Memory Reserved	VCores
1	0	0	1	0	0 B	3 GB	0 B	0

Cluster Nodes Metrics

Active Nodes	Decommissioning Nodes	Decommissioned Nodes	Lost Nodes	Unhealthy Nodes
1	0	0	0	0

User Metrics for dr.who

Apps Submitted	Apps Pending	Apps Running	Apps Completed	Containers Running	Containers Pending	Containers Reserved	Memory Used	Memory Pending	Memory Reserved
0	0	0	0	0	0	0	0 B	0 B	0 B

Show 20 entries

ID	User	Name	Application Type	Queue	StartTime	FinishTime	State	FinalStatus	Running Containers	Allocated CPU VCoers	Allocated Memory MB
application_1790183608540_0001	cloudera	word count	MAPREDUCE	root.users.cloudera	Wed Sep 23 10:25:07 -0700 2026	Wed Sep 23 10:29:59 -0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A

Showing 1 to 1 of 1 entries

شكل 3: قراءة r-00000 part والبحث بـ grep -w عن Sherlock (96) و Holmes (198) و Watson (4) مع صور الترقيم

لقطه 4: البحث عن كلمات إضافية


```

application_1790183608540_0001 word count MAPREDUCE
cloudera root.users.cloudera FINISHED SUCCEED
ED 100% http://quickstart.cloudera:19888/jobhistory/job/job_1790
183608540_0001
[cloudera@quickstart ~]$ application_1790183608540_0001 | word count | MAPREDUCE | FINISHED | SUCCEED | 100%
bash: FINISHED: command not found
bash: SUCCEED: command not found
bash: 100%: command not found
bash: MAPREDUCE: command not found
bash: word: command not found
bash: application_1790183608540_0001: command not found
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/sherlock/output
Found 2 items
-rw-r--r-- 1 cloudera supergroup 0 2026-09-23 10:29 /bigdata/sherlock/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup 163591 2026-09-23 10:29 /bigdata/sherlock/output/part-r-00000
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | head -20
#1661] 1
$5,000) 1
& 5
&c, 1
&c. 1
($1 1
(3rd 1
(801) 1
(a) 1
(and 1
(any 1
(b) 1
(c) 1
(does 1
(for 1
(if 1
(now 1
(or 3
(the 1
(trademark/copyright) 1
cat: Unable to write to output stream.
[cloudera@quickstart ~]$

```

شكل 4: متابعة نتائج grep والبحث عن كلمات أخرى داخل مخرجات Hadoop

لقطة 5: حالة المهمة عبر YARN من التيرمينال



```
[cloudera@quickstart ~]$ yarn application -list -appStates FINISHED
26/09/23 10:46:39 INFO client.RMPProxy: Connecting to ResourceManager at quicksta
rt.cloudera/192.168.96.130:8032
Total number of applications (application-types: [] and states: [FINISHED]):1
  User      Application-Id  Application-Name  Application-Type  State  Final-State
  Progress
application_1790183608540_0001  word count  MAPREDUCE
cloudera      root.users.cloudera  FINISHED  SUCCEED
ED          100% http://quickstart.cloudera:19888/jobhistory/job/job_1790
183608540_0001
[cloudera@quickstart ~]$
```

شكل 5: yarn application -list -appStates FINISHED — المهمة
application_1790183608540_0001 بحالة FINISHED / SUCCEED بنسبة 100%

لقطه 6: واجهة YARN عبر المتصفح

```
cloudera@quickstart:~$
Search Terminal Help
HDFS: Number of write operations=2
Map Input Records=12306
Launched map tasks=1
Launched reduce tasks=1
Data-local map tasks=1
Total time spent by all maps in occupied slots (ms)=39443968
Total time spent by all reduces in occupied slots (ms)=35254272
Total time spent by all map tasks (ms)=77039
Total time spent by all reduce tasks (ms)=68856
Total vcore-milliseconds taken by all map tasks=77039
Total vcore-milliseconds taken by all reduce tasks=68856
Total megabyte-milliseconds taken by all map tasks=39443968
Total megabyte-milliseconds taken by all reduce tasks=35254272
Map Output Records=107562
Map output bytes=1022331
Map output materialized bytes=113067
Input split bytes=132
Combine input records=107562
Combine output records=15187
Reduce input groups=15187
Reduce shuffle bytes=113067
Reduce input records=15187
Reduce output records=15187
Spilled Records=30374
Shuffled Maps =1
Failed Shuffles=0
Merged Map outputs=1
GC time elapsed (ms)=2043
CPU time spent (ms)=9480
Physical memory (bytes) snapshot=265453568
Virtual memory (bytes) snapshot=1409044480
Total committed heap usage (bytes)=101449728
Map Errors
BAD_ID=0
CONNECTION=0
IO_ERROR=0
WRONG_LENGTH=0
WRONG_MAP=0
WRONG_REDUCE=0
Map Input Format Counters
Bytes Read=607504
Map Output Format Counters
Bytes Written=163591
cloudera@quickstart:~$
```

شكل 6: واجهة YARN على http://192.168.96.130:8088 — تطبيق word count من نوع
MAPREDUCE بحالة FINISHED و FinalStatus SUCCEEDED

لقطة 7: التأكد من تشغيل خدمات Hadoop

```
File Edit View Search Terminal Help
oop/./usr/lib/hadoop-hdfs/./usr/lib/hadoop-hdfs/lib/./usr/lib/hadoop-hdfs
./usr/lib/hadoop-yarn/lib/./usr/lib/hadoop-yarn/./usr/lib/hadoop-mapr
duce/lib/./usr/lib/hadoop-mapreduce/./usr/share/cmf/lib/plugins/tt-instru
mentation-5.13.0.jar:/usr/share/cmf/lib/plugins/event-publish-5.13.0-shaded.jar:/u
sr/lib/hadoop-yarn/./usr/lib/hadoop-yarn/lib/./var/run/cloudera-scm-agent/p
rocess/63-yarn-NODEMANAGER/nm-config/log4j.properties org.apache.hadoop.yarn.ser
ver.nodemanager.NodeManager
yarn 3534 1.7 2.1 832496 171668 ? Sl 10:50 1:07 /usr/java/jdk1.
7.0_67-cloudera/bin/java -Dproc_resourcemanager -Xmx1000m -Djava.net.preferIPv4S
tack=true -Xms52428800 -Xmx52428800 -XX:+UseParNewGC -XX:+UseConcMarkSweepGC -XX
:CMSInitiatingOccupancyFraction=70 -XX:+CMSParallelRemarkEnabled -Dlibrary.level
objni.path=/var/run/cloudera-scm-agent/process/64-yarn-RESOURCEMANAGER -Dhadoop.
event.appenders=EventCatcher -XX:+HeapDumpOnOutOfMemoryError -XX:HeapDumpPath=/t
mp/yarn yarn-RESOURCEMANAGER_pid3534.hprof -XX:OnOutOfMemoryError=/usr/lib64/cmf
/service/common/killparent.sh -Djute.maxbuffer=4194304 -Dhadoop.log.dir=/var/log
/hadoop-yarn -Dyarn.log.dir=/var/log/hadoop-yarn -Dhadoop.log.file=hadoop-cmf-ya
rn-RESOURCEMANAGER-quickstart.cloudera.log.out -Dyarn.log.file=hadoop-cmf-yarn-R
ESOURCEMANAGER-quickstart.cloudera.log.out -Dyarn.home.dir=/usr/lib/hadoop-yarn
-Dhadoop.home.dir=/usr/lib/hadoop-yarn -Dhadoop.root.logger=INFO,RFA -Dyarn.root
.logger=INFO,RFA -Djava.library.path=/usr/lib/hadoop/lib/native -classpath /var
/run/cloudera-scm-agent/process/64-yarn-RESOURCEMANAGER:/var/run/cloudera-scm-age
nt/process/64-yarn-RESOURCEMANAGER:/var/run/cloudera-scm-agent/process/64-yarn-R
ESOURCEMANAGER:/usr/lib/hadoop/lib/./usr/lib/hadoop/./usr/lib/hadoop-hdfs/.
/./usr/lib/hadoop-hdfs/lib/./usr/lib/hadoop-hdfs/./usr/lib/hadoop-yarn/lib/
./usr/lib/hadoop-yarn/./usr/lib/hadoop-mapreduce/lib/./usr/lib/hadoop-mapr
educe/./usr/share/cmf/lib/plugins/tt-instrumentation-5.13.0.jar:/usr/share/c
mf/lib/plugins/event-publish-5.13.0-shaded.jar:/usr/lib/hadoop-yarn/./usr/li
b/hadoop-yarn/lib/./var/run/cloudera-scm-agent/process/64-yarn-RESOURCEMANAGER/
rm-config/log4j.properties org.apache.hadoop.yarn.server.resourcemanager.Resourc
eManager
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ wget --no-check-certificate --header='Host: www.gutenberg.org' https://152.19.134.47/files/11/11-0.txt -O alice.txt
--2026-09-22 11:57:06-- https://152.19.134.47/files/11/11-0.txt
Connecting to 152.19.134.47:443... connected.
WARNING: certificate common name "*.gutenberg.org" doesn't match requested host name "152.19.134.47".
HTTP request sent, awaiting response... 200 OK
Length: 151191 (148K) [text/plain]
Saving to: "alice.txt"

100%[=====] 151,191 45.0K/s in 3.3s

2026-09-22 11:57:12 (45.0 KB/s) - "alice.txt" saved [151191/151191]

[cloudera@quickstart ~]$
```

شكل 7: ps aux يبين عمليات ResourceManager و NodeManager، ثم تحميل كتاب Alice من Gutenberg بـ (200 OK) wget

لقطة 8: فحص كتاب Alice قبل الرفع

```
File Edit View Search Terminal Help

[cloudera@quickstart ~]$ ls -lh alice.txt
-rw-r--r-- 1 cloudera cloudera 148K Jun 26 2025 alice.txt
[cloudera@quickstart ~]$ head -20 alice.txt
*** START OF THE PROJECT GUTENBERG EBOOK 11 ***

[Illustration]

Alice's Adventures in Wonderland

by Lewis Carroll

THE MILLENNIUM FULCRUM EDITION 3.0

Contents

CHAPTER I.    Down the Rabbit-Hole
CHAPTER II.   The Pool of Tears
CHAPTER III.  A Caucus-Race and a Long Tale
CHAPTER IV.   The Rabbit Sends in a Little Bill
CHAPTER V.    Advice from a Caterpillar
[cloudera@quickstart ~]$ tail -20 alice.txt
teacups would change to tinkling sheep-bells, and the Queen's shrill
cries to the voice of the shepherd boy-and the sneeze of the baby, the
shriek of the Gryphon, and all the other queer noises, would change
(she knew) to the confused clamour of the busy farm-yard-while the
lowing of the cattle in the distance would take the place of the Mock
Turtle's heavy sobs.

Lastly, she pictured to herself how this same little sister of hers
would, in the after-time, be herself a grown woman; and how she would
keep, through all her riper years, the simple and loving heart of her
childhood: and how she would gather about her other little children,
and make their eyes bright and eager with many a strange tale,
perhaps even with the dream of Wonderland of long ago: and how she
would feel with all their simple sorrows, and find a pleasure in all
their simple joys, remembering her own child-life, and the happy summer
days.

THE END

*** END OF THE PROJECT GUTENBERG EBOOK 11 ***
[cloudera@quickstart ~]$
```

شكل 8: ls -lh و head -20 و tail -20 على alice.txt (148K) — بداية ونهاية الكتاب

لقطة 9: تحميل Pride and Prejudice ورفعها لـ HDFS

```
cloudera@quickstart:~  
File Edit View Search Terminal Help  
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/sherlock/input/  
Found 1 items  
-rw-r--r-- 1 cloudera supergroup 593.3 K 2026-09-23 07:03 /bigdata/sherlock/input/sherlock.txt  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/input/sherlock.txt | head -10  
The Project Gutenberg eBook of The Adventures of Sherlock Holmes,  
by Arthur Conan Doyle  
  
This eBook is for the use of anyone anywhere in the United States and  
most other parts of the world at no cost and with almost no restrictions  
whatsoever. You may copy it, give it away or re-use it under the terms  
of the Project Gutenberg License included with this eBook or online at  
www.gutenberg.org. If you are not located in the United States, you  
will have to check the laws of the country where you are located before  
using this eBook.  
cat: Unable to write to output stream.  
[cloudera@quickstart ~]$ hdfs dfs -du -h /bigdata/sherlock/input  
593.3 K 593.3 K /bigdata/sherlock/input/sherlock.txt  
[cloudera@quickstart ~]$ hdfs fsck /bigdata/sherlock/input/sherlock.txt -files -blocks  
Connecting to namenode via http://quickstart.cloudera:50070/fscck?ugi=cloudera&files=1&blocks=1&path=%2Fbigdata%2Fsherlock%2Finput%2Fsherlock.txt  
FSCK started by cloudera (auth:SIMPLE) from /192.168.96.130 for path /bigdata/sherlock/input/sherlock.txt at Wed Sep 23 07:09:36 PDT 2026  
/bigdata/sherlock/input/sherlock.txt 607504 bytes, 1 block(s): OK  
0. BP-333635372-127.0.0.1-1508779710286:blk_1073743332_2518 len=607504 Live_repl=1  
  
Status: HEALTHY  
Total size: 607504 B  
Total dirs: 0  
Total files: 1  
Total symlinks: 0  
Total blocks (validated): 1 (avg. block size 607504 B)  
Minimally replicated blocks: 1 (100.0 %)  
Over-replicated blocks: 0 (0.0 %)  
Under-replicated blocks: 0 (0.0 %)  
Mis-replicated blocks: 0 (0.0 %)  
Default replication factor: 1  
Average block replication: 1.0  
Corrupt blocks: 0  
Missing replicas: 0 (0.0 %)  
Number of data-nodes: 1  
Number of racks: 1  
FSCK ended at Wed Sep 23 07:09:36 PDT 2026 in 25 milliseconds  
  
The filesystem under path '/bigdata/sherlock/input/sherlock.txt' is HEALTHY  
[cloudera@quickstart ~]$ hdfs dfs -rm -r -skipTrash /bigdata/sherlock/output  
rm: '/bigdata/sherlock/output': No such file or directory  
[cloudera@quickstart ~]$
```

شكل 9: تحميل pride.txt (721K) بـ wget، ثم إنشاء bigdata/books/input و رفع الكتابين
hdfs dfs -put

لقطة 10: تشغيل WordCount على الكتابين

ware

```
File Edit View Search Terminal Help
& 5
&c, 1
&c. 1
($1 1
(3rd 1
(801) 1
(a) 1
(and 1
(any 1
(b) 1
(c) 1
(does 1
(for 1
(if 1
(now 1
(or 3
(the 1
(trademark/copyright) 1
cat: Unable to write to output stream.
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Sherlock"
Sherlock 96
"Sherlock 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Holmes"
Holmes 198
Holmes! 1
Holmes!" 4
Holmes, 126
Holmes," 11
Holmes. 78
Holmes.'" 1
Holmes." 5
Holmes; 7
Holmes? 1
Holmes?" 4
Holmes-a 1
Holmes' 17
"Holmes!" 1
"Holmes, 2
"Holmes," 4
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Watson"
Watson 4
Watson, 40
Watson," 19
Watson. 10
Watson? 1
Watson?" 6
```

شكل 10: hadoop jar ... wordcount /bigdata/books/input :10
/bigdata/books/output — المهمة job_1790183608540_0002، تقدم Map حتى 100%

لقطة 11: عدّادات المهمة — كتاب واحد

```
HDFS: Number of write operations=2
Job Counters
  Launched map tasks=2
  Launched reduce tasks=1
  Data-local map tasks=2
  Total time spent by all maps in occupied slots (ms)=84571136
  Total time spent by all reduces in occupied slots (ms)=16956416
  Total time spent by all map tasks (ms)=165178
  Total time spent by all reduce tasks (ms)=33118
  Total vcore-milliseconds taken by all map tasks=165178
  Total vcore-milliseconds taken by all reduce tasks=33118
  Total megabyte-milliseconds taken by all map tasks=84571136
  Total megabyte-milliseconds taken by all reduce tasks=16956416
Map-Reduce Framework
  Map input records=17921
  Map output records=153921
  Map output bytes=1493165
  Map output materialized bytes=142813
  Input split bytes=252
  Combine input records=153921
  Combine output records=19431
  Reduce input groups=17115
  Reduce shuffle bytes=142813
  Reduce input records=19431
  Reduce output records=17115
  Spilled Records=38862
  Shuffled Maps =2
  Failed Shuffles=0
  Merged Map outputs=2
  GC time elapsed (ms)=2995
  CPU time spent (ms)=14190
  Physical memory (bytes) snapshot=393179136
  Virtual memory (bytes) snapshot=2107514880
  Total committed heap usage (bytes)=152174592
Shuffle Errors
  BAD_ID=0
  CONNECTION=0
  IO_ERROR=0
  WRONG_LENGTH=0
  WRONG_MAP=0
  WRONG_REDUCE=0
File Input Format Counters
  Bytes Read=889237
File Output Format Counters
  Bytes Written=190149
jdera@quickstart ~]$
```

Home - Cloudera Man... cloudera@quickstart:~ All Applications - Mozil...

شكل 11: عِدّادات مهمة Map input records=12306, Reduce output records=15187, Bytes Read=607504

لقطة 12: عِدّادات المهمة — كتابان (التحدي المتقدم)

```
at org.apache.hadoop.ts.FSNeLL.main(FSNeLL.java:3/2)
chmod: No Route to Host from quickstart.cloudera/192.168.96.130 to quickstart.cloudera:8020 failed on socket timeout exception: java.net.NoRouteToHostException: No route to host; For more details see: http://wiki.apache.org/hadoop/NoRouteToHost
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ wget --no-check-certificate --header='Host: www.gutenberg.org' \
> https://152.19.134.47/files/1342/1342-0.txt -O pride.txt
--2026-09-24 00:23:13-- https://152.19.134.47/files/1342/1342-0.txt
Connecting to 152.19.134.47:443... connected.
WARNING: certificate common name "*.gutenberg.org" doesn't match requested host name "152.19.134.47".
HTTP request sent, awaiting response... 200 OK
Length: 738046 (721K) [text/plain]
Saving to: "pride.txt"

100%[=====] 738,046 472K/s in 1.5s

2026-09-24 00:23:15 (472 KB/s) - "pride.txt" saved [738046/738046]

[cloudera@quickstart ~]$ wget --no-check-certificate --header='Host: www.gutenberg.org' \
> https://152.19.134.47/files/1342/1342-0.txt -O pride.txt
--2026-09-24 00:23:41-- https://152.19.134.47/files/1342/1342-0.txt
Connecting to 152.19.134.47:443... connected.
WARNING: certificate common name "*.gutenberg.org" doesn't match requested host name "152.19.134.47".
HTTP request sent, awaiting response... 200 OK
Length: 738046 (721K) [text/plain]
Saving to: "pride.txt"

100%[=====] 738,046 385K/s in 1.9s

2026-09-24 00:23:44 (385 KB/s) - "pride.txt" saved [738046/738046]

[cloudera@quickstart ~]$ ls -lh pride.txt alice.txt
-rw-r--r-- 1 cloudera cloudera 148K Jun 26 2025 alice.txt
-rwxrwx-rw- 1 cloudera cloudera 721K Sep 1 16:50 pride.txt
[cloudera@quickstart ~]$ sudo -u hdfs hdfs dfs -mkdir -p /bigdata/books/input
[cloudera@quickstart ~]$ sudo -u hdfs hdfs dfs -chmod -R 777 /bigdata
[cloudera@quickstart ~]$ hdfs dfs -put pride.txt alice.txt /bigdata/books/input/
[cloudera@quickstart ~]$ hdfs dfs -put pride.txt alice.txt /bigdata/books/input/
put: '/bigdata/books/input/pride.txt': File exists
put: '/bigdata/books/input/alice.txt': File exists
[cloudera@quickstart ~]$ # 4. معب عم زعمالعللأ ولع WordCount لوعفب
[cloudera@quickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
> wordcount /bigdata/books/input /bigdata/books/output
```

شكل 12: عدادات مهمة الكتابين — Launched map tasks=2 (واحد لكل ملف)، Map input records=17921, Reduce output records=17115, Bytes Read=889237

لقطة 13: تنفيذ التحدي المتقدم كاملاً

```

Saving to: "pride.txt"

100%[=====]

2026-09-24 00:23:44 (385 KB/s) - "pride.txt" saved [738046/738046]

[cloudera@quickstart ~]$ ls -lh pride.txt alice.txt
-rw-r--r-- 1 cloudera cloudera 148K Jun 26  2025 alice.txt
-rwxrw-rw- 1 cloudera cloudera 721K Sep  1 16:50 pride.txt
[cloudera@quickstart ~]$ sudo -u hdfs hdfs dfs -mkdir -p /bigdata/books/input
[cloudera@quickstart ~]$ sudo -u hdfs hdfs dfs -chmod -R 777 /bigdata
[cloudera@quickstart ~]$ hdfs dfs -put pride.txt alice.txt /bigdata/books/input/
[cloudera@quickstart ~]$ hdfs dfs -put pride.txt alice.txt /bigdata/books/input/
put: `/bigdata/books/input/pride.txt': File exists
put: `/bigdata/books/input/alice.txt': File exists
[cloudera@quickstart ~]$ # 4. وضع عم نوبانكلا قلع WordCount ليعغشيت
[cloudera@quickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
> wordcount /bigdata/books/input /bigdata/books/output
26/09/24 00:28:46 INFO client.RMProxy: Connecting to ResourceManager at quickstart.cloudera/192.168.96.130:8032
26/09/24 00:28:49 INFO input.FileInputFormat: Total input paths to process : 2
26/09/24 00:28:49 INFO mapreduce.JobSubmitter: number of splits:2
26/09/24 00:28:51 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1790183608540_0002
26/09/24 00:28:54 INFO impl.YarnClientImpl: Submitted application application_1790183608540_0002
26/09/24 00:28:54 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/application_1790183608540_000
26/09/24 00:28:54 INFO mapreduce.Job: Running job: job_1790183608540_0002
26/09/24 00:29:36 INFO mapreduce.Job: Job job_1790183608540_0002 running in uber mode : false
26/09/24 00:29:36 INFO mapreduce.Job:  map 0% reduce 0%
26/09/24 00:30:53 INFO mapreduce.Job:  map 67% reduce 0%
26/09/24 00:30:58 INFO mapreduce.Job:  map 83% reduce 0%
26/09/24 00:31:02 INFO mapreduce.Job:  map 100% reduce 0%

```

شكل 13: تسلسل التنفيذ الكامل — put, mkdir, ls, wget, ثم hadoop jar wordcount على مجلد الكتب