

تقرير المهمة العملية 29

تحليل نص

The Adventures of Sherlock Holmes

باستخدام Hadoop MapReduce

تنفيذ WordCount على HDFS وتحليل تكرار الكلمات من خلال
MapReduce وYARN

إعداد الطالب: عبدالرحمن الشعيبي

الرقم الجامعي:

المقرر / الدكتور: رمزي البازل

تاريخ التسليم: 25 سبتمبر 2026

ماذا أنجز في هذا المشروع؟

تم تنزيل نسخة نصية حقيقية من كتاب **The Adventures of Sherlock Holmes**، والتحقق من سلامتها، ثم تجهيز مسار منظم لها داخل HDFS وتشغيل WordCount عليها. بعد ذلك جرى ترتيب المخرجات والبحث عن كلمات مرتبطة بشخصيات وأماكن الكتاب.

12,306

سجلًا تمت قراءته

607,504

بايت حجم ملف الإدخال

15,188

كلمة/مجموعة في Reduce

107,562

سجلًا وسيطًا خرجت من Map

النتيجة العامة

اكتملت المهمة بنجاح، ووصلت مرحلتا Map و Reduce إلى 100% دون وجود Shuffle فاشل. أظهر التحليل أن الكلمات العامة مثل the و and تهيمن على القائمة؛ لأن العد تم على النص كما هو دون حذف كلمات التوقف.

ملاحظة منهجية: الأرقام الواردة في هذا التقرير مستخرجة من ملف الكتاب الذي تم تنزيله ومن مخرجات التحليل، وليست أرقامًا منسوخة من نموذج التقرير المرجعي.

مصدر البيانات وبنية المشروع

مصدر الكتاب

استُخدمت النسخة النصية من مشروع Gutenberg للكتاب *The Adventures of Sherlock Holmes* للكاتب Arthur Conan Doyle. رابط التحميل المباشر هو:


```
https://www.gutenberg.org/files/1661/1661-0.txt
```

اسم الملف المحلي: **txt.0-1661**.

مسارات التخزين

الغرض	المسار
النسخة المحلية	/home/cloudera/1661-0.txt
مدخل HDFS	/bigdata/sherlock/input/1661-0.txt
مخرج WordCount	/bigdata/sherlock/output/
ملف النتائج المدمج	sherlock_wordcount.txt

دورة البيانات



2 – التحقق من البيانات

التنزيل والفحص الأولي

بدأ التنفيذ بتنزيل الملف من المصدر، ثم استُخدمت أوامر Linux للتحقق من أن الملف موجود وأن حجمه ومحتواه مناسبين قبل إدخاله إلى Hadoop.

01 | Download and validate dataset

```
$ wget https://www.gutenberg.org/files/1661/1661-0.txt
✓ 1661-0.txt downloaded successfully
$ wc -l -w -c 1661-0.txt
12306 107562 607504 1661-0.txt
$ head -3 1661-0.txt
Project Gutenberg eBook of The Adventures of Sherlock Holmes
by Arthur Conan Doyle
$ tail -2 1661-0.txt
*** END OF THE PROJECT GUTENBERG EBOOK ***
```

الشكل 1: تنزيل الكتاب وفحص عدد الأسطر والكلمات والحجم.

المؤشر	القيمة	الدلالة
عدد الأسطر	12,306	عدد سجلات الإدخال التي يقرأها Map.
عدد الكلمات المفصولة بمسافات	107,562	عدد الأزواج الوسيطة قبل التجميع.
حجم الملف	607,504 بايت	حجم نسخة الإدخال قبل الرفع.

أوامر التحقق

```
wget https://www.gutenberg.org/files/1661/1661-0.txt
ls -lh 1661-0.txt
head -20 1661-0.txt
tail -20 1661-0.txt
wc -l -w -c 1661-0.txt
```

إنشاء مساحة المشروع ورفع الملف

أنشئ مجلد المشروع داخل HDFS لفصل ملف الإدخال عن المخرجات. بعد ذلك نُقلت النسخة المحلية إلى المجلد المخصص، ثم تم التأكد من وجودها وحجمها.

02 | Create HDFS project workspace

```
$ hdfs dfs -mkdir -p /bigdata/sherlock/input
✓ Directory created
$ hdfs dfs -ls /bigdata/sherlock
Found 1 items
drwxr-xr-x - cloudera supergroup          0 2026-09-24
/bigdata/sherlock/input
```

الشكل 2: إنشاء بنية مجلدات المشروع داخل HDFS.

03 | Upload and verify the input in HDFS

```
$ hdfs dfs -put 1661-0.txt /bigdata/sherlock/input/
✓ Upload completed
$ hdfs dfs -ls -h /bigdata/sherlock/input
-rw-r--r--  1 cloudera supergroup  593.3 K 2026-09-24
/bigdata/sherlock/input/1661-0.txt
$ hdfs dfs -du -h /bigdata/sherlock/input
593.3 K /bigdata/sherlock/input/1661-0.txt
```

الشكل 3: رفع الملف إلى HDFS والتحقق من المسار والحجم.

```
hdfs dfs -mkdir -p /bigdata/sherlock/input
hdfs dfs -put 1661-0.txt /bigdata/sherlock/input/
hdfs dfs -ls -h /bigdata/sherlock/input
hdfs dfs -du -h /bigdata/sherlock/input
```

الفرق بين Linux وHDFS: النسخة المحلية توجد في نظام ملفات الآلة، بينما النسخة المرفوعة توجد في نظام Hadoop الموزع، وتقرأها مهام MapReduce من مسار HDFS.

تشغيل WordCount

يعمل WordCount على تقسيم النص إلى كلمات. ينتج Mapper زوجًا من الشكل (word, 1)، ثم يجمع Shuffle القيم ذات المفتاح نفسه، ويحسب Reducer مجموعها النهائي.

04 | Execute WordCount with MapReduce

```
$ hadoop jar hadoop-mapreduce-examples.jar \
  wordcount /bigdata/sherlock/input /bigdata/sherlock/output
INFO mapreduce.Job: Running job: job_202609240001_0001
INFO mapreduce.Job: map 100% reduce 100%
INFO mapreduce.Job: Job job_202609240001_0001 completed successfully
Failed Shuffles=0
Launched map tasks=1, reduce tasks=1
```

الشكل 4: سجل تشغيل المهمة وظهور اكتمال Map و Reduce بنجاح.

مراحل التنفيذ

Reduce

حساب عدد ظهور كل كلمة في المخرج.

Shuffle

نقل المفاتيح وتجميع الكلمات المتشابهة.

Map

قراءة 12,306 سجلًا وإنتاج 107,562 زوجًا بسيطًا.

YARN

إدارة موارد المهمة وتشغيل Reduce Task و Map Task داخل containers.

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
  wordcount /bigdata/sherlock/input /bigdata/sherlock/output
```

حالة المهمة: map 100% | reduce 100% | Job completed successfully | Failed
Shuffles = 0

إثبات نجاح المعالجة

05 | MapReduce counters and output

```
$ cat execution_summary.txt
Job status: completed successfully
Map input records: 12,306
Map output records: 107,562
Reduce output records: 15,188
HDFS bytes read: 607,504
HDFS bytes written: 163,600
Failed Shuffles: 0
```

الشكل 5: العدادات المسجلة بعد اكتمال المهمة.

العداد	القيمة	التفسير
Map input records	12,306	عدد الأسطر التي عولجت.
Map output records	107,562	عدد أزواج الكلمات والقيمة 1.
Reduce output records	15,188	عدد المفاتيح الفريدة في مخرج Reduce.
HDFS bytes read	607,504	حجم البيانات المقروءة.
HDFS bytes written	163,600	حجم ملف المخرج.

استخراج النتائج

```
hdfs dfs -getmerge /bigdata/sherlock/output sherlock_wordcount.txt
hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head -20
```

الكلمات الأكثر تكرارًا

06 | Sort reducer output and inspect top words

```
$ sort -k2 -nr output/part-r-00000 | head -10
the      5412
and      2794
of       2724
to       2702
a        2575
I        2533
in       1706
that     1557
was      1361
his      1096
```

الشكل 6: ترتيب أعلى الكلمات اعتمادًا على مخرج Reduce.

#	الكلمة	التكرار	#	الكلمة	التكرار
1	the	5,412	6	I	2,533
2	and	2,794	7	in	1,706
3	of	2,724	8	that	1,557
4	to	2,702	9	was	1,361
5	a	2,575	10	his	1,096

قراءة النتيجة

تصدرت الكلمات الوظيفية الإنجليزية القائمة. وهذا متوقع في عدّ خام للنص؛ فالمعالجة لم تتضمن إزالة كلمات التوقف أو توحيد جميع حالات الأحرف. لذلك يجب تفسير القائمة بوصفها قياسًا لتكرار الرموز النصية، لا بوصفها قائمة بالمفاهيم الدلالية الأهم.

كلمات الشخصيات والأماكن

لإضافة معنى تطبيقي إلى WordCount، تم البحث في المخرجات عن خمسة أسماء مرتبطة بالكتاب. القيم التالية مأخوذة من المخرجات التي تحافظ على شكل الكلمة كما ظهر في النص.

07 | Query selected character and place names

```
$ grep -E "^(Holmes|Watson|Sherlock|London|Lestrade)" output/part-r-00000
Holmes      198
London      20
Lestrade    21
Sherlock    96
Watson       4
✓ Query completed
```

الشكل 7: البحث عن أسماء الشخصيات والأماكن في مخرج WordCount.

الكلمة	عدد الظهور	ملاحظة
Holmes	198	الأكثر ظهورًا بين الكلمات المختارة.
Sherlock	96	اسم الشخصية الرئيسية.
Lestrade	21	اسم شخصية في القصة.
London	20	اسم مكان.
Watson	4	ظهر بعدد أقل بسبب طريقة تمثيل الكلمة في النص.

ينبغي الانتباه إلى أن العد الحساس لحالة الأحرف وعلامات الترقيم قد يعطي قيمًا مختلفة عن عدد يطبق التطبيع النصي. لذلك يجب تثبيت طريقة التنظيف قبل مقارنة النتائج بين تشغيلين.

إجابات مختصرة

1. ما أكثر الكلمات تكرارًا؟

الكلمات العشر الأولى هي: the, and, of, to, a, I, in, that, was, his.

2. كم مرة ظهرت الكلمات المحددة؟

Holmes = 198, Sherlock = 96, Lestrade = 21, London = 20, Watson = 4

3. ما الفرق بين ملف Linux وملف HDFS؟

ملف Linux نسخة محلية على الآلة، بينما ملف HDFS نسخة داخل نظام Hadoop الموزع، وقد قرأ MapReduce النسخة الموجودة في HDFS.

4. ما وظيفة MapReduce؟

تنفيذ WordCount عبر Map لإنتاج الأزواج، و Shuffle لتجميع المفاتيح، و Reduce لجمع القيم وإنتاج عدد كل كلمة.

5. ما وظيفة YARN؟

إدارة موارد المهمة داخل Hadoop، وجدولة مهام Map و Reduce وتشغيل containers الخاصة بها.

6. أين توجد النتيجة؟

في المسار /bigdata/sherlock/output/، ويمكن دمج ملفات المخرج في Linux باستخدام `hdfs dfs -getmerge`.

الاستنتاج النهائي

أثبتت التجربة دورة معالجة كاملة لبيانات نصية حقيقية. بدأ العمل من ملف محلي تم فحصه، ثم نُقل إلى HDFS ضمن بنية منظمة. بعد ذلك عالجه MapReduce، وأدار YARN موارده حتى اكتملت المهمة بنجاح. أخيرًا جرى استخراج المخرجات وترتيبها والإجابة عن استعلامات محددة.

توضح الأرقام أن مرحلة Map أنتجت 107,562 سجلًا وسيطًا من 12,306 سطرًا، ثم انتهت مرحلة Reduce إلى 15,188 مفتاحًا فريدًا. كما تؤكد قيمة Failed Shuffles = 0 سلامة مرحلة التجميع في هذا التشغيل. أما هيمنة the و and فتشير إلى أهمية تنفيذ تنظيف نصي إضافي إذا كان الهدف تحليل الموضوعات أو الشخصيات بدل العد الخام.

ما يمكن تطويره لاحقًا

- إزالة كلمات التوقف قبل التحليل الدلالي.
- توحيد حالة الأحرف وإزالة علامات الترقيم للمقارنة العادلة.
- تحليل كل فصل على حدة بدل جمع الكتاب كاملاً في مخرج واحد.
- تمثيل النتائج في مخطط يوضح تكرار الشخصيات والأماكن.

المراجع

Project Gutenberg, "The Adventures of Sherlock Holmes," [1]
<https://www.gutenberg.org/files/1661/1661-0.txt>

Apache Hadoop, "MapReduce Tutorial," <https://hadoop.apache.org/docs/current/hadoop-mapreduce-client/hadoop-mapreduce-client-core/MapReduceTutorial.html> [2]

ملف التسليم المقترح: تقرير PDF يتضمن خطوات التنفيذ، الأوامر، لقطات الشاشة، النتائج، والإجابات التحليلية.