

تقرير مشروع تحليل نصي باستخدام Hadoop MapReduce

تحليل كتاب نصي حقيقي باستخدام HDFS و MapReduce و YARN

الكتاب المستخدم

The Memoirs of Sherlock Holmes

Project Gutenberg - الكتاب الإلكتروني رقم 834

إعداد الطالب

24 سبتمبر 2026

فهرس التقرير

1	الملخص التنفيذي	1
1	بيانات المشروع وأهدافه	2
1	بيئة التنفيذ والأدوات	3
1	مراحل التنفيذ والأوامر	4
1	4.1 تحميل الملف وفحصه	4.1
2	4.2 إنشاء مساحة المشروع في HDFS	4.2
2	4.3 رفع الملف إلى HDFS والتحقق منه	4.3
2	4.4 التحقق من خدمات YARN	4.4
2	4.5 تشغيل WordCount	4.5
3	5 نتائج مهمة MapReduce	5
3	6 استكشاف ملفات الإخراج	6
4	7 البحث عن الشخصيات واستخراج أعلى الكلمات	7
5	8 استخراج النتائج إلى Linux	8
5	9 تحليل النتائج والمناقشة	9
5	9.1 ملاحظة تحقق مهمة حول هوية الكتاب	9.1
6	10 الخلاصة	10
6	11 ملحق: الأوامر الأساسية مجمعة	11
7	12 المراجع	12

1 الملخص التنفيذي

يستعرض هذا التقرير تنفيذ مشروع عملي لتحليل نص كتاب إلكتروني باستخدام منظومة Hadoop. بدأت العملية بتحميل ملف نصي من Project Gutenberg، ثم التحقق من سلامة الملف وحجمه، وإنشاء مساحة منظمة داخل HDFS، ورفع الملف إليها. بعد ذلك شغل برنامج WordCount الجاهز ضمن Hadoop MapReduce، وتابعت المهمة عبر YARN، ثم استُخرجت النتائج وفُحصت باستخدام أوامر Linux مثل grep و sort و head. أظهرت سجلات التنفيذ أن مهمة MapReduce انتهت بنجاح، إذ اكتملت مرحلتا Map و Reduce بنسبة 100%، وأنشئ الملفان SUCCESS_ و part-r-00000. كما أنشئ ملف محلي باسم ali_wordcount.txt يحتوي على نتائج العد.

2 بيانات المشروع وأهدافه

يهدف المشروع إلى تطبيق دورة البيانات الكاملة في Hadoop: الحصول على البيانات، فحصها، تنظيمها داخل HDFS، معالجتها باستخدام MapReduce، مراقبتها عبر YARN، ثم استخراج النتائج وتحليلها. استخدم التنفيذ ملفاً باسم ali.txt، ووضع في المسار المحلي home//cloudera، ثم رفع إلى المسار التالي في HDFS:

```
bigdata/ali/input/ali.txt/
```

أما مسار النتائج فكان:

```
bigdata/ali/output/
```

3 بيئة التنفيذ والأدوات

تم التنفيذ داخل بيئة Cloudera QuickStart باستخدام حساب cloudera. وتضمنت الأدوات والخدمات المستخدمة ما يأتي:

الأداة	الوظيفة	الاستخدام في المشروع
Linux	إدارة الملفات المحلية	تحميل الكتاب وفحصه وإنشاء ملف النتائج المحلي
HDFS	نظام الملفات الموزع	تخزين ملف الإدخال ونتائج WordCount
MapReduce	المعالجة الموزعة	حساب مرات ظهور الكلمات
YARN	إدارة الموارد والمهام	تشغيل مهمة WordCount ومراقبتها
WordCount	برنامج Hadoop جاهز	إنتاج زوج الكلمة والعدد

4 مراحل التنفيذ والأوامر

4.1 تحميل الملف وفحصه

انتقل التنفيذ إلى مجلد المستخدم، ثم حُذف أي ملف سابق بالاسم نفسه، وحُمِل ملف البيانات باستخدام wget:

```
cd /home/cloudera
rm -f ali.txt
\ 'wget --no-check-certificate --header='Host: www.gutenberg.org
https://152.19.134.47/files/1342/1342-0.txt -O ali.txt
ls -lh ali.txt
```

```
head -5 ali.txt
wc -l -w ali.txt
```

أظهر التنفيذ أن حجم الملف بلغ نحو 721 KB، وأنه يحتوي على 14,537 سطراً و127,378 كلمة وفق أمر wc. كما أظهر رأس الملف العبارة التالية:

```
*** START OF THE PROJECT GUTENBERG EBOOK 1342 ***
```

4.2 إنشاء مساحة المشروع في HDFS

أنشئ مجلد الإدخال باستخدام حساب HDFS، ثم منحت ملكية المسار للمستخدم cloudera:

```
sudo -u hdfs hdfs dfs -mkdir -p /bigdata/ali/input
sudo -u hdfs hdfs dfs -chown -R cloudera:cloudera /bigdata
hdfs dfs -ls /bigdata/ali
```

أظهر الفحص وجود مجلدي input و output داخل /bigdata/ali.

4.3 رفع الملف إلى HDFS والتحقق منه

```
/hdfs dfs -put -f ali.txt /bigdata/ali/input
hdfs dfs -ls -h /bigdata/ali/input
hdfs dfs -cat /bigdata/ali/input/ali.txt | head -20
hdfs dfs -du -h /bigdata/ali/input
```

أظهر HDFS أن الملف أصبح موجوداً بحجم 598.4 KB داخل المسار المحدد. كما أمكن قراءة محتواه مباشرة من HDFS. وقد ظهر في المحتوى عنوان مختلف عن الوصف الأولي، وهو:

```
The Project Gutenberg eBook of The Memoirs of Sherlock Holmes
```

4.4 التحقق من خدمات YARN

```
sudo service hadoop-yarn-resourcemanager status
sudo service hadoop-yarn-nodemanager status
sudo service hadoop-mapreduce-historyserver status
```

أكدت النتائج أن ResourceManager و NodeManager و History Server كانت جميعها في حالة تشغيل.

4.5 تشغيل WordCount

قبل تشغيل المهمة، حُذِف مجلد النتائج السابق، ثم شُغِل برنامج WordCount:

```
hdfs dfs -rm -r -f /bigdata/ali/output
hdfs dfs -rm -r -f /user/cloudera/.Trash/Current/bigdata/ali/output
\ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
wordcount /bigdata/ali/input /bigdata/ali/output
```

اعتمد البرنامج على ملف الإدخال الموجود في /bigdata/ali/input/، ووضع النتائج في /bigdata/ali/output/.

5 نتائج مهمة MapReduce

أظهرت السجلات أن المهمة حصلت على المعرف:

job_1790196936094_0012

ورُبطت بتطبيق YARN:

application_1790196936094_0012

المؤشر	القيمة
حالة المهمة	اكتملت بنجاح
Map	100%
Reduce	100%
مهام Map المُشغلة	1
مهام Reduce المُشغلة	1
سجلات الإدخال في Map	11,753
السجلات الناتجة من Map	98,532
مجموعات الإدخال إلى Reduce	14,017
سجلات الإخراج من Reduce	14,017
عمليات Shuffle الفاشلة	0
البيانات المقروءة من HDFS	612,861 بايت
البيانات المكتوبة إلى HDFS	151,524 بايت

أكد السجل العبارة التالية:

Job job_1790196936094_0012 completed successfully

وتعني هذه النتيجة أن المهمة انتهت دون فشل، وأن البيانات انتقلت بنجاح عبر مراحل Mapper و Shuffle و Reducer.

6 استكشاف ملفات الإخراج

```
hdfs dfs -ls /bigdata/ali/output
hdfs dfs -cat /bigdata/ali/output/part-r-00000 | head -20
```

أظهر المجلد ملفين رئيسيين:

SUCCESS_
part-r-00000

يمثل SUCCESS_ علامة نجاح المهمة، بينما يحتوي part-r-00000 على النتائج الفعلية في صورة كلمة متبوعة بعدد مرات ظهورها. ظهرت في بداية النتائج كلمات وعناصر مثل:

1 [#834
1 (\$5,000
6 &
1 (a)
and 1)
or 3)

ويكشف ذلك أن WordCount الأساسي عدّ بعض علامات الترقيم والرموز والأجزاء الوصفية ضمن الكلمات، لأنه لم يُجرَ تنظيف متقدم للنص قبل التحليل.

7 البحث عن الشخصيات واستخراج أعلى الكلمات

استخدم التنفيذ حلقة للبحث عن أسماء الشخصيات المطلوبة:

```
for w in Elizabeth Darcy Bennet Jane Bingley; do
    echo $w
    "hdfs dfs -cat /bigdata/ali/output/part-r-000000 | grep -w \"$w"
done
```

كانت النتيجة الظاهرة في السجل:

الكلمة	العدد الظاهر في النتائج
Elizabeth	لم يظهر في المخرجات المعروضة
Darcy	لم يظهر في المخرجات المعروضة
Bennet	لم يظهر في المخرجات المعروضة
Jane	2
Bingley	لم يظهر في المخرجات المعروضة

لا يعني عدم ظهور كلمة في المخرجات المعروضة بالضرورة أنها غير موجودة في النص؛ فقد يكون السبب اختلاف حالة الأحرف أو علامات الترقيم أو طريقة تقسيم الكلمات. لاستخراج أعلى 20 كلمة تكررًا:

```
hdfs dfs -cat /bigdata/ali/output/part-r-000000 | sort -k2 -nr | head -20
```

كانت النتائج كما يأتي:

the 5108
and 2540
of 2526
to 2448
a 2227
I 2121
in 1583
that 1516

was	1506
his	1027
had	1019
he	969
you	927
it	831
have	816
my	811
is	811
with	787
as	711
at	698

8 استخراج النتائج إلى Linux

استُخدم الأمر getmerge لنقل مخرجات HDFS إلى ملف محلي:

```
rm -f ali_wordcount.txt
hdfs dfs -getmerge /bigdata/ali/output ali_wordcount.txt
ls -lh ali_wordcount.txt
wc -l ali_wordcount.txt
head -20 ali_wordcount.txt
```

أصبح الملف المحلي باسم ali_wordcount.txt، وبحجم يقارب 148 KB، ويحتوي على 14,017 سطرًا.

9 تحليل النتائج والمناقشة

أثبت المشروع العلاقة بين مكونات Hadoop. فقد تولى HDFS تخزين ملف الإدخال والنتائج، بينما تولى MapReduce حساب تكرار الكلمات من خلال Mapper وReducer، وأدار YARN موارد التشغيل وجدولة المهمة. أما أوامر Linux مثل grep و sort و head فقد استخدمت لتحليل المخرجات بعد تنفيذ المعالجة الموزعة.

تُظهر قائمة أعلى 20 كلمة أن الكلمات الوظيفية الإنجليزية مثل the و of و and هي الأكثر تكرارًا. وهذا أمر متوقع في نص أدبي باللغة الإنجليزية، لكنه يوضح أيضًا أن التحليل الدلالي للشخصيات يحتاج إلى تنظيف النص وإزالة الكلمات الشائعة، وتوحيد الحروف الكبيرة والصغيرة، وإزالة علامات الترقيم.

9.1 ملاحظة تحقق مهمة حول هوية الكتاب

يوجد تعارض بين اسم الملف وطريقة التحميل والوصف الأولي. فقد استخدم الرابط الذي يحتوي على الرقم 1342، وهو رقم مرتبط بكتاب Pride and Prejudice، بينما أظهر محتوى الملف في HDFS العنوان:

The Memoirs of Sherlock Holmes

كما أن السجل يذكر أن الملف المحمل حجمه 738,046 بايت، في حين يشير محتوى HDFS إلى كتاب مختلف. لذلك يجب قبل التسليم النهائي للدكتور التحقق من أن الملف المقصود هو الكتاب المطلوب فعلاً، وذلك باستخدام:

```
head -30 ali.txt
grep -i "Title:" ali.txt | head
```

إذا كان المطلوب هو **Pride and Prejudice**، فيجب إعادة تحميل الرابط الرسمي الصحيح من Project Gutenberg والتحقق من العنوان قبل إعادة تشغيل WordCount. أما إذا كان المطلوب هو **The Memoirs of Sherlock Holmes**، فيجب تسمية المشروع والملف وفق هذا الكتاب وتحديث قائمة الشخصيات المراد البحث عنها.

10 الخلاصة

تم تنفيذ مشروع Hadoop MapReduce بنجاح من الناحية التقنية. حُمِلَ الملف وفُصِّل، ثم رُفِعَ إلى HDFS، وشُغِلَت مهمة WordCount تحت إدارة YARN، واكتملت مرحلتا Map و Reduce بنجاح، وأنشئت النتائج داخل HDFS ثم استُخرجت إلى ملف محلي باسم .ali_wordcount.txt.

كما أظهر التحليل أن جودة نتائج WordCount تعتمد على جودة البيانات وتنظيفها. وبالرغم من نجاح التنفيذ، فإن التحقق من هوية الكتاب ضروري قبل اعتماد التقرير، لأن السجل يحتوي على اختلاف بين رقم الكتاب 1342 والعنوان الظاهر في الملف داخل HDFS.

11 ملحق: الأوامر الأساسية مجمعة

```
cd /home/cloudera
rm -f ali.txt
wget --no-check-certificate --header='Host: www.gutenberg.org'
https://152.19.134.47/files/1342/1342-0.txt -O ali.txt
ls -lh ali.txt
head -5 ali.txt
wc -l -w ali.txt

sudo -u hdfs hdfs dfs -mkdir -p /bigdata/ali/input
sudo -u hdfs hdfs dfs -chown -R cloudera:cloudera /bigdata
/hdfs dfs -put -f ali.txt /bigdata/ali/input
hdfs dfs -ls -h /bigdata/ali/input
hdfs dfs -du -h /bigdata/ali/input

sudo service hadoop-yarn-resourcemanager status
sudo service hadoop-yarn-nodemanager status
sudo service hadoop-mapreduce-historyserver status

hdfs dfs -rm -r -f /bigdata/ali/output
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount /
bigdata/ali/input /bigdata/ali/output

hdfs dfs -ls /bigdata/ali/output
hdfs dfs -cat /bigdata/ali/output/part-r-000000 | sort -k2 -nr | head -20
hdfs dfs -getmerge /bigdata/ali/output ali_wordcount.txt
```



```
ls -lh ali_wordcount.txt  
wc -l ali_wordcount.txt
```

12 المراجع

- [Project Gutenberg](<https://www.gutenberg.org/>): مستودع الكتب الإلكترونية المستخدمة في المشروع.
- سجل التنفيذ المرفق: مستند نصي يد (5).txt.