

تقرير مشروع عملي

تحليل كتاب حقيقي باستخدام

# Hadoop MapReduce

Big Data Text Analytics

|              |                                                        |
|--------------|--------------------------------------------------------|
| الطالب       | عمران                                                  |
| الكتاب       | The Adventures of Sherlock Holmes — Arthur Conan Doyle |
| البيئة       | VMware على Cloudera QuickStart VM 5.13                 |
| مسارات العمل | bigdata/omran/input • /bigdata/omran/output/           |

مشروع عملي متكامل: تحليل كتاب حقيقي باستخدام Hadoop MapReduce

Big Data Text Analytics — The Adventures of Sherlock Holmes — Arthur Conan Doyle

الطالب: عمران | البيئة: Cloudera QuickStart VM 5.13 على VMware | الإدخال: /bigdata/omran/input/

الإخراج: /bigdata/omran/output/

## 1) فكرة المشروع ودورة البيانات

---

جمع كل مفاهيم المقرر (Hadoop وHDFS وMapReduce وYARN وLinux) في مشروع واحد على بيانات حقيقية من Project Gutenberg. الدورة: تحميل الكتاب في Linux وفحصه، ثم تنظيم مساحة في HDFS ورفع الكتاب إليها، ثم تشغيل WordCount تحت إدارة YARN، ثم تحليل النتائج والبحث عن الشخصيات، ثم استخراج النتائج إلى Linux عبر .getmerge

## 2) الحصول على البيانات وفحصها في Linux

---

```
cd /home/cloudera
wget --no-check-certificate --header='Host: www.gutenberg.org'
https://152.19.134.47/files/1661/1661-0.txt -O omran.txt
```

ناتج التنفيذ الفعلي (من الطالب): الملف omran.txt حجم 594K بعدد 12306 أسطر و107562 كلمة، وبدايته عنوان الكتاب The Adventures of Sherlock Holmes للمؤلف Arthur Conan Doyle.

```
ls -lh omran.txt => -rw-r--r-- 1 cloudera cloudera 594K Oct 10 2023 omran.txt
wc -l omran.txt => 12306 omran.txt | wc -w omran.txt => 107562 omran.txt
```

## 3) مساحة المشروع في HDFS ورفع الكتاب

---

```
hadoop fs -mkdir -p /bigdata/omran/input
hadoop fs -put omran.txt /bigdata/omran/input/
```

ناتج التنفيذ الفعلي: الملف موجود في HDFS بحجم 607504 بايت (593.3K)، والقراءة عبر `hdfs dfs -cat` تعطي نفس بداية الكتاب، وهذا يثبت انتقال النسخة من Linux إلى HDFS.

```
hadoop fs -ls -R /bigdata/omran => input + input/omran.txt (607504) + output
hadoop fs -du -h /bigdata/omran/input/omran.txt => 593.3 K
```

```

cloudera@quickstart:~$ ls -lh omran.txt
-rw-r--r-- 1 cloudera cloudera 594K Oct 10 2023 omran.txt
cloudera@quickstart:~$ wc -l omran.txt
12306 omran.txt
cloudera@quickstart:~$ wc -w omran.txt
107562 omran.txt
cloudera@quickstart:~$ head -5 omran.txt
The Project Gutenberg eBook of The Adventures of Sherlock Holmes,
by Arthur Conan Doyle

This eBook is for the use of anyone anywhere in the United States and
most other parts of the world at no cost and with almost no restrictions
cloudera@quickstart:~$ hadoop fs -ls -R /bigdata/omran
drwxr-xr-x - cloudera supergroup 0 2026-09-23 11:55 /bigdata/omran/input
-rw-r--r-- 1 cloudera supergroup 607504 2026-09-23 11:55 /bigdata/omran/input/omran.txt
drwxr-xr-x - cloudera supergroup 0 2026-09-23 13:23 /bigdata/omran/output
-rw-r--r-- 1 cloudera supergroup 0 2026-09-23 13:23 /bigdata/omran/output/ SUCCESS
-rw-r--r-- 1 cloudera supergroup 163591 2026-09-23 13:23 /bigdata/omran/output/part-r-00000
cloudera@quickstart:~$ hadoop fs -du -h /bigdata/omran/input/omran.txt
593.3 K 593.3 K /bigdata/omran/input/omran.txt
cloudera@quickstart:~$ hadoop fs -cat /bigdata/omran/input/omran.txt | head -5
The Project Gutenberg eBook of The Adventures of Sherlock Holmes,
by Arthur Conan Doyle

This eBook is for the use of anyone anywhere in the United States and
most other parts of the world at no cost and with almost no restrictions
cat: Unable to write to output stream.
cloudera@quickstart:~$ hadoop fs -rm -r /bigdata/omran/output
Deleted /bigdata/omran/output
cloudera@quickstart:~$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount /bigdata/omran/input /bigdata/omran/output
26/09/23 13:43:33 INFO client.RMProxy: Connecting to ResourceManager at /0.0.0.0:8032
26/09/23 13:43:34 INFO input.FileInputFormat: Total input paths to process : 1
26/09/23 13:43:34 INFO mapreduce.JobSubmitter: number of splits:1
26/09/23 13:43:35 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1790119089946_0002
26/09/23 13:43:35 INFO impl.YarnClientImpl: Submitted application application_1790119089946_0002
26/09/23 13:43:35 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/application_1790119089946_0002/
26/09/23 13:43:35 INFO mapreduce.Job: Running job: job_1790119089946_0002

```

صورة 1: فحص الملف المحلي وفحص HDFS وبدء مهمة WordCount

## 4) تشغيل WordCount بتقنية MapReduce

واجهتنا مشكلة: مجلد الإخراج كان موجودا فرفض Hadoop العمل برسالة FileAlreadyExistsException، فحذفناه (Deleted /bigdata/omran/output) ثم أعدنا التشغيل بنجاح.

```

hadoop fs -rm -r /bigdata/omran/output
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount
/bigdata/omran/input /bigdata/omran/output

```

نتائج التنفيذ الفعلي للمهمة job\_1790119089946\_0002: التقدم 0% map ثم 100% map ثم 100% reduce  
 100% ثم Job completed successfully. العدادات: Map input records = 12306 و Map output records = 107562 والكلمات المميزة 15187 و Bytes Read = 607504 و Bytes Written = 163591.

```

cloudera@quickstart:~$
26/09/23 13:43:34 INFO input.FileInputFormat: Total input paths to process : 1
26/09/23 13:43:34 INFO mapreduce.JobSubmitter: number of splits:1
26/09/23 13:43:35 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1790119089946_0002
26/09/23 13:43:35 INFO impl.YarnClientImpl: Submitted application application_1790119089946_0002
26/09/23 13:43:35 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/application_1790119089946_0002/
26/09/23 13:43:35 INFO mapreduce.Job: Running job: job_1790119089946_0002
26/09/23 13:43:40 INFO mapreduce.Job: Job job_1790119089946_0002 running in uber mode : false
26/09/23 13:43:40 INFO mapreduce.Job: map 0% reduce 0%
26/09/23 13:43:46 INFO mapreduce.Job: map 100% reduce 0%
26/09/23 13:43:51 INFO mapreduce.Job: map 100% reduce 100%
26/09/23 13:43:51 INFO mapreduce.Job: Job job_1790119089946_0002 completed successfully
26/09/23 13:43:51 INFO mapreduce.Job: Counters: 49

File System Counters
  FILE: Number of bytes read=223111
  FILE: Number of bytes written=733451
  FILE: Number of read operations=0
  FILE: Number of large read operations=0
  FILE: Number of write operations=0
  HDFS: Number of bytes read=607630
  HDFS: Number of bytes written=163591
  HDFS: Number of read operations=6
  HDFS: Number of large read operations=0
  HDFS: Number of write operations=2

Job Counters
  Launched map tasks=1
  Launched reduce tasks=1
  Data-local map tasks=1
  Total time spent by all maps in occupied slots (ms)=3692
  Total time spent by all reduces in occupied slots (ms)=2844
  Total time spent by all map tasks (ms)=3692
  Total time spent by all reduce tasks (ms)=2844
  Total vcore-milliseconds taken by all map tasks=3692
  Total vcore-milliseconds taken by all reduce tasks=2844
  Total megabyte-milliseconds taken by all map tasks=3780608
  Total megabyte-milliseconds taken by all reduce tasks=2912256

Map-Reduce Framework
  Map input records=12306
  Map output records=107562
  Map output bytes=1022331
  Map output materialized bytes=223111

```

## صورة 2: تقدم المهمة وبداية العدادات

```

cloudera@quickstart:~$
Total time spent by all reduces in occupied slots (ms)=2844
Total time spent by all map tasks (ms)=3692
Total time spent by all reduce tasks (ms)=2844
Total vcore-milliseconds taken by all map tasks=3692
Total vcore-milliseconds taken by all reduce tasks=2844
Total megabyte-milliseconds taken by all map tasks=3780608
Total megabyte-milliseconds taken by all reduce tasks=2912256

Map-Reduce Framework
  Map input records=12306
  Map output records=107562
  Map output bytes=1022331
  Map output materialized bytes=223111
  Input split bytes=126
  Combine input records=107562
  Combine output records=15187
  Reduce input groups=15187
  Reduce shuffle bytes=223111
  Reduce input records=15187
  Reduce output records=15187
  Spilled Records=30374
  Shuffled Maps =1
  Failed Shuffles=0
  Merged Map outputs=1
  GC time elapsed (ms)=128
  CPU time spent (ms)=2540
  Physical memory (bytes) snapshot=529313792
  Virtual memory (bytes) snapshot=3135205376
  Total committed heap usage (bytes)=547880960

Shuffle Errors
  BAD_ID=0
  CONNECTION=0
  IO_ERROR=0
  WRONG_LENGTH=0
  WRONG_MAP=0
  WRONG_REDUCE=0

File Input Format Counters
  Bytes Read=607504
File Output Format Counters
  Bytes Written=163591

[cloudera@quickstart ~]$

```

## صورة 3: نهاية العدادات ونجاح المهمة

## 5) مراقبة المهمة عبر YARN

واجهة YARN على quickstart.cloudera:8088 أظهرت المهمتين ناجحتين: application\_1790119089946\_0001 و application\_1790119089946\_0002 بحالة FINISHED و SUCCEEDED ونوع MAPREDUCE واسم word count.

The screenshot shows the Cloudera Quickstart VM interface. The main window displays the 'All Applications' page. The left sidebar shows navigation options like Cluster, Nodes, Applications, and Scheduler. The main content area shows cluster metrics and a table of applications. The table lists two applications: application\_1790119089946\_0002 and application\_1790119089946\_0001, both in a FINISHED state with a SUCCEEDED final status.

| ID                             | User     | Name       | Application Type | Queue         | StartTime                      | FinishTime                     | State    | FinalStatus | Running Containers | Allocated CPU | Allocated Memory | Reserved CPU | Reserved Memory | Progress | Tracking UI |
|--------------------------------|----------|------------|------------------|---------------|--------------------------------|--------------------------------|----------|-------------|--------------------|---------------|------------------|--------------|-----------------|----------|-------------|
| application_1790119089946_0002 | cloudera | word count | MAPREDUCE        | root.cloudera | Wed Sep 23 13:43:35 -0700 2026 | Wed Sep 23 13:43:50 -0700 2026 | FINISHED | SUCCEEDED   | N/A                | N/A           | N/A              | N/A          | N/A             |          | History     |
| application_1790119089946_0001 | cloudera | word count | MAPREDUCE        | root.cloudera | Wed Sep 23 13:22:38 -0700 2026 | Wed Sep 23 13:23:05 -0700 2026 | FINISHED | SUCCEEDED   | N/A                | N/A           | N/A              | N/A          | N/A             |          | History     |

صورة 4: واجهة YARN تعرض المهمتين ناجحتين

## 6) استكشاف نتائج WordCount

مجلد الإخراج يحتوي ملف SUCCESS\_ (دليل نجاح المهمة) وملف part-r-00000 (النتائج الفعلية بحجم 163591 بايت). أول 20 سطرا مرتبة أبجديا وتبدأ برموز مثل # 1661.

```
hadoop fs -ls /bigdata/omran/output => _SUCCESS (0) + part-r-00000 (163591) 2026-09-23 13:43
```

```
hadoop fs -cat /bigdata/omran/output/part-r-00000 | head -20
```

```

cloudera@quickstart:~$
cloudera@quickstart:~$
cloudera@quickstart:~$ hadoop fs -ls /bigdata/omran/output
Found 2 items
-rw-r--r-- 1 cloudera supergroup 0 2026-09-23 13:43 /bigdata/omran/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup 163591 2026-09-23 13:43 /bigdata/omran/output/part-r-00000
cloudera@quickstart:~$ hadoop fs -cat /bigdata/omran/output/part-r-00000 | head -20
#1661] 1
$5,000] 1
6, 5
6c, 1
6c, 1
($1 1
(3rd 1
(801) 1
(a) 1
(and 1
(any 1
(b) 1
(c) 1
(does 1
(for 1
(if 1
(now 1
(or 3
(the 1
(trademark/copyright) 1
cat: Unable to write to output stream.
cloudera@quickstart:~$

```

صورة 5: محتويات مجلد الإخراج وعينة النتائج

## (7) البحث عن الشخصيات والأماكن

نتائج grep الفعلية: Holmes الدقيقة 198 ومع مشتقات الترقيم (Holmes, بعدد 126 و Holmes. بعدد 78) الإجمالي نحو 461. و Watson الدقيقة 4 ومع المشتقات نحو 81. و Sherlock بعدد 96. و Lestrade بعدد 21 والإجمالي نحو 38. و London بعدد 20 والإجمالي نحو 41. الاستنتاج: Holmes يتصدر بفارق كبير عن Watson. وملاحظة الجودة: WordCount الخام لا يوحد الحالة ولا يزيل الترقيم، وهذا درس Data Cleaning.

| الكلمة   | الدقيقة | الإجمالي مع الترقيم |
|----------|---------|---------------------|
| Holmes   | 198     | 461 ~               |
| Watson   | 4       | 81 ~                |
| Sherlock | 96      | 97 ~                |
| Lestrade | 21      | 38 ~                |

|        |    |     |
|--------|----|-----|
| London | 20 | 41~ |
|--------|----|-----|

```

[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hadoop fs -cat /bigdata/omran/output/part-r-00000 | grep -w "Holmes"
Holmes 198
Holmes! 1
Holmes, 4
Holmes, 126
Holmes, 11
Holmes, 78
Holmes, 1
Holmes, 5
Holmes; 7
Holmes? 1
Holmes? 4
Holmes-a 1
Holmes' 17
Holmes, 1
Holmes, 2
Holmes, 4
[cloudera@quickstart ~]$ hadoop fs -cat /bigdata/omran/output/part-r-00000 | grep -w "Watson"
Watson 4
Watson, 19
Watson, 10
Watson? 1
Watson? 6
Watson, 1
[cloudera@quickstart ~]$ hadoop fs -cat /bigdata/omran/output/part-r-00000 | grep -w "Sherlock"
Sherlock 96
Sherlock 1
[cloudera@quickstart ~]$ hadoop fs -cat /bigdata/omran/output/part-r-00000 | grep -w "Lestrade"
Lestrade 21
Lestrade! 2
Lestrade, 8
Lestrade, 3
Lestrade, 3
Lestrade's 1
[cloudera@quickstart ~]$ hadoop fs -cat /bigdata/omran/output/part-r-00000 | grep -w "London"
London 20
London, 8
London, 8
London, 1
London, 2
London-eastern 1
London-quite 1
[cloudera@quickstart ~]$
  
```

صورة 6: نتائج البحث عن الشخصيات الخمس

## (8) أعلى 20 كلمة واستخراج النتائج

الأعلى تكرارا هي كلمات وظيفية: the بعدد 5412 و and بعدد 2794 و of بعدد 2724 و to بعدد 2702 و a بعدد 2575 و بعدد 2533، ثم in و that و was و his و is و you و he و it و my و have و with و had و as و which. ثم استخرجنا النتائج عبر getmerge إلى ملف محلي omran\_wordcount.txt بحجم 160K.


| #  | الكلمة | التكرار |
|----|--------|---------|
| 1  | the    | 5412    |
| 2  | and    | 2794    |
| 3  | of     | 2724    |
| 4  | to     | 2702    |
| 5  | a      | 2575    |
| 6  | I      | 2533    |
| 7  | in     | 1706    |
| 8  | that   | 1557    |
| 9  | was    | 1361    |
| 10 | his    | 1096    |
| 11 | is     | 1073    |
| 12 | you    | 1034    |
| 13 | he     | 1014    |
| 14 | it     | 977     |
| 15 | my     | 901     |
| 16 | have   | 894     |
| 17 | with   | 843     |
| 18 | had    | 807     |
| 19 | as     | 776     |

20

which

753

```
hadoop fs -cat /bigdata/omran/output/part-r-00000 | sort -k2 -nr | head -20
hadoop fs -getmerge /bigdata/omran/output omran_wordcount.txt => 160K
```



صورة 7: أعلى 20 كلمة واستخراج النتائج

## 9) أجوبة الأسئلة السبعة

الأول: الأكثر تكرارا the و of. الثاني: Holmes نحو 461 و Watson نحو 81 و Sherlock نحو 97 و Lestrade نحو 41. الثالث: قائمة العشرين في القسم السابق. الرابع: ملف Linux نسخة مفردة على قرص واحد، وملف HDFS مقسم إلى Blocks وموزع مع Replication. الخامس: وظيفة MapReduce هي عد الكلمات عبر Mapper ثم Shuffle ثم Reducer. السادس: وظيفة YARN هي إدارة الموارد وتشغيل المهمة ومراقبتها. السابع: النتيجة النهائية في /bigdata/omran/output/part-r-00000 ونسخة محلية omran\_wordcount.txt.

الكلمة

الدقيقة

الإجمالي مع الترتيم

|          |     |       |
|----------|-----|-------|
| Holmes   | 198 | 461 ~ |
| Watson   | 4   | 81 ~  |
| Sherlock | 96  | 97 ~  |
| Lestrade | 21  | 38 ~  |
| London   | 20  | 41 ~  |

## 10 المطلوب تسليمه

تم تسليم: ملف Dataset وهو `omran.txt`، ومسار HDFS وهو `bigdata/omran/input/`، ومخرجات MapReduce وهي `bigdata/omran/output/`، وجدول الكلمات المطلوبة، ولقطات الشاشة وهي الصور السبع داخل هذا التقرير، وملف النتائج `omran_wordcount.txt`، وهذا التحليل المختصر.

## 11 سلامة العقدة

فحص `dfsadmin` أظهر عقدة حية واحدة بحالة Normal بسعة 54.51GB وصفر Blocks تالفة أو مفقودة، وفحص `yarn` أظهر عقدة واحدة بحالة RUNNING، أي أن العقدة الوحيدة سليمة وتخدم HDFS وYARN.