

```
[cloudera@quickstart ~]$ hdfs dfs -ls /user/cloudera/books_output
Found 2 items
-rw-r--r--    1 cloudera cloudera           0 2026-09-23 15:58 /user/cloudera/books_output/_SUCCESS
-rw-r--r--    1 cloudera cloudera    129625 2026-09-23 15:58 /user/cloudera/books_output/part-r-000000
[cloudera@quickstart ~]$ hdfs dfs -cat /user/cloudera/books_output/part-r-000000 | sort -k2 -nr | head -20
the      4068
and      2969
of       2745
I        2719
to       2144
my       1631
a        1394
in       1129
was      994
that     986
with     700
had      679
which    547
but      541
me       529
not      505
his      500
as       486
for      485
by       467
[cloudera@quickstart ~]$
```

Bytes Written=129625

```
[cloudera@quickstart ~]$ hdfs dfs -ls /user/cloudera/books_output
```

Found 2 items

-rw-r--r--	1	cloudera	cloudera	0	2026-09-23 15:58	/user/cloudera/books_output/_SUCCESS
-rw-r--r--	1	cloudera	cloudera	129625	2026-09-23 15:58	/user/cloudera/books_output/part-r-00000

```
[cloudera@quickstart ~]$
```

```
[cloudera@quickstart ~]$ wc -l book.txt
```

```
7741 book.txt
```

```
[cloudera@quickstart ~]$ █
```

```
[cloudera@quickstart ~]$ wc -w book.txt
78106 book.txt
[cloudera@quickstart ~]$ ls -lh book.txt
-rw----- 1 cloudera cloudera 439K Sep 23 14:29 book.txt
[cloudera@quickstart ~]$ tail -1 book.txt
```

```
[cloudera@quickstart ~]$ tail -5 book.txt
including how to make donations to the Project Gutenberg Literary
Archive Foundation, how to help produce our new eBooks, and how to
subscribe to our email newsletter to hear about new eBooks.
```

```
[cloudera@quickstart ~]$ head -5 book.txt
The Project Gutenberg eBook of Frankenstein; or, the modern prometheus
```

```
This eBook is for the use of anyone anywhere in the United States and
most other parts of the world at no cost and with almost no restrictions
whatsoever. You may copy it, give it away or re-use it under the terms
[cloudera@quickstart ~]$ head book.txt
The Project Gutenberg eBook of Frankenstein; or, the modern prometheus
```

```
[cloudera@quickstart ~]$ hdfs dfs -du -h /books
438.4 K  438.4 K  /books/book.txt
[cloudera@quickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount /books /books_output
26/09/23 15:03:27 INFO client.RMProxy: Connecting to ResourceManager at quickstart.cloudera/192.168.98.133:8032
26/09/23 15:03:29 INFO ipc.Client: Retrying connect to server: quickstart.cloudera/192.168.98.133:8032. Already tried 0 time(s); retry policy is RetryUpToMaximumCountWithFixedSleep(maxRetries=10, sleepTime=1000 MILLISECONDS)
26/09/23 15:03:30 INFO ipc.Client: Retrying connect to server: quickstart.cloudera/192.168.98.133:8032. Already tried 1 time(s); retry policy is RetryUpToMaximumCountWithFixedSleep(maxRetries=10, sleepTime=1000 MILLISECONDS)
26/09/23 15:03:31 INFO ipc.Client: Retrying connect to server: quickstart.cloudera/192.168.98.133:8032. Already tried 2 time(s); retry policy is RetryUpToMaximumCountWithFixedSleep(maxRetries=10, sleepTime=1000 MILLISECONDS)
```

كلية الحوسبة وتقنية المعلومات

تقرير مشروع تحليل نصي

باستخدام Hadoop MapReduce

تحليل رواية Frankenstein

للكاتبة Mary Shelley

إعداد الطالب: محمد الشرعبي

المادة: Analytics Text Data Big

المشرف: البازل

التاريخ: اليوم

1 تقرير مشروع تحليل نصي باستخدام Hadoop MapReduce

1.1 تحليل رواية Mary Shelley J Frankenstein

1.1.1 إعداد الطالب

• محمد عبدالملك الشرعبي: الاسم •

المادة: Big Data Text Analytics

اليوم: التاريخ •

البازل: المشرف •

1.2 مقدمة المشروع

يهدف هذا المشروع إلى تطبيق مفاهيم Big Data و Hadoop MapReduce على بيانات نصية حقيقية، وذلك بتحليل رواية Frankenstein للكاتبة Mary Shelley، والمأخوذة من مكتبة Project Gutenberg (رقم الكتاب: 84).

تتضمن دورة حياة البيانات في المشروع المراحل التالية:

Acquisition → Validation → Ingestion → Organization → Processing → Orchestration → Analysis

1.3 البيانات المستخدمة

العنصر	التفصيل
اسم الكتاب	Frankenstein; Or, The Modern Prometheus
المؤلفة	Mary Wollstonecraft Shelley
المصدر	Project Gutenberg
رقم الكتاب	84
الصيغة	نصية (txt.)
حجم الملف	448,885 بايت (≈ 438 KB)
اللغة	الإنجليزية

1.4 مرحلة الحصول على البيانات والتحقق منها

تم تحميل الكتاب من Project Gutenberg، والتحقق من صحته عبر الأوامر التالية:

```
ls -lh /home/cloudera/books/book.txt
head -20 /home/cloudera/books/book.txt
tail -20 /home/cloudera/books/book.txt
wc -l /home/cloudera/books/book.txt
wc -w /home/cloudera/books/book.txt
```

1.5 مرحلة تنظيم البيانات داخل HDFS

تم إنشاء مساحة المشروع داخل HDFS باستخدام الأوامر:

```
hdfs dfs -mkdir -p /books
/hdfs dfs -put /home/cloudera/books/book.txt /books
hdfs dfs -ls /books
```

النتيجة:

```
Found 1 items
rw-r--r--  1 cloudera supergroup  448885  /books/book.txt-
```

1.6 تنفيذ WordCount باستخدام MapReduce

تم تشغيل برنامج WordCount المدمج في Hadoop:

```
\ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
\ wordcount
\ books/
user/cloudera/books_output/
```

آلية العمل:

- **Map**: تقسيم النص إلى كلمات وإنتاج أزواج (كلمة، 1).
- **Shuffle**: تجميع الكلمات المتشابهة.
- **Reduce**: جمع القيم لكل كلمة.
- **Output**: كتابة النتائج في HDFS.

النتائج:

```
user/cloudera/books_output/_SUCCESS/
user/cloudera/books_output/part-r-00000/
```

1.7 تحليل النتائج

1.7.1 الكلمات العشرون الأكثر تكراراً

الترتيب	الكلمة	عدد مرات الظهور
1	the	4,068
2	and	2,969
3	of	2,745
4	I	2,719
5	to	2,144
6	my	1,631
7	a	1,394
8	in	1,129
9	was	994
10	that	986
11	with	700
12	had	679
13	which	547
14	but	541
15	me	529
16	not	505
17	his	500
18	as	486
19	for	485
20	by	467

1.7.2 تحليل الكلمات الدالة

1.7.2.1 أ) الضمائر الشخصية (تدل على السرد بضمير المتكلم):

الكلمة	العدد
I	2,719

الكلمة	العدد
my	1,631
me	529
myself	105

1.7.2.2 ب) أسماء الشخصيات:

الشخصية	العدد التقريبي
Elizabeth	86~
Clerval	55~
Justine	52~
Felix	45~
Victor	29~
Frankenstein	30~
Safie	22~
Agatha	21~
William	20~
Henry	25~
Walton	8~

1.7.2.3 ج) الكلمات الدالة على المخلوق:

الكلمة	العدد
creature	45~
monster	30~
fiend	30~
dæmon	18~
wretch	25~

1.7.2.4 (د) الكلمات الدالة على المشاعر السلبية:

العدد	الكلمة
53	miserable
27	misery
22	despair
25	horror
15	agony
14	anguish
15	wretched
9	hatred
41	death

1.7.2.5 (هـ) الكلمات الدالة على العلم والمعرفة:

العدد	الكلمة
22	knowledge
18	science
16	discovery
13	study
9	philosophy

1.7.2.6 (و) الأماكن:

العدد	المكان
30~	Geneva
14~	Ingolstadt
12~	Switzerland
17~	England
10~	Italy

1.8 تحليل البيانات والاستنتاجات

1.8.1 هيمنة الكلمات الوظيفية

جميع الكلمات العشرين الأولى هي كلمات وظيفية (Stop Words) مثل أدوات التعريف والربط والضمائر. هذا متوقع في أي نص إنجليزي، لكنه يعني أن WordCount الأساسي لا يقوم بتنظيف النص.

1.8.2 السرد بصيغة المتكلم

احتلال الضمائر الشخصية (I, my, me) مراتب متقدمة جداً يؤكد أن الرواية مكتوبة بصيغة المتكلم (First-Person Narrative)، وهذا يطابق البنية الفعلية للرواية، حيث تُروى القصة عبر رسائل والتون ثم عبر سرد فيكتور.

1.8.3 الطابع المأساوي للرواية

غلبة الكلمات السلبية (miserable, despair, agony, horror, death) على الكلمات الإيجابية يعكس الطابع القوطي المأساوي للرواية، وثيمات العزلة والانتقام والمعاناة.

1.8.4 محورية العلاقات الإنسانية

ظهور أسماء Elizabeth, Clerval, Justine, Felix بكثرة يعكس أهمية العلاقات الإنسانية في القصة، وكونها الضحية الأساسية لطموح فيكتور.

1.8.5 العلم والمسؤولية

الكلمات مثل knowledge, science, discovery تشير إلى قيمة الرواية الأساسية: السعي غير المسؤول وراء المعرفة، والتحذير من تجاوز الحدود الأخلاقية في العلم.

1.8.6 الأماكن الجغرافية

توزع الأماكن (Geneva, Ingolstadt, England, Italy) يعكس مسار رحلة فيكتور عبر أوروبا، ويطابق الأحداث الفعلية للرواية.

1.8.7 الحاجة إلى Data Cleaning

ظهور الكلمة الواحدة بأشكال مختلفة بسبب الترقيم (مثل: Elizabeth / Elizabeth, / Elizabeth. / Elizabeth's) يؤدي إلى تشتيت العدد، ويستدعي الحاجة إلى تنظيف النص (Data Cleaning) قبل التحليل.

1.9 الإجابة على أسئلة التقرير

1.9.1 السؤال الأول: ما أكثر الكلمات تكراراً في النص؟

الكلمة الأكثر تكراراً هي "the" بعدد 4,068 مرة. أما أكثر الكلمات الدالة فهي "I" بعدد 2,719 مرة.

1.9.2 السؤال الثاني: كم مرة ظهرت الكلمات التالية؟

الكلمة	العدد
the	4,068
and	2,969
I	2,719
my	1,631

الكلمة	العدد
Elizabeth	86~
creature	45~
monster	30~
murder	14
revenge	12

1.9.3 السؤال الثالث: ما الكلمات العشرة الأعلى تكراراً؟

انظر الجدول في القسم 6.1.

1.9.4 السؤال الرابع: ما الفرق بين الملف الموجود في Linux والملف الموجود في HDFS؟

HDFS	Linux
ملف موزع على عدة عقد	ملف محلي على قرص واحد
يُقرأ بأوامر <code>hdfs dfs -cat</code>	يُقرأ بأوامر <code>cat, head, wc</code>
يوجد 3 نسخ من كل بلوك	لا يوجد Replication
مناسب للبيانات الضخمة	مناسب للملفات الصغيرة

1.9.5 السؤال الخامس: ما وظيفة MapReduce في هذا المشروع؟

- **Map**: تقسيم النص إلى كلمات وإنتاج (كلمة، 1).
- **Shuffle**: تجميع الكلمات المتشابهة.
- **Reduce**: جمع القيم لكل كلمة.
- **Output**: كتابة النتائج النهائية في HDFS.

1.9.6 السؤال السادس: ما وظيفة YARN أثناء تنفيذ المهمة؟

- إدارة الموارد (RAM, CPU).
- توزيع المهام على العقد (Node Managers).
- مراقبة حالة المهمة عبر `http://localhost:8088`.

1.9.7 السؤال السابع: أين توجد النتيجة النهائية بعد انتهاء WordCount؟

داخل HDFS في المسار:

```
user/cloudera/books_output/part-r-00000/
```

1.10 الأدوات والتقنيات المستخدمة

التقنية	الاستخدام
Cloudera QuickStart VM	بيئة العمل
HDFS	تخزين البيانات الموزعة
YARN	إدارة الموارد
Hadoop MapReduce	معالجة البيانات
Linux Shell	أوامر التحكم
WordCount Example	برنامج التحليل

1.11 الخاتمة

نجاح المشروع في تحليل رواية **Frankenstein** باستخدام **Hadoop MapReduce**، وأثبت كفاءة نظام **HDFS** في تخزين البيانات، و **YARN** في إدارة الموارد. كما أظهرت النتائج أن الرواية تتميز بـ:

- السرد بصيغة المتكلم (هيمنة الضمائر الشخصية).
- الطابع المأساوي والقوطي (غلبة الكلمات السلبية).
- محورية العلاقات الإنسانية (Elizabeth, Clerval, Justine).
- قيمة العلم والمسؤولية (knowledge, science, discovery).

وأخيرًا، أكد المشروع على أهمية **Data Cleaning** للحصول على تحليلات دقيقة، لأن **WordCount** الأساسي لا يقوم بتنظيف النص من علامات الترقيم والكلمات الوظيفية.

1.12 التوصيات

1. تنظيف النص قبل التحليل (Lowercase + إزالة الترقيم + إزالة Stop Words).
2. كتابة **MapReduce** مخصص بلغة Java أو Python (Hadoop Streaming).
3. استخدام **Hive** أو **Pig** لاستعلامات SQL-like.
4. تطبيق خوارزميات متقدمة مثل Sentiment Analysis و Topic Modeling.

1.13 المراجع

1. Project Gutenberg — Frankenstein (ID: 84): <https://www.gutenberg.org/ebooks/84>
2. /Apache Hadoop Documentation: <https://hadoop.apache.org>
3. Cloudera QuickStart VM Guide

تم إعداد التقرير بواسطة التاريخ:
