



مشروع عملي متكامل

Hadoop MapReduce

تحليل النصوص باستخدام

Big Data Text Analytics with Hadoop MapReduce

وثيقة تنفيذ ومناقشة المشروع

.....	اسم الطالب
Big Data	المقرر
Cloudera QuickStart VM 5.13	البيئة
سبتمبر 2026	تاريخ التنفيذ

المشروع الأساسي: Alice's Adventures in Wonderland | التحدي المتقدم: 4 كتب

1. فكرة المشروع ومتطلبات التسليم

يطبق المشروع دورة معالجة نصية كاملة باستخدام Hadoop: فحص Dataset حقيقية في Linux، رفعها إلى HDFS، تشغيل WordCount باستخدام MapReduce، متابعة المهمة من YARN، تحليل النتائج، ثم استخراجها مرة أخرى إلى Linux.

تم تنفيذ المشروع على كتاب جديد مختلف عن مثال الملزمة، ثم تنفيذ التحدي المتقدم باستخدام أربعة كتب.

المتطلبات التي تم توثيقها

- Dataset نصية حقيقية وفحص الحجم والمحتوى وعدد الأسطر والكلمات.
- إنشاء مسار منظم داخل HDFS ورفع البيانات إليه والتحقق منها.
- تشغيل WordCount ومتابعة Map وReduce حتى اكتمال الـ Job بنجاح.
- متابعة الـ Application داخل YARN.
- البحث عن كلمات محددة واستخراج أعلى 20 كلمة تكررًا.
- استخراج النتائج من HDFS إلى Linux باستخدام getmerge.
- تنفيذ التحدي المتقدم على أربعة كتب وتحليل النتائج المجمعة والمقارنة بينها.

دورة المشروع

```
Dataset -> Linux Validation -> HDFS -> MapReduce -> YARN -> Analysis ->
getmerge -> Linux
```

Dataset 2. المشروع الأساسي - اختيار وفحص الـ

تم اختيار كتاب Alice's Adventures in Wonderland للكاتب Lewis Carroll من Project Gutenberg، واسم الملف المستخدم هو pg11.txt.

KB 171	3,762	29,569
حجم الملف	عدد الأسطر	عدد الكلمات

```
ls -lh pg11.txt
head -20 pg11.txt
tail -20 pg11.txt
wc -l pg11.txt
wc -w pg11.txt
```

```
File Edit View Search Terminal Help
[cloudera@quickstart ~]$ ls
2661-0.txt  ca_wpi.py  Documents  eclipse  enterprise-deployment.json  express-deployment.json  large.txt  mma.text  Music  pg11.txt  Public  stmohamed.txt  students.txt  Videos
cloudera-manager  Desktop  Downloads  enterprise-deployment.json  express-deployment.json  large.txt  mma.text  Mohamed.text  parcels  Pictures  Public  small.txt  students_from_hdfs.txt  students_templates  workspace
[cloudera@quickstart ~]$ ls -lh pg11.txt
ls: cannot access pg11.txt: No such file or directory
[cloudera@quickstart ~]$ ls -lh pg11.txt
-rw-rw-r-- 1 cloudera cloudera 171K Sep 22 08:00 pg11.txt
[cloudera@quickstart ~]$ head -20 pg11.txt
The Project Gutenberg eBook of Alice's Adventures in Wonderland

This eBook is for the use of anyone anywhere in the United States and
most other parts of the world at no cost and with almost no restrictions
whatsoever. You may copy it, give it away or re-use it under the terms
of the Project Gutenberg License included with this eBook or online
at www.gutenberg.org. If you are not located in the United States,
you will have to check the laws of the country where you are located
before using this eBook.

Title: Alice's Adventures in Wonderland

Author: Lewis Carroll

Release date: June 27, 2008 [eBook #11]
Most recently updated: June 26, 2025

Language: English
[cloudera@quickstart ~]$ tail -20 pg11.txt
Gutenberg concept of a library of electronic works that could be
freely shared with anyone. For forty years, he produced and
distributed Project Gutenberg eBooks with only a loose network of
volunteer support.

Project Gutenberg eBooks are often created from several printed
editions, all of which are confirmed as not protected by copyright in
the U.S. unless a copyright notice is included. Thus, we do not
necessarily keep eBooks in compliance with any particular paper
edition.

Most people start at our website which has the main PG search
facility: www.gutenberg.org.

This website includes information about Project Gutenberg,
including how to make donations to the Project Gutenberg Literary
Archive Foundation, how to help produce our new eBooks, and how to
subscribe to our email newsletter to hear about new eBooks.

[cloudera@quickstart ~]$ wc -l pg11.txt
3762 pg11.txt
[cloudera@quickstart ~]$ wc -w pg11.txt
bash: wc: command not found
[cloudera@quickstart ~]$ wc -w nml.txt
```

لقطة فعلية لفحص الملف وعرض عنوان الكتاب وعدد الأسطر والكلمات.

تم الاعتماد في التقرير على النتائج الصحيحة النهائية، مع استبعاد أوامر الكتابة الخاطئة التي تم تصحيحها أثناء التنفيذ.

3. رفع الكتاب إلى HDFS وتشغيل WordCount

تم إنشاء مسار HDFS خاص بالمشروع، ثم نسخ الكتاب إليه وتشغيل برنامج WordCount الجاهز ضمن أمثلة Hadoop.

```
hdfs dfs -mkdir -p /bigdata/alice/input
hdfs dfs -cp bigdata/alice/input/pg11.txt /bigdata/alice/input/
hdfs dfs -ls /bigdata/alice/input

hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount
/bigdata/alice/input /bigdata/alice/output
```

```
[cloudera@quickstart ~]$ hdfs dfs -cp bigdata/alice/input/pg11.txt /bigdata/alice/
input/
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/alice/input
Found 1 items
-rw-r--r-- 1 cloudera supergroup 174311 2026-09-22 09:03 /bigdata/alice/in
put/pg11.txt
[cloudera@quickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
wordcount \
/bigdata/alice/input \
/bigdata/alice/output
26/09/22 09:06:17 INFO client.RMPProxy: Connecting to ResourceManager at /0.0.0.0:8032
26/09/22 09:06:18 INFO input.FileInputFormat: Total input paths to process : 1
26/09/22 09:06:18 WARN hdfs.DFSClient: Caught exception
java.lang.InterruptedException
    at java.lang.Object.wait(Native Method)
    at java.lang.Thread.join(Thread.java:1281)
    at java.lang.Thread.join(Thread.java:1355)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.closeResponder(DFSOutputStream.java:967)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.endBlock(DFSOutputStream.java:705)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.run(DFSOutputStream.java:894)
26/09/22 09:06:18 WARN hdfs.DFSClient: Caught exception
java.lang.InterruptedException
    at java.lang.Object.wait(Native Method)
    at java.lang.Thread.join(Thread.java:1281)
    at java.lang.Thread.join(Thread.java:1355)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.closeResponder(DFSOutputStream.java:967)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.endBlock(DFSOutputStream.java:705)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.run(DFSOutputStream.java:894)
26/09/22 09:06:18 INFO mapreduce.JobSubmitter: number of splits:1
26/09/22 09:06:19 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1790087908353_0001
26/09/22 09:06:20 INFO impl.YarnClientImpl: Submitted application application_1790087908353_0001
26/09/22 09:06:20 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/application_1790087908353_0001/
26/09/22 09:06:20 INFO mapreduce.Job: Running job: job_1790087908353_0001
26/09/22 09:06:32 INFO mapreduce.Job: Job job_1790087908353_0001 running in uber mode : false
26/09/22 09:06:32 INFO mapreduce.Job: map 0% reduce 0%
26/09/22 09:06:44 INFO mapreduce.Job: map 100% reduce 0%
26/09/22 09:06:56 INFO mapreduce.Job: map 100% reduce 100%
26/09/22 09:06:57 INFO mapreduce.Job: Job job_1790087908353_0001 completed successfully
26/09/22 09:06:57 INFO mapreduce.Job: Counters: 49
```

تشغيل WordCount على كتاب Alice ووصول التنفيذ إلى 100% map و 100% reduce.

النتيجة النهائية للمهمة: Job completed successfully.

4. إحصائيات Job والناتج داخل HDFS

3,762	29,569	5,973
Map Input Records	Map Output Records	Reduce Output Records

تطابق Map Output Records مع عدد الكلمات المحسوب مسبقًا بواسطة wc -w، وهو تحقق عملي مفيد من المعالجة.

```

joo counters
  Launched map tasks=1
  Launched reduce tasks=1
  Data-local map tasks=1
  Total time spent by all maps in occupied slots (ms)=8927
  Total time spent by all reduces in occupied slots (ms)=9401
  Total time spent by all map tasks (ms)=8927
  Total time spent by all reduce tasks (ms)=9401
  Total vcore-milliseconds taken by all map tasks=8927
  Total vcore-milliseconds taken by all reduce tasks=9401
  Total megabyte-milliseconds taken by all map tasks=9141248
  Total megabyte-milliseconds taken by all reduce tasks=9626624
Map-Reduce Framework
  Map input records=3762
  Map output records=29569
  Map output bytes=287619
  Map output materialized bytes=84931
  Input split bytes=125
  Combine input records=29569
  Combine output records=5973
  Reduce input groups=5973
  Reduce shuffle bytes=84931
  Reduce input records=5973
  Reduce output records=5973
  Spilled Records=11946
  Shuffled Maps =1
  Failed Shuffles=0
  Merged Map outputs=1
  GC time elapsed (ms)=210
  CPU time spent (ms)=3960
  Physical memory (bytes) snapshot=356786176
  Virtual memory (bytes) snapshot=3017277440
  Total committed heap usage (bytes)=226627584
Shuffle Errors
  BAD_ID=0
  CONNECTION=0
  IO_ERROR=0
  WRONG_LENGTH=0
  WRONG_MAP=0
  WRONG_REDUCE=0
File Input Format Counters
  Bytes Read=174311
File Output Format Counters
  Bytes Written=61440
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/alice/output
Found 2 items

```

Counters الخاصة بالمهمة والتحقق من ملفات output.

العنصر	الدلالة
SUCCESS_	إشارة إلى أن الـ Job انتهى بنجاح.
part-r-00000	ملف النتائج الفعلي الذي يحتوي على الكلمة وعدد مرات ظهورها.
Failed Shuffles = 0	لا توجد أخطاء Shuffle في المهمة.

YARN . متابعة المهمة باستخدام

تم فتح واجهة YARN لمتابعة الـ Application الخاصة بـ WordCount. تُظهر اللقطة أن نوع التطبيق MAPREDUCE. وأن الحالة النهائية SUCCEEDED / FINISHED.

```
http://localhost:8088
Application: application_1790087908353_0001
```

The screenshot shows the Cloudera Manager web interface. The 'All Applications' page displays a table of application metrics. The application 'application_1790087908353_0001' is listed with a status of 'SUCCEEDED'. The table includes columns for various metrics such as App Submitted, App Pending, App Running, App Completed, Containers Running, Memory Used, Memory Total, Memory Reserved, VCores Used, VCores Total, and VCores Reserved. The application is also shown in the 'User Metrics for dr.who' section.

Cluster Metrics											
Apps Submitted	Apps Pending	Apps Running	Apps Completed	Containers Running	Memory Used	Memory Total	Memory Reserved	VCores Used	VCores Total	VCores Reserved	
1	0	0	1	0	0 B	8 GB	0 B	0	8	0	

Cluster Nodes Metrics											
Active Nodes	Decommissioning Nodes	Decommissioned Nodes	Lost Nodes	Unhealthy Nodes	Rebooted Nodes						
1	0	0	0	0	0						

User Metrics for dr.who											
Apps Submitted	Apps Pending	Apps Running	Apps Completed	Containers Running	Containers Pending	Containers Reserved	Memory Used	Memory Pending	Memory Reserved	VCores Used	VCores Pending
0	0	0	0	0	0	0	0 B	0 B	0 B	0	0

ID	User	Name	Application Type	Queue	StartTime	FinishTime	State	FinalStatus	Running Containers	Allocated CPU VCores	Allocated Memory MB	Reserved CPU VCores	Reserved Memory MB	Progress	Tracking UI
application_1790087908353_0001	cloudera	word count	MAPREDUCE	root.cloudera	Tue Sep 22 09:06:19 -0700 2026	Tue Sep 22 09:06:55 -0700 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A		History

واجهة YARN - متابعة Application الخاصة بالمشروع الأساسي.

دور YARN: إدارة الموارد، جدولة وتشغيل المهام، ومتابعة حالة تطبيق MapReduce.

6. تحليل الكلمات والشخصيات

تم البحث داخل نتائج WordCount عن مجموعة كلمات مرتبطة بشخصيات الكتاب باستخدام grep.

```
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Alice"
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Rabbit"
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Queen"
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "King"
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Hatter"
```

الكلمة	العدد المباشر في WordCount
Alice	221
Rabbit	30
Queen	34
King	27
Hatter	24

```
File Edit View Search Terminal Help
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | head -20
cat: /bigdata/alice/output/part-r-00000: No such file or directory
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | head -20
#11 1
#516, 1
#5,000 1
(s1 1
(082) 1
(Alice 4
(And, 1
(As 1
(Before 1
(Dinah 1
(For, 1
(He 1
(If 1
(In 1
(It 1
(Sounds 1
(The 3
(We 1
(Which 2
( with 1
cat: Unable to write to output stream.
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Alice"
(Alice 4
Alice 221
Alice! 3
Alice! 1
Alice's 2
Alice)-and 1
Alice, 76
Alice,) 2
Alice. 54
Alice: 7
Alice; 16
Alice's 11
Alice's, 1
"Alice!" 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/alice/output/part-r-00000 | grep -w "Rabbit"
Rabbit 30
Rabbit, 8
Rabbit-Hole 2
Rabbit. 1
```

جزء من البحث الفعلي عن الكلمات داخل ملف النتائج.

7. أعلى 20 كلمة وملاحظة تنظيف البيانات

```
hdfs dfs -cat /bigdata/alice/output/part-r-00000 | sort -k2 -nr | head -20
```

#	الكلمة	التكرار	#	الكلمة	التكرار
1	the	1683	11	you	306
2	and	783	12	I	249
3	to	778	13	as	246
4	a	667	14	that	225
5	of	604	15	Alice	221
6	she	485	16	with	214
7	said	416	17	at	209
8	in	406	18	her	204
9	it	357	19	had	176
10	was	329	20	all	168

WordCount الأساسي لا ينظف علامات الترقيم؛ لذلك Alice و Alice و Alice. تظهر كقيم منفصلة. هذه ملاحظة مهمة عند تفسير النتائج.

Linux إلى HDFS 8. استخراج النتائج من

بعد اكتمال التحليل تم دمج مخرجات HDFS في ملف محلي واحد لتسهيل التسليم والمراجعة.

```
cd /home/cloudera
hdfs dfs -getmerge /bigdata/alice/output alice_wordcount.txt
ls -lh alice_wordcount.txt
head -20 alice_wordcount.txt
pwd
```

alice_wordcount.txt	KB 60	5,973
ملف النتائج	الحجم	عدد النتائج

```
File Edit View Search Terminal Help
[cloudera@quickstart ~]$ cd /home/cloudera
[cloudera@quickstart ~]$ hdfs dfs -getmerge /bigdata/alice/output alice_wordcount.txt
[cloudera@quickstart ~]$ ls -lh alice_wordcount.txt
-rw-r--r-- 1 cloudera cloudera 60K Sep 22 09:46 alice_wordcount.txt
[cloudera@quickstart ~]$ head -20 alice_wordcount.txt
#11) 1
#516, 1
$5,000) 1
($1 1
(862) 1
(Alice 4
(And, 1
(As 1
(Before 1
(Dinah 1
(For, 1
(He 1
(If 1
(In 1
(It 1
(Sounds 1
(The 3
(We 1
(Which 2
( with 1
[cloudera@quickstart ~]$ pwd
/home/cloudera
[cloudera@quickstart ~]$ ls
1661-0.txt cloudera-manager Desktop Downloads enterprise-deployment.json kerberos lib Mohammed.text parcels Pictures small.txt students_from_hdfs.txt Templates workspace
alice_wordcount.txt cm_api.py Documents eclipse express-deployment.json large.txt mm.txt Music pg11.txt Public stmohammed.text students.txt Videos
[cloudera@quickstart ~]$
```

استخراج ملف النتائج النهائي إلى /home/cloudera/

9. إجابات مختصرة لأسئلة المناقشة الأساسية

السؤال	الإجابة المختصرة
ما أكثر كلمة تكرارًا؟	the - ظهرت 1683 مرة.
ما الكلمات المختارة ونتائجها؟	Alice=221, Rabbit=30, Queen=34, King=27, Hatter=24.
ما الفرق بين ملف Linux وملف HDFS؟	الأول موجود في نظام الملفات المحلي، والثاني نسخة داخل HDFS مخصصة لمعالجة Hadoop.
ما وظيفة MapReduce؟	تنفيذ المعالجة على مراحل Mapper ثم Shuffle ثم Reducer لإنتاج WordCount.
ما وظيفة YARN؟	إدارة موارد وتشغيل ومراقبة تطبيق MapReduce.
أين توجد النتيجة النهائية في HDFS؟	bigdata/alice/output/part-r-00000/
ما ملف النتيجة المحلي؟	home/cloudera/alice_wordcount.txt/

نقطة مهمة للمناقشة

إذا سُئلت لماذا تظهر Alice بأكثر من شكل، فالإجابة أن WordCount الجاهز يقسم النص حسب المسافات ولا ينفذ تنظيفًا متقدمًا لعلامات الترقيم؛ لذلك جودة التحليل ترتبط أيضًا بمرحلة Data Cleaning.

10. التحدي المتقدم - تحليل أربعة كتب

تم توسيع التجربة من كتاب واحد إلى أربعة كتب نصية من Project Gutenberg، وهو ما يقرب التجربة من فكرة معالجة بيانات متعددة الملفات.

الكتاب	الملف	عدد الكلمات
Alice's Adventures in Wonderland	pg11.txt	29,569
Frankenstein	pg84.txt	78,106
Pride and Prejudice	pg1342.txt	130,416
Dracula	pg345.txt	164,356
الإجمالي	-	402,447

أكبر كتاب من حيث عدد الكلمات هو Dracula بعدد 164,356 كلمة.

```
File Edit View Search Terminal Help
[cloudera@quickstart ~]$ ls -lh pg11.txt pg84.txt pg1342.txt pg345.txt
-rw-rw-r-- 1 cloudera cloudera 171K Sep 22 08:00 pg11.txt
-rw-rw-r-- 1 cloudera cloudera 755K Sep 22 10:59 pg1342.txt
-rw-rw-r-- 1 cloudera cloudera 870K Sep 22 10:59 pg345.txt
-rw-rw-r-- 1 cloudera cloudera 439K Sep 22 10:59 pg84.txt
[cloudera@quickstart ~]$ wc -w pg11.txt pg84.txt pg1342.txt pg345.txt
 29569 pg11.txt
 78106 pg84.txt
130416 pg1342.txt
164356 pg345.txt
402447 total
[cloudera@quickstart ~]$ head -20 pg11.txt
The Project Gutenberg eBook of Alice's Adventures in Wonderland

This eBook is for the use of anyone anywhere in the United States and
most other parts of the world at no cost and with almost no restrictions
whatsoever. You may copy it, give it away or re-use it under the terms
of the Project Gutenberg License included with this eBook or online
at www.gutenberg.org. If you are not located in the United States,
you will have to check the laws of the country where you are located
before using this eBook.

Title: Alice's Adventures in Wonderland
Author: Lewis Carroll

Release date: June 27, 2008 [eBook #11]
Most recently updated: June 26, 2025

Language: English
[cloudera@quickstart ~]$ head -20 pg84.txt
The Project Gutenberg eBook of Frankenstein; or, the modern Prometheus

This eBook is for the use of anyone anywhere in the United States and
most other parts of the world at no cost and with almost no restrictions
whatsoever. You may copy it, give it away or re-use it under the terms
of the Project Gutenberg License included with this eBook or online
at www.gutenberg.org. If you are not located in the United States,
you will have to check the laws of the country where you are located
before using this eBook
```

التحقق من الملفات الأربعة وحساب عدد الكلمات الإجمالي.

HDFS 11. رفع الكتب الأربعة إلى

```
hdfs dfs -mkdir -p /bigdata/books/input
hdfs dfs -put pg11.txt pg84.txt pg1342.txt pg345.txt /bigdata/books/input
hdfs dfs -ls -h /bigdata/books/input
```

تم التحقق من وجود الملفات الأربعة داخل المسار /bigdata/books/input/ قبل تشغيل Job التحدي.

```
at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.closeResponder(DFSOutputStream.java:967)
at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.endBlock(DFSOutputStream.java:705)
at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.run(DFSOutputStream.java:894)
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/books/input
Found 4 items
-rw-r--r-- 1 cloudera supergroup 170.2 K 2026-09-22 11:36 /bigdata/books/input/pg11.txt
-rw-r--r-- 1 cloudera supergroup 754.3 K 2026-09-22 11:36 /bigdata/books/input/pg1342.txt
-rw-r--r-- 1 cloudera supergroup 869.5 K 2026-09-22 11:36 /bigdata/books/input/pg345.txt
-rw-r--r-- 1 cloudera supergroup 438.4 K 2026-09-22 11:36 /bigdata/books/input/pg84.txt
[cloudera@quickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
wordcount \
/bigdata/books/input \
/bigdata/books/output
26/09/22 11:42:28 INFO client.RMProxy: Connecting to ResourceManager at /0.0.0.0:8032
26/09/22 11:42:29 INFO input.FileInputFormat: Total input paths to process : 4
26/09/22 11:42:29 WARN hdfs.DFSClient: Caught exception
java.lang.InterruptedExcep
at java.lang.Object.wait(Native Method)
at java.lang.Thread.join(Thread.java:1281)
at java.lang.Thread.join(Thread.java:1355)
at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.closeResponder(DFSOutputStream.java:967)
at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.endBlock(DFSOutputStream.java:705)
at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.run(DFSOutputStream.java:894)
26/09/22 11:42:29 WARN hdfs.DFSClient: Caught exception
java.lang.InterruptedExcep
at java.lang.Object.wait(Native Method)
at java.lang.Thread.join(Thread.java:1281)
at java.lang.Thread.join(Thread.java:1355)
at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.closeResponder(DFSOutputStream.java:967)
at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.endBlock(DFSOutputStream.java:705)
at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.run(DFSOutputStream.java:894)
26/09/22 11:42:29 INFO mapreduce.JobSubmitter: number of splits:4
26/09/22 11:42:30 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1790087908353_0002
26/09/22 11:42:30 INFO impl.YarnClientImpl: Submitted application application_1790087908353_0002
```

الجزء الصحيح من التنفيذ: ظهور أربعة ملفات داخل HDFS وبدء Job متعدد الملفات.

4	4	402,447
Input Paths	Input Splits	إجمالي الكلمات

12. تشغيل MapReduce على الكتب الأربعة

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount
/bigdata/books/input /bigdata/books/output
```

عالج Hadoop الملفات الأربعة في Job واحدة. يظهر التقدم 25% ثم 50% ثم 75% ثم 100%، ثم مرحلة Reduce حتى الاكتمال.

```
at org.apache.hadoop.mapreduce.lib.output.StreamOutput$DataStreamer.run(StreamOutput$DataStreamer.java:894)
26/09/22 11:42:29 INFO mapreduce.JobSubmitter: number of splits:4
26/09/22 11:42:30 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1790087908353_0002
26/09/22 11:42:30 INFO impl.YarnClientImpl: Submitted application application_1790087908353_0002
26/09/22 11:42:30 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/application_1790087908353_0002/
26/09/22 11:42:30 INFO mapreduce.Job: Running job: job_1790087908353_0002
26/09/22 11:42:41 INFO mapreduce.Job: Job job_1790087908353_0002 running in uber mode : false
26/09/22 11:42:41 INFO mapreduce.Job: map 0% reduce 0%
26/09/22 11:43:18 INFO mapreduce.Job: map 25% reduce 0%
26/09/22 11:43:22 INFO mapreduce.Job: map 50% reduce 0%
26/09/22 11:43:23 INFO mapreduce.Job: map 75% reduce 0%
26/09/22 11:43:25 INFO mapreduce.Job: map 100% reduce 0%
26/09/22 11:43:33 INFO mapreduce.Job: map 100% reduce 100%
26/09/22 11:43:33 INFO mapreduce.Job: Job job_1790087908353_0002 completed successfully
26/09/22 11:43:34 INFO mapreduce.Job: Counters: 50
  File System Counters
    FILE: Number of bytes read=759117
    FILE: Number of bytes written=2236407
    FILE: Number of read operations=0
    FILE: Number of large read operations=0
    FILE: Number of write operations=0
    HDFS: Number of bytes read=2286433
    HDFS: Number of bytes written=306968
    HDFS: Number of read operations=15
    HDFS: Number of large read operations=0
    HDFS: Number of write operations=2
  Job Counters
    Killed map tasks=1
```

تقدم Job التحدي حتى 100% reduce / 100% map وانتهائه بنجاح.

Job job_1790087908353_0002 completed successfully

13. إحصائيات التحدي المتقدم

402,447	34,537	4
Map Output Records	Reduce Output Records	Shuffled Maps

المؤشر	القيمة
Total input paths to process	4
number of splits	4
Map input records	42,271
Map output records	402,447
Reduce input groups	34,537
Reduce output records	34,537
Failed Shuffles	0

القيمة 402,447 تطابق مجموع كلمات الكتب الأربعة المحسوب مسبقاً بواسطة $wc -w$ ، مما يوفر تحققاً إضافياً من صحة المعالجة.

```

File Edit View Search Terminal Help
Job Counters
  Killed map tasks=1
  Launched map tasks=5
  Launched reduce tasks=1
  Data-local map tasks=5
  Total time spent by all maps in occupied slots (ms)=154823
  Total time spent by all reduces in occupied slots (ms)=12505
  Total time spent by all map tasks (ms)=154823
  Total time spent by all reduce tasks (ms)=12505
  Total vcore-milliseconds taken by all map tasks=154823
  Total vcore-milliseconds taken by all reduce tasks=12505
  Total megabyte-milliseconds taken by all map tasks=158538752
  Total megabyte-milliseconds taken by all reduce tasks=12885120
Map-Reduce Framework
  Map input records=42271
  Map output records=402447
  Map output bytes=3831719
  Map output materialized bytes=759135
  Input split bytes=503
  Combine input records=402447
  Combine output records=51840
  Reduce input groups=34537
  Reduce shuffle bytes=759135
  Reduce input records=51840
  Reduce output records=34537
  Spilled Records=103680
  Shuffled Maps =4
  Failed Shuffles=0
  Merged Map outputs=4
  GC time elapsed (ms)=1929
  CPU time spent (ms)=11010
  Physical memory (bytes) snapshot=974524416
  Virtual memory (bytes) snapshot=7529160704
  Total committed heap usage (bytes)=723861504
Shuffle Errors
  BAD_ID=0
  CONNECTION=0
  IO_ERROR=0
  WRONG_LENGTH=0
  WRONG_MAP=0
  WRONG_REDUCE=0
File Input Format Counters
  Bytes Read=2285930

```

14. أعلى 20 كلمة عبر الكتب الأربعة

```
hdfs dfs -cat /bigdata/books/output/part-r-00000 | sort -k2 -nr | head -20
```

#	الكلمة	التكرار	#	الكلمة	التكرار
1	the	17,696	11	my	3,425
2	and	12,835	12	not	3,366
3	to	11,660	13	as	3,344
4	of	10,927	14	with	3,260
5	I	9,227	15	her	3,253
6	a	6,969	16	his	3,152
7	in	5,843	17	it	3,128
8	that	4,991	18	for	3,092
9	was	4,932	19	had	2,997
10	he	3,546	20	you	2,815

أكثر كلمة تكرارًا عبر جميع الكتب هي the بعدد 17,696 مرة.

15. مقارنة كلمة love بين الكتب

لتحقيق شرط المقارنة بين كتابين أو أكثر، تم تشغيل WordCount لكل كتاب بصورة منفصلة ثم البحث عن كلمة love.

الكتاب	love بالضبط	جميع الأشكال مع علامات الترقيم
Alice's Adventures in Wonderland	0	2
Frankenstein	41	59
Pride and Prejudice	64	102
Dracula	58	82

بالاعتماد على token المطابق تمامًا "love"، أعلى نتيجة هي Pride and Prejudice بعدد 64 مرة.

```
File Edit View Search Terminal Help
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/books/alice_output/part-r-00000 | grep -w "love"
love, 2
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/books/frankenstein_output/part-r-00000 | grep -w "love"
love, 41
love, 9
love," 1
love, 4
love; 3
love?" 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/books/pride_output/part-r-00000 | grep -w "love"
love, 64
love!" 1
love, 17
love," 1
love-making 1
love, 5
love," 3
love; 6
love? 1
love!" 2
love' 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/books/dracula_output/part-r-00000 | grep -w "love"
love, 58
love!" 1
love, 10
love--for 1
love--though 1
love-letter, 1
love-making, 1
love, 6
love," 1
love; 1
love' 1
[cloudera@quickstart ~]$
```

مخرجات grep الفعلية لمقارنة كلمة love بين الكتب.

اختلاف عمود "جميع الأشكال" سببه أن WordCount يعتبر love و love, و love. رموزًا مستقلة، وهو دليل عملي على أهمية Data Cleaning.

16. الاستنتاج النهائي وملفات التسليم

نجاح المشروع في تطبيق دورة البيانات كاملة من Linux إلى HDFS ثم MapReduce وYARN وتحليل النتائج واستخراجها. كما نجح التحدي في معالجة أربعة ملفات في Job واحدة بإجمالي 402,447 كلمة.

لماذا يصبح Hadoop أكثر فائدة مع زيادة البيانات؟

عند زيادة حجم البيانات وعدد الملفات يستطيع Hadoop تقسيم المدخلات إلى Input Splits وتشغيل مهام Map متعددة ثم تجميع النتائج عبر Shuffle وReduce. في بيئة موزعة حقيقية يمكن توزيع هذه المهام على عدة عقد بالتوازي، لذلك تتضح قيمة Hadoop أكثر كلما زادت كمية البيانات والعمل المطلوب.

الملفات النهائية

الغرض	الملف
Dataset المشروع الأساسي - Alice	pg11.txt
Frankenstein	pg84.txt
Pride and Prejudice	pg1342.txt
Dracula	pg345.txt
نتائج المشروع الأساسي	alice_wordcount.txt
نتائج الكتب الأربعة المجمعة	books_wordcount.txt

أرقام يجب تذكرها أثناء المناقشة

29,569	402,447	164,356
كلمات Alice	إجمالي 4 كتب	أكبر كتاب - Dracula

- المشروع الأساسي: Job_0001 - انتهى بنجاح، Map 100% / Reduce 100%.
- التحدي المتقدم: Job_0002 - أربعة Input Paths وأربعة Splits.
- أعلى كلمة في Alice: the = 1,683.

- أعلى كلمة في الكتب الأربعة: the = 17,696.

- مقارنة love: Alice=0, Frankenstein=41, Pride=64, Dracula=58.

- ملف النتائج داخل HDFS هو part-r-00000، وملف SUCCESS_ مجرد علامة نجاح.

هذه الوثيقة تجمع المتطلبات، الأوامر الصحيحة، لقطات التنفيذ الفعلية، النتائج، والتحدي المتقدم لتكون مرجعًا مباشرًا أثناء المناقشة.