

تقرير مشروع WordCount و Hadoop

تحليل النصوص باستخدام MapReduce و YARN

الملفات: pg11.txt و pg345.txt
الطالبان: سامر الأكحلي واخي محمد الأكحلي
المشرف: المهندس رمزي البازل

الملف الأول

pg11.txt
Alice's Adventures in Wonderland

الملف الثاني

pg345.txt
Dracula

السؤال الأول: ما أكثر الكلمات تكراراً في النص؟

pg11.txt
الكلمة الأكثر تكراراً: the

عدد التكرارات: 1683

pg345.txt
الكلمة الأكثر تكراراً: the

السؤال الثاني: كم مرة ظهرت الكلمات المحددة؟

القيم غير المتاحة في النتائج الموثقة لا تُستبدل بصفر افتراضي.

الكلمة	pg11.txt	pg345.txt
Lestrade	0	
London	1	27 مباشرة / 67 مع الصيغ المرتبطة بعلامات الترقيم
Sherlock	0	
Watson	0	
Holmes	0	

السؤال الثالث: ما الكلمات العشرون الأعلى تكراراً؟

pg11.txt
the 1683
and 783
to 778
a 667
of 604
she 485
said 416

in 406
it 357
was 329
you 306
I 249
as 246
that 225
Alice 221
with 214
at 209
her 204
had 176
all 168

pg345.txt

the 7436
and 5639
I 4495
to 4463
of 3679
a 2887
in 2385
that 2322
he 1948
was 1792
as 1447
is 1432
for 1419
it 1409
his 1363
not 1300
with 1260
we 1227

السؤال الرابع: ما الفرق بين ملف Linux وملف HDFS؟

ملف Linux

ملف محلي موجود على نظام الملفات في ال-VM، ويمكن قراءته أو معالجته مباشرة من البيئة المحلية.

ملف HDFS

ملف مخزن داخل Hadoop Distributed File System ويُستخدم كمدخل لمعالجة MapReduce.

الملف	المسار المحلي في Linux	مسار الإدخال في HDFS
pg11.txt	pg11.txt	bigdata/alice/input/pg11.txt/
pg345.txt	pg345.txt	bigdata/pg345/input/pg345.txt/

السؤال الخامس: ما وظيفة MapReduce في هذا المشروع؟

Map

تقرأ النص وتحول كل كلمة إلى زوج مثل:

(word, 1)

Shuffle / Combine

تجمع القيم الخاصة بالكلمة نفسها وتجهزها لمرحلة الاختزال.

Reduce

تحسب مجموع التكرارات وتخرج نتيجة مثل:

(the, 7436)

السؤال السادس: ما وظيفة YARN أثناء تنفيذ المهمة؟

يدير YARN موارد Hadoop وينسق تشغيل مهام MapReduce. كما يخصص الموارد، ويتابع حالة التطبيق، ويعرض نتيجة التنفيذ حتى انتهاء المهمة.

المهام الأساسية

- إدارة الموارد.
- تنسيق تشغيل مهام MapReduce.
- تخصيص الموارد للتطبيق.
- متابعة حالة التطبيق حتى الانتهاء.

حالات النجاح المتاحة

Application Type: MAPREDUCE

State: FINISHED

FinalStatus: SUCCEEDED

أضف لقطة شاشة لواجهة YARN أو سجل حالة التطبيق
يمكن إظهار Map 100% و Reduce 100% إذا كانت متاحة
YARN: الموارد والحالة والتنسيق 8

السؤال السابع: أين توجد النتيجة النهائية بعد انتهاء WordCount؟

الملف	مسار نتيجة HDFS	النسخة المحلية
pg11.txt	bigdata/alice/output/part-r-00000/	alice_wordcount.txt
pg345.txt	bigdata/pg345/output/part-r-00000/	pg345_wordcount.txt 198K ≈

يوجد الملف SUCCESS_ داخل مجلد الإخراج لإثبات نجاح المهمة، بينما part-r-00000 هو ملف النتائج الفعلي. أضف لقطة شاشة لمجلد الإخراج أو لمحتوى part-r-00000 النتيجة الفعلية: part-r-000009

ملخص سريع للحفظ

الملف	أعلى كلمة وعددها	مسار الإدخال في HDFS	مسار النتيجة	النسخة المحلية
pg11.txt	the — 1683	bigdata/alice/input/pg11.txt/	bigdata/alice/output/part-r-00000/	alice_wordcount.txt
pg345.txt	the — 7436	bigdata/pg345/input/pg345.txt/	bigdata/pg345/output/part-r-00000/	pg345_wordcount.txt ≈ 198K


الفكرة الأساسية

Linux يحفظ الملف محلياً، و HDFS يحفظ نسخة موزعة تستخدمها مهمة MapReduce.

علامة النجاح

SUCCESS_ يثبت نجاح المهمة، و part-r-00000 يحتوي النتائج.

المطلوب تسليمه يتم تسليم ملف:Dataset HDFS:



cloudera-quickstart-vm-5.13.0-0-vmware - VMware Workstation

File Edit View VM Tabs Help

Home cloudera-quickstart-vm-5....

Applications Places System Thu Sep 24, 12:24 PM cloudera

Browse and run installed applications cloudera@quickstart:~

File Edit View Search Terminal Help


```
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/sherlock/input
Found 1 items
-rw-r--r-- 1 cloudera supergroup      172 2026-09-18 12:59 /bigdata/sherlock
/input/1661-0.txt
[cloudera@quickstart ~]$
```

To direct input to this VM, click inside or press Ctrl+G.

Search

ENG 10:24 PM

HDFS مسار/bigdata/sherlock/input




The screenshot shows a Cloudera Quickstart VM window with a terminal running a MapReduce job. The output displays various metrics for the Map-Reduce Framework, including input/output records, bytes, and shuffle errors. Below the metrics, the command `hdfs dfs -ls /bigdata/sherlock/output` is executed, showing two files: `_SUCCESS` and `part-r-00000`.

```
cloudera-quickstart-vm-5.13.0-0-vmware - VMware Workstation
File Edit View VM Tabs Help
Applications Places System
cloudera@quickstart:~
File Edit View Search Terminal Help
Total megabyte-milliseconds taken by all map tasks=30755840
Total megabyte-milliseconds taken by all reduce tasks=8901632
Map-Reduce Framework
  Map input records=1
  Map output records=25
  Map output bytes=272
  Map output materialized bytes=214
  Input split bytes=130
  Combine input records=25
  Combine output records=16
  Reduce input groups=16
  Reduce shuffle bytes=214
  Reduce input records=16
  Reduce output records=16
  Spilled Records=32
  Shuffled Maps =1
  Failed Shuffles=0
  Merged Map outputs=1
  GC time elapsed (ms)=356
  CPU time spent (ms)=2970
  Physical memory (bytes) snapshot=413462528
  Virtual memory (bytes) snapshot=3132907520
  Total committed heap usage (bytes)=285212672
Shuffle Errors
  BAD_ID=0
  CONNECTION=0
  IO_ERROR=0
  WRONG_LENGTH=0
  WRONG_MAP=0
  WRONG_REDUCE=0
File Input Format Counters
  Bytes Read=172
File Output Format Counters
  Bytes Written=144
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/sherlock/output
Found 2 items
-rw-r--r-- 1 cloudera supergroup          0 2026-09-24 12:38 /bigdata/sherlock/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup       144 2026-09-24 12:38 /bigdata/sherlock/output/part-r-00000
[cloudera@quickstart ~]$
```

To direct input to this VM, click inside or press Ctrl+G.


MapReduce: /bigdata/sherlock/output مخرجات



The screenshot shows a VMware Workstation window titled "cloudera-quickstart-vm-5.13.0-0-vmware - VMware Workstation". Inside the VM, a terminal window titled "cloudera@quickstart:~" displays the output of a MapReduce job. The output includes log messages from the JobSubmitter and Job, followed by a summary of File System Counters, Job Counters, and Map-Reduce Framework statistics.

```
26/09/24 12:37:11 INFO mapreduce.JobSubmitter: number of splits:1
26/09/24 12:37:12 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1790187766543_0004
26/09/24 12:37:15 INFO impl.YarnClientImpl: Submitted application application_1790187766543_0004
26/09/24 12:37:15 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/application_1790187766543_0004/
26/09/24 12:37:15 INFO mapreduce.Job: Running job: job_1790187766543_0004
26/09/24 12:37:49 INFO mapreduce.Job: Job job_1790187766543_0004 running in uber mode : false
26/09/24 12:37:49 INFO mapreduce.Job:  map 0% reduce 0%
26/09/24 12:38:22 INFO mapreduce.Job:  map 100% reduce 0%
26/09/24 12:38:33 INFO mapreduce.Job:  map 100% reduce 100%
26/09/24 12:38:34 INFO mapreduce.Job: Job job_1790187766543_0004 completed successfully
26/09/24 12:38:35 INFO mapreduce.Job: Counters: 49
  File System Counters
    FILE: Number of bytes read=214
    FILE: Number of bytes written=287679
    FILE: Number of read operations=0
    FILE: Number of large read operations=0
    FILE: Number of write operations=0
    HDFS: Number of bytes read=302
    HDFS: Number of bytes written=144
    HDFS: Number of read operations=6
    HDFS: Number of large read operations=0
    HDFS: Number of write operations=2
  Job Counters
    Launched map tasks=1
    Launched reduce tasks=1
    Data-local map tasks=1
    Total time spent by all maps in occupied slots (ms)=30035
    Total time spent by all reduces in occupied slots (ms)=8693
    Total time spent by all map tasks (ms)=30035
    Total time spent by all reduce tasks (ms)=8693
    Total vcore-milliseconds taken by all map tasks=30035
    Total vcore-milliseconds taken by all reduce tasks=8693
    Total megabyte-milliseconds taken by all map tasks=30755840
    Total megabyte-milliseconds taken by all reduce tasks=8901632
  Map-Reduce Framework
    Map input records=1
    Map output records=25
    Map output bytes=272
    Map output materialized bytes=214
```

النتائج: عدد مرات ظهور الكلمات المطلوبة .لقطات شاشة:



```
cloudera-quickstart-vm-5.13.0-0-vmware - VMware Workstation
File Edit View VM Tabs Help
Applications Places System
cloudera@quickstart:~
Browse and run installed applications
File Edit View Search Terminal Help
Shuffle Errors
BAD_ID=0
CONNECTION=0
IO_ERROR=0
WRONG_LENGTH=0
WRONG_MAP=0
WRONG_REDUCE=0
File Input Format Counters
Bytes Read=172
File Output Format Counters
Bytes Written=144
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/sherlock/output
Found 2 items
-rw-r--r-- 1 cloudera supergroup 0 2026-09-24 12:38 /bigdata/sherlock/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup 144 2026-09-24 12:38 /bigdata/sherlock/output/part-r-00000
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head -20
Watson 3
Sherlock 3
Holmes 3
The 2
of 2
London 2
Project 1
Lestrade 1
Holmes, 1
Gutenberg 1
eBook 1
Doyle. 1
Conan 1
by 1
Arthur 1
Adventures 1
[cloudera@quickstart ~]$
```

cloudera-quickstart-vm-5.13.0-0-vmware - VMware Workstation

File Edit View VM Tabs Help

Home x cloudera-quickstart-vm-5...

Applications Places System Thu Sep 24, 12:51 PM cloudera

Change desktop appearance and behavior, get help, or log out cloudera@quickstart:~

File Edit View Search Terminal Help

```
File Input Format Counters
Bytes Read=172
File Output Format Counters
Bytes Written=144
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/sherlock/output
Found 2 items
-rw-r--r-- 1 cloudera supergroup          0 2026-09-24 12:38 /bigdata/sherlock/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup        144 2026-09-24 12:38 /bigdata/sherlock/output/part-r-000000
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | sort -k2 -nr | head -20
Watson 3
Sherlock 3
Holmes 3
The 2
of 2
London 2
Project 1
Lestrade 1
Holmes, 1
Gutenberg 1
eBook 1
Doyle. 1
Conan 1
by 1
Arthur 1
Adventures 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | grep -w -E "Lestrade|London|Sherlock|Watson|Holmes"
Holmes 3
Holmes, 1
Lestrade 1
London 2
Sherlock 3
Watson 3
[cloudera@quickstart ~]$
```

To direct input to this VM, click inside or press Ctrl+G.

Search

10:51 PM

نقطة الشاشة البيانات داخل ، تنفيذ MapReduce ، Job داخل YARN

cloudera-quickstart-vm-5.13.0-0-vmware - VMware Workstation

File Edit View VM Tabs Help

Home Applications Places System

Mozilla Firefox

http://quick...766543_0001

quickstart.cloudera:8088/cluster/app/application_179018776654

Cloudera Hue Hadoop HBase Impala Spark Solr Oozie Cloudera Manager Getting Started

Logged in as: dr.who

 **hadoop**

Cluster

- About
- Nodes
- Applications
 - NEW
 - NEW SAVING
 - SUBMITTED
 - ACCEPTED
 - RUNNING
 - FINISHED
 - FAILED
 - KILLED
- Scheduler

Tools

Application Overview

User:	cloudera
Name:	word count
Application Type:	MAPREDUCE
Application Tags:	
State:	FINISHED
FinalStatus:	SUCCEEDED
Started:	Wed Sep 23 13:03:13 -0700 2026
Elapsed:	1mins, 19sec
Tracking URL:	History
Diagnostics:	

Application Metrics

Total Resource Preempted:	<memory:0, vCores:0>
Total Number of Non-AM Containers Preempted:	0
Total Number of AM Containers Preempted:	0
Resource Preempted from Current Attempt:	<memory:0, vCores:0>
Number of Non-AM Containers Preempted from Current Attempt:	0
Aggregate Resource Allocation:	219517 MB-seconds, 128 vcore-seconds


Cloud... cloudera cloude... All Ap... cloude... cloude... Cloud... Mozill... Cloud... Cloud... Cloud... Cloud... Cloud...

To direct input to this VM, click inside or press Ctrl+G.

Search

10:56 PM

ملف النتائج sherlock_wordcount.txt .



```
cloudera-quickstart-vm-5.13.0-0-vmware - VMware Workstation
File Edit View VM Tabs Help
Home Applications Places System
Browse and run installed applications cloudera@quickstart:~
File Edit View Search Terminal Help
Holmes 3
The 2
of 2
London 2
Project 1
Lestrade 1
Holmes, 1
Gutenberg 1
eBook 1
Doyle. 1
Conan 1
by 1
Arthur 1
Adventures 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w -E "Lestrade|London|Sherlock|Watson|Holmes"
Holmes 3
Holmes, 1
Lestrade 1
London 2
Sherlock 3
Watson 3
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | head -20
Adventures 1
Arthur 1
Conan 1
Doyle. 1
Gutenberg 1
Holmes 3
Holmes, 1
Lestrade 1
London 2
Project 1
Sherlock 3
The 2
Watson 3
by 1
eBook 1
of 2
[cloudera@quickstart ~]$
```

تحليل مختصر

تم استخدام مجموعة بيانات كتاب Sherlock Holmes وتخزينها داخل HDFS في المسار `/bigdata/sherlock/input`. بعد ذلك تم تنفيذ خوارزمية WordCount باستخدام MapReduce لحساب عدد مرات ظهور الكلمات في النص. قام YARN بإدارة موارد المهمة وتشغيلها ومتابعة تنفيذها حتى اكتمالها بنجاح. تم تخزين مخرجات المعالجة في المسار `/bigdata/sherlock/output`، ثم استخراج النتائج في ملف

sherlock_wordcount.txt أظهرت النتائج الكلمات الأكثر تكرارًا في النص، كما تم استخراج عدد مرات ظهور الكلمات المطلوبة لestrade و: London وSherlock وWatson وHolmes.

والأفضل نضيف الأرقام التي حصلنا عليها:

ظهرت الكلمات المطلوبة بالعدد التالي Lestrade = 1، London = 2، Sherlock = 3، Watson = 3، Holmes = 3، مع ملاحظة أن Holmes، ظهرت مرة إضافية بسبب وجود الفاصلة كجزء من الكلمة في مخرجات WordCount.