

تقرير المشروع العملي المتكامل

تحليل البيانات النصية الضخمة

تطبيق WordCount باستخدام Hadoop و MapReduce

على كتاب Frankenstein; or, The Modern Prometheus

إعداد الطالب: محمد اليافعي

الكتاب الإلكتروني رقم 84 — مشروع عملي على بيئة Cloudera QuickStart VM

VMware | تاريخ التنفيذ المدون: 23 سبتمبر 2026

المادة: غير مدونة في النسخة الأصلية | الدكتور: غير مدون | الرقم الجامعي: غير مدون

محتويات التقرير

1	الملخص التنفيذي	1
1	هدف المشروع ونطاقه	2
1	البيئة ومجموعة البيانات	3
1	3.1 بيئة التنفيذ	3.1
1	3.2 مصدر البيانات وفحصها	3.2
2	4 مسار البيانات ومعمارية التنفيذ	4
2	4.1 مسار البيانات	4.1
2	4.2 دور المكونات	4.2
2	5 خطوات التنفيذ	5
2	5.1 إنشاء مجلد الإدخال في HDFS	5.1
2	5.2 التحقق من خدمات المعالجة	5.2
3	5.3 تشغيل WordCount	5.3
3	5.4 استخراج ملف النتائج	5.4
3	6 النتائج والتحقق منها	6
3	6.1 مؤشرات التنفيذ	6.1
4	6.2 ما الذي تثبته النتائج؟	6.2
4	7 الخلاصة	7
4	8 الملفات والمسارات الناتجة	8
5	9 معجم المصطلحات	9
5	10 المراجع	10
5	11 لقطات التنفيذ	11
6	11.1 لقطة 1 — تنفيذ WordCount	11.1
7	11.2 لقطة 2 — متابعة التطبيق في YARN	11.2
8	11.3 لقطة 3 — عرض نتائج المهمة	11.3

1 الملخص التنفيذي

يعرض هذا التقرير تنفيذ تجربة تحليل نصي موزع على رواية **Frankenstein; or, The Modern Prometheus** للكاتبة Mary Shelley. نُزل النص إلى نظام Linux، ثم نُقل إلى نظام الملفات الموزع HDFS، وشُغل عليه برنامج WordCount باستخدام Hadoop MapReduce، بينما تولّت YARN إدارة موارد تنفيذ المهمة ومراقبة حالتها. بعد اكتمال المعالجة، جُمعت ملفات النتائج من HDFS إلى ملف محلي لإتاحة فحصها.

تشير سجلات التشغيل المدرجة في التقرير الأصلي إلى أن المهمة اكتملت بنجاح بنسبة 100% في مرحلتي Map وReduce. عالجت مرحلة Map عدد 7,649 سجل إدخال وأنتجت 75,721 سجل وسيط، ثم كتب Reducer عدد 12,152 سجل نتيجة. هذه الأرقام تصف سجلات المعالجة ومفاتيح الناتج، ولا تعني أن الناتج يحتوي العدد نفسه من الكلمات المختلفة التي قرأها القارئ؛ فعدد سجلات Reduce يمثل عدد المفاتيح النصية التي ظهرت في المخرجات وفق طريقة التقسيم المستخدمة.

2 هدف المشروع ونطاقه

يهدف المشروع إلى تطبيق دورة عمل مختصرة لتحليل ملف نصي كبير نسبياً باستخدام مكونات Hadoop الأساسية. ويشمل ذلك الحصول على مجموعة البيانات وفحصها، ونقلها من نظام الملفات المحلي إلى HDFS، وتشغيل مهمة MapReduce، والتحقق من حالة التنفيذ، ثم استخراج ملف النتائج.

تقتصر التجربة على حساب تكرار الرموز النصية بواسطة WordCount الجاهز المرفق مع Hadoop. لم يتضمن الملف المصدر معالجة لغوية متقدمة؛ لذلك فإن اختلاف حالة الأحرف أو علامات الترقيم قد ينتج مفاتيح منفصلة. كما لم يتضمن التقرير الأصلي جدولاً كاملاً لأعلى الكلمات أو قائمة الكلمات الرقمية، ولهذا لا يستنتج هذا الإصدار نتائج تفصيلية غير ظاهرة في سجلات التنفيذ.

3 البيئة ومجموعة البيانات

3.1 بيئة التنفيذ

نُفذ العمل داخل جهاز افتراضي يعمل عبر VMware باستخدام Cloudera QuickStart VM. وتضم البيئة خدمات Hadoop اللازمة للتخزين والمعالجة وجدولة الموارد. أشار سجل التنفيذ إلى أن خدمات YARN ResourceManager وNodeManager وMapReduce History Server كانت في حالة تشغيل قبل بدء المهمة.

3.2 مصدر البيانات وفحصها

مجموعة البيانات هي النص الإنجليزي الكامل للكتاب الإلكتروني **Frankenstein; or, The Modern Prometheus**، المعروف بالرقم 84 في مشروع Gutenberg. حفظ الملف محلياً باسم frankenstein.txt. أظهرت أوامر الفحص الواردة في التقرير حجماً مقداره 437,869 بايت، أي نحو 428 كيلوبايت بالتقريب، و7,649 سطراً، و75,721 كلمة وفق أداة wc في Linux.

```
\ 'wget --no-check-certificate --header='Host: www.gutenberg.org
https://152.19.134.47/files/84/84-0.txt -O frankenstein.txt
ls -lh frankenstein.txt
head -5 frankenstein.txt
wc -l -w frankenstein.txt
```

يُستخدم ls -lh لمراجعة الحجم المقروء، بينما يعرض head -5 بداية النص للتحقق من أن التنزيل يحتوي على الكتاب المتوقع. أما wc -l -w فيعد الأسطر والكلمات وفق تعريف أدوات GNU المعتاد. وفي WordCount، يقسم المثال النص إلى رموز اعتماداً على

المسافات البيضاء؛ لذلك تكون نتيجة العد مرتبطة بطريقة فصل الرموز، ولا تعني بالضرورة عدّاً لغوياً يزيل علامات الترقيم أو يوحّد الأحرف [1].

4 مسار البيانات ومعمارية التنفيذ

4.1 مسار البيانات

اتبع الملف التسلسل التالي: ملف محلي في Linux، ثم ملف إدخال في HDFS، ثم مهمة MapReduce تُدار على YARN، ثم ملف ناتج في HDFS، وأخيراً ملف محلي جُمعت إليه النتائج.

Linux: frankenstein.txt → HDFS: /bigdata/frankenstein/input → MapReduce / YARN → HDFS: /bigdata/frankenstein/output → Linux: frankenstein_wordcount.txt

4.2 دور المكونات

يخزن HDFS الملفات في كتل موزعة على عقد المجموعة، ويمكنه الاحتفاظ بنسخ مكررة من الكتل وفق إعدادات المجموعة. لذلك يختلف مسار الملف في HDFS عن المسار المحلي، حتى لو بدا اسم الملف نفسه متشابهاً [3].

يقرأ Mapper سجلات الإدخال ويصدر لكل رمز زوجاً من الشكل (الكلمة، 1). بعد ذلك تنقل مرحلة Shuffle المخرجات وتجمع السجلات التي تحمل المفتاح نفسه. ثم يجمع Reducer قيم كل كلمة ويكتب العدد النهائي. هذه هي الفكرة الأساسية التي يطبقها مثال WordCount في وثائق [1] Hadoop.

تتولى YARN تخصيص موارد المجموعة ومتابعة تشغيل التطبيق. ينسق ResourceManager الموارد على مستوى المجموعة، بينما يتابع NodeManager الحاويات واستخدام الموارد على العقدة. كما يتولى ApplicationMaster الخاص بالتطبيق التفاوض على الموارد ومراقبة تقدم المهام [2].

5 خطوات التنفيذ

5.1 إنشاء مجلد الإدخال في HDFS

أنشئ مجلد الإدخال، ثم ضُبِطت ملكية المسار للمستخدم cloudera حتى يتمكن من رفع الملف وتشغيل المهمة. بعد ذلك نُسخ الملف المحلي إلى المجلد المحدد في HDFS.

```
sudo -u hdfs hdfs dfs -mkdir -p /bigdata/frankenstein/input
sudo -u hdfs hdfs dfs -chown -R cloudera:cloudera /bigdata
/hdfs dfs -put -f frankenstein.txt /bigdata/frankenstein/input
hdfs dfs -ls -h /bigdata/frankenstein/input
hdfs dfs -du -h /bigdata/frankenstein/input
```

يُظهر الأمر `ls -ls` اسم الملف ومعلوماته داخل المجلد. ويعرض `du -h` حجمه المخزن بصيغة سهلة القراءة. سجّل التقرير الأصلي حجماً مقداره 427.6K في HDFS، وهو متنسق تقريباً مع الحجم المحلي 437,869 بايت بعد اختلاف أسلوب التقريب ووحدة العرض.

5.2 التحقق من خدمات المعالجة

قبل تشغيل المهمة، جرى التحقق من حالة الخدمات ذات الصلة. ينبغي أن تكون الخدمات المطلوبة عاملة كي يتمكن Hadoop من قبول التطبيق وجدولة مهامه.

```
sudo service hadoop-yarn-resourcemanager status
sudo service hadoop-yarn-nodemanager status
sudo service hadoop-mapreduce-historyserver status
```

5.3 تشغيل WordCount

استخدم مثال WordCount المرفق مع توزيع Hadoop. يأخذ الأمر مسار الإدخال في HDFS ثم مسار الإخراج. ويتطلب Hadoop أن يكون مجلد الإخراج غير موجود مسبقاً؛ فإذا أعيد تشغيل المهمة على المجلد نفسه، يجب إزالة مجلد النتائج السابق أو اختيار مسار جديد قبل التنفيذ.

```
\ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
wordcount /bigdata/frankenstein/input /bigdata/frankenstein/output
```

يقرأ Hadoop الملف من HDFS ويقسم العمل إلى مهام Map. ثم يجمع المفاتيح المتطابقة عبر Shuffle، وينفذ Reduce لتجميع التكرارات. أما YARN فيخصص موارد التشغيل ويراقب حالة التطبيق، ويمكن متابعة المهمة في واجهة ResourceManager التي كانت متاحة في البيئة على المنفذ 8088 [1] [2].

5.4 استخراج ملف النتائج

بعد اكتمال المهمة، جُمعت أجزاء الناتج من HDFS في ملف محلي واحد. ويتضمن مجلد الإخراج عادةً ملف SUCCESS_ للدلالة على اكتمال المهمة وملف جزء مثل part-r-000000 يحوي بيانات Reducer.

```
hdfs dfs -ls /bigdata/frankenstein/output
\ hdfs dfs -getmerge /bigdata/frankenstein/output
frankenstein_wordcount.txt
ls -lh frankenstein_wordcount.txt
wc -l frankenstein_wordcount.txt
```

أظهر الفحص المحلي 12,152 سطرًا في الملف المدمج، وهو يطابق عدد سجلات Reduce المبلغ عنها. يحتوي كل سطر عادةً على مفتاح نصي وعدده، مفصولين بعلامة تبويب في صيغة إخراج المثال.

6 النتائج والتحقق منها

6.1 مؤشرات التنفيذ

المؤشر	القيمة المسجلة	التفسير
حجم الملف المحلي	437,869 بايت	حجم النص قبل رفعه إلى HDFS.
عدد أسطر الإدخال	7,649	السجلات التي قرأها Mapper وفق عدادات المهمة.
سجلات Map الناتجة	75,721	عدد الرموز التي أصدرتها مرحلة Map قبل التجميع النهائي.
سجلات Reduce الناتجة	12,152	عدد المفاتيح النصية المكتوبة في ملف النتيجة.
البيانات المقروءة	437,869 بايت	قيمة Bytes Read الواردة في سجل المهمة.

البيانات المكتوبة	129,319 بايت	قيمة Bytes Written الواردة في سجل المهمة.
حالة التنفيذ	Map 100%, Reduce 100%	سجل المهمة يذكر اكتمالها بنجاح.

تساعد هذه العدادات على التحقق من أن المهمة قرأت المدخلات وأنتجت ناتجاً. فعدد سجلات Map الناتجة أكبر من عدد الأسطر لأن السطر الواحد قد يحتوي كلمات كثيرة. أما الفرق بين 75,721 سجلاً وسيطاً و12,152 سجلاً نهائياً فينتج عن جمع مرات تكرار الكلمات المتطابقة خلال مرحلة Reduce. ولا يساوي حجم الملف المكتوب عدد السجلات؛ فالحجم يقاس بالبايتات ويتأثر بطول الكلمات والأعداد والفواصل النصية.

6.2 ما الذي تثبته النتائج؟

يثبت سجل التشغيل أن إدخال الملف إلى HDFS نجح، وأن مهمة MapReduce انتهت دون فشل ظاهر، وأن ملفات النتائج كُتبت في مجلد الإخراج ثم جُمعت محلياً. كما أن تطابق عدد أسطر الملف النهائي المعلن (12,152) مع Reduce output records يوفر فحصاً إضافياً لاتساق الناتج.

ذكر التقرير الأصلي أن الكلمة الأكثر تكراراً هي the بعدد 5,412. أُبقيت هذه المعلومة باعتبارها قيمة مذكورة في التقرير المقدم، لكن لم تتوفر في الملف الأصلي قائمة النتائج النصية الكاملة للتحقق المستقل من ترتيب الكلمات. كذلك وردت إشارات إلى «الأعداد» و«الكلمة العشرين» في جدول غير مضمّن؛ لذلك لم تُخترع قيم بديلة لهما. يمكن استكماهما عند إرفاق ملف frankenstein_wordcount.txt أو جدول النتائج المطلوب في أسئلة المقرر.

7 الخلاصة

نجح المشروع في تنفيذ دورة معالجة نصية موزعة باستخدام Hadoop: تخزين الملف في HDFS، تشغيل WordCount عبر MapReduce، إدارة التطبيق بواسطة YARN، ثم استرجاع المخرجات إلى Linux. وتوضح العدادات المسجلة انتقال البيانات من 7,649 سجل إدخال إلى 75,721 سجل Map وسيطاً ثم إلى 12,152 سجل Reduce نهائياً. يوضح التطبيق عملياً أن MapReduce يفصل إنتاج الأزواج عن تجميعها، وأن HDFS يقدم طبقة تخزين موزعة، فيما يدير YARN موارد التنفيذ ومراقبته. ولتقوية نسخة التسليم الأكاديمية، يستحسن إضافة جدول أعلى الكلمات ونتائج الأسئلة الأصلية كاملة، وإرفاق ملف الإخراج النصي وسجل التنفيذ؛ فالنسخة المتاحة لا تتضمن سوى إجابات مقتضبة وبعض اللقطات.

8 الملفات والمسارات الناتجة

العنصر	المسار أو الاسم
ملف الإدخال المحلي	frankenstein.txt
مدخل HDFS	bigdata/frankenstein/input/frankenstein.txt/
مجلد نتائج HDFS	/bigdata/frankenstein/output/
ملف الجزء الناتج	part-r-00000
الملف المحلي المدمج	frankenstein_wordcount.txt
سجل التنفيذ	frankenstein_project.log — مذكور في قائمة التسليم الأصلية

9 معجم المصطلحات

- HDFS** - نظام ملفات Hadoop الموزع: طبقة تخزين توَزَع الملفات الكبيرة على كتل وعقد متعددة داخل مجموعة Hadoop.
- Mapper** - المحوّل: يعالج سجلات الإدخال ويحوّل كل كلمة إلى زوج من الكلمة والعدد 1 في تطبيق WordCount.
- MapReduce** - نموذج المعالجة الموزعة: إطار يقسم العمل إلى مرحلة Map لإنتاج أزواج مفتاح وقيمة، ثم Reduce لتجميع القيم حسب المفتاح.
- Reducer** - المجمع: يجمع القيم التي تحمل المفتاح نفسه ويكتب الناتج النهائي لكل كلمة.
- Shuffle** - مرحلة نقل وتجميع مخرجات الخرائط: تنقل مخرجات Mapper إلى Reducer المناسب وتجمع السجلات ذات المفاتيح المتطابقة قبل الاختزال.
- WordCount** - عدّ الكلمات: مثال Hadoop يحصي تكرار كل رمز نصي في مجموعة الإدخال.
- YARN - Yet Another Resource Negotiator**: طبقة إدارة موارد المجموعة وجدولة التطبيقات ومتابعة تنفيذها.

10 المراجع

- تستند التعريفات التقنية في شرح مراحل Hadoop إلى الوثائق الرسمية للمشروع. أما بيانات المشروع والأرقام التشغيلية فمصدرها التقرير الأصلي المرفق.
- [1] [Apache Hadoop MapReduce Tutorial](#) — شرح Mapper و Reducer و WordCount.
 - [2] [Apache Hadoop YARN](#) — البنية وإدارة الموارد وتشغيل التطبيقات.
 - [3] [HDFS Architecture Guide](#) — تخزين الملفات والكتل والنسخ المكررة.
 - [4] [Project Gutenberg — Frankenstein; or, The Modern Prometheus](#)، الكتاب الإلكتروني رقم 84.

11 لقطات التنفيذ

اللقطات التالية هي الصور المضمّنة في التقرير الأصلي، وقد أُدرجت لإثبات مراحل التنفيذ. تختلف درجة وضوح النص داخل الصور بسبب طريقة التقاطها وحجمها في المصدر.

11.1 لقطة 1 — تنفيذ WordCount

```


File Edit View Search Terminal Help
Number of racks: 1
FSCK ended at Wed Sep 23 11:18:28 PDT 2026 in 3 milliseconds

The filesystem under path '/bigdata/frankenstein/input/frankenstein.txt' is HEALTHY
[cloudera@quickstart ~]$ hdfs dfs -stat %r /bigdata/frankenstein/input/frankenstein.txt
1
[cloudera@quickstart ~]$ ls /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
/usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
[cloudera@quickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount /bigdata/frankenstein/input /bigdata/frankenstein/output
26/09/23 11:22:11 INFO client.RMProxy: Connecting to ResourceManager at quickstart.cloudera:8088/p
68.91.128.8032
26/09/23 11:22:11 INFO input.FileInputFormat: Total input paths to process : 1
26/09/23 11:22:12 INFO mapreduce.JobSubmitter: number of splits:1
26/09/23 11:22:12 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1790184681256_0001
26/09/23 11:22:12 INFO impl.YarnClientImpl: Submitted application application_1790184681256_0001
26/09/23 11:22:12 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/p
roxy/application_1790184681256_0001/
26/09/23 11:22:12 INFO mapreduce.Job: Running job: job_1790184681256_0001
26/09/23 11:22:19 INFO mapreduce.Job: Job job_1790184681256_0001 running in uber mode : false
26/09/23 11:22:19 INFO mapreduce.Job: map 0% reduce 0%
26/09/23 11:22:26 INFO mapreduce.Job: map 100% reduce 0%
26/09/23 11:22:32 INFO mapreduce.Job: map 100% reduce 100%
26/09/23 11:22:33 INFO mapreduce.Job: Job job_1790184681256_0001 completed successfully
26/09/23 11:22:33 INFO mapreduce.Job: Counters: 49
File System Counters
FILE: Number of bytes read=88497
FILE: Number of bytes written=471913
FILE: Number of read operations=0
FILE: Number of large read operations=0
FILE: Number of write operations=0
HDFS: Number of bytes read=437869
HDFS: Number of bytes written=129319
HDFS: Number of read operations=6

```


شكل 1: لقطة شاشة نافذة الطرفية وسجل مهمة WordCount.

11.2 لقطة 2 — متابعة التطبيق في YARN



شكل 2: واجهة متابعة تطبيق YARN كما ظهرت في البيئة الافتراضية.

11.3 لقطة 3 — عرض نتائج المهمة



شكل 3: لقطة شاشة نتائج المهمة في نافذة الطرفية.