

المهمة العملية 29

تقرير تحليل نص Sherlock باستخدام Hadoop MapReduce

تنفيذ WordCount على HDFS باستخدام YARN و MapReduce، ثم تحليل الكلمات الأكثر تكرارًا ونتائج التنفيذ.

607,504

بايت حجم ملف الإدخال

12,306

سجل إدخال تمت معالجته

15,187

مجموعة كلمات في مخرجات Reduce

1. بيانات المهمة

العنصر

القيمة

ملف الإدخال

1661-0.txt

مسار HDFS

/bigdata/sherlock/input/1661-0.txt

حجم الملف

607,504 بايت

/bigdata/sherlock/output

مخرج WordCount المطلوب

/bigdata/sherlock/output2

مخرج التشغيل الناجح الأخير

ملاحظة: تم تنفيذ WordCount بنجاح على المسار output2. أما المسار output فكان يحتوي بالفعل على نتائج ناجحة عند محاولة إعادة تشغيل المهمة، لذلك ظهر الخطأ Output directory already exists.

2. إجابات أسئلة المهمة العملية

السؤال الأول: ما أكثر الكلمات تكرارًا في النص؟

أكثر الكلمات تكرارًا هي كلمات شائعة في اللغة الإنجليزية، وفي مقدمتها **the** بعدد **5,412**، ثم **and** بعدد **2,794**، ثم **of** بعدد **2,724**، و **to** بعدد **2,702**.

السؤال الثاني: كم مرة ظهرت الكلمات المحددة؟

وفق مخرجات WordCount المطابقة للكلمة نفسها تمامًا: **Holmes = 198**، **Watson = 4**، **Sherlock = 96**، **London = 20**، **Lestrade**، لذلك لا يوجد رقم موثق له ضمن النتائج المرفقة.

السؤال الثالث: ما الكلمات العشرة الأعلى تكرارًا؟

الترتيب التالي مأخوذ مباشرة من أمر `sort -k2 -nr | head -20`.

#	الكلمة	التكرار
1	the	5,412
2	and	2,794
3	of	2,724
4	to	2,702
5	a	2,575

2,533	I	6
1,706	in	7
1,557	that	8
1,361	was	9
1,096	his	10
1,073	is	11
1,034	you	12
1,014	he	13
977	it	14
901	my	15
894	have	16
843	with	17
807	had	18
776	as	19
753	which	20

السؤال الرابع: ما الفرق بين الملف الموجود في Linux والملف الموجود في HDFS؟

ملف Linux يكون على نظام الملفات المحلي للآلة الافتراضية، بينما ملف HDFS يكون داخل نظام الملفات الموزع الخاص بـ Hadoop. في هذه المهمة تم وضع الملف في HDFS على المسار `/bigdata/sherlock/input/1661-0.txt` ثم قرأه MapReduce من HDFS أثناء التنفيذ.

السؤال الخامس: ما وظيفة MapReduce في هذا المشروع؟

وظيفته تنفيذ عملية **WordCount**: قراءة النص، إنتاج أزواج للكلمات وقيمها، ثم تنفيذ مرحلة Shuffle وتجميع الكلمات المتشابهة في Reduce لإنتاج عدد ظهور كل كلمة.

السؤال السادس: ما وظيفة YARN أثناء تنفيذ المهمة؟

YARN تولّى إدارة وتشغيل موارد المهمة داخل Hadoop. ويظهر ذلك في سجل التنفيذ من خلال تشغيل Map Task و Reduce Task وإدارة containers الخاصة بهما.

السؤال السابع: أين توجد النتيجة النهائية بعد انتهاء WordCount؟

النتيجة الموجودة مسبقًا كانت في `/bigdata/sherlock/output`، بينما التشغيل الناجح الأخير تم إلى `/bigdata/sherlock/output2`. وبحسب التنفيذ الناجح الأخير، فإن المخرجات موجودة تحت مسار `output2`.

3. دليل نجاح تنفيذ MapReduce

نجاح حالة المهمة

- map 100%
- reduce 100%
- Job completed successfully
- Failed Shuffles = 0
- Launched map tasks = 1
- Launched reduce tasks = 1

إحصاءات المعالجة

- Map input records: **12,306**
- Map output records: **107,562**
- Combine output records: **15,187**
- Reduce input groups: **15,187**
- Reduce output records: **15,187**
- HDFS bytes read: **607,634**

HDFS bytes written: **163,591** •

4. تسلسل التنفيذ

1 — تجهيز البيانات: وجود الملف 1661-0.txt في HDFS بحجم 607,504 بايت.

2 — قراءة الإدخال: MapReduce وجد Split واحدًا للملف.

3 — Map: تمت معالجة 12,306 سجلًا وإنتاج 107,562 سجلًا وسيطًا.

4 — Shuffle: تم نقل وتجميع نتائج Map، مع **Failed Shuffles = 0**.

5 — Reduce: تم إنتاج 15,187 مجموعة/كلمة في المخرجات.

6 — النتيجة: انتهت المهمة بحالة **completed successfully**.

5. أوامر التحقق المستخدمة

```
hdfs dfs -ls /bigdata/sherlock/input
```

```
hdfs dfs -getmerge /bigdata/sherlock/output sherlock_wordcount.txt
```

```
hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head -20
```

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \  
wordcount /bigdata/sherlock/input /bigdata/sherlock/output2
```

6. تحليل مختصر للنتائج

أظهرت عملية WordCount نجاح معالجة ملف Sherlock باستخدام Hadoop MapReduce. تصدرت الكلمات الإنجليزية العامة مثل **the** و **and** و **of** قائمة التكرار، وهو ما يعكس أن العد تم على الكلمات كما ظهرت في النص دون إزالة كلمات التوقف.

كما توضح الإحصاءات أن مرحلة Map أنتجت 107,562 سجلًا وسيطًا، ثم قامت مرحلة Combine بتقليلها إلى 15,187 سجلًا قبل Reduce، وانتهت المهمة بإنتاج 15,187 مجموعة في المخرج. كذلك

كانت قيمة **Failed Shuffles = 0**، ما يؤكد نجاح مرحلة Shuffle في التشغيل الأخير.

تنبيه منهجي: نتائج Holmes و Watson و Sherlock و London التي تظهر في هذا التقرير تعتمد على التطابق النصي للكلمة كما نفذته `grep -w`. لذلك تظهر صيغ أخرى منفصلة عندما تكون الكلمة ملتصقة بعلامة ترقيم مثل Holmes, أو Watson. لم يتم دمج هذه الصيغ في أرقام التقرير.

7. الخلاصة

تم تنفيذ مشروع WordCount على نص Sherlock داخل بيئة Hadoop، مع استخدام HDFS لتخزين البيانات و YARN لإدارة تشغيل المهمة و MapReduce لتنفيذ العد والتجميع. التشغيل الناجح الأخير وصل إلى 100% في مرحلتي Map و Reduce وانتهى بالحالة **completed successfully**.

تقرير مبني على نتائج التنفيذ والسجلات التي تم توفيرها — Sherlock / Hadoop WordCount

التوثيق البصري

الصور المطلوبة للتسليم

الصور التالية مبنية مباشرة من أوامر ومخرجات الـ Terminal التي أرسلتها، ومدرجة داخل صفحة التقرير نفسها.

البيانات داخل HDFS الصورة 1

إثبات وجود ملف Sherlock داخل HDFS والمسار `bigdata/sherlock/input/1661-0.txt`.

```
cloudera@quickstart: ~  
  
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/sherlock/input  
Found 1 items  
-rw-r--r--  1 cloudera supergroup      607504 2026-09-22 12:31 /bigdata/sherlock/input/1661-0.txt  
  
[cloudera@quickstart ~]$ hdfs dfs -ls -d /bigdata/sherlock  
drwxr-xr-x  - cloudera supergroup      0 2026-09-22 12:26 /bigdata/sherlock
```

الصورة 2 تنفيذ MapReduce بنجاح

إثبات وصول Map إلى 100% و Reduce إلى 100% وظهور completed successfully.

```
WordCount - MapReduce / YARN  
  
[cloudera@quickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount \  
> /bigdata/sherlock/input /bigdata/sherlock/output2  
26/09/22 14:16:03 INFO mapreduce.Job: Running job: job_1790108468989_0005  
26/09/22 14:16:19 INFO mapreduce.Job: map 0% reduce 0%  
26/09/22 14:16:33 INFO mapreduce.Job: map 100% reduce 0%  
26/09/22 14:16:46 INFO mapreduce.Job: map 100% reduce 100%  
26/09/22 14:16:47 INFO mapreduce.Job: Job job_1790108468989_0005 completed successfully  
  
Launched map tasks=1  
Launched reduce tasks=1  
Map input records=12306  
Map output records=107562  
Reduce input groups=15187  
Reduce output records=15187
```

الصورة 3 أعلى 20 كلمة تكرارًا

نتائج WordCount مرتبة تنازليًا حسب عدد التكرارات.

```
WordCount - Top 20  
  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head -20  
  
the      5412  
and      2794  
of       2724  
to       2702  
a        2575  
I        2533  
in       1706  
that     1557  
was      1361  
his      1096  
is       1073  
you      1034  
he       1014  
it       977  
my       901  
have     894  
with     843  
had      807  
as       776  
which    753
```

الكلمات المطلوبة الصورة 4

نتائج Holmes و Watson و Sherlock و London كما ظهرت في مخرجات WordCount.

WordCount — Named Terms

```
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Holmes"
```

```
Holmes 198
```

```
Holmes, 126
```

```
Holmes. 78
```

```
Holmes' 17
```

```
[cloudera@quickstart ~]$ ... grep -w "Watson"
```

```
Watson 4
```

```
Watson, 40
```

```
Watson. 10
```

```
[cloudera@quickstart ~]$ ... grep -w "Sherlock"
```

```
Sherlock 96
```

```
[cloudera@quickstart ~]$ ... grep -w "London"
```

```
London 20
```

```
London, 8
```

```
London. 8
```

ملاحظة: علامات الترقيم تُحسب كجزء من الكلمة في WordCount الحالي.