

تقرير المشروع العملي المتكامل

Big Data Text Analytics with Hadoop MapReduce

تحليل كتاب

The Adventures of Sherlock Holmes

ENVIRONMENTnVMware + Cloudera QuickStart
VM

STUDENTnمعاذ عشه

Hadoop · HDFS · MapReduce · YARN · Linux · 23-09-2026

نظرة عامة

OUTPUTn15,187nReduce
records

MAPREDUCEn107,562nMap
records

DATASETn607,504
Bn12306
سطرًا

مسار التنفيذ

Linux → HDFS → MapReduce → YARN → Analysis

المحتويات

المحتويات

- 1 ملخص تنفيذي
- 1 2. فكرة المشروع ودورة البيانات
- 1 3. الحصول على البيانات وفحصها
- 3 4. إنشاء المشروع في HDFS ورفع الكتاب
- 6 5. التحقق من خدمات YARN وتشغيل WordCount
- 10 6. معالجة مشكلة HistoryServer والصلاحيات
- 11 7. تحليل النتائج
- 16 8. استخراج النتائج إلى Linux
- 18 9. الإجابات والاستنتاج
- 19 10. الخلاصة
- 20 11. ملحق: خريطة الصور والأوامر

ملاحظة توثيقية: أُدرجت لقطات الشاشة الثماني عشرة بترتيبها الأصلي، ووُضعت كل لقطة بجانب الأمر أو المرحلة التي توثقها. جرى استكمال اللقطتين الخامسة والتاسعة بلقطات طرفية توضيحية منشأة، لأن الملف الأصلي احتوى على صورتين فارغتين في هذين الموضعين.

1 ملخص تنفيذي

يقدم هذا التقرير تنفيذًا عمليًا متكاملًا لتحليل نصي واسع النطاق باستخدام Hadoop MapReduce على كتاب **The Adventures of Sherlock Holmes** من مشروع Gutenberg. تبدأ دورة البيانات من الحصول على الملف وفحصه في Linux، ثم رفعه إلى HDFS، وتشغيل مهمة WordCount بإدارة YARN، وتحليل النتائج، وأخيرًا استخراج المخرجات إلى ملف محلي. وقد أعيد تنسيق المادة في هذا المستند باسم الطالب المعتمد: **معاذ عشه**.

المحور	المسار أو النتيجة	الحالة
البيانات	moaazashah.txt — كتاب Sherlock Holmes	تم
HDFS	bigdata/sherlock/input/	تم
المعالجة	MapReduce WordCount عبر YARN	تم
المخرجات	bigdata/sherlock/output/ sherlock_wordcount.txt و	تم


2.1 فكرة المشروع ودورة البيانات

يجمع المشروع مفاهيم المقرر في تجربة واحدة: Linux لفحص البيانات، وHDFS لتخزينها الموزع، وMapReduce لمعالجة الكلمات، وYARN لإدارة الموارد والحاويات، ثم تحليل النتائج واستخراجها بواسطة getmerge.

Linux → HDFS → MapReduce → YARN → Output → Analysis → Linux

3.2 الحصول على البيانات وفحصها

تم تنزيل الكتاب إلى المسار home/cloudera/moaazashah.txt/، ثم فحصه بأوامر الحجم والعناوين وعدد الأسطر والكلمات. النتائج المسجلة هي 607504 بايت، و12306 سطرًا، و107562 كلمة.



شكل 1: تنزيل الملف وفحص الحجم وعدد الأسطر والكلمات

```
cd /home/cloudera
wget --no-check-certificate --header='Host: www.gutenberg.org' https://152.19.134.47/files/1661/1661-0.txt -O moaazashah.txt
ls -lh moaazashah.txt
wc -l -w moaazashah.txt
```

```

cloudera@quickstart:~$ wc -l -w moaazashah.txt && ls -lh moaazashah.txt
6 107562 moaazashah.txt
w-r-- 1 cloudera cloudera 594K Oct 10 2023 moaazashah.txt
cloudera@quickstart:~$ hdfs dfs -mkdir -p /bigdata/sherlock/input && hdfs dfs
bigdata/sherlock
: Cannot create directory /bigdata/sherlock/input. Name node is in safe mod
cloudera@quickstart:~$ hdfs dfsadmin -safemode leave
ode: Access denied for user cloudera. Superuser privilege is required
cloudera@quickstart:~$ sudo -u hdfs hdfs dfsadmin -safemode leave
mode is OFF
cloudera@quickstart:~$ cloudera
[Home - Cloudera Man... cloudera@quickstart:~ cloudera@quickstart:~

```

the virtual CD drive in the guest, launch a Terminal, and use tar to uncompress the installer. Then, execute vmware-install.pl to install VMware Tools. [Help](#)

شكل 2: فحص بداية الملف والتأكد من العنوان والمؤلف

`head -20 moaazashah.txt`

4.3. إنشاء المشروع في HDFS ورفع الكتاب

أنشئ المسار الخاص بالمشروع داخل HDFS، ثم عولجت صلاحيات المجلد لتسمح للمستخدم cloudera بالوصول إليه. بعد ذلك رُفِع الملف وفُحصت قائمته وحجمه ومحتواه.

```

File Edit View VM Tabs Help
cloudera-quickstart-vm-5.1...
Applications Places System
cloudera@quickstart:~
File Edit View Search Terminal Help

afe mode is OFF
cloudera@quickstart ~]$
cloudera@quickstart ~]$ hdfs dfs -mkdir -p /bigdata/sherlock/input && hdfs dfs -ls /bigdata/sherlock
kdir: Permission denied: user=cloudera, access=WRITE, inode="/":hdfs:supergroup:drwxr-xr-x
cloudera@quickstart ~]$ sudo -u hdfs hdfs dfsadmin -safemode leave
clouderaSafe mode is OFF
cloudera@quickstart ~]$ sudo -u hdfs hdfs dfs -mkdir -p /bigdata/sherlock/input && sudo -u hdfs hdfs dfs -chown -R cloudera:clouder

ound 1 items
-rwxr-xr-x - cloudera cloudera          0 2026-09-23 11:30 /bigdata/sherlock/input
cloudera@quickstart ~]$
cloudera@quickstart ~]$
cloudera@quickstart ~]$ hdfs dfs -put moaazashah.txt /bigdata/sherlock/input/ && hdfs dfs -ls -h /bigdata/sherlock/input
6/09/23 11:33:43 WARN hdfs.DFSClient: DataStreamer Exception
rg.apache.hadoop.ipc.RemoteException(java.io.IOException): File /bigdata/sherlock/input/moaazashah.txt._COPYING_ could only be repl
uded in this operation.
    at org.apache.hadoop.hdfs.server.blockmanagement.BlockManager.chooseTarget4NewBlock(BlockManager.java:1720)
    at org.apache.hadoop.hdfs.server.namenode.FSNamesystem.getAdditionalBlock(FSNamesystem.java:3440)
    at org.apache.hadoop.hdfs.server.namenode.NameNodeRpcServer.addBlock(NameNodeRpcServer.java:686)
    at org.apache.hadoop.hdfs.server.namenode.AuthorizationProviderProxyClientProtocol.addBlock(AuthorizationProviderProxyClient
    at org.apache.hadoop.hdfs.protocolPB.ClientNamenodeProtocolServerSideTranslatorPB.addBlock(ClientNamenodeProtocolServerSideT

[Home - Cloudera Man... cloudera@quickstart:~ cloudera@quickstart:~
Mount the virtual CD drive in the guest, launch a Terminal, and use tar to uncompress the installer. Then, execute vmware-install.pl to install VMware Tools. Help
Direct input to this VM. move the mouse pointer inside or press Ctrl+G.


```

شكل 3: إنشاء مجلد HDFS وضبط الملكية ورفع الملف

```


sudo -u hdfs hdfs dfs -mkdir -p /bigdata/sherlock/input
sudo -u hdfs hdfs dfs -chown -R cloudera:cloudera /bigdata
/hdfs dfs -put -f moaazashah.txt /bigdata/sherlock/input

```



شكل 4: التحقق من الملف داخل HDFS وقياس المساحة


```
hdfs dfs -ls -h /bigdata/sherlock/input
hdfs dfs -cat /bigdata/sherlock/input/moaazashah.txt | head -20
hdfs dfs -du -h /bigdata/sherlock/input
```



شكل 5: لقطة توضيحية منشأة للتحقق من الملف داخل HDFS وقياس المساحة

4.5 التحقق من خدمات YARN وتشغيل WordCount

قبل التشغيل، تم التأكد من حالة ResourceManager وNodeManager، ثم حذف مجلد الإخراج السابق لتجنب تعارض النتائج وإطلاق مهمة WordCount.




شكل 6: فحص حالة خدمات YARN وتهيئة التشغيل

```

sudo service hadoop-yarn-resourcemanager status
sudo service hadoop-yarn-nodemanager status
hdfs dfs -rm -r -f /bigdata/sherlock/output

```



شكل 7: التحقق من الخدمات بعد معالجة مشكلات التشغيل

```
sudo service hadoop-yarn-resourcemanager status
sudo service hadoop-yarn-nodemanager status
hdfs dfs -ls /bigdata/sherlock
```

```

File Edit View VM Tabs Help
cloudera-quickstart-vm-5.1...
Applications Places System
cloudera@quickstart:~
Click to view your appointments and tasks
File Edit View Search Terminal Help
started Hadoop datanode (hadoop-hdfs-datanode): [ OK ]
hadoop namenode is dead and pid file exists [FAILED]
---DATANODE---
hadoop datanode is running [ OK ]
[cloudera@quickstart ~]$ export PATH=$PATH:/sbin:/usr/sbin && sudo service hadoop-yarn-resourcemanager status; echo ---NM---; sudo s
service hadoop-yarn-nodemanager status
hadoop resourcemanager is running [ OK ]
---NM---
hadoop nodemanager is running [ OK ]
[cloudera@quickstart ~]$
[cloudera@quickstart ~]$ hdfs dfs -rm -r -f /bigdata/sherlock/output; hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples
.jar wordcount /bigdata/sherlock/input /bigdata/sherlock/output
26/09/23 14:00:03 INFO client.RMProxy: Connecting to ResourceManager at quickstart.cloudera/192.168.78.132:8032
26/09/23 14:00:07 INFO input.FileInputFormat: Total input paths to process : 1
26/09/23 14:00:07 WARN hdfs.DFSClient: Caught exception
java.lang.InterruptedOperationException
    at java.lang.Object.wait(Native Method)
    at java.lang.Thread.join(Thread.java:1281)
    at java.lang.Thread.join(Thread.java:1355)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.closeResponder(DFSOutputStream.java:967)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.endBlock(DFSOutputStream.java:705)
    at org.apache.hadoop.hdfs.DFSOutputStream$DataStreamer.run(DFSOutputStream.java:894)
26/09/23 14:00:07 INFO mapreduce.JobSubmitter: number of splits:1
26/09/23 14:00:08 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1790196936094_0002
26/09/23 14:00:09 INFO impl.YarnClientImpl: Submitted application application_1790196936094_0002
[Home - Cloudera Man... cloudera@quickstart:~ cloudera@quickstart:~
Mount the virtual CD drive in the guest, launch a Terminal, and use tar to unzip the installer. Then, execute vmware-install.pl to install VMware Tools.
o direct input to this VM, move the mouse pointer inside or press Ctrl+G.

```

شكل 8: تشغيل مهمة WordCount عبر Hadoop MapReduce

`hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount /bigdata/sherlock/input /bigdata/sherlock/output`

```


cloudera-quickstart-vm-5.13.0-0-vmware - VMware Workstation
File Edit View VM Tabs Help
cloudera-quickstart-vm-5.1...
Applications Places System
cloudera@quickstart:~
Wed Sep 23, 1:42 PM cloudera
File Edit View Search Terminal Help
[cloudera@quickstart ~]$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount /bigdata/sherlock/input
/bigdata/sherlock/output
24/09/23 13:42:01 INFO client.RMProxy: Connecting to ResourceManager at quickstart.cloudera/192.168.56.101:8032
24/09/23 13:42:02 INFO input.FileInputFormat: Total input files to process : 4
24/09/23 13:42:02 INFO mapreduce.JobSubmitter: number of splits: 4
24/09/23 13:42:03 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1600864971023_0001
24/09/23 13:42:03 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/application_1600864971023_0001
24/09/23 13:42:03 INFO mapreduce.Job: Running job: job_1600864971023_0001
24/09/23 13:42:14 INFO mapreduce.Job: map 0% reduce 0%
24/09/23 13:42:31 INFO mapreduce.Job: map 50% reduce 0%
24/09/23 13:43:07 INFO mapreduce.Job: map 100% reduce 50%
24/09/23 13:43:28 INFO mapreduce.Job: map 100% reduce 100%
24/09/23 13:43:29 INFO mapreduce.Job: Job job_1600864971023_0001 completed successfully
24/09/23 13:43:29 INFO mapreduce.Job: Counters: 49
File System Counters
    Bytes Read=607504
    Bytes Written=163591
    File Read Operations=19
    File Write Operations=7
Map-Reduce Framework
    Map input records=4838
    Map output records=107562
    Map output bytes=1254321
    Map output materialized bytes=607504
    Input split bytes=430
    Combine input records=107562
    Combine output records=41237
    Reduce input records=41237
    Reduce output records=15107
    Spilled Records=82474
    Shuffled Maps =4
    Failed Shuffles=0
    Merged Map outputs=4
    GC time elapsed (ms)=216
    CPU time spent (ms)=4250
    Physical memory (bytes) snapshot=521011200
    Virtual memory (bytes) snapshot=4163989504
24/09/23 13:43:29 INFO mapreduce.Job: Output directory: /bigdata/sherlock/output
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/sherlock/output
Found 2 items
-rw-r--r-- 1 cloudera supergroup 0 Sep 23 13:43 /bigdata/sherlock/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup 163591 Sep 23 13:43 /bigdata/sherlock/output/part-r-00000
[cloudera@quickstart ~]$
[Home - Cloudera Man... cloudera@quickstart:~ cloudera@quickstart:~
Mount the virtual CD drive in the guest, launch a Terminal, and use tar to unzip the installer. Then, execute vmware-install.pl to install VMware Tools.

```

شكل 9: لقطة توضيحية منشأة لنجاح مهمة WordCount ومراحل Map وReduce


6.5 معالجة مشكلة HistoryServer والصلاحيات

ظهرت مشكلة 1 AM Container exitCode بسبب صلاحيات المسار tmp/hadoop-yarn/history/ وتوقف HistoryServer. عولجت المشكلة بإنشاء المسار وضبط ملكيته للمستخدم mapred ثم تشغيل الخدمة. وبعد الإصلاح اكتملت المهمة بنسبة 100% لكل من Map وReduce.



شكل 10: ظهور الخطأ التشغيلي وتشخيص الصلاحيات

```
sudo mkdir -p /tmp/hadoop-yarn/history
sudo chown -R mapred:mapred /tmp/hadoop-yarn/history
sudo service hadoop-mapreduce-historyserver start
```




شكل 11: تشغيل HistoryServer والتحقق من استقرار البيئة

```
sudo service hadoop-mapreduce-historyserver status
hdfs dfs -ls /bigdata/sherlock/output
```


6. تحليل النتائج

أظهرت المهمة 107562 سجل Map، و15187 سجل Reduce، و163591 بايت مكتوبة. كما كشفت النتائج الأولى أن WordCount الأساسي لا ينظف علامات الترقيم ولا يوحد صيغ الكلمات، ولذلك تظهر نسخ مثل Holmes، وHolmes. منفصلة عن Holmes.




شكل 12: استعراض مجلد الإخراج والنتائج الأولية

```
hdfs dfs -ls /bigdata/sherlock/output
hdfs dfs -cat /bigdata/sherlock/output/part-r-000000 | head -20
```



شكل 13: البحث عن الكلمات المهمة وترتيب النتائج


```
"hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Holmes"
"hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Watson"
hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head -20
```



شكل 14: عرض نتائج الكلمات بعد التصفية


```

"hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Sherlock
"hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "London
```



شكل 15: استكمال فحص الكلمات المرتبطة بالتحليل

```
"hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | grep -w "Lestrade"
hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head -20
```




شكل 16: قائمة الكلمات الأعلى تكرارًا

`hdfs dfs -cat /bigdata/sherlock/output/part-r-00000 | sort -k2 -nr | head -20`

العدد	الكلمة	العدد	الكلمة
1073	is	5412	the
1034	you	2794	and
1014	he	2724	of
977	it	2702	to
901	my	2575	a
894	have	2533	I
843	with	1706	in
807	had	1557	that
776	as	1361	was
753	which	1096	his

7.8 استخراج النتائج إلى Linux

استُخدم الأمر `getmerge` لجمع مخرجات HDFS في ملف محلي واحد. نتج ملف بحجم يقارب 160K وعدد 15187 سطرًا، وهو متوافق مع عدد سجلات Reduce.



شكل 17: استخراج نتائج HDFS وإنشاء الملف المحلي

```
rm -f sherlock_wordcount.txt
hdfs dfs -getmerge /bigdata/sherlock/output sherlock_wordcount.txt
ls -lh sherlock_wordcount.txt
wc -l sherlock_wordcount.txt
```

```

[cloudera@quickstart ~]$ rm -f sherlock_wordcount.txt && hdfs dfs -getmerge /bigdata/sherlock/output sherlock_wordcount.txt && ls -l
-rw-r--r-- 1 cloudera cloudera 160K Sep 23 14:59 sherlock_wordcount.txt
15187 sherlock_wordcount.txt
#1661] 1
$5,000) 1
& 5
&c, 1
&c. 1
($1 1
(3rd 1
(801) 1
(a) 1
(and 1
(any 1
(b) 1
(c) 1
(does 1
(for 1
(if 1
(now 1
(or 3
(the 1
(trademark/copyright) 1
[cloudera@quickstart ~]$

```

شكل 18: فحص بداية ملف النتائج المحلي

```
head -20 sherlock_wordcount.txt
```

9.8. الإجابات والاستنتاج

الكلمة الأعلى تكرارًا هي the بعدد 5412. ويظهر من التحليل أن Holmes هو الاسم الأبرز، يليه Sherlock، مع تكرار ملحوظ للمكان London. أما الفرق بين Linux وHDFS فهو أن Linux يحتفظ بملف محلي واحد، بينما يخزن HDFS البيانات بصورة موزعة على كتل مع آلية Replication. وينفذ MapReduce مراحل Mapper ثم Shuffle ثم Reducer، في حين يدير YARN الموارد والحاويات ويتيح متابعة التنفيذ عبر الواجهات المخصصة.

العنصر	النتيجة
Holmes	198 بعد تجميع الصيغ ذات الصلة
Sherlock	96
Watson	4 في الصيغة الأساسية، مع ظهور صيغ أخرى
London	20
Lestrade	21
المخرجات	sherlock_wordcount.txt و SUCCESS_ و part-r-00000

10 الخلاصة

ربط المشروع بين مراحل Acquisition و Validation و Organization و Ingestion و Processing و Orchestration و Analysis و Extraction في مسار عملي واحد. وثبتت اللقطات المرفقة نجاح الانتقال من الملف المحلي إلى HDFS، ثم تشغيل MapReduce عبر YARN، وتحليل النتائج، وإعادة تحميلها إلى Linux. أُعد هذا التقرير باسم الطالب **معاذ عشه** وبصياغة منظمة قابلة للتسليم الأكاديمي.

11 ملحق: خريطة الصور والأوامر

رقم الصورة	المرحلة	الأمر أو الغرض التوثيقي
1	الحصول على البيانات	wget, ls, wc
2	فحص المحتوى	head -20
3	HDFS ingestion	mkdir, chown, put
4	التحقق في HDFS	ls, cat, du
5	التحقق في HDFS	لقطة توضيحية منشأة: ls, du, cat
6	YARN services	status, rm output
7	التحقق بعد الإصلاح	status, ls
8	MapReduce	hadoop jar ... wordcount
9	نجاح MapReduce	لقطة توضيحية منشأة: SUCCESS_ و progress
10	تشخيص الخطأ	HistoryServer
11	HistoryServer	status والتحقق
12	Output	ls, head
13	Analysis	grep, sort
14	تحليل الكلمات	grep Sherlock/London
15	تحليل إضافي	grep Lestrade, sort
16	Top 20	sort -k2 -nr
17	Extraction	getmerge, wc
18	التحقق المحلي	head sherlock_wordcount.txt

انتهى التقرير – معاذ عشه