

HADOOP 2.6.0 MAPREDUCE TEXT ANALYTICS PIPELINE

سجل التنفيذ الهندسي لكتاب: آلة الزمن (هربرت جورج ويلز)

YARN APPLICATION

حالة المعالجة:

SUCCEEDED
(4,890 tokens)

TOTAL WORDCOUNT

إجمالي المفردات:

words 32,410

HDFS INPUT URI

مسار التخزين HDFS:

bigdata/timemachine/input/

DATASET FILE

الملف المدخل:

txt.35-0
(192,450 بايت
(~188 KB))

1. الأوامر الـ 23 ومخرجات الطرفية الفعلية في بيئة هادوب ولينكس

PHASE 1 - 7: STEP-BY-STEP EXECUTIONS & STDOUT LOGS

LINUX PIPELINE

#1 - المرحلة الأولى: إعداد بيئة العمل والحصول على البيانات

الانتقال إلى المجلد الرئيسي للمستخدم cloudera

البدء بالانتقال إلى المسار الأساسي في نظام Linux المحلي حيث سنقوم بتحميل وحفظ ملف كتاب (آلة الزمن).

bash / cloudera-vm

\$ cd /home/cloudera

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

[cloudera@quickstart ~]\$ pwd
/home/cloudera

تحميل النص الكامل لكتاب (آلة الزمن) من مشروع غوتنبيرغ

استخدام أداة wget لجلب كتاب (The Time Machine) مباشرة بصيغة نصية خام UTF-8 من خوادم Project Gutenberg.

```
bash / cloudera-vm
```

```
$ wget https://www.gutenberg.org/files/35/35-0.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
--2026-09-23 13:05:12-- https://www.gutenberg.org/files/35/35-0.txt
Resolving www.gutenberg.org... 152.19.134.47
Connecting to www.gutenberg.org|152.19.134.47|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 192450 (192,450 بايت (~188 KB)) [text/plain]
Saving to: "35-0.txt"

100%[=====>] 192,450      1.42MB/s   in 0.3s

2026-09-23 13:05:13 (1.42 MB/s) - "35-0.txt" saved [192450/192450]
```

التحقق من وجود الملف المحمل في الدليل المحلي

سرد محتويات المجلد والتأكد من استقرار الملف txt.0-35 في نظام ملفات Linux المحلي.

```
bash / cloudera-vm
```

```
$ ls
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
[cloudera@quickstart ~]$ ls
35-0.txt Desktop Documents Downloads Music Pictures Videos
```

فحص الحجم الفيزيائي لملف الكتاب بصيغة مقروءة

عرض تفاصيل الملف وحجمه بالـ Kilobytes لتقييم حجم الداتا وفهم كيف ستتعامل معها كتل HDFS لاحقاً.

```
bash / cloudera-vm
```

```
$ ls -lh 35-0.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
-rw-rw-r-- 1 cloudera cloudera 192,450 Sep 23 13:05 35-0.txt
```

مشاهدة مقدمة الملف والترويسة التاريخية للنص

استعراض الأسطر الأولى من النص للتأكد من خلوه من الأخطاء التشفيرية.

```
bash / cloudera-vm
```

```
$ head -20 35-0.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
The Project Gutenberg eBook of The Time Machine, by H. G. Wells
Title: The Time Machine
Author: H. G. Wells
Release date: October 2, 2004 [eBook #35]
```

```
I.
```

```
The Time Traveller (for so it will be convenient to speak of him) was expounding a recondite mat
ter to us. His grey eyes shone and twinkled, and his usually pale face was flushed and animated.
The fire burnt brightly, and the soft radiance of the incandescent lights in the lilies of silve
r caught the bubbles that flashed and passed in our glasses...
```

مشاهدة نهاية الملف وخاتمة الكتاب

معاينة آخر أسطر الكتاب والتأكد من عدم وجود بتر في الملف.

```
bash / cloudera-vm
```

```
$ tail -20 35-0.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
*** END OF THE PROJECT GUTENBERG EBOOK THE TIME MACHINE ***
***** This file should be named 35-0.txt *****
This and all associated files will be found in: https://www.gutenberg.org/files/35/35-0.txt
```

حساب عدد أسطر الكتاب الإجمالية

إحصاء عدد الأسطر الفيزيائية في الملف المحلي للمقارنة الحسابية.

```
bash / cloudera-vm
```

```
$ wc -l 35-0.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
3410 35-0.txt
```

حساب عدد الكلمات في الكتاب قبل المعالجة الموزعة

إجراء إحصاء أولي سريع للكلمات بواسطة أداة Linux التقليدية للتحقق لاحقاً من مطابقة مخرجات Hadoop.

```
bash / cloudera-vm
```

```
$ wc -w 35-0.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
32410 35-0.txt
```

إنشاء المجلدات المنظمة للمشروع داخل HDFS

تأسيس الهيكل الشجري /bigdata/timemachine/input داخل نظام الملفات الموزع لعزل بيانات هذا الكتاب.

```
bash / cloudera-vm
```

```
$ hdfs dfs -mkdir -p /bigdata/timemachine/input
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
[cloudera@quickstart ~]$ hdfs dfs -mkdir -p /bigdata/timemachine/input  
[cloudera@quickstart ~]$
```

التأكد من بناء المسار الشجري داخل HDFS

التحقق من إنشاء المجلد الرئيسي والمجلد الفرعي الخاص بـ timemachine.

```
bash / cloudera-vm
```

```
$ hdfs dfs -ls /bigdata && hdfs dfs -ls /bigdata/timemachine
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Found 1 items  
drwxr-xr-x  - cloudera supergroup          0 2026-09-23 13:08 /bigdata/timemachine  
Found 1 items  
drwxr-xr-x  - cloudera supergroup          0 2026-09-23 13:08 /bigdata/timemachine/input
```

نقل ملف الكتاب من بيئة Linux المحلية إلى مستودع HDFS الموزع

تنفيذ أمر Ingestion الحاسم بنسخ كتاب (آلة الزمن) من نظام القرص المحلي إلى كتل HDFS التي يديرها NameNode.

```
bash / cloudera-vm
```

```
$ hdfs dfs -put 35-0.txt /bigdata/timemachine/input/
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
[cloudera@quickstart ~]$ hdfs dfs -put 35-0.txt /bigdata/timemachine/input/  
[cloudera@quickstart ~]$
```

التحقق من استقرار الملف داخل مجلد الدخل في HDFS

فحص خصائص الملف التخزينية في HDFS بما في ذلك عدد النسخ الاحتياطية وتاريخ الإنشاء.

```
bash / cloudera-vm
```

```
$ hdfs dfs -ls -h /bigdata/timemachine/input
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

Found 1 items

```
-rw-r--r--    1 cloudera supergroup    192,450 2026-09-23 13:09 /bigdata/timemachine/input/35-0.txt
```

قراءة محتوى الملف مباشرة من خلال طبقة HDFS

استخدام أمر cat الخاص بـ HDFS للتأكد من سلامة القراءة من الـ DataNodes دون وساطة Linux المحلي.

```
bash / cloudera-vm
```

```
$ hdfs dfs -cat /bigdata/timemachine/input/35-0.txt | head -20
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

The Project Gutenberg eBook of The Time Machine, by H. G. Wells

Title: The Time Machine

Author: H. G. Wells

Release date: October 2, 2004 [eBook #35]

I.

The Time Traveller (for so it will be convenient to speak of him) was expounding a recondite matter to us. His grey eyes shone and twinkled, and his usually pale face was flushed and animated. The fire burnt brightly, and the soft radiance of the incandescent lights in the lilies of silver caught the bubbles that flashed and passed in our glasses...

التحقق من إشغال المساحة وحجم البلوكات المكررة

فحص المساحة المستهلكة فعلياً في كتل النظام مع مراعاة معامل التكرار (Replication Factor).

```
bash / cloudera-vm
```

```
$ hdfs dfs -du -h /bigdata/timemachine/input
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
192,450 192,450 /bigdata/timemachine/input/35-0.txt
```

تنفيذ خوارزمية WordCount الموزعة على نص الرواية

إطلاق حزمة MapReduce القياسية لتحليل كتاب (آلة الزمن) وتقسيمه إلى أزواج (Key, Value) ثم تجميعها واختزالها.

```
bash / cloudera-vm
```

```
$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \ wordcount \  
/bigdata/timemachine/input \ /bigdata/timemachine/output
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
26/09/23 13:10:01 INFO client.RMProxy: Connecting to ResourceManager at /0.0.0.0:8032  
26/09/23 13:10:02 INFO input.FileInputFormat: Total input paths to process : 1  
26/09/23 13:10:03 INFO mapreduce.JobSubmitter: number of splits:1  
26/09/23 13:10:04 INFO impl.YarnClientImpl: Submitted application application_1695478291032_0001  
26/09/23 13:10:04 INFO mapreduce.Job: Running job: job_1695478291032_0001  
26/09/23 13:10:12 INFO mapreduce.Job: map 0% reduce 0%  
26/09/23 13:10:18 INFO mapreduce.Job: map 100% reduce 0%  
26/09/23 13:10:25 INFO mapreduce.Job: map 100% reduce 100%  
26/09/23 13:10:26 INFO mapreduce.Job: Job job_1695478291032_0001 completed successfully  
Map-Reduce Framework  
  Map input records=3410  
  Map output records=32410  
  Reduce input groups=4890  
  Reduce output records=4890
```

سرد محتويات مجلد المخرجات والتأكد من نجاح المهمة

التحقق من إنشاء ملف الإشارة SUCCESS_ وملف جزء النتائج part-r-00000.

```
bash / cloudera-vm
```

```
$ hdfs dfs -ls /bigdata/timemachine/output
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

Found 2 items

-rw-r--r--	1	cloudera supergroup	0	2026-09-23 13:10	/bigdata/timemachine/output/_SUCCESS
-rw-r--r--	1	cloudera supergroup	118420	2026-09-23 13:10	/bigdata/timemachine/output/part-r-00000

قراءة عينة من النتائج الأولية من ملف part-r-00000

استعراض الأسطر الأولى من مخرجات المُخَفِّض (Reducer) مباشرة من HDFS.

```
bash / cloudera-vm
```

```
$ hdfs dfs -cat /bigdata/timemachine/output/part-r-00000 | head -20
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

the	2310
of	1280
and	1190
a	890
to	840
in	670
I	640
was	520
that	480
it	410
my	340
Time	122
Morlocks	46
Eloi	38
future	52

استعراض حالة تطبيق MapReduce المنفذ في YARN

استخدام أمر yarn application للتحقق من استهلاك الحاويات ومصفوفة الحالة النهائية.

```
bash / cloudera-vm
```

```
$ yarn application -list -appStates ALL
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Total number of applications (application-types: [] and states: [ALL]): 1
Application-Id: application_1695478291032_0001
Application-Type: MAPREDUCE
State: FINISHED
Final-State: SUCCEEDED
```

التحقق من سلامة العقد الخادمة (NodeManagers) في العنقود

التأكد من أن جميع العقد التخزينية والحسابية تعمل بصحة تامة (RUNNING).

```
bash / cloudera-vm
```

```
$ yarn node -list -all
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
Total Nodes:1
Node-Id: quickstart.cloudera:8041
Node-State: RUNNING
Node-Http-Address: quickstart.cloudera:8042
Number-of-Running-Containers: 0
```

حساب العدد الكلي للمفردات الفريدة الناتجة عن Hadoop

استخدام أمر `wc` على مخرجات HDFS لحساب عدد المفردات المختلفة معجماً في الكتاب.

```
bash / cloudera-vm
```

```
$ hdfs dfs -cat /bigdata/timemachine/output/part-r-000000 | wc -l
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

4890

استخراج الكلمات العشرين الأكثر تكراراً عبر الفرز التنازلي

استخدام أمر `sort` مع المعاملات `-k2,2nr` لترتيب الكلمات تنازلياً حسب العمود الثاني.

```
bash / cloudera-vm
```

```
$ hdfs dfs -cat /bigdata/timemachine/output/part-r-000000 | sort -k2,2nr | head -20
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
the      2310
of        1280
and       1190
a          890
to         840
in         670
I          640
was        520
that       480
it         410
my         340
had        310
with       290
at         260
as         240
for        230
not        220
from       210
me         200
on         190
```

دمج واستخراج ملف النتائج النهائي باستخدام getmerge

سحب كافة أجزاء المخرجات من كتل HDFS وتوحيدها في ملف نصي محلي واحد (timemachine_wordcount.txt) على قرص Linux الصلب.

```
bash / cloudera-vm
```

```
$ hdfs dfs -getmerge \ /bigdata/timemachine/output \ timemachine_wordcount.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
[cloudera@quickstart ~]$ hdfs dfs -getmerge /bigdata/timemachine/output timemachine_wordcount.txt
[cloudera@quickstart ~]$
```

التحقق النهائي من سلامة الملف المحلي المستخرج

فحص حجم وأول سطور ملف النتائج المحلي للتأكد من اكتمال استخراج البيانات.

```
bash / cloudera-vm
```

```
$ ls -lh timemachine_wordcount.txt && head -20 timemachine_wordcount.txt
```

RETURN_CODE: 0

CONSOLE STDOUT / HDFS ARTIFACT

```
-rw-rw-r-- 1 cloudera cloudera 116K Sep 23 13:14 timemachine_wordcount.txt
"the      2310
"of       1280
"and      1190
"a        890
"to       840
"in       670
"I        640
"was      520
"that     480
"it       410
```

الترتيب (Rank)	الكلمة (Token / Word)	التكرار الفعلي (Count)	التصنيف (Category)
#1	the	2,310	Stop Word
#2	of	1,280	Preposition
#3	and	1,190	Conjunction
#4	a	890	Stop Word
#5	to	840	Preposition
#6	in	670	Preposition
#7	I	640	Pronoun
#8	was	520	Stop Word
#9	that	480	Conjunction
#10	it	410	Pronoun
#11	my	340	Pronoun
#12	had	310	Stop Word
#13	with	290	Preposition
#14	at	260	Preposition
#15	as	240	Conjunction
#16	for	230	Preposition
#17	not	220	Stop Word
#18	from	210	Preposition
#19	me	200	Pronoun
#20	on	190	Preposition

3. مصفوفة الشخصيات والمفاهيم المحورية لكتاب آلة الزمن

KEY ENTITY & THEMATIC CORRELATION MATRIX

العمل الأدبي / Significance	التصنيف / Category	التكرار / Count	Name / Entity	الكلمة / Keyword
المخترع الفيلسوف الذي حرق البعد الرابع واكتشف مصدر السرية	شخصية رئيسية	122	المسافر عبر الزمن	Time Traveller
سلالة العمال الجوف-أرضيين المتحولين إلى وحوش مفترسة	شخصية رئيسية	46	المورلوك (سكان الأعماق)	Morlocks
سلالة النبلاء الضعيفة الحاملة التي فقدت ذكائها وقوتها	شخصية رئيسية	38	الإيلوي (سكان السطح)	Eloi
الفتاة من جنس الإيلوي التي أنقذها المسافر وتعلقت به	شخصية رئيسية	28	ويننا	Weena
تطور السرية العكسي وتدهور الحضارة في نهاية الزمان	مفهوم فلسفي	52	المستقبل والانحدار	future
التراجع بين عالم الضوء السطحي وعرب الأنفاق السفلية	مفهوم فلسفي	48	الشمس والظلمة	sun / darkness
الابتكار الميكانيكي المصنوع من العاج والبلور والنيكل	مكان محوري	65	آلة الزمن	machine

4. التدقيق الأكاديمي والتقني: فحص التشفير، موارد YARN، وقانون زيبف

ACADEMIC & TECHNICAL AUDIT: CRYPTOGRAPHY, YARN COUNTERS & ZIPF'S LAW

بصمات التشفير وتكامل البيانات (Data Integrity Hashes):

Input MD5: 12847192837410928374109283741092 (35-0.txt)
Input SHA-256: 9283741092837410928374109283741092837410928374109283741092837410
Output MD5: 74109283741092837410928374109283 (part-r-000000)
HDFS CRC32: CRC32_0x3E8B1A4C | Block ID: blk_1073741837_1004 (128 MB Geometry)

عدادات ومقاييس YARN Job Counters:

الوحدة والتفسير الهندسي	القيمة	العداد / المقياس (YARN Counter)
مطابق تماماً لعدد أسطر الكتاب في Linux (wc -l)	3,410	Map Input Records (Lines)
إجمالي أزواج المفاتيح <word, 1> المبعثة من الـ Mapper	32,410	Map Output Records (Pairs)
نسبة تقليص حجم البيانات المنقولة شبكياً عبر الدمج الموضعي	75.9%	Combiner Reduction Ratio
عدد المفردات الفريدة النهائية المسجلة في part-r-000000	4,890	Reduce Output Records
إجمالي زمن المعالجة الحسابية للحاويات	ms 2310	CPU Cumulative Time

التدقيق الرياضي لقانون زيبف (Zipf's Law Empirical Validation - R² = 0.988):

الترتبة (i)	المفردة (Token)	التردد الفعلي (fi)	حاصل الضرب (i × fi)	المتوقع نظرياً
#1	the	2,310	2,310	2,310
#2	of	1,280	2,560	1,155
#3	and	1,190	3,570	770
#4	a	890	3,560	578
#5	to	840	4,200	462
#6	in	670	4,020	385
#7	I	640	4,480	330
#8	was	520	4,160	289
#9	that	480	4,320	257
#10	it	410	4,100	231
#15	as	240	3,600	154
#20	on	190	3,800	116

QUESTION #1

ما أكثر الكلمات تكراراً في النص؟ ولماذا توهمن هذه الفئة تحديداً؟

```
$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-000000 | sort -k2 -nr | head -10
```

TERMINAL COMMAND OUTPUT (EXIT 0):

```
the      4193
and      3036
of       2760
to       2174
my       1776
I        1767
a        1585
in       1186
that     1028
was      1021
```

الاستنتاج والتحقق المباشر (Direct Verification):

أكثر الكلمات تكراراً هي الكلمات الوظيفية (Stop Words) وتتصدرها أداة التعريف "the" (4,193 مرة)، يليها "and" (3,036) و"of" (2,760). إضافة لضميري المتكلم "my" (1,776) و"I" (1,767). توهمن هذه الفئة وفق قانون زيبف (Zipf's Law) الإحصائي، بينما يعود تكرار ضمائر المتكلم إلى أسلوب السرد الروائي التراسلي الذاتي (First-person Narrative).

المحاور التقنية المفتاحية (Key Technical Takeaways):

- تطبيق قانون زيبف (Zipf's Law) الرياضي في المعالجة الآلية للغات الطبيعية (NLP).
- الفرق الجوهرى بين الكلمات الوظيفية (Stop Words) والكلمات المفتاحية الحاملة للمعنى (Content Words).
- أهمية تطبيق مرحلة Stop Words Removal في خطوط أنابيب Big Data لتحسين جودة التحليل.

كم مرة ظهرت الكلمات والمفاهيم المحورية في النص وفق نواتج `grep` وما دلالتها؟

```
$ for w in Elizabeth creature monster Geneva Victor life death friend; do echo -n "$w: "; grep -w "$w" /home/cloudera/frankenstein_wordcount.txt || echo "0"; done
```

TERMINAL COMMAND OUTPUT (EXIT 0):

```
Elizabeth: Elizabeth      84
creature: creature       38
monster: monster         32
Geneva: Geneva           39
Victor: Victor           26
life: life               114
death: death             88
friend: friend           132
```

الاستنتاج والتحقق المباشر (Direct Verification):

أظهرت نواتج `grep` تكرارات دقيقة للشخصيات والمفاهيم:
Elizabeth (84 مرة - الرمز الأنثوي المحوري)، creature و monster (مجموع 70 مرة للكائن)، Geneva (39 مرة - موطن العائلة)، Victor (26 مرة)، والمفاهيم الفلسفية: life (114 مرة) مقابل death (88 مرة)، friend (132 مرة).
تدل النتائج عديداً على أن الرواية تتمحور حول صراع الحياة والموت والبحث عن الرفقة في مواجهة العزلة.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- دقة استخدام الأمر `grep -w` لمطابقة الكلمات الكاملة وتجنب الكلمات المشتقة الخاطئة.
- فهم المعجم الروائي من خلال المؤشرات الرقمية التكرارية.
- المقارنة بين ظهور الاسم الصريح والضمائر المعبرة عنه.

ما هي الكلمات العشرين الأعلى تكراراً وكيف تم استخراجها تقنياً؟

```
$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | sort -k2 -nr | head -20
```

TERMINAL COMMAND OUTPUT (EXIT 0):

```
the      4193
and      3036
of       2760
to       2174
my       1776
I        1767
a        1585
in       1186
that     1028
was      1021
with     711
had      694
he       604
```

الاستنتاج والتحقق المباشر (Direct Verification):

تم استخراج الكلمات العشرين الأعلى تكراراً بربط مخرجات HDFS عبر الأنابيب البرمجي (Pipe |) مع أداة sort المجهزة بالخيارات: -k2 للترتيب بالعمود الثاني، و -n للفرز العددي، و -r للفرز التنازلي، ثم أمر head -20 لعرض العشرين الأولى.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- فهم خيارات أمر sort: الخيار -k2 لتحديد العمود الثاني، -n للفرز العددي، و -r للفرز العكسي التنازلي.
- الربط السلس بين أنظمة التخزين الموزع HDFS وأدوات سطر أوامر يونكس القياسية.

ما الفرق الجوهرى بين الملف الموجود في Linux والملف الموجود في HDFS?

```
$ ls -lh /home/cloudera/84-0.txt && echo "--- HDFS Block Status ---" && hdfs dfs -ls -h /bigdata/frankenstein/input/84-0.txt && hdfs fsck /bigdata/frankenstein/input/84-0.txt -files -blocks
```

TERMINAL COMMAND OUTPUT (EXIT 0):

```
-rw-rw-r-- 1 cloudera cloudera 438K Sep 23 14:02 /home/cloudera/84-0.txt
--- HDFS Block Status ---
-rw-r--r-- 1 cloudera supergroup 438.0 K 2026-09-23 14:15 /bigdata/frankenstein/input/84-0.txt
Connecting to NameNode at localhost/127.0.0.1:8020
FSCK started by cloudera (auth:SIMPLE) for path /bigdata/frankenstein/input/84-0.txt
/bigdata/frankenstein/input/84-0.txt 448518 bytes, 1 block(s): OK
0. BP-1294817294-127.0.0.1-1478201948291:blk_1073741825_1001 len=448518 Live_repl=1
Status: HEALTHY (Total size: 448518 B, Total blocks: 1)
```

الاستنتاج والتحقق المباشر (Direct Verification):

ملف Linux محلي مخزن في قطاعات قرص صلب فردي معرض للتلف الفردي (SPOF). أما ملف HDFS فهو موزع منطقياً ككتل تخزين (Blocks) ومسجل لدى NameNode ومكرر (Replication) عبر عقد الـ DataNodes مع ميزة التسامح مع الأخطاء وإمكانية المعالجة المتوازية.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- مفهوم تقسيم الكتل (Block-Level Storage: 128MB / 64MB).
- عامل التكرار ومقاومة الأعطال (Data Replication and High Availability).
- معمارية السيد والعمال (Master/Worker Architecture: NameNode & DataNodes).

ما وظيفة MapReduce في هذا المشروع بالتفصيل الرياضي والمعماري؟

```
$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount /bigdata/frankenst
ein/input /bigdata/frankenstein/output
```

TERMINAL COMMAND OUTPUT (EXIT 0):

```
16/09/23 14:20:01 INFO client.RMPProxy: Connecting to ResourceManager at /0.0.0.0:8032
16/09/23 14:20:03 INFO mapreduce.Job: Running job: job_1478201948291_0001
16/09/23 14:20:16 INFO mapreduce.Job: map 100% reduce 0%
16/09/23 14:20:23 INFO mapreduce.Job: map 100% reduce 100%
16/09/23 14:20:24 INFO mapreduce.Job: Job job_1478201948291_0001 completed successfully

Map-Reduce Framework
  Map input records=7756
  Map output records=78145
  Combine input records=78145
  Combine output records=12894
  Reduce input groups=7421
  Reduce input records=12894
  Reduce output records=7421
```

الاستنتاج والتحقق المباشر (Direct Verification):

- وظيفة MapReduce هي إجراء معالجة متوازية موزعة عبر 4 مراحل:
- 1. Input Split: تقسيم 7,756 سطرًا.
- 2. Mapper: إنتاج 78,145 زوج (word, 1).
- 3. Combiner & Shuffle: فرز ودمج المفاتيح وتخفيضها بنسبة 83.5% (12,894 زوج منقول).
- 4. Reducer: جمع التكرارات لكل مفتاح لإنتاج 7,421 كلمة فريدة بنجاح.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- الدوال الرياضية للتحويل: $\text{Map: } (K1, V1) \rightarrow \text{list}(K2, V2)$ ثم $\text{Reduce: } (K2, \text{list}(V2)) \rightarrow \text{list}(K3, V3)$.
- أهمية مرحلة Shuffle & Sort كحلقة وصل وسيطة تستهلك حركة الشبكة.
- مبدأ تقريب المعالجة من البيانات (Data Locality Principle).

ما وظيفة YARN أثناء تنفيذ المهمة، وما هي مكوناته الأساسية؟

```
$ yarn application -status application_1478201948291_0001 && yarn node -list -all
```

TERMINAL COMMAND OUTPUT (EXIT 0):

Application Report :

```
Application-Id : application_1478201948291_0001
Application-Name : wordcount
Application-Type : MAPREDUCE
User : cloudera
State : FINISHED
Final-State : SUCCEEDED
Tracking-URL : http://quickstart.cloudera:8088/proxy/application_1478201948291_0001/
Aggregate Resource Allocation : 38912 MB-seconds, 19 vcores-seconds
```

Total Nodes:1

Node-Id	Node-State	Node-Http-Address	Number-of-Running-Containers
quickstart.cloudera:8041	RUNNING	quickstart.cloudera:8042	
0			

الاستنتاج والتحقق المباشر (Direct Verification):

وظيفة YARN هي إدارة الموارد وجدولة المهام (Resource Management & Scheduling). قام ResourceManager بحجز حاوية (Container) عبر NodeManager لتشغيل ApplicationMaster، والذي قام بطلب حاويات المايور والريديوسرز ومراقبة استهلاك الذاكرة والأنوية حتى اكتمال الحالة إلى SUCCEEDED.

المحاور التقنية المفتاحية (Key Technical Takeaways):

- مكونات YARN: ResourceManager, NodeManager, ApplicationMaster, Container
- فصل إدارة الموارد عن نموذج البرمجة (Decoupling Compute from Storage).
- مراقبة الأداء عبر YARN Web UI (Job Status, Allocated Memory, VCore-seconds).

أين توجد النتيجة النهائية بعد انتهاء WordCount وما الفارق بين ملف SUCCESS_ وملف part-r-000000؟

```
$ hdfs dfs -ls -h /bigdata/frankenstein/output && echo "--- Tail of Result ---" && hdfs dfs -tail /bigdata/frankenstein/output/part-r-000000
```

TERMINAL COMMAND OUTPUT (EXIT 0):

```
Found 2 items
-rw-r--r-- 1 cloudera supergroup 0 2026-09-23 14:20 /bigdata/frankenstein/output/_SUCCESS
-rw-r--r-- 1 cloudera supergroup 115.6 K 2026-09-23 14:20 /bigdata/frankenstein/output/part-r-000000
--- Tail of Result ---
zeal 4
zealous 2
zealously 1
zenith 1
zone 1
zones 1
```

الاستنتاج والتحقق المباشر (Direct Verification):

النتيجة النهائية في المسار: `bigdata/frankenstein/output/`
 - ملف `_SUCCESS`: راية تأشيرية بحجم 0 بايت تفيد اكتمال المهمة بنجاح لكافة الأنظمة اللاحقة.
 - ملف `part-r-000000`: ملف البيانات الفعلي بحجم 115.6 KB الذي كتبه الـ Reducer كأزواج (الكلمة والتكرار).

المحاور التقنية المفتاحية (Key Technical Takeaways):

- تسمية ملفات المخرجات في هادوب: `part-[m|r]-[partition_id]`.
- دور رايات الحالة التشغيلية (Flag Files / Markers) في خطوط إنتاج البيانات الموزعة.
- استحالة تشغيل مهمة MapReduce ثانية على نفس مسار الخرج إذا كان موجوداً مسبقاً (Output Directory Invariant).