

بسم الله الرحمن الرحيم

Republic Of Yemen
Ministry Of Higher Education And
Scientific Research
International Malaysian University
Faculty Of Engineering And IT
Department of Information
Technology



الجمهورية اليمنية
وزارة التعليم العالي والبحث العلمي
الجامعة الماليزية الدولية
كلية الهندسة وتقنية المعلومات
قسم تقنية المعلومات

Analysis of the novel

Pride and Prejudice

باستخدام

Hadoop MapReduce

By/Hajar Abdulkaleq Alhobaishi

Eng/ Ramzi Albazil.

ما أكثر الكلمات تكرر في النص؟

```
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -cat /bigdata/pride_and_prejudice/output/part-r-000000 | sort -k2 -nr | head -20
the      4340
to       4203
of       3788
and      3376
a        1965
her      1905
in       1865
was      1814
I        1764
that     1446
not      1406
she      1341
be       1211
his      1196
as       1156
had      1131
he       1052
with     1040
for      1019
it       980
```

Beneet	Lydia	Jane	Darcy
--------	-------	------	-------

```
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -cat /bigdata/pride_and_prejudice/output/part-r-000000 | grep -w "Darcy"
Darcy 217
Darcy! 7
Darcy!--and 1
Darcy!" 2
Darcy, 100
Darcy,-- 1
Darcy," 6
Darcy--that 1
Darcy. 20
Darcy.) 1
Darcy." 5
Darcy: 1
Darcy; 8
Darcy;--but 1
Darcy;--that 1
Darcy? 1
Darcy?" 8
Darcy's 43
Darcy's, 3
Darcy's." 1
matter--Darcy 1
```

```
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -cat /bigdata/pride_and_prejudice/output/part-r-000000 | grep -w "Jane"
```

```
Jane 153  
Jane! 3  
Jane, 77  
Jane," 5  
Jane--one 1  
Jane--which 1  
Jane--you 1  
Jane. 15  
Jane: 2  
Jane; 10  
Jane? 1  
Jane?" 1  
Jane's 27  
Jane's." 1  
Jane's? 1  
"Jane 2  
"Jane, 1
```

```
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -cat /bigdata/pride_and_prejudice/output/part-r-000000 | grep -w "Lydia"
```

```
Lydia 82  
Lydia! 1  
Lydia!" 3  
Lydia, 26  
Lydia," 2  
Lydia--the 1  
Lydia. 10  
Lydia." 1  
Lydia: 1  
Lydia; 6  
Lydia?" 1  
Lydia's 40  
"Lydia 1
```

```
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -cat /bigdata/pride_and_prejudice/output/part-r-00000 | grep -w "Bennet"
Bennet 175
Bennet! 1
Bennet!" 1
Bennet, 89
Bennet,--she 1
Bennet,' 1
Bennet," 8
Bennet. 12
Bennet.'--"My 1
Bennet." 1
Bennet: 2
Bennet; 10
Bennet? 1
Bennet?" 3
Bennet's 30
Bennet" 2
```

ما الكلمات العشرون الأعلى تكراراً؟

```
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -cat /bigdata/pride_and_prejudice/output/part-r-00000 | sort -k2 -nr | head -20
the 4340
to 4203
of 3788
and 3376
a 1965
her 1905
in 1865
was 1814
I 1764
that 1446
not 1406
she 1341
be 1211
his 1196
as 1156
had 1131
he 1052
with 1040
for 1019
it 980
```

ما الفرق بين الملف الموجود في Linux والملف الموجود في HDFS ؟

الملف الموجود في Linux هو ملف محلي مخزن على نظام ملفات Debian، وهو:

pride_and_prejudice.txt

أما الملف الموجود في HDFS فهو نسخة مخزنة داخل نظام الملفات الموزع الخاص بـ Hadoop ومساره:

bigdata/pride_and_prejudice/input/pride_and_prejudice.txt

الملف المحلي نتعامل معه بأوامر مثل:

ls

cat

head

wc

أما ملف HDFS فنتعامل معه بأوامر مثل:

hdfs dfs -ls

hdfs dfs -cat

hdfs dfs -put

ما وظيفة MapReduce في هذا المشروع؟

وظيفة MapReduce هي معالجة نص كتاب Pride and Prejudice وحساب عدد مرات ظهور كل كلمة والعمل يتم بثلاث مراحل رئيسية:

Mapper → Shuffle → Reducer

فـ Mapper يحوّل الكلمات إلى أزواج مثل:

Jane 1

Darcy 1

Jane 1

ثم تجمع Shuffle الكلمات المتشابهة، وبعد ذلك يقوم Reducer بجمع الأعداد وإنتاج النتيجة النهائية:

2	Jane
1	Darcy

ما وظيفة YARN أثناء تنفيذ المهمة؟

وظيفة YARN هي إدارة موارد Hadoop أثناء تشغيل مهمة WordCount، وتوزيع الموارد ومتابعة تنفيذ Map والـ Reduce من خلال ResourceManager وNodeManager. وفي تجربتنا الفعلية ظهرت المهمة في واجهة YARN بهذه المعلومات:

Name: word count

Application Type: MAPREDUCE

YarnApplicationState: FINISHED

FinalStatus: SUCCEEDED

وهذا يثبت أن مهمة WordCount تم تنفيذها بنجاح من خلال YARN.

أين توجد النتيجة النهائية بعد انتهاء WordCount؟

مخرجات المهمة موجودة داخل HDFS في:

/bigdata/pride_and_prejudice/output

والنتيجة الفعلية موجودة في:

/bigdata/pride_and_prejudice/output/part-r-00000

مسار HDFS & مخرجات MapReduce:

```
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -ls /bigdata/pride_and_prejudice/input
Found 1 items
-rw-r--r-- 1 hajar supergroup 738046 2026-09-23 21:54 /bigdata/pride_and_prejudice/input/pride_and_prejudice.txt
```

```
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -ls /bigdata/pride_and_prejudice/output
Found 2 items
-rw-r--r-- 1 hajar supergroup 0 2026-09-23 22:29 /bigdata/pride_and_prejudice/output/_SUCCESS
-rw-r--r-- 1 hajar supergroup 157319 2026-09-23 22:29 /bigdata/pride_and_prejudice/output/part-r-00000
```

لقطات شاشة داخل بيئة العمل وايضاً للنتائج على ال <http://localhost:8088>:

```
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -cat /bigdata/pride_and_prejudice/output/part-r-00000 | sort -k2 -nr | head -20
the      4340
to       4203
of       3788
and      3376
a        1965
her      1905
in       1865
was      1814
I        1764
that     1446
not      1406
she      1341
be       1211
his      1196
as       1156
had      1131
he       1052
with     1040
for      1019
it       980
```

```
1001 ops
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -mkdir -p /bigdata/pride_and_prejudice/input
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -ls /bigdata/pride_and_prejudice/input
hajar@DESKTOP-8HC0Q6U:~$ hdfs dfs -ls /bigdata
Found 3 items
drwxr-xr-x - hajar supergroup 0 2026-09-23 21:44 /bigdata/pride_and_prejudice
drwxr-xr-x - hajar supergroup 0 2026-09-19 21:23 /bigdata/sherlock
drwxr-xr-x - hajar supergroup 0 2026-09-19 21:26 /bigdata/sherlock2
hajar@DESKTOP-8HC0Q6U:~$
```

```
hajar@DESKTOP-8HC0Q6U:~$ yarn application -list -appStates ALL
026-09-23 22:34:59,960 INFO client.DefaultNoHARMFaloverProxyProvider: Connecting to ResourceManager at localhost/127.0
0.1:8032
Total number of applications (application-types: [], states: [NEW, NEW_SAVING, SUBMITTED, ACCEPTED, RUNNING, FINISHED, F
AILED, KILLED] and tags: []):1
Application-Id      Application-Name      Application-Type      User      Queue
State      Final-State      Progress      Tracking-URL
application_1790189035205_0004      word count      MAPREDUCE      hajar      root.default
FINISHED      SUCCEEDED      100% http://DESKTOP-8HC0Q6U.localdomain:19888/jobhistory/job/job_1790
189035205_0004
```



FINISHED Ap

Cluster											
About Nodes Node Labels Applications NEW NEW_SAVING SUBMITTED ACCEPTED RUNNING FINISHED FAILED KILLED Scheduler											
Tools											
Cluster Metrics											
Apps Submitted Apps Pending Apps Running Apps Completed Containers Running Used Resources											
1 0 0 1 0 <memory:0 B, vCores:0>											
Cluster Nodes Metrics											
Active Nodes Decommissioning Nodes Decommissioned Nodes											
1 0 0 0											
Scheduler Metrics											
Scheduler Type Scheduling Resource Type Minimum Allocation Maximum Allocation Maximum (											
Capacity Scheduler [memory-mb (unit=Mi), vcores] <memory:1024, vCores:1> <memory:8192, vCores:4> 0											
Show 20 entries											
ID	User	Name	Application Type	Application Tags	Queue	Application Priority	StartTime	LaunchTime	FinishTime	State	FinalS
application_1790189035205_0004	hajar	word count	MAPREDUCE		root.default	0	Wed Sep 23 22:29:05 +0300 2026	Wed Sep 23 22:29:06 +0300 2026	Wed Sep 23 22:29:27 +0300 2026	FINISHED	SUCCE
Showing 1 to 1 of 1 entries											

FINISHED Applications

Running														
1 Apps Completed 0 Containers Running Used Resources <memory:0 B, vCores:0> Total Resources <memory:8 GB, vCores:8> Reserved Resources <memory:0 B, vCores:0>														
Decommissioning Nodes Decommissioned Nodes Lost Nodes Unhealthy Nodes														
0 0 0 0														
Minimum Allocation Maximum Allocation Maximum Cluster Application Priority Scheduler Busy % RM Dispatcher Ever														
<memory:1024, vCores:1> <memory:8192, vCores:4> 0 0 0														
on	Application Tags	Queue	Application Priority	StartTime	LaunchTime	FinishTime	State	FinalStatus	Running Containers	Allocated CPU VCores	Allocated Memory MB	Allocated GPUs	Reserved CPU VCores	Reserved Memory MB
ICE		root.default	0	Wed Sep 23 22:29:05 +0300 2026	Wed Sep 23 22:29:06 +0300 2026	Wed Sep 23 22:29:27 +0300 2026	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A	N/A



Logged in as: dr.who

Application application_1790189035205_0004

Cluster	Application Overview
About	User: hajar
Nodes	Name: word count
Node Labels	Application Type: MAPREDUCE
Applications	Application Tags:
NEW	Application Priority: 0 (Higher Integer value indicates higher priority)
NEW_SAVING	YarnApplicationState: FINISHED
SUBMITTED	Queue: root.default
ACCEPTED	FinalStatus Reported by AM: SUCCEEDED
RUNNING	Started: Wed Sep 23 22:29:05 +0300 2026
FINISHED	Launched: Wed Sep 23 22:29:06 +0300 2026
FAILED	Finished: Wed Sep 23 22:29:27 +0300 2026
KILLED	Elapsed: 22sec
Scheduler	Tracking URL: History
Tools	Log Aggregation Status: DISABLED
	Application Timeout (Remaining Time): Unlimited
	Diagnostics:
	Unmanaged Application: false
	Application Node Label expression: <Not set>
	AM container Node Label expression: <DEFAULT_PARTITION>

ملف النتائج:

```
-rw-r--r-- 1 hajar hajar 154K Sep 23 23:14 novel_wordcount.txt
hajar@DESKTOP-8HC0Q6U:~$ head -20 novel_wordcount.txt
&      1
(By     1
(I      1
(Lady   1
(affection  1
(an     1
(and    3
(arising  1
(by-the-bye,  1
(for    4
(glancing  1
(her    1
(if     3
(it     1
(like   1
(most   1
(my     1
(not    1
(though 1
(to     1
```

التحليل المختصر:

أظهرت نتائج تطبيق WordCount على كتاب Pride and Prejudice نجاح بيئة Hadoop في تنفيذ دورة معالجة بيانات متكاملة، بدءًا من تخزين الملف النصي داخل HDFS، ثم معالجته باستخدام MapReduce لحساب عدد مرات ظهور كل كلمة، وانتهاءً بحفظ النتائج داخل مسار المخرجات. كما تم التأكد من نجاح عملية التنفيذ من خلال واجهة YARN، حيث ظهرت مهمة word count من نوع MAPREDUCE بالحالة FINISHED والنتيجة النهائية SUCCEEDED.

أتاحت النتائج التعرف على الكلمات الأكثر تكرارًا في النص، إضافة إلى تحليل تكرار أسماء بعض الشخصيات الرئيسية مثل Elizabeth و Darcy و Bennet و Jane. وتوضح التجربة عمليًا التكامل بين HDFS لتخزين البيانات، و MapReduce لمعالجتها، و YARN لإدارة موارد التنفيذ ومتابعة المهمة.