



تقرير مشروع عملي

تحليل النصوص الكبيرة باستخدام Hadoop MapReduce

تنفيذ عملي على VM Cloudera QuickStart داخل VMware

إعدادات الطالب	هاجر الصنعاني
المقرر	Big Data Text Analytics
الأدوات	Linux · HDFS · MapReduce · YARN
البيانات المستخدمة فعليًا	كتاب Frankenstein

تقرير موثق بالصور والنتائج الفعلية من بيئة Cloudera

الملخص التنفيذي

يوثق هذا التقرير تنفيذ مشروع تحليل نصي باستخدام منظومة Hadoop على بيئة Cloudera QuickStart VM داخل VMware. جرى فحص ملف كتاب نصي في Linux، ورفعته إلى HDFS، وتشغيل WordCount باستخدام MapReduce، ثم مراقبة المهمة عبر YARN وتحليل المخرجات.

ملاحظة حول الاختلاف في البيانات: الإرشادات الأكاديمية تشير إلى كتاب *The Adventures of Sherlock Holmes*، إلا أن لقطات التنفيذ الفعلية المرفقة توضح استخدام كتاب *Frankenstein* ومساراته. لذلك يعرض هذا التقرير ما تم تنفيذه فعليًا في الصور، مع المحافظة على متطلبات المشروع الأكاديمية وشرح سبب الاختلاف.

1. أهداف المشروع

يهدف المشروع إلى تطبيق دورة معالجة بيانات نصية كاملة على Hadoop، بدءًا من التحقق من البيانات، مرورًا بتخزينها ومعالجتها بصورة موزعة، وانتهاءً باستخراج النتائج وتحليلها.

- التمييز بين نظام الملفات المحلي Linux ونظام الملفات الموزع HDFS.
- إنشاء مسارات منظمة داخل HDFS ورفع البيانات إليها.
- تشغيل Mapper وShuffle وReducer ضمن WordCount.
- فهم دور YARN في إدارة موارد وتشغيل المهمة.
- قراءة النتائج، وترتيب الكلمات، والبحث عن أسماء الشخصيات.
- التعرف على أثر علامات الترقيم في دقة عدّ الكلمات.

2. بيئة التنفيذ والبيانات

العنصر	القيمة الفعلية
البيئة	VMware QuickStart VM داخل Cloudera
المستخدم	cloudera@quickstart

frankenstein.txt	الملف النصي
428 KB محليًا، و437,729 بايت داخل HDFS	الحجم
7,649	عدد الأسطر
75,721	عدد الكلمات
/bigdata/frankenstein/input	مسار الإدخال
/bigdata/frankenstein/output	مسار الإخراج

3. دورة البيانات

1. Data Validation

فحص الملف محليًا باستخدام ls و wc.

2. HDFS Ingestion

تخزين نسخة البيانات داخل مسار الإدخال.

3. MapReduce Processing

حساب تكرار كل كلمة بصورة موزعة.

4. YARN Orchestration

إدارة الموارد ومتابعة حالة التطبيق.

5. Analysis

قراءة النتائج وترتيبها والبحث داخلها.

6. Extraction

استخراج النتائج من HDFS إلى Linux.


4. أوامر التنفيذ

4.1 فحص الملف محليًا

تم التحقق من وجود الملف وحجمه وعدد أسطره وكلماته قبل إدخاله إلى Hadoop.

قسم فحص الملف محليًا


الصورة 12



فحص الملف محليًا باستخدام ls و wc قبل المعالجة.

قسم إدخال البيانات إلى HDFS

الصورة 6




```
frankenstein.txt
[cloudera@quickstart ~]$ hdfs dfs -ls -h /bigdata/frankenstein/input/
Found 1 items
-rw-r--r-- 1 cloudera supergroup 427.5 K 2026-09-23 11:10 /bigdata/frankenstein/input/frankenstein.txt
[cloudera@quickstart ~]$
```

التحقق من وجود ملف الإدخال داخل HDFS وحجمه.

قسم فحص HDFS وسلامة الكتلة

الصورة 10

A screenshot of a terminal window on a Linux system. The terminal shows the execution of the 'hdfs fsck' command to check the integrity of a file in HDFS. The output indicates that the file 'frankenstein.txt' is healthy, with a total size of 437,729 bytes and 1 block. The replication factor is 1, and all blocks are properly replicated. The terminal also shows the file's location in the HDFS hierarchy and the path to the Hadoop MapReduce examples jar file.

```
*** START OF THIS PROJECT GUTENBERG EBOOK FRANKENSTEIN ***
cat: Unable to write to output stream.
[cloudera@quickstart ~]$ hdfs dfs -du -h /bigdata/frankenstein/input
427.5 K 427.5 K /bigdata/frankenstein/input/frankenstein.txt
[cloudera@quickstart ~]$ hdfs fsck /bigdata/frankenstein/input/frankenstein.txt -files -blocks
Connecting to namenode via http://quickstart.cloudera:50070/fsck?ugi=cloudera&files=1&blocks=1&path=/bigdata%2Ffrankenstein%2Finput%2Ffrankenstein.txt
FSCK started by cloudera (auth:SIMPLE) from /192.168.91.128 for path /bigdata/frankenstein/input/
frankenstein.txt at Wed Sep 23 11:18:28 PDT 2026
0. BP-333635372-127.0.0.1-1508779710286:blk_1073742815_1991 len=437729 Live_repl=1

Status: HEALTHY
Total size: 437729 B
Total dirs: 0
Total files: 1
Total symlinks: 0
Total blocks (validated): 1 (avg. block size 437729 B)
Minimally replicated blocks: 1 (100.0 %)
Over-replicated blocks: 0 (0.0 %)
Under-replicated blocks: 0 (0.0 %)
Mis-replicated blocks: 0 (0.0 %)
Default replication factor: 1
Average block replication: 1.0
Corrupt blocks: 0
Missing replicas: 0 (0.0 %)
Number of data-nodes: 1
Number of racks: 1
FSCK ended at Wed Sep 23 11:18:28 PDT 2026 in 3 milliseconds

The filesystem under path '/bigdata/frankenstein/input/frankenstein.txt' is HEALTHY
[cloudera@quickstart ~]$ hdfs dfs -stat %r /bigdata/frankenstein/input/frankenstein.txt
1
[cloudera@quickstart ~]$ ls /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
```

فحص HDFS باستخدام fsck والتأكد من سلامة الملف والكتلة.

```
ls -lh frankenstein.txt
wc -l frankenstein.txt
wc -w frankenstein.txt
```

4.2 فحص HDFS وسلامة الكتل

```
hdfs dfs -du -h /bigdata/frankenstein/input
hdfs fsck /bigdata/frankenstein/input/frankenstein.txt -files -blocks
-locations
```

أظهر الفحص أن نظام الملفات سليم، وأن الملف مخزن في كتلة واحدة دون كتل تالفة أو مفقودة. كما ظهر عامل نسخ يساوي 1، وهو متوقع في بيئة QuickStart المحلية.

4.3 تشغيل WordCount

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
wordcount \
  /bigdata/frankenstein/input \
  /bigdata/frankenstein/output
```

4.4 قراءة النتائج واستخراجها


```
hdfs dfs -ls /bigdata/frankenstein/output
hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | head -20
hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | sort -k2 -nr
| head -20
hdfs dfs -getmerge /bigdata/frankenstein/output
frankenstein_wordcount.txt
```

5. النتائج ومؤشرات الأداء

توضح اللقطات أن المهمة اكتملت بنجاح، وأن YARN أدار تطبيق MapReduce حتى ظهور الحالة النهائية **.FINISHED / SUCCEEDED**

قسم تشغيل WordCount

الصورة 5



```
File Edit View Search Terminal Help
cloudera@quickstart:~$ hdfs dfs -stat %r /bigdata/frankenstein/input/frankenstein.txt
Number of racks: 1
FSCK ended at Wed Sep 23 11:18:28 PDT 2026 in 3 milliseconds

The filesystem under path '/bigdata/frankenstein/input/frankenstein.txt' is HEALTHY
cloudera@quickstart:~$ hdfs dfs -stat %r /bigdata/frankenstein/input/frankenstein.txt
1
cloudera@quickstart:~$ ls /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
/usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar
cloudera@quickstart:~$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar wordcount /bigdata/frankenstein/input /bigdata/frankenstein/output
26/09/23 11:22:11 INFO client.RMPProxy: Connecting to ResourceManager at quickstart.cloudera:192.168.91.128:8032
26/09/23 11:22:11 INFO input.FileInputFormat: Total input paths to process : 1
26/09/23 11:22:12 INFO mapreduce.JobSubmitter: number of splits:1
26/09/23 11:22:12 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1790184681256_0001
26/09/23 11:22:12 INFO impl.YarnClientImpl: Submitted application application_1790184681256_0001
26/09/23 11:22:12 INFO mapreduce.Job: The url to track the job: http://quickstart.cloudera:8088/proxy/application_1790184681256_0001/
26/09/23 11:22:12 INFO mapreduce.Job: Running job: job_1790184681256_0001
26/09/23 11:22:19 INFO mapreduce.Job: Job job_1790184681256_0001 running in uber mode : false
26/09/23 11:22:19 INFO mapreduce.Job: map 0% reduce 0%
26/09/23 11:22:26 INFO mapreduce.Job: map 100% reduce 0%
26/09/23 11:22:32 INFO mapreduce.Job: map 100% reduce 100%
26/09/23 11:22:33 INFO mapreduce.Job: Job job_1790184681256_0001 completed successfully
26/09/23 11:22:33 INFO mapreduce.Job: Counters: 49
File System Counters
FILE: Number of bytes read=88497
FILE: Number of bytes written=471913
FILE: Number of read operations=0
FILE: Number of large read operations=0
FILE: Number of write operations=0
HDFS: Number of bytes read=437869
HDFS: Number of bytes written=129319
HDFS: Number of read operations=6
```

تشغيل WordCount وظهور انتقال Map و Reduce إلى 100%.

المؤشر	القيمة
نوع التطبيق	MAPREDUCE
مهام Map	1
مهام Reduce	1
Map input records	7,649
Map output records	75,721
Reduce input groups	12,152
Reduce output records	12,152
حجم الخرج	129,319 بايت تقريبًا
الزمن المنقضي	18 ثانية تقريبًا


6. تحليل الكلمات الأكثر تكرارًا

تظهر النتائج أن الكلمات العامة في اللغة الإنجليزية تتصدر القائمة. جاءت كلمة **the** بعدد 3,911 مرة، تليها **I** بعدد 1,317، ثم **in** بعدد 1,069، و**he** بعدد 998.

الكلمة	عدد الظهور الظاهر
the	3911
I	1317
in	1069
he	998
was	957

قسم تحليل الكلمات الأكثر تكرارًا


الصورة 1



ترتيب الكلمات الأعلى تكرارًا واستخراج ملف النتائج محليًا.

قسم قراءة النتائج واستخراجها


الصورة 2



عرض بداية ملف frankenstein_wordcount.txt بعد استخراج النتائج.

قسم قراءة النتائج واستخراجها

الصورة 3




```
cloudera@quickstart:~  
File Edit View Search Terminal Help  
Bytes Written=129319  
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/frankenstein/output  
ls: /bigdata/frankenstein/output: No such file or directory  
[cloudera@quickstart ~]$ hdfs dfs -ls /bigdata/frankenstein/output  
Found 2 items  
cloudera@quickstart:~$ hdfs dfs -ls /bigdata/frankenstein/output  
-rw-r--r-- 1 cloudera supergroup 0 2026-09-23 11:22 /bigdata/frankenstein/output/_SUCCESS  
-rw-r--r-- 1 cloudera supergroup 129319 2026-09-23 11:22 /bigdata/frankenstein/output/part-r-000000  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-000000 | head -20  
"Defects," 1  
"Information 1  
"Plain 2  
"Project 5  
"Right 1  
#41445] 1  
$5,000) 1  
& 3  
&c. 1  
Trash "AS-IS", 1  
("the 1  
($1 1  
(801) 1  
(I 3  
(July 1  
(May 1  
(a 2  
(a) 1  
(although 2  
(and 1  
cat: Unable to write to output stream.  
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-000000 | grep -w "Frankenstein*v"
```

عرض نتائج HDFS والبحث عن مخرجات WordCount.

قسم النتائج ومؤشرات الأداء


الصورة 4



تفاصيل عدادات MapReduce ومؤشرات الأداء.

قسم النتائج ومؤشرات الأداء

الصورة 11



```
File Edit View Search Terminal Help
FILE: Number of bytes written=471913
FILE: Number of read operations=0
FILE: Number of large read operations=0
FILE: Number of write operations=0
HDFS: Number of bytes read=437869
HDFS: Number of bytes written=129319
HDFS: Number of read operations=6
HDFS: Number of large read operations=0
HDFS: Number of write operations=2


Job Counters
  Launched map tasks=1
  Launched reduce tasks=1
  Data-local map tasks=1
  Total time spent by all maps in occupied slots (ms)=1835520
  Total time spent by all reduces in occupied slots (ms)=1649152
  Total time spent by all map tasks (ms)=3585
  Total time spent by all reduce tasks (ms)=3221
  Total vcore-milliseconds taken by all map tasks=3585
  Total vcore-milliseconds taken by all reduce tasks=3221
  Total megabyte-milliseconds taken by all map tasks=1835520
  Total megabyte-milliseconds taken by all reduce tasks=1649152

Map-Reduce Framework
  Map input records=7649
  Map output records=75721
  Map output bytes=730647
  Map output materialized bytes=88493
  Input split bytes=140
  Combine input records=75721
  Combine output records=12152
  Reduce input groups=12152
  Reduce shuffle bytes=88493
  Reduce input records=12152
  Reduce output records=12152
  Spilled Records=24384
  Shuffled Maps =1
```

تفاصيل Job Counters و Map-Reduce Framework.

قسم النتائج ومؤشرات الأداء

الصورة 9



واجهة YARN وتفاصيل تطبيق MapReduce المنتهي بنجاح.

681	with
654	had
541	which
510	not
496	but
467	for
467	as
462	his
454	you
449	by

تعرض الصور الجزء الواضح من قائمة الترتيب. ويمكن استخراج القيم العشرين كاملة بإعادة تنفيذ أمر sort داخل بيئة Cloudera.


7. تحليل الشخصيات وتنظيف البيانات

أظهرت أوامر grep أن الاسم الواحد قد يظهر في صفوف متعددة بسبب علامات الترقيم، مثل Frankenstein Frankenstein, Frankenstein! Frankenstein?. لذلك لا تمثل قيمة صف واحد بالضرورة العدد الكلي للاسم.

الشخصية	الملاحظة من الصور
Frankenstein	ظهرت صيغ متعددة؛ منها Frankenstein! بقيمة 9، وصيغ أخرى بعلامات ترقيم مختلفة.
Victor	ظهرت صيغ متعددة؛ من القيم الظاهرة 16 و4.
Elizabeth	ظهرت Elizabeth بقيمة 39 وElizabeth, بقيمة 27.
Henry	ظهرت الصيغة الأساسية بقيمة 13، إلى جانب صيغ مرتبطة بعلامات ترقيم.

قسم تحليل الشخصيات وتنظيف البيانات

الصورة 7




```
cat: unable to write to output stream.
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | grep -w "Frankenstein"
Frankenstein! 9
Frankenstein! 2
Frankenstein, 7
Frankenstein, 3
Frankenstein--he 1
Frankenstein. 1
Frankenstein: 1
Frankenstein; 1
"Frankenstein! 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | grep -w "Victor"
Victor 1
Victor! 1
Victor, 16
Victor," 4
Victor. 1
Victor; 3
Victor? 2
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | grep -w "Elizabeth"
Elizabeth 39
Elizabeth! 2
Elizabeth!" 1
Elizabeth, 27
Elizabeth,--of 1
Elizabeth," 1
Elizabeth--and 1
```

البحث عن Frankenstein و Victor و Elizabeth داخل نتائج WordCount.

قسم تحليل الشخصيات وتنظيف البيانات

الصورة 8



```
Victor: 1
Victor: 3
Victor? 2
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | grep -w "Elizabeth"
cloudera Elizabeth 39
Elizabeth! 2
Elizabeth! 1
Elizabeth, 27
Elizabeth, --of 1
Elizabeth, " 1
Configure W Elizabeth--and 1
Elizabeth, 7
Elizabeth, " 1
Elizabeth: 1
Elizabeth: 1
Elizabeth: 1
Elizabeth: 1
Elizabeth: 3
Elizabeth? 1
Elizabeth?" 1
Elizabeth's 2
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | grep -w "Henry"v
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | grep -w "Henry"
Henry 13
Henry, 5
Henry--they 1
Henry, 2
Launch Cl Henry, 1
Expre Henry: 1
Henry: 1
Henry? 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | grep -w "Walton"
Walton! 1
Walton, 3
Enterprise Walton, 1
[cloudera@quickstart ~]$ hdfs dfs -cat /bigdata/frankenstein/output/part-r-00000 | sort -k2 -nr | head -20
the 3911
```

استكمال البحث عن Elizabeth و Henry و Walton وترتيب أعلى الكلمات.

ينتج هذا الاختلاف لأن WordCount الأساسي يعد كل سلسلة مفصولة بمسافة كلمة مستقلة. ولتحسين الدقة يجب تحويل الأحرف إلى حالة موحدة، وإزالة علامات الترقيم، ثم إعادة تشغيل المهمة.

8. الإجابة عن أسئلة المشروع

1. ما أكثر الكلمات تكرارًا؟ الكلمات العامة؛ تصدرها the بعدد 3,911.
2. ما وظيفة MapReduce؟ تحويل الكلمات إلى أزواج، وتجميع القيم المتشابهة، ثم جمعها لإنتاج عدد التكرار.
3. ما وظيفة YARN؟ إدارة موارد العنقود، جدولة الحاويات، وتشغيل ومتابعة ApplicationMaster.
4. أين توجد النتيجة النهائية؟ في HDFS داخل `/bigdata/frankenstein/output`، وبالأخص في `part-r-00000`، بينما SUCCESS_ مؤشر اكتمال.
5. ما الفرق بين Linux وHDFS؟ Linux يخزن الملف محليًا ويستخدم أوامر النظام، أما HDFS فيخزن نسخة موزعة وتتم إدارته بأوامر `hdfs dfs`.

9. الخلاصة والتوصيات

نجح المشروع في تطبيق دورة Hadoop كاملة على بيانات نصية حقيقية. فقد انتقلت البيانات من الملف المحلي إلى HDFS، ثم عولجت بواسطة MapReduce، وأديرت المهمة من خلال YARN، وأصبحت النتائج متاحة للتحليل والاستخراج.

توصي الطالبة في تجربة لاحقة بإنشاء Mapper مخصص ينظف النص قبل العد، لأن إزالة الترقيم وتوحيد حالة الأحرف ستجعل مقارنة الشخصيات أكثر دقة. كما يوصى بحفظ الملف النهائي باسم `frankenstein_wordcount.txt`.

