

تقرير مشروع تحليل نصي متكامل

باستخدام Hadoop MapReduce على كتاب

The Adventures of Sherlock Holmes

اسم الطالب: هاني مروان النمري

اسم المادة: Big Data Text Analytics

اسم المشرف: رمزي البازل

التاريخ: 2026/9/24

1. مقدمة المشروع

يهدف هذا المشروع إلى تطبيق مفاهيم **Big Data** و **Hadoop MapReduce** على بيانات نصية حقيقية، وذلك بتحليل كتاب **The Adventures of Sherlock Holmes** للكاتب **Arthur Conan Doyle**، والمأخوذ من مكتبة **Project Gutenberg** (رقم الكتاب: 1661).

دورة حياة البيانات في المشروع:

Acquisition → Validation → Ingestion → Organization → Processing → Orchestration → Analysis

2. البيانات المستخدمة

العنصر	التفصيل
اسم الكتاب	The Adventures of Sherlock Holmes
المؤلف	Arthur Conan Doyle
المصدر	Project Gutenberg
رقم الكتاب	1661
الصيغة	نصية (.txt)
حجم الملف	607,504 بايت (≈ 593 KB)
اللغة	الإنجليزية

3. مرحلة تنظيم البيانات داخل HDFS

تم إنشاء مساحة المشروع داخل HDFS باستخدام الأوامر التالية:

```
hdfs dfs -mkdir -p /bigdata/sherlock/input
hdfs dfs -put sherlock.txt /bigdata/sherlock/input/
```

```
hdfs dfs -ls /bigdata/sherlock/input
```

النتيجة:

```
Found 1 items
-rw-r--r-- 1 cloudera supergroup 607504 /bigdata/sherlock/input/sherlock.txt
```



4. تنفيذ WordCount باستخدام MapReduce

تم تشغيل برنامج WordCount المدمج في Hadoop:

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples.jar \
wordcount \
/bigdata/sherlock/input \
/bigdata/sherlock/output
```

النتائج النهائية:

```
/bigdata/sherlock/output/_SUCCESS
/bigdata/sherlock/output/part-r-00000
```

- Bytes Read: 607,504 (حجم الإدخال)
- Bytes Written: 163,591 (حجم المخرجات)

5. تحليل النتائج

5.1 الكلمات العشرة الأكثر تكراراً

#	الكلمة	عدد مرات الظهور
1	the	5,412
2	and	2,794
3	of	2,724
4	to	2,702
5	a	2,575
6	I	2,533
7	in	1,706
8	that	1,557
9	was	1,361
10	is	1,073
11	you	1,034
12	he	1,014
13	it	977
14	my	901
15	with	843
16	had	807
17	as	776
18	which	753
19	at	737
20	for	698

استنتاج: جميع الكلمات العشرين الأولى هي كلمات وظيفية (Stop Words). الالفت هو أن "I" (2,533) و "my"

(901) في مراتب متقدمة، مما يدل على أن السرد بصيغة المتكلم، وهي طبيعة كتابات الدكتور واتسون.

5.2 أسماء الشخصيات الرئيسية

الشخصية	مجموع الأشكال
Holmes	~440
Sherlock	~100
Watson	~80
Baker (Street)	~40
Lestrade	~34

استنتاج:

- **Holmes** هو الشخصية المحورية بلا منازع (~440 مرة).
- **Watson** يظهر ~80 مرة فقط، لأنه الراوي (يستخدم "I" بدلاً من اسمه).
- **Lestrade** هو المفتش الثانوي من Scotland Yard.
- **Baker Street** هو مسكن هولمز الشهير.

5.3 الكلمات الدالة على الجريمة والتحقيق

العدد التقريبي	الكلمة
118~	case
33~	crime
25~	police
24~	deduction
15~	mystery
14~	murder
14~	clue
12~	evidence
10~	theory
10~	investigation

استنتاج: كلمة "**case**" هي الأكثر دلالة على التحقيق (لأن كل قصة هي قضية)، بينما "**deduction**" تؤكد على المنهج الاستنباطي لهولمز.

5.4 الكلمات الدالة على الذكاء والتحليل

العدد التقريبي	الكلمة
32~	singular
27~	reason / reasoning
23~	obvious
18~	extraordinary
17~	remarkable
6~	observation
4~	logic / logical

5.5 مشكلة علامات الترقيم (Data Cleaning Issue)

مثال واضح على تشتت الكلمة الواحدة:

شكل الكلمة	العدد
Holmes	198
,Holmes	126
.Holmes	78
'Holmes	17
;Holmes	7
”.Holmes	5
”!Holmes	4
”?Holmes	4
?Holmes	1
Holmes—a	1
المجموع الفعلي	~440

مشكلة: بدون Data Cleaning، الكلمة الواحدة تبدو وكأنها 10 كلمات مختلفة!
الحل: إزالة علامات الترقيم + توحيد حالة الأحرف + إزالة Stop Words.

6. الإجابة على أسئلة التقرير

السؤال الأول: ما أكثر الكلمات تكراراً في النص؟

الكلمة الأكثر تكراراً هي "the" بعدد 5,412 مرة. وهي كلمة وظيفية.
أما أكثر الكلمات الدالة فهي "Holmes" بعدد ~440 مرة.

السؤال الثاني: كم مرة ظهرت الكلمات التالية؟

الكلمة	العدد التقريبي
Holmes	440~
Watson	80~
Sherlock	100~
London	40~
Lestrade	34~
case	118~
crime	33~

السؤال الثالث: ما الكلمات العشرون الأعلى تكراراً؟

انظر الجدول في القسم 5.1.

السؤال الرابع: ما الفرق بين الملف الموجود في Linux والملف الموجود في HDFS؟

HDFS	Linux
ملف موزع على عدة عقد (DataNodes)	ملف محلي على قرص واحد
يُقرأ بأوامر <code>hdfs dfs -ls</code> و <code>hdfs dfs -cat</code>	يُقرأ بأوامر <code>cat</code> و <code>head</code> و <code>wc</code>
يوجد 3 نسخ من كل بلوك	لا يوجد Replication
مناسب للبيانات الضخمة	مناسب للملفات الصغيرة
المسار: <code>/bigdata/sherlock/input/</code>	المسار: <code>/home/cloudera/...</code>

السؤال الخامس: ما وظيفة MapReduce في هذا المشروع؟

- **Map**: تقسيم النص إلى كلمات وإنتاج أزواج (كلمة، 1).
- **Shuffle**: تجميع الكلمات المتشابهة معاً.

- **Reduce**: جمع القيم لكل كلمة وإنتاج العدد النهائي.
- **Output**: كتابة النتائج في HDFS.

السؤال السادس: ما وظيفة YARN أثناء تنفيذ المهمة؟

- إدارة الموارد (RAM, CPU).
- توزيع المهام على العقد (Node Managers).
- مراقبة حالة المهمة عبر `http://quickstart.cloudera:8088`.

السؤال السابع: أين توجد النتيجة النهائية بعد انتهاء WordCount؟

داخل HDFS في المسار:

```
/bigdata/sherlock/output/part-r-00000
```

مع ملف `_SUCCESS` للإشارة إلى نجاح المهمة.

7. الاستنتاجات النهائية

7.1 طبعة الكتاب

The Adventures of Sherlock Holmes هي مجموعة قصص قصيرة (12 قصة) وليست رواية واحدة، وكل قصة لها "case" مختلف. لهذا ظهرت كلمة "case" بكثرة.

7.2 السرد بصيغة المتكلم

هيمنة الضمائر الشخصية ($I = 2,533$ ، $my = 901$ ، $me = 414$) تؤكد أن السرد بصوت الدكتور واتسون.

7.3 الطابع الاستنباطي

كلمات مثل "deduction" و "reasoning" و "logic" و "observation" تعكس منهج هولمز في التحقيق.

7.4 ثنائية هولمز وواتسون

- Holmes يظهر ~440 مرة (المحور).
- Watson يظهر ~80 مرة (لكنه الراوي).
- الحوارات بينهما كثيفة (لهذا "you" = 1,034).

7.5 أماكن لندن الشهيرة

- Baker Street = ~40 مرة (مسكن هولمز).
- London = ~40 مرة.
- St. = 79 مرة (Saint، للكنائس والشوارع).

7.6 مشكلة البيانات الخام

علامات الترقيم تشنت الكلمة الواحدة إلى عدة أشكال. الحل هو **Data Cleaning** (Lowercase + إزالة الترقيم + إزالة Stop Words).

8. مقارنة مع Frankenstein

المعيار	Sherlock Holmes	Frankenstein
أكثر كلمة دالة	Holmes (~440)	I (2,719)
طبيعة السرد	Third-Person عن هولمز	First-Person من فيكتور
التيمة	التحقيق والمنطق	العلم والخلق والانتقام
الكلمات المميزة	case, deduction, crime	creature, monster, despair

9. التوصيات لتحسين التحليل

1. تنظيف النص قبل WordCount:

- تحويل إلى أحرف صغيرة.
- إزالة علامات الترقيم.
- إزالة Stop Words.

2. كتابة **MapReduce** مخصص بلغة Java أو Python (Hadoop Streaming) لتنظيف النص أثناء المعالجة.

3. استخدام **Hive** أو **Pig** لاستعلامات SQL-like أكثر تعقيداً.

4. تصفية النتائج بـ **grep** بعد التنظيف للحصول على أرقام دقيقة.

10. الأدوات والتقنيات المستخدمة

التقنية	الاستخدام
Cloudera QuickStart VM	بيئة العمل
HDFS	تخزين البيانات الموزعة
YARN	إدارة الموارد
Hadoop MapReduce	معالجة البيانات
Linux Shell	أوامر التحكم
WordCount Example	برنامج التحليل

11. المراجع

1. Project Gutenberg — The Adventures of Sherlock Holmes (ID: 1661) :
<https://www.gutenberg.org/ebooks/1661>
2. Apache Hadoop Documentation :
<https://hadoop.apache.org/>
3. Cloudera QuickStart VM Guide .
4. "Hadoop: The Definitive Guide" — Tom White .

تم إعداد التقرير بواسطة:

التاريخ: